



МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ
(национальный исследовательский университет)»

Институт (Филиал) № 8 «Компьютерные науки и прикладная математика»

Образовательный центр 806

Группа М8О-206СВ-24 Направление подготовки 02.04.02 «Фундаментальная информатика и информационные технологии»

Магистерская программа Информатика

Квалификация: магистр

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА МАГИСТРА

На тему: Система автоматизированного обогащения товарных данных для интернет-магазина

Автор ВКРМ: _____ Фролов Михаил Александрович _____ ()

Научный руководитель: _____ Судаков Владимир Анатольевич _____ ()

Консультант: _____ ()

Консультант: _____ ()

Рецензент: _____ ()

К защите допустить

Заведующий кафедрой № 806 «Вычислительная математика и программирование»
Крылов Сергей Сергеевич _____ ()

_____ 2026 года

Москва 2026

РЕФЕРАТ

Выпускная квалификационная работа магистра состоит из 117 страниц, 11 рисунков, 33 таблиц, 58 использованных источников, 1 приложения. ОБОГАЩЕНИЕ ТОВАРНЫХ ДАННЫХ, КАСКАДНАЯ АРХИТЕКТУРА, СЛАБЫЙ НАДЗОР, OPEN FOOD FACTS, БАЙЕСОВСКАЯ СЕТЬ, БОЛЬШАЯ ЯЗЫКОВАЯ МОДЕЛЬ, КАЛИБРОВКА, ИЗВЛЕЧЕНИЕ ПРИЗНАКОВ, ДОМИНИРОВАНИЕ ПО ПАРЕТО, АУДИТ-ЦИКЛ, ВЕКТОРНЫЕ ПРЕДСТАВЛЕНИЯ

Объём работы. Общий объём 117 страниц, основная часть — 92 страницы (от Введения до Заключения включительно), 4 главы, 11 рисунков, 24 таблицы, 58 источников (18 российских и 40 зарубежных).

Объект исследования. Процесс автоматизированного обогащения товарных каталогов интернет-магазинов с использованием открытых источников данных.

Предмет исследования. Гибридная каскадная архитектура с ансамблевой оценкой уверенности классификаторов и адаптивным обращением к большой языковой модели как запасному слою.

Цель работы. Разработать гибридную каскадную систему автоматизированного обогащения товарных данных для интернет-магазина, обеспечивающую высокую точность извлечения категориальных атрибутов при сокращённой стоимости обращения к большой языковой модели и поддерживающую развёртывание на открытых моделях.

Методы. Многоязычные векторные представления текста на базе модели paraphrase-multilingual-mpnet-base-v2 (SBERT с архитектурой MPNet, поддержка 50+ языков), классификатор XGBoost с регуляризацией и поатрибутными порогами уверенности, байесовская сеть со структурой, найденной алгоритмом Hill Climb по критерию BIC (библиотека pgmpy), доверительные интервалы с кластеризацией по брендам через ресэмплированный бутстрэп, бакетирование числовых нутри-полей, согласие трёх независимых больших языковых моделей (Sonnet 4.5 + GPT-4o + Gemini 2.5 Flash) для построения эталонной разметки на текстово-семантических атрибутах, слепая верификация моделью Claude Opus 4, разбиение на обучающую и тестовую части без пересечения товарных кодов (code-disjoint), проверка гипотезы, зафиксированной до получения результатов с поправкой

Бонферрони на множественные сравнения.

Результаты. Реализована и эмпирически проверена гибридная каскадная архитектура из пяти слоёв (категорайзер Слой 0 — регулярные выражения — классификатор XGBoost на векторных представлениях SBERT — байесовский валидатор плотностей — запасной слой большой языковой модели) на трёх продуктовых категориях открытого каталога Open Food Facts (паста, шоколад, сыры). На тестовой выборке без пересечения товарных кодов (code-disjoint, новые SKU) размером 16 360 ячеек по 20 парам «категория-атрибут» итоговая конфигурация достигает 93,0 % сквозной точности при обращении к большой языковой модели на 4,1 % ячеек в режиме «каскад + gemini-flash»; точность только-каскадной части (без учёта непокрытых ячеек) составляет 95,5 % (cells-weighted macro-F1 0,890; attr-unweighted 0,892). На консервативной нижней оценке с независимой экспертной разметкой моделью Claude Opus 4 (n=566 cascade-valid из 688 в-score) — 86,7 % сквозной точности. При развёртывании на собственных мощностях с открытой моделью gpt-oss-120b — 90,6 % точности, что на 21,3 п. п. выше прямого использования gpt-oss-120b (69,3 %). Каскад без запасного слоя покрывает 97,3 % ячеек. Достигнуто доминирование по Парето разработанной системы над прямым использованием большой языковой модели по двум осям одновременно — точности и стоимости (+9,2 п. п. точности и сокращение стоимости в 580 раз при той же экономии по сравнению с прямым использованием Claude Sonnet 4.5; архитектурное сокращение стоимости в 24 раза обеспечивается переводом 95,9 % ячеек на дешёвые слои каскада). Гипотеза, зафиксированная до получения результатов, о превосходстве обучаемого стоимостно-чувствительного маршрутизатора над статическим правилом отклонена после поправки Бонферрони на трёх бюджетах. Реализован замкнутый цикл «аудит — правки экстрактора — переобучение — измерение» с кросс-категорийной репликацией 3 из 3. Разработана демонстрационная система из трёх компонентов (шлюз API на Go, ML-сервис на Python/FastAPI, веб-интерфейс), реализующая стабильный контракт REST API.

Использование результатов. Разработанная архитектура применима в системах управления товарной информацией (ПИМ-системах) интернет-магазинов. Внедрение системы позволяет: повысить полноту автоматического заполнения карточек товаров до 93,0 % (сквозная точность с

учётом маршрутизации; 95,5 % по каскадной части как верхняя граница при идеальной маршрутизации категории), сократить стоимость обработки в 580 раз по сравнению с прямым использованием Claude Sonnet 4.5 (комбинированное сокращение, включающее архитектурный вклад каскада в 24 раза и удешевление модели запасного слоя), сократить ручную нагрузку оператора каталога в 12–25 раз за счёт перевода в режим выборочной верификации, обеспечить развёртывание на собственных мощностях без отправки партнёрских данных во внешние API больших языковых моделей.

СОДЕРЖАНИЕ

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ	9
ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ	11
ВВЕДЕНИЕ	13
1 РАЗВЁРНУТАЯ АКТУАЛЬНОСТЬ ТЕМЫ	22
1.1 Проблема обогащения товарных каталогов интернет-магазина .	22
1.1.1 Роль товарных данных и неоднородность партнёрского ввода	22
1.1.2 Эффекты неполной карточки на пользовательский опыт . .	24
1.1.3 Существующие системы управления товарной информацией не решают задачу	25
1.1.4 Противоречие и постановка задачи	25
1.2 Литературный обзор	26
1.2.1 Извлечение признаков из текстовых описаний товаров . . .	26
1.2.2 Стоимостно-чувствительные каскады больших языковых моделей	27
1.2.3 Существующие промышленные РІМ-системы и анализ аналогов	28
1.2.4 Слабый надзор, калибровка и сопутствующая методология	30
1.3 Техническое задание на разрабатываемую систему	31
1.3.1 Функциональные требования	31
1.3.2 Нефункциональные требования	32
1.3.3 Архитектурные требования	32
1.3.4 Соотношение технического задания и решаемых задач работы	33
1.4 Выводы по главе 1	34
2 ТЕОРЕТИЧЕСКОЕ ОБОСНОВАНИЕ РЕШЕНИЯ	35
2.1 Логика работы разрабатываемого программного обеспечения .	35
2.1.1 Формальная постановка задачи обогащения	35
2.1.2 Каскадная схема принятия решения	35
2.1.3 Поведение системы при выходе категории за пределы поддерживаемых	36
2.1.4 Метрики качества и стоимости	37
2.2 Архитектура и стек технологий	37
2.2.1 Архитектура системы	38

2.2.2	Обоснование выбора компонентов стека	40
2.2.3	Стек технологий — сводная таблица	41
2.3	Сценарий работы программного обеспечения	43
2.3.1	Сквозной пример прохождения запроса	43
2.4	Выводы по главе 2	44
3	ОПИСАНИЕ ПРОГРАММНО-ТЕХНОЛОГИЧЕСКОЙ РЕАЛИЗАЦИИ	45
3.1	Описание программного обеспечения	45
3.1.1	Программная реализация слоёв каскада	45
3.1.2	Демонстрационный комплекс и контракт API	47
3.2	Данные	48
3.2.1	Источник данных, фильтрация и стратифицированная выборка	48
3.2.2	Эталонная разметка: иерархическая схема трёх ярусов . .	50
3.2.3	Разбиение без пересечения товарных кодов (code-disjoint) .	50
3.2.4	Дополнительные источники сигналов	51
3.3	Доказательство работоспособности и применимости	51
3.3.1	Условия проверки и метрики	51
3.3.2	Стратификация точности по типу эталонного сигнала . . .	52
3.3.3	Воспроизводимость	53
3.3.4	Главный результат: точность и стоимость производственной конфигурации	54
3.3.5	Декомпозиция по категориям	57
3.3.6	Обобщение на новые бренды (brand-disjoint side-study) . .	58
3.3.7	Поатрибутная картина точности и доверительные интервалы	60
3.3.8	Анализ доминирования по Парето: почему каскад превосходит одиночный вызов LLM	62
3.3.9	Учёт точности маршрутизатора первого уровня	62
3.3.10	Вклад каждого слоя каскада	62
3.3.11	Поатрибутная калибровочная ошибка до и после калибровки	63
3.3.12	Таксономия ошибок каскада	64
3.3.13	Разбор примеров прохождения каскада	69
3.3.14	Сравнение классификаторов Слой 2: XGBoost, Random Forest, логистическая регрессия, MLP	72
3.3.15	Обоснование сохранения слоя регулярных выражений: сопоставление с обучаемыми альтернативами	73

3.3.16	Поведение байесовского валидатора и архитектурный вывод	75
3.3.17	Чувствительность к выбору порога отсечки	77
3.3.18	Стоимостно-чувствительный маршрутизатор: отрицательный результат на проверке гипотезы H1	78
3.3.19	Цикл «аудит → правки → переобучение → измерение» . .	79
3.3.20	Переобучение моделей и прирост каскада	80
3.3.21	Кросс-категорийная репликация цикла 3/3	81
3.3.22	Устойчивость каскада по языкам	81
3.3.23	Устойчивость каскада к шуму во входных данных	82
3.3.24	Симуляция активного обучения на 3-LLM consensus gold .	83
3.3.25	Уточнение схемы атрибутов: ортогональные свойства . . .	84
3.3.26	Поатрибутные архитектурные решения	85
3.4	Выводы по главе 3	86
4	ОПИСАНИЕ РЕЗУЛЬТАТОВ	88
4.1	Руководство пользователя	88
4.1.1	Роли и интерфейсы	88
4.2	Сценарии применения и порядок внедрения	90
4.2.1	Встраивание в бизнес-процесс магазина	90
4.2.2	Сценарий многоязычного каталога	90
4.2.3	Применимость в смежных доменах	91
4.3	Риски развёртывания и план мониторинга	94
4.3.1	Мониторинг в производственном контуре	96
4.4	Что позволяет использование разработки (характеристика достигнутых результатов)	97
4.5	Выводы по главе 4	100
	ЗАКЛЮЧЕНИЕ	102
	СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	110
	ПРИЛОЖЕНИЕ А Электронные материалы	117

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ

В настоящей выпускной квалификационной работе магистра применяют следующие термины с соответствующими определениями:

Серебряная разметка — набор пар «товар — целевое значение атрибута», полученный автоматически из открытых источников данных (теги Open Food Facts) и используемый для обучения моделей. Содержит шум и неполноту; противопоставляется эталонной разметке

Эталонная разметка — пары «товар — целевое значение», прошедшие верификацию согласованным мнением нескольких языковых моделей и/или слепой разметкой более сильной языковой модели; используется как опорная истина при оценке каскада

Слабый надзор — режим обучения с использованием неполной или зашумлённой разметки, формируемой автоматически из доступных источников вместо ручной разметки экспертом

Каскадная архитектура — последовательность алгоритмических слоёв, каждый из которых обрабатывает только те объекты или атрибуты, которые не были закрыты предыдущими слоями с заданной уверенностью

Многоуровневая фильтрация по уверенности — формализация поведения каскада как последовательного конъюнктивного условия на прохождение калиброванных порогов уверенности на каждом слое. Реализует требование утверждённой темы об «ансамблевой оценке уверенности моделей»

Покрытие — доля ячеек «товар, атрибут» в тестовой выборке, для которых каскад дал предсказание выше порога уверенности на слоях 1–3 (без обращения к запасному слою)

Точность на покрытом срезе — доля верных предсказаний среди тех ячеек, для которых каскад дал ответ без обращения к запасному слою

Сквозная точность — точность системы на полной тестовой выборке, при которой отказы каскада засчитываются как неверные ответы (либо заменяются ответом запасного слоя при включённом Слое 4)

Разбиение без пересечения товарных кодов (code-disjoint) — построение разбиения выборки на обучающую, валидационную и тестовую части, при котором один бренд попадает ровно в одну из трёх частей. Исключает утечку признака «бренд — атрибут» при оценке качества системы

Цикл «аудит — правки — переобучение — измерение» — методологический

приём улучшения системы, при котором обнаружение конкретных дефектов эталонной разметки через аудит приводит к правкам экстрактора, затем к переобучению моделей и измерению прироста точности на той же аудит-выборке

ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ

В настоящей выпускной квалификационной работе магистра применяют следующие сокращения и обозначения:

OFF — Open Food Facts, открытый краудсорсинговый каталог продовольственных товаров под лицензией ODbL

SBERT — Sentence-BERT, многоязычная модель векторного представления предложений

XGBoost — Extreme Gradient Boosting, библиотека градиентного бустинга деревьев решений

ECE — Expected Calibration Error, ожидаемая ошибка калибровки вероятностей классификатора

CPD — Conditional Probability Distribution, условное распределение вероятности

DAG — Directed Acyclic Graph, направленный ациклический граф

BIC — Bayesian Information Criterion, критерий выбора структуры байесовской сети

PDO — Protected Designation of Origin, защищённое наименование товара

AOP — Appellation d'Origine Protégée, защищённое наименование товара (фр.)

LLM — large language model, большая языковая модель

TF-IDF — term frequency $\times$ inverse document frequency, частотно-инверсный показатель

OOD — out of distribution, выход за пределы обучающего распределения

AUROC — area under the ROC curve, площадь под кривой ошибок

ТЗ — техническое задание

BPMN — Business Process Model and Notation, модель и нотация бизнес-процессов

PIM — product information management, управление информацией о товарах

CJM — customer journey map, карта пути клиента

СМ — контент-менеджер

ML — machine learning, машинное обучение

API — application programming interface, программный интерфейс приложения

REST — representational state transfer, архитектурный стиль программного интерфейса

JSON — JavaScript Object Notation, текстовый формат обмена данными

CSV — comma-separated values, текстовый формат табличных данных с разделителями

DOCX — Office Open XML Document, формат текстового документа

E2E — end-to-end, сквозной — точность системы с учётом маршрутизации и отказа от ответа (None=wrong); production-realistic метрика (см. 2.1.4)

MPNet — Masked and Permuted Pre-training, архитектура трансформера, использованная в paraphrase-multilingual-mpnet-base-v2 для 768-мерных эмбедингов

NBSP — non-breaking space, неразрывный пробел; используется в LaTeX между числом и единицей

code-disjoint — разбиение train/test по идентификатору товара (code); brand overlap при этом сохраняется, см. 3.2.4 и 3.3.7

ODbL — Open Database License v1.0, лицензия share-alike для открытых баз данных (применяется к Open Food Facts)

TCO — total cost of ownership, совокупная стоимость владения системой за период

CI — confidence interval, доверительный интервал (95 % если не указано иное)

RF — Random Forest, ансамбль деревьев решений с bagging

MLP — multi-layer perceptron, многослойный перцептрон (полносвязная нейросеть)

ВВЕДЕНИЕ

Актуальность темы исследования.

Электронная коммерция продолжает устойчиво расти. Годовой объём российского сегмента в 2025 году составил 11,5 трлн руб. [1], мировой рынок также показывает уверенный рост [2]. Каталоги крупных интернет-магазинов исчисляются десятками миллионов товарных позиций: только индексируемая часть каталога Ozon в открытых аналитических базах превышает 38 млн позиций [3]. Ежедневно к ним добавляются тысячи новых записей от партнёров-поставщиков.

Карточка товара становится центральным элементом цифровой витрины. От её содержательной полноты зависят работа фасетного поиска, релевантность ранжирования и рекомендаций, корректность аналитики и в конечном счёте конверсия в покупки. Структура партнёрского ввода при этом неоднородна: от одного наименования и бренда до расширенного набора полей с фотографиями и иноязычным составом. Образующиеся пробелы исторически закрывают контент-менеджеры вручную, проверяя и дополняя десятки целевых атрибутов на каждую карточку. При характерных масштабах каталога в миллионы позиций и тысячах новых записей в сутки такой подход не масштабируется ни по затратам, ни по доступности знаний иностранных языков [4].

Класс систем управления товарной информацией Product Information Management — Akeneo, Pimcore, Salsify и аналогичные — сложился из потребности хранить уже сформированную товарную информацию [5; 6; 7]. Задачу извлечения этой информации из неструктурированного партнёрского ввода такие системы систематически не решают. Появляющиеся в них модули автоматического обогащения в большинстве случаев представляют собой обёртку над одной публичной большой языковой моделью, вызываемой напрямую на каждый товар. Подробное сопоставление приведено в 1.2.3. Такой вызов экономически приемлем лишь для каталогов небольшого и среднего размера и не сопровождается гарантиями фактической корректности. На числовых полях большие языковые модели систематически допускают фактические ошибки (3.3.12). Рост ставок коммерческих API, ужесточение требований к локализации данных и отраслевой тренд на открытые модели в локальном развёртывании [8] дополнительно усиливают запрос на

архитектурные решения, которые не сводятся к прямому вызову одной модели.

Из изложенного следует противоречие, которое и определяет актуальность работы. С одной стороны, автоматизация наполнения карточек — инженерная необходимость. С другой стороны, ни одна изолированная технология не покрывает все типы целевых атрибутов с приемлемой точностью и стоимостью одновременно. Правила надёжны на числовых атрибутах, но мало покрывают семантически нагруженные поля. Классические классификаторы требуют значительной размеченной выборки. Большие языковые модели универсальны, однако дороги и подвержены фактическим ошибкам, особенно на числовых полях.

В качестве разрешения этого противоречия в работе рассматривается гибридная каскадная архитектура. Она представляет собой композицию последовательных слоёв, в которой каждый следующий слой подключается только к остатку, не закрытому предыдущими с заданной уверенностью. Такая композиция объединяет семантические возможности генеративных моделей с предсказательной силой классического машинного обучения и автоматической фильтрацией недостоверных значений. Этим определяется актуальность работы с научной стороны как систематическая проверка эффективности гибридного каскада. С практической стороны актуальность задаётся созданием производственно-применимого комплекса с контролируемой стоимостью и возможностью локального развёртывания.

Цель работы.

Целью работы является разработка гибридной каскадной системы автоматизированного обогащения товарных данных интернет-магазина. Система должна обеспечивать высокую точность извлечения категориальных атрибутов при сокращённой стоимости обращения к большой языковой модели, поддерживать локальное развёртывание на открытых моделях и доминировать по Парето над прямым вызовом большой языковой модели одновременно по точности и стоимости.

Задачи работы.

Для достижения поставленной цели сформулированы и решены

следующие пять задач:

- 1) разработать архитектуру гибридного каскадного конвейера обработки товарных данных с многоуровневой фильтрацией по уверенности и явным разделением слоёв. Слои каскада: предкаскадный категорайзер, экстрактор регулярных выражений, классификатор машинного обучения на векторных представлениях, байесовский валидатор плотностей, запасной слой большой языковой модели. Многоуровневая фильтрация формализует требование утверждённой темы об ансамблевой оценке уверенности моделей как последовательное конъюнктивное условие на калиброванные пороги слоёв;
- 2) реализовать каждый слой каскада в виде самостоятельного программного компонента: экстрактор регулярных выражений; классификатор машинного обучения, обучаемый на многоязычных векторных представлениях партнёр-доступных полей; байесовский валидатор, использующий обученную сеть атрибутов в роли фильтра статистически невероятных пар «бренд × значение»; запасной слой на основе большой языковой модели с поддержкой нескольких поставщиков, включая открытые модели для локального развёртывания;
- 3) построить эталонную разметку и проверочную выборку без пересечения товарных кодов (code-disjoint) для оценки качества системы на трёх категориях товаров: паста, шоколад, сыры. Разметка сочетает слабый надзор от тегов открытого каталога, поатрибутное согласие трёх независимых больших языковых моделей и слепую разметку референсной моделью. Разбиение на обучающую, валидационную и тестовую части выполняется без повторного появления одних и тех же брендов;
- 4) провести экспериментальную оценку разработанной системы. Необходимо измерить точность сквозного прохождения каскада, поатрибутное покрытие и стоимость обработки на эталонной тестовой выборке; сопоставить полученные показатели с показателями прямого использования большой языковой модели; оценить вклад каждого слоя каскада, устойчивость к смещению по языкам входных данных и поведение байесовского валидатора как

селективного сигнала на отбраковку фактических ошибок;

- 5) разработать демонстрационный программный комплекс. Комплекс должен обеспечивать взаимодействие оператора каталога с каскадом через веб-интерфейс и стабильный программный интерфейс. Поддерживаются три производственных сценария развёртывания: с премиум-коммерческой большой языковой моделью, с бюджетной коммерческой языковой моделью и с открытой языковой моделью в локальном развёртывании.

Каждой задаче соответствует измеримый результат, который изложен в подразделе «Новизна и основные результаты».

Объект и предмет исследования.

Объектом исследования является процесс автоматизированного обогащения товарных каталогов интернет-магазинов на основе открытых источников данных. На входе процесса имеется минимальный набор партнёр-доступных полей, на выходе требуется получить структурированный набор целевых атрибутов.

Предметом исследования является гибридная каскадная архитектура обработки товарных данных с ансамблевой оценкой уверенности классификаторов и адаптивным селективным обращением к большой языковой модели в роли запасного слоя. Рассматриваются её точность, стоимостные характеристики, устойчивость к смещению входного распределения, а также вычислительные и эксплуатационные свойства, существенные для производственного применения.

Теоретические и методические основы работы.

Работа основывается на следующих методах и инструментах:

извлечение признаков из неструктурированного текста выполняется регулярными выражениями и многоязычным энкодером paraphrase-multilingual-mpnet-base-v2;

классификатор уровня машинного обучения — градиентный бустинг XGBoost поверх полученных векторных представлений;

валидатор атрибутов реализован вероятностной графической моделью средствами библиотеки pgmpy; структура сети обучается алгоритмом Hill

Climb по критерию BIC;

обучающая выборка формируется методом слабого надзора по тегам открытого каталога Open Food Facts;

эталонная разметка строится сочетанием детерминированных правил для нутриентно-производных атрибутов, регуляторных тегов и поатрибутного согласия трёх независимых больших языковых моделей со слепой проверкой референсной моделью; процедура подробно описана в 3.2.3;

оценка качества выполняется на отложенной выборке без пересечения товарных кодов (code-disjoint); доверительные интервалы получены кластерным бутстрэпом с ресэмплированием брендов;

проверка гипотез о превосходстве каскада над одиночной языковой моделью выполняется по заранее зафиксированному протоколу с поправкой Бонферрони на множественные сравнения.

Архитектурный подход к выбору модели по соотношению цена/качество опирается на работы L. Chen и соавторов FrugalGPT [9], P. Aggarwal и соавторов AutoMix [10], D. Ding и соавторов Hybrid LLM [11], а также на бенчмарк Q. J. Hu и соавторов RouterBench [12]. Оформление работы выполнено в соответствии с ГОСТ 7.32-2018, библиографическое описание источников — с ГОСТ 7.1-2003.

Новизна и основные результаты.

Каждой из сформулированных выше задач в работе соответствует не менее одного измеримого результата.

По задаче 1 — проектирование архитектуры каскада, разделы 2.1, 3.1.1. Спроектирован гибридный каскад из пяти последовательных слоёв с конъюнктивным условием на калиброванные пороги уверенности каждого слоя. Разработанная формальная постановка задачи допускает явный отказ системы от ответа и явное определение слоя-источника каждого предсказания.

По задаче 2 — реализация слоёв, раздел 3.1.2. Каскад реализован в виде набора независимо обновляемых программных компонентов. Разработана демонстрационная система в трёхкомпонентной архитектуре «шлюз API на языке Go — ML-сервис на Python/FastAPI — статический веб-интерфейс». Система запускается одной командой и проходит проверку готовности всех слоёв через диагностический интерфейс.

По задаче 3 — построение эталонной разметки, раздел 3.2. Построена многоисточниковая эталонная разметка для трёх категорий товаров на основе

тегов открытого каталога, нутриентно-производных правил, поатрибутного согласия трёх независимых больших языковых моделей и слепой разметки референсной моделью. Разбиение на обучающую, валидационную и тестовую части выполнено без пересечения товарных кодов (code-disjoint).

По задаче 4 — экспериментальная оценка, разделы 3.3.2, 3.3.3, 3.3.4, 3.3.7. Получена сквозная точность 93,0 % (точность только-каскадной части 95,5 %, macro-F1 0,890) на тестовой выборке без пересечения товарных кодов (code-disjoint, новые SKU) из 16 360 ячеек по 20 парам «категория-атрибут» при 580-кратном сокращении стоимости в режиме «каскад + Gemini 2.5 Flash» относительно прямого вызова Claude Sonnet 4.5 (комбинированное сокращение, включающее архитектурный вклад каскада в 24 раза и удешевление модели). На независимом эталоне ручной разметки моделью Claude Opus 4 (n=566 cascade-valid из 688 в-scope) — 86,7 % сквозной точности. Доминирование каскада по Парето над прямым использованием большой языковой модели подтверждено на пяти моделях запасного слоя. Вклад каждого слоя количественно охарактеризован, в том числе селективный вклад байесовского валидатора. Каскад покрывает 97,3 % ячеек.

По задаче 5 — разработка демонстрационного программного комплекса, разделы 4.1, 4.2. Реализована поддержка трёх производственных сценариев развёртывания: премиум-коммерческий, бюджетный коммерческий, локальный с открытой моделью. Поддерживаются три роли пользователей: контент-менеджер, системный аналитик, инженер машинного обучения.

На основании совокупности полученных результатов сформулированы три пункта научной новизны. Их общая особенность относительно известных стоимостно-ориентированных каскадов для языковых задач — FrugalGPT [9], AutoMix [10], Hybrid LLM [11], RouterBench [12] — состоит в гетерогенности слоёв. Перечисленные работы комбинируют однотипные генеративные модели разной мощности; в настоящей работе исследован гетерогенный каскад «правила (регулярные выражения) — дискриминативная модель машинного обучения — генеративная большая языковая модель» с явным правилом маршрутизации на уровне пары «категория-атрибут». Подобной комбинации трёх парадигм для задачи обогащения товарных каталогов в литературе не зафиксировано.

Первый пункт научной новизны. Доказано доминирование

разработанной гибридной каскадной системы по Парето над прямым использованием большой языковой модели на задаче обогащения товарных каталогов. На тестовой выборке без пересечения товарных кодов (code-disjoint, новые SKU) размером 16 360 ячеек одновременно достигаются превышение точности на 9,2 процентного пункта (93,0 % против 83,8 %) и сокращение стоимости обработки в 580 раз (комбинированное сокращение, включающее архитектурный вклад каскада в 24 раза и удешевление модели запасного слоя). Компромисса между точностью и стоимостью не возникает.

Второй пункт научной новизны. Эмпирически установлено, что в сценарии локального развёртывания с открытой большой языковой моделью gpt-oss-120b в роли запасного слоя каскад компенсирует ограниченные возможности малой открытой модели на сложных атрибутах за счёт специализированного слоя машинного обучения. Прирост сквозной точности составляет 21,3 процентного пункта над прямым использованием той же открытой модели (90,6 % против 69,3 %) при сокращении стоимости в 810 раз относительно опорного прямого вызова Claude Sonnet 4.5. Это позволяет говорить об архитектурной независимости решения от конкретного поставщика большой языковой модели.

Третий пункт научной новизны объединяет два самостоятельных результата. Первый — **зафиксированный до получения результатов отрицательный исход проверки гипотезы H1**: впервые на задаче обогащения товарных каталогов по процедуре, зафиксированной до получения окончательных результатов, с поправкой Бонферрони на множественные сравнения количественно установлено, что статическое рег-(категория, атрибут) правило маршрутизации не уступает обучаемому XGBoost-маршрутизатору с учётом стоимости по сквозной точности при равных бюджетах вызовов запасного слоя. Полученный результат уточняет применимость подхода обучаемой маршрутизации к рассматриваемому классу задач и согласуется с выводами бенчмарка RouterBench [12]. Второй — **кросс-категорийная репликация замкнутого цикла «аудит эталонной разметки — корректировка экстрактора признаков — переобучение моделей — повторное измерение»** в пределах продуктового домена. Цикл воспроизведён на трёх категориях товаров из трёх с приростом сквозной точности на подвыборке аудированных проблемных ячеек +18,2, +16,3 и +14,4 процентного пункта для пасты, шоколада и сыров соответственно.

Апробация и внедрение результатов.

Разработка велась по практическим требованиям, типичным для розничной электронной торговли крупного масштаба (российские и международные интернет-магазины). Архитектурные и эксплуатационные характеристики системы ориентированы на встраивание в производственный процесс обогащения товарного каталога без перестройки соседних звеньев (см. 4.2.1 — описание точки встраивания в маршрут «партнёрский фид → каталог → витрина»). Поддерживаются три производственных сценария развёртывания: с премиум-коммерческой большой языковой моделью (Claude Sonnet 4.5 / GPT-4o), с бюджетной коммерческой (Gemini 2.5 Flash), с открытой моделью в полностью локальном развёртывании (gpt-oss-120b) — последний сценарий критичен для требований локализации обработки партнёрских данных.

Апробация выполнена в виде демонстрационного программного комплекса. Комплекс запускается одной командой и проверяется на работоспособность через диагностический программный интерфейс. Демонстрация подтверждает, что все слои каскада функционируют на трёх предметных категориях: паста, шоколад, сыры. Воспроизводимость численных показателей обеспечена сценарием `reproduce.sh`, который регенерирует основные результаты из артефактов в каталоге `datasets/processed/` репозитория. Разработанный комплекс готов к интеграции в системы управления товарной информацией розничной торговли (см. 4.2.1).

Структура и объём работы.

Выпускная квалификационная работа состоит из введения, четырёх глав, заключения и списка использованных источников. Общий объём работы — 117 страниц, основная часть (от введения до заключения включительно) — 92 страницы. Список использованных источников включает 58 наименований: 18 российских источников, индексируемых в РИНЦ и доступных в открытых российских репозиториях, и 40 зарубежных публикаций, отраслевых отчётов и стандартов.

Первая глава содержит обоснование актуальности темы, литературный обзор по трём направлениям и техническое задание (ТЗ) на разрабатываемую систему. Вторая глава посвящена теоретическому обоснованию решения. В

ней приводятся формальная постановка задачи, обоснование архитектуры и стека технологий, а также сценарии прохождения запроса через каскад. Третья глава содержит описание программной реализации, использованных данных и доказательство работоспособности каскада на эталонной тестовой выборке без пересечения товарных кодов (code-disjoint). Четвёртая глава представляет порядок применения системы, сценарии её развёртывания и характеристику достигнутых результатов в формате «повышено / ускорено / сокращено». В заключении собраны выводы по главам, научная новизна и перспективы развития темы.

1 РАЗВЁРНУТАЯ АКТУАЛЬНОСТЬ ТЕМЫ

В главе обосновывается тема работы, систематизируются существующие подходы к автоматическому обогащению товарных данных и формулируется техническое задание на разрабатываемую систему.

1.1 Проблема обогащения товарных каталогов интернет-магазина

1.1.1 Роль товарных данных и неоднородность партнёрского ввода

Рынок электронной коммерции устойчиво растёт: годовой оборот российского сегмента в 2025 году — 11,5 трлн руб. [1], мировой рынок продолжает расширяться [2]. Каталоги крупных площадок насчитывают десятки миллионов позиций (индексируемая часть Ozon — > 38 млн [3]); ежедневно добавляются тысячи новых артикулов. Карточка товара — центральный элемент цифровой витрины: от её атрибутов (тип, состав, маркировки качества, страна происхождения) зависит фасетный поиск, релевантность ранжирования и конверсия.



Рисунок 1 – Место системы автоматизированного обогащения в инфраструктуре интернет-магазина

Партнёрские данные принципиально неоднородны: для одного товара поставщик передаёт только название и бренд, для другого — расширенный набор полей с фотографиями, для третьего — состав на иностранном языке,

для четвёртого доступен только штрихкод. Анализ Open Food Facts [13] показывает, что заполненность нутри-полей систематически ниже базовых. Пробелы исторически закрываются контент-менеджерами вручную; при каталоге в миллионы позиций и тысячах новых записей в сутки такой путь экономически неприемлем [4] и плохо масштабируется по языкам (FR, DE, IT, ES в категориях импортной пищевой продукции).

Типовой процесс работы контент-менеджера сводится к последовательности «приём — поиск аналогов — заполнение — внутренняя проверка — публикация» (рисунок 1.2, а). Внедрение гибридного каскада заменяет ручное заполнение автоматическим выводом системы, а ручной труд сосредоточивается на выборочной верификации и периодическом аудите ошибок (рисунок 1.2, б).




Рисунок 2 – Процесс работы контент-менеджера: (а) текущий, (б) целевой с интеграцией гибридного каскада обогащения

Примечание. Этапы текущего процесса реконструированы по материалам публичной документации Akeneo [5], Pimcore [6] и Salsify [7]; целевой процесс — авторская конструкция.

1.1.2 Эффекты неполной карточки на пользовательский опыт

Неполная карточка даёт три независимых воздействия: снижается качество фасетного поиска (товар выпадает из подборок при применении

фильтров), растут возвраты и негативная обратная связь по атрибутам правового или диетического значения (органика, глютен, аллергены), а также увеличивается нагрузка на модерацию — «брошенная» карточка удлиняет цикл выхода товара на витрину.

1.1.3 Существующие системы управления товарной информацией не решают задачу

Класс систем управления информацией о товарах (PIM, product information management) — Akeneo, Pimcore, Salsify, Riversand, inRiver [5; 6; 7] — сложился из корпоративной потребности хранить и публиковать товарную информацию в едином каталоге. Их функциональность сосредоточена на управлении уже сформированной информацией, не на её извлечении. Сравнительный анализ платформ управления нормативно-справочной информацией с учётом MDM/PIM-функциональности проведён С. А. Долгоруковой [14]. Появляющиеся модули автоматического обогащения — обёртки над одной публичной большой языковой моделью (LLM, large language model) с прямым вызовом на каждый товар, экономически приемлемы лишь для каталогов небольшого и среднего размера и не дающие гарантий корректности. Альтернатива в виде агрегаторов готовых описаний задачу извлечения атрибутов из произвольного партнёрского текста не решает и ограничена крупными брендами.

1.1.4 Противоречие и постановка задачи

Изложенное определяет противоречие в основе актуальности: автоматизация наполнения — инженерная необходимость, но ни одна отдельная технология не покрывает все типы целевых атрибутов с приемлемой точностью и стоимостью. Правила надёжны на числовых атрибутах, но дают низкое покрытие на семантически нагруженных полях. Классические классификаторы требуют значительной разметки и плохо переносятся между языками. LLM универсальны, но дороги [9] и систематически ошибаются на числовых полях, требующих агрегирования из текста (эмпирическая характеристика — 3.3.2.4).

Из противоречия вытекает рабочая архитектурная гипотеза: каскадная композиция слоёв, в которой каждый следующий слой подключается только к

остатку, не закрытому предыдущими с заданной уверенностью, способна совместить преимущества отдельных технологий. Проверка этой гипотезы — содержательное ядро работы.

1.2 Литературный обзор

В разделе систематизируется научный и индустриальный задел по трём направлениям, которые образуют основу разрабатываемой системы:

извлечение признаков из текстовых описаний товаров;
каскады больших языковых моделей с учётом стоимости вызовов;
существующие промышленные системы управления товарной информацией.

1.2.1 Извлечение признаков из текстовых описаний товаров

Задача восполнения пропущенных атрибутов рассматривается как частный случай извлечения признаков из неструктурированного текста (information extraction, IE). Систематизация методов IE приведена в обзоре Л. М. Ермаковой [15]; гибридная природа практических решений по русскоязычным текстам отмечена в работе А. С. Ванюшкина и Л. А. Гращенко [16]. Подходы делятся на три группы — формальные правила, классические статистические модели и нейросетевые трансформеры — и их сочетание образует основу каскадных архитектур.

Правила и регулярные выражения надёжно извлекают атрибуты с устойчивой лексической разметкой при околонулевой стоимости, но ограничены низким покрытием на семантически нагруженных полях. *Статистические модели* над TF-IDF и градиентный бустинг (XGBoost [17], LightGBM [18]) работают при достаточной выборке и одноязычном входе (применение к электронной коммерции — Г. И. Афанасьев и соавторы [19]). *Векторные представления* на основе трансформеров [20] и BERT [21], в частности Sentence-BERT [22] и многоязычные дистиллированные варианты [23], дают фиксированные представления предложений; категоризация товарных каталогов рассмотрена А. Г. Колониным [24], систематическое изложение IE — в учебнике Е. И. Большаковой и соавторов [25].

Специализированные системы извлечения атрибутов товаров. В индустриальной литературе выделяются три эталонные системы: TXtract [26]

(Karamanolakis et al., ACL 2020, Amazon) — многозадачный кодировщик с условием на таксономию; MAVE [27] (Yang et al., WSDM 2022, Google) — BERT с кросс-вниманием по нескольким полям карточки; OpenTag [28] (Zheng et al., KDD 2018) — BiLSTM-CRF с механизмом внимания. Эти системы дают 85–92 % F1 на специализированных корпусах. Сопоставление с каскадными архитектурами, привлекающими LLM в роли запасного слоя, в открытой литературе систематически не представлено; настоящая работа частично закрывает этот пробел.

Поколение 2024 года. Свежие работы идут по двум линиям. L. Yang и соавторы предложили EAVE [29] — лёгкий энкодер со sparse-layer-интеракцией, обеспечивающий сопоставимое качество при меньшей стоимости вывода. С. Fang и соавторы предложили LLM-Ensemble [30] — взвешенный ансамбль коммерческих LLM с итеративной коррекцией, продемонстрировав, что ни одна модель не доминирует на всех типах атрибутов. В отличие от обеих линий настоящая работа не заменяет специализированный экстрактор более компактным трансформером и не наращивает число параллельных LLM-вызовов; предлагается ортогональная композиция, где большая языковая модель привлекается селективно — лишь для тех (товар, атрибут), на которых классические слои не вышли на калиброванный порог уверенности.

1.2.2 Стоимостно-чувствительные каскады больших языковых моделей

С появлением спектра LLM разной мощности оформилась подобласть cost-aware LLM routing. *FrugalGPT* [9] (L. Chen, M. Zaharia, J. Zou) предложил каскад LLM по возрастанию стоимости с прерыванием на первом уверенном ответе; настоящая работа опирается на идеи последовательного прерывания и калибровки. *AutoMix* [10] (P. Aggarwal, A. Madaan и соавторы) основан на самопроверке ответа малой моделью; разрабатываемая система, наоборот, разносит роли валидатора и предсказателя в отдельные слои. *Hybrid LLM* [11] (D. Ding, A. Mallick и соавторы) рассматривает маршрутизацию между моделью на пограничном устройстве и облачной — постановка прямо соответствует сценарию «локальная gpt-oss-120b + коммерческое API как запасной слой». *RouterBench* [12] (Q. J. Hu, J. Bieker и соавторы) показал, что обучаемые маршрутизаторы не доминируют над простыми политиками при

локализованной структуре ошибок; настоящая работа подтверждает это на задаче обогащения каталогов по пред-зарегистрированному протоколу.

RouteLLM [31] (I. Ong, A. Almahairi и соавторы, ICLR 2025) обучил маршрутизатор поверх пользовательских предпочтений Chatbot Arena и достиг двукратного снижения стоимости в general-purpose диалоге. Однако подход опирается на парные предпочтения и сводится к выбору одной из двух моделей на запрос; в задаче обогащения каталога такой сигнал отсутствует принципиально, а маршрутизация ведётся на уровне пары (товар, атрибут), а не запроса. Это обосновывает переход от обучаемого маршрутизатора к статической политике.

1.2.3 Существующие промышленные PIM-системы и анализ аналогов

Для позиционирования разработки отобраны три коммерческие PIM-системы — Akeneo, Pimcore и Salsify — и построена сравнительная таблица по семи функциональным критериям (таблица 1.1). Источники — документация вендоров [5; 6; 7].

Таблица 1 – Сравнение существующих PIM-систем и разрабатываемой системы

№	Критерий	Akeneo	Pimcore	Salsify	Разрабатываемая система
1	Централизованное хранение каталога	да	да	да	не входит в задачу
2	Распределение по каналам сбыта	да	да	да	не входит в задачу

Продолжение таблицы

№	Критерий	Akeneo	Pimcore	Salsify	Разрабатываемая система
3	Автоматическое обогащение атрибутов	частично (Akeneo AI / GenAI, 2023+ — обёртка над сторонней LLM)	частично (правила обогащения + плагины)	частично (Salsify AI Suite — обёртка над сторонней LLM)	да (каскадная архитектура с многоуровневой фильтрацией по уверенности)
4	Извлечение признаков из неструктурированного текста	нет	нет	нет	да (слои ML и LLM)
5	Поддержка многоязычного ввода	через ручные переводы	через ручные переводы	через ручные переводы	встроенная (многоязычные эмбединги, 50+ языков)
6	Открытый исходный код	community-редакция	да	нет	да (включая возможность локального развёртывания LLM)

Продолжение таблицы

№	Критерий	Akeneo	Pimcore	Salsify	Разрабатываемая система
7	Стоимостно-чувствительная обработка	нет	нет	нет	да (каскадная композиция с доминированием по Парето по стоимости и качеству)

Из таблицы 1.1 следует, что коммерческие PIM-системы покрывают хранение и распределение уже сформированной информации, но функция автоматического обогащения у всех трёх (Akeneo с 2023 года, Salsify через AI Suite, Pimcore через плагины) реализуется как прямая обёртка над сторонней LLM — без учёта стоимости массовых вызовов, без поатрибутной маршрутизации и без гарантий локального развёртывания. Ни одно из проанализированных решений не закрывает одновременно весь набор критериев интернет-магазина, что обосновывает целесообразность самостоятельной разработки.

1.2.4 Слабый надзор, калибровка и сопутствующая методология

Сложность задачи — отсутствие достаточной ручной разметки (weak supervision); инструментарий систематизирован Snorkel [32], обзор активного обучения и слабого надзора — B. Settles [33]. Пригодным источником слабого эталона выступает Open Food Facts [13]; эмпирическая устойчивость классических алгоритмов (KNN, SVM) к шуму разметки показана В. А. Дюком [34], что обосновывает применимость серебряной разметки.

Для корректной работы каскада выходы классификаторов калибруются: масштабирование Платта [35], изотоническая регрессия [36], анализ ECE — С. Guo и соавторы [37]. Критерии качества классификаторов, включая ROC и выбор порога, систематизированы Ю. С. Шуниной и соавторами [38] и А. А.

Ковалевым и соавторами [39]. Оценка точности — кросс-валидация и бутстрэп [40], интервалы пропорций — формула Вильсона [41]. Аппарат байесовских сетей опирается на J. Pearl [42], D. Heckerman et al. [43], А. Л. Тулупьева и соавторов [44], библиотеку pgmpy [45], поиск структуры — Hill Climb + BIC [46]. Прикладные вопросы устойчивости ML-моделей к дрейфу в каталогах — А. А. Артемов [47], масштабируемость на маркетплейсах — С. А. Сергеев [48], краудсорсинг — Р. А. Гилязов и Д. Ю. Турдаков [49], семантические пространства — В. Ф. Хорошевский [50].

1.3 Техническое задание на разрабатываемую систему

В разделе формулируется техническое задание (ТЗ) на разрабатываемую систему. Оно подразделяется на три группы требований: функциональные (что система должна делать), нефункциональные (с какими характеристиками) и архитектурные (каким способом она организована).

1.3.1 Функциональные требования

Ф-1. Входные данные. Система принимает товар, описанный партнёрскими полями: `product_name` (обязательное), `brands`, `ingredients_text`, `quantity`, `category` (опционально).

Ф-2. Возврат значений целевых атрибутов. Для каждого атрибута возвращается предсказанное значение, оценка уверенности и идентификатор слоя-источника, что обеспечивает отслеживаемость и возможность ручной верификации.

Ф-3. Покрывание категорий. Поддерживается заполнение атрибутов для трёх категорий пищевой продукции — паста, шоколад и шоколадные изделия, сыры. Выбор обоснован достаточным объёмом данных в OFF, доступностью аудит-эталона (согласие трёх LLM + слепая разметка Opus) и репрезентативностью по типам атрибутов (числовые, бинарные, мультиклассовые семантические).

Ф-4. Автоматическое определение категории. Если категория не указана, она определяется автоматически предкасадным слоем 0.

Ф-5. Запасной слой на основе LLM. Когда слои 1–3 не дают уверенного ответа на конкретный атрибут, система обращается к LLM селективно — только по тем атрибутам товара, где предыдущие слои отказались.

Ф-6. Диагностический вывод. Возвращается результат работы валидатора, агрегированные оценки уверенности по слоям и маршрут запроса по каскаду — для отладки, аудита и накопления операционных данных.

1.3.2 Нефункциональные требования

НФ-1. Точность. Целевая сквозная точность на code-disjoint тестовой выборке — не менее 85 %; в конфигурации с коммерческой LLM в запасном слое — не менее 90 %.

НФ-2. Стоимость. Стоимость обработки одного товара каскадом — существенно ниже прямого вызова LLM; целевое снижение — не менее 2,5×, фактически достижимое значение фиксируется в 3.3.2.

НФ-3. Производительность. Время отклика на один товар без запасного слоя — не более 500 мс на потребительском ноутбуке без ускорителя; с запасным слоем — не более 5 с (определяется временем ответа внешнего API).

НФ-4. Многоязычность. Поддерживаются пять рабочих языков европейского рынка пищевой продукции (FR, EN, DE, IT, ES), наиболее представленных в OFF.

НФ-5. Локальное развёртывание. Поддерживается сценарий полностью локального развёртывания через открытую модель gpt-oss-120b в запасном слое — требование вендорной независимости.

1.3.3 Архитектурные требования

А-1. Каскадная архитектура с отдельными слоями. Последовательность слоёв по принципу «передачи остатка»: каждый последующий обрабатывает только атрибуты, не закрытые предыдущими с уверенностью выше калиброванного порога.

А-2. Независимое обновление слоёв. Изменение или переобучение любого отдельного слоя (правил, классификаторов слоя 2, LLM в запасном слое) не должно требовать перезапуска остальных слоёв и API-шлюза.

А-3. Демонстрационный комплекс с веб-интерфейсом. Система сопровождается комплексом из трёх компонентов: API-шлюза на Go, ML-сервиса на Python/FastAPI и одностраничного веб-интерфейса — для верификации работоспособности и наглядного представления результатов

контент-менеджеру.

1.3.4 Соотношение технического задания и решаемых задач работы

Сформулированные требования полностью покрываются задачами, поставленными во введении (таблица 1.2).

Таблица 2 – Соответствие требований технического задания и задач работы

№ задачи	Краткая формулировка задачи	Покрываемые требования ТЗ
1	Разработать архитектуру гибридного каскадного конвейера	Ф-1, Ф-2, Ф-4, Ф-5, А-1
2	Реализовать каждый слой каскада как самостоятельный программный компонент	Ф-6, А-2
3	Построить эталонную разметку и проверочную выборку без пересечения товарных кодов (code-disjoint)	Ф-3 (в части обеспечения данных для оценки на трёх категориях)
4	Провести экспериментальную оценку точности, покрытия и стоимости	НФ-1, НФ-2, НФ-3, НФ-4, НФ-5
5	Разработать демонстрационный программный комплекс	А-3

Установленное соответствие подтверждает, что выполнение пяти задач работы влечёт за собой выполнение технического задания в полном объёме.

1.4 Выводы по главе 1

В главе проведён анализ предметной области, систематизировано состояние литературы и обосновано техническое задание. По результатам анализа можно сформулировать следующие выводы.

- 1) Проблема автоматического обогащения остаётся открытой. Промышленные PIM-системы, такие как Akeneo [5], Pimcore [6], Salsify [7], ориентированы на хранение и распределение уже сформированной информации. Появляющиеся модули автоматического обогащения реализуются как обёртки над одной коммерческой большой языковой моделью и не отвечают требованиям обработки больших каталогов с учётом стоимости.
- 2) Научные подходы делятся на две группы, и ни одна из них не покрывает задачу полностью. Специализированные системы извлечения атрибутов, такие как TXtract [26], MAVE [27], OpenTag [28], решают задачу с высоким качеством. Однако они требуют значительной размеченной выборки и не учитывают экономики обращения к моделям. Каскады больших языковых моделей с учётом стоимости — FrugalGPT, AutoMix, Hybrid LLM — дают инструменты управления стоимостью, систематически сопоставленные в бенчмарке RouterBench. Однако эти каскады рассматривают композицию из однородных моделей и не интегрируют классическое машинное обучение.
- 3) Разрабатываемая система объединяет оба подхода в гибридный каскад. Каскад сочетает специализированные слои извлечения признаков — правила, машинное обучение на многоязычных эмбедингах, байесовский валидатор — и запасной слой LLM с учётом стоимости. Совокупность шести функциональных, пяти нефункциональных и трёх архитектурных требований ТЗ формирует обязательство, выполнение которого верифицируется в экспериментальной части работы.

2 ТЕОРЕТИЧЕСКОЕ ОБОСНОВАНИЕ РЕШЕНИЯ

В главе формально описывается разрабатываемая система и обосновываются принятые архитектурные решения. Сначала приводится формальная постановка задачи и логика работы программного обеспечения (2.1). Затем рассматриваются архитектура и стек технологий, а также обоснование выбора каждой компоненты (2.2). В конце разбирается логика прохождения типового запроса через систему (2.3).

2.1 Логика работы разрабатываемого программного обеспечения

2.1.1 Формальная постановка задачи обогащения

Пусть товарная позиция, поступающая в систему от партнёра, представлена кортежем партнёр-доступных полей

$$x = (x^{\text{name}}, x^{\text{brand}}, x^{\text{ingr}}, x^{\text{qty}}), \quad (1)$$

где компоненты — название, бренд, состав и количество соответственно; пустым может быть любое поле, кроме названия. Каждому товару ставится в соответствие категория $c \in \mathcal{C} = \{c_1, \dots, c_M\} \cup \{\text{OOD}\}$ ($M = 3$: pasta, chocolate, cheeses; OOD — выход за пределы поддерживаемых доменов), определяемая отдельной моделью

$$c = f_0(x), \quad (2)$$

(Слой 0, см. 2.2.1). Для каждой категории задана схема $\mathcal{A}_c = \{a_1, \dots, a_{K_c}\}$ с областями $\mathcal{Y}_k$; система строит

$$\hat{y} = (\hat{y}_1, \dots, \hat{y}_{K_c}) \in (\mathcal{Y}_1 \cup \{\text{null}\}) \times \dots \times (\mathcal{Y}_{K_c} \cup \{\text{null}\}), \quad (3)$$

где $\hat{y}_k = \text{null}$ — явный отказ от ответа. Честное молчание предпочтительнее неверного заполнения: повторное обращение к оператору дешевле ошибки на витрине.

2.1.2 Каскадная схема принятия решения

Логика обогащения реализована как каскад из четырёх содержательных

слоёв; ему предшествует определение категории. Для каждого атрибута k итоговое предсказание формируется по правилу

$$\hat{y}_k = \begin{cases} f_k^{\text{regex}}(x), & f_k^{\text{regex}}(x) \neq \emptyset; \\ f_k^{\text{ML}}(x), & f_k^{\text{regex}}(x) = \emptyset, P_{\text{ML}}(\hat{y}_k | x) \geq \tau_k, P_B(\hat{y}_k | \mathbf{e}) \geq \theta_k; \\ f_k^{\text{LLM}}(x), & \text{otherwise.} \end{cases} \quad (4)$$

Здесь f_k^{regex} — детерминированный экстрактор регулярных выражений (Слой 1); f_k^{ML} — классификатор машинного обучения (Слой 2) над многоязычным векторным представлением партнёр-доступных полей с калиброванной апостериорной вероятностью P_{ML} и поатрибутным порогом τ_k ; $P_B(\hat{y}_k | \mathbf{e})$ — оценка байесовской сети при свидетельствах $\mathbf{e} = (x^{\text{brand}}, \hat{y}_{j \neq k})$ с порогом θ_k , заданным как пятый перцентиль распределения P_B по верно размеченным обучающим примерам; f_k^{LLM} — запасной слой на большой языковой модели (LLM, large language model), возвращающий значение из $\mathcal{Y}_k$ или null. Предсказание Слоя 2 принимается тогда и только тогда, когда одновременно выполнены

$$[P_{\text{ML}}(\hat{y}_k | x) \geq \tau_k] \wedge [P_B(\hat{y}_k | \mathbf{e}) \geq \theta_k]. \quad (5)$$

Это конъюнктивное условие формализует требование темы об ансамблевой оценке уверенности: не параллельное голосование, а последовательная фильтрация с правом каждого слоя отказаться. По итогам 3.3.4 валидатор включён селективно — только на парах «категория — атрибут» с неотрицательным приростом. Схема обеспечивает стратифицированное распределение нагрузки (дешёвый Слой 1 — массовые случаи, дорогой Слой 4 — трудный остаток), композиционную отбраковку статистически невероятных пар «бренд × значение» и архитектурную объяснимость: для каждой ячейки известно, какой слой принял решение.

2.1.3 Поведение системы при выходе категории за пределы поддерживаемых

Слой 0 определяет $c = f_0(x)$ до запуска каскада. Если достоверность ниже порога OOD-детектора, товару присваивается метка OOD и система

возвращает «категория не поддерживается»: $f_0(x) \in \mathcal{C} \setminus \{\text{OOD}\} \Rightarrow$ запуск per-category каскада со схемой $\mathcal{A}_{f_0(x)}$; $f_0(x) = \text{OOD} \Rightarrow \hat{y} = \emptyset$. Явный отказ выбран по соображениям эксплуатационной безопасности: ошибочное отнесение к чужой категории даёт неверную схему всем атрибутам.

2.1.4 Метрики качества и стоимости

Каскад поддерживает явный отказ от ответа; используются две согласованные метрики качества и одна сводная по стоимости.

$$\text{acc}_k^{\text{cov}} = \frac{|\{i : \hat{y}_k^{(i)} = y_k^{(i)} \wedge \hat{y}_k^{(i)} \neq \text{null}\}|}{|\{i : \hat{y}_k^{(i)} \neq \text{null}\}|}. \quad (6)$$

Точность на покрытой части $\text{acc}_k^{\text{cov}}$ — доля верных предсказаний среди ячеек с непустым ответом.

$$\text{cov}_k = \frac{|\{i : \hat{y}_k^{(i)} \neq \text{null}\}|}{N}, \quad (7)$$

Покрытие cov_k — доля ячеек, на которых система решилась дать ответ (где N — мощность проверочной выборки).

$$\text{acc}_k^{\text{e2e}} = \text{acc}_k^{\text{cov}} \cdot \text{cov}_k. \quad (8)$$

Сквозная точность $\text{acc}_k^{\text{e2e}}$ — основная метрика и заголовочное число (3.3.2); ячейки с $\hat{y}_k^{(i)} = \text{null}$ засчитываются как неверные, что исключает завышение качества за счёт молчания.

$$\text{cost}_{\text{LLM}} = \frac{1000}{N \cdot K_c} \sum_{i=1}^N \sum_{k=1}^{K_c} \mathbb{1}[\hat{y}_k^{(i)} \text{ получен через } f_k^{\text{LLM}}]. \quad (9)$$

Стоимость cost_{LLM} — ожидаемая доля вызовов запасного слоя на 1000 ячеек; метрика инвариантна к выбору модели Слой 4 и характеризует структуру каскада. Совместный анализ $(\text{acc}^{\text{e2e}}, \text{cost}_{\text{LLM}})$ образует матрицу «точность — стоимость», на которой строится заголовочный результат (3.3.2).

2.2 Архитектура и стек технологий

В разделе описывается архитектурное решение, реализующее

формальную постановку 2.1, и обосновывается выбор каждой компоненты стека.

2.2.1 Архитектура системы

Функциональная модель системы в виде диаграммы потоков данных приведена на рисунке 2.1. Внешние акторы (партнёр-продавец и витрина каталога интернет-магазина) обмениваются данными со шлюзом API и ML-сервисом, который содержит каскад из пяти слоёв и обращается к хранилищам моделей XGBoost, байесовских сетей и внешнему API большой языковой модели.




Рисунок 3 – Функциональная модель системы обогащения товарных данных

Система реализована как пятислойный конвейер (Слой 0 + четыре содержательных слоя). Состав и роль каждого слоя:

- **Слой 0 — категорайзер.** LightGBM поверх TF-IDF-представления (term frequency $\times$ inverse document frequency, частотно-инверсный показатель) названия и бренда с порогом OOD; определяет $c \in \mathcal{C}$ либо относит к OOD.
- **Слой 1 — экстрактор регулярных выражений.** Извлекает значения, явно присутствующие в тексте (форма пасты, % какао, цельнозерновой, шаблоны количества). Применяется только к шаблонам с высокой точностью совпадения.
- **Слой 2 — классификатор машинного обучения.** Основной слой:

партнёр-доступные поля конкатенируются и кодируются SBERT в 768-мерный вектор (модель `paraphrase-multilingual-mpnet-base-v2`, архитектура MPNet); поатрибутный XGBoost с порогом τ_k на отложенной выборке. Изотоническая пост-калибровка исследована в двух режимах (3.3.3.3): серебряная деградирует на эталоне из-за дрейфа; перекрёстная на эталонной выборке даёт улучшение ECE с 0,070 до 0,043 (в производственную конфигурацию не включена).

- **Слой 3 — байесовский валидатор.** Сеть (структура — Hill Climb + BIC) вычисляет $P_B(\hat{y}_k | \mathbf{e})$; ниже порога θ_k — флаг и передача дальше. Роль пересмотрена (3.1): не классификатор, а валидатор плотностей.
- **Слой 4 — запасной слой на большой языковой модели.** Взаимозаменяемые модели семейств GPT [51] и Claude [52]: Sonnet 4.5, GPT-4o, Gemini 2.5 Flash, открытая `gpt-oss-120b`, малая `llama-3.2-3b` (сопоставление — 3.3.2). Структурированный запрос со схемой и партнёр-доступными полями; возвращает значение или честный отказ.

Слои упорядочены по росту удельной стоимости решения: регулярные выражения по существу бесплатны, ML работает на уже вычисленном векторном представлении, байесовский вывод требует одного прохода по сети, запасной слой — самый дорогой.

Структура обученной байесовской сети для категории `chocolate` приведена на рисунке 4. Узлы графа — целевые атрибуты и бренд; направленные рёбра показывают условные зависимости, найденные алгоритмом Hill Climb на серебряной выборке. Бренд выступает корневым узлом и через производный признак `brand_has_organic_marker` влияет на `chocolate_type` и `is_organic`. Тип шоколада обуславливает процент какао и подтип `chocolate_extra`, от которого расходятся рёбра к `contains_nuts`, `nutri_score_grade`, `protein_class` и повторно к `is_organic` — это согласуется с интуицией о связи органичности, бренда и подтипа. Эмпирическая роль сети как селективного валидатора и количественные характеристики приведены в 3.3.4.




Рисунок 4 – Структура байесовской сети категории *chocolate* (направленный ациклический граф; алгоритм Hill Climb с критерием BIC, библиотека pgmpy 1.1.2)

2.2.2 Обоснование выбора компонентов стека

Каскад вместо сквозного решения. Сквозной all-LLM даёт 83–94 % точности (3.3.2), но стоимость линейно растёт с числом ячеек; каскад при равной или большей точности экономит порядка двух порядков за счёт стратифицированного распределения нагрузки. Сквозной all-ML не подходит из-за производных атрибутов, требующих знаний за пределами товарного описания, и сценария холодного старта новых категорий.

SBERT *paraphrase-multilingual-mpnet-base-v2* [23] выбран за бесплатную многоязычность (50+ языков в едином пространстве без дообучения), умеренную 768-мерную размерность и готовность к работе без доменной адаптации; архитектура MPNet объединяет преимущества маскированного и перестановочного языкового моделирования и устойчиво превосходит дистиллированные MiniLM-варианты на задачах семантической близости.

XGBoost [17] с регуляризацией (*subsample=0.8*, *colsample=0.8*, ранняя остановка, *gamma=0.1*) выбран как Слой 2 за устойчивость на плотных векторных признаках при ограниченной разметке ($n \approx 1250$ на категорию),

калибруемость вероятностей (изотоническая регрессия [36]) и миллисекундный вывод на CPU. Поэтапная оптимизация по остаткам и явные L1/L2/ γ -штрафы дают более тонкие нелинейные границы и более прямой контроль переобучения, чем у Random Forest [53; 54]; на табличных бенчмарках [55; 56] градиентный бустинг устойчиво превосходит Random Forest и нейросетевые архитектуры в характерной для Слой 2 размерности. Эмпирическое сравнение (§ 3.3.14) подтверждает преимущество: при сопоставимой точности XGBoost обеспечивает наименьшую ECE (0,026 против 0,031 у MLP и 0,035 у LogReg).

Байесовская сеть на pgmpy [45] 1.1.2. В сравнении с MRF и автоэнкодерами дискретная байесовская сеть допускает структурное обучение (Hill Climb + BIC [46]) с интерпретируемым ориентированным графом, дешёвый вывод через Variable Elimination и явное выражение условных зависимостей; pgmpy поддерживает как структурное обучение, так и параметрическую оценку через BayesianEstimator.

Шлюз API на Go при ML-сервисе на Python. Демо-система — два сервиса: шлюз на Go (:8080) и ML-сервис на Python/FastAPI (:8001). Go подходит для сетевого ввода-вывода (малое потребление памяти, быстрый запуск, конкурентный I/O); Python-экосистема (PyTorch, sentence-transformers, XGBoost, pgmpy) безальтернативна для ML-инференса. Разделение соответствует типовой production-архитектуре и позволяет масштабировать компоненты независимо.

Открытая LLM как запасной слой. Конфигурация многомодельна через OpenRouter (Claude Sonnet 4.5, GPT-4o, Gemini 2.5 Flash, открытая gpt-oss-120b, малая llama-3.2-3b). Открытую gpt-oss-120b можно запустить в инфраструктуре заказчика без передачи данных вовне; коммерческие LLM взаимозаменяемы, что снижает зависимость от провайдера; каскад компенсирует слабость малой модели — при самостоятельном применении gpt-oss-120b проигрывает Sonnet 14–15 п. п., но в составе каскада превосходит безусловное обращение к ней на 21,3 п. п. (3.3.2).

2.2.3 Стек технологий — сводная таблица

Сводное представление принятых решений приведено в таблице 2.1.

Таблица 3 – Сводная таблица стека технологий с обоснованием выбора

Компонент	Технология	Ключевое обоснование
Шлюз API	Go, стандартная библиотека net/http	Малое потребление ресурсов, быстрый запуск, отсутствие внешних зависимостей
ML-сервис	Python 3.14, FastAPI, Uvicorn	Доступ к ML-экосистеме, автоматическая валидация через Pydantic, поддержка OpenAPI
Векторное представление	SBERT paraphrase-multilingual-mpnet	Многоязычность (50+ языков), 768-мерный вектор (архитектура MPNet), отсутствие необходимости в fine-tuning
Классификатор Слой 2	XGBoost с регуляризацией; перекрёстная изотоническая калибровка на эталонной выборке снижает среднюю ECE с 0,070 до 0,043 (3.3.3.3), внедрение в производственную конфигурацию вынесено в раздел «Перспективы развития темы» заключения	Устойчивость на плотных признаках, калибруемые вероятности, дешёвый вывод

Продолжение таблицы

Компонент	Технология	Ключевое обоснование
Байесовская сеть	pgmpy 1.1.2, DiscreteBayesianNetwork	Структурное обучение Mark Climb + BIC, дешёвый вывод (Variable Elimination), интерпретируемый граф
Категорайзер Слой 0	LightGBM (поверх TF-IDF-представления) + порог OOD	Многоклассовая классификация с вероятностями + явный отказ при низкой уверенности
Запасной слой	OpenRouter API: Sonnet 4.5, GPT-4o, Gemini 2.5 Flash, gpt-oss-120b, llama-3.2-3b	Единый интерфейс, возможность локального развёртывания, независимость от поставщика
Фронтенд	HTML/CSS/JavaScript без сборочной системы	Минимальные требования к окружению, прозрачность демонстрации

2.3 Сценарий работы программного обеспечения

2.3.1 Сквозной пример прохождения запроса

Прохождение рассматривается на примере *Spaghetti #5 Barilla* (повторяется в 3.1.2). Партнёр шлёт POST /api/enrich с полями category=null, product_name=«Spaghetti #5 Barilla», brands=«Barilla», ingredients_text=«Durum wheat semolina, water», quantity=«500g». Поле category пустое — категоризация делегирована системе.

Шаг 1. Определение категории (Слой 0). Возвращает c = pasta с

уверенностью 0,97; OOD не активирован, выбрана схема $\mathcal{A}_{\text{pasta}}$ (8 атрибутов).

Шаг 2. Поочерёдная обработка атрибутов. Каскад обходит атрибуты по схеме. Для `pasta_shape` срабатывает шаблон Слой 1 на «spaghetti» с уверенностью 1,0 — следующие слои не вызываются. Для `grain_type` Слой 1 не даёт совпадения; Слой 2 выдаёт "wheat" с $P_{\text{ML}} = 0,99 \geq \tau = 0,5$, валидатор подтверждает ($P_B = 0,85 \geq \theta = 0,04$) — отметка ml. Для `nutri_score_grade` — класс "A", $P_{\text{ML}} = 0,83$, валидатор подтверждает. Для `is_filled` $P_{\text{ML}} = 0,45 < \tau$ — ячейка идёт в Слой 4.

Шаг 3. Формирование ответа. ML-сервис собирает поатрибутный ответ с агрегированными счётчиками и возвращает JSON шлюзу (формат — 3.1.2). В сценарии 7 из 8 атрибутов закрыты дешёвыми слоями (1 regex + 6 ML), 1 — Слой 4. Именно такое распределение обеспечивает доминирование каскада в матрице «точность — стоимость» (3.3.2).

2.4 Выводы по главе 2

- 1) Задача обогащения формализована как поатрибутное предсказание $\hat{y}_k$ с явным отказом ($\hat{y}_k = \text{null}$); каскадная логика — последовательная фильтрация по уверенности с конъюнктивным условием $P_{\text{ML}} \geq \tau_k \wedge P_B \geq \theta_k$ для принятия предсказания Слая 2.
- 2) Архитектурный выбор каждой компоненты (каскад вместо сквозного решения; SBERT, XGBoost, pgmpy; Go-шлюз + Python-ML; открытая gpt-oss-120b) обоснован эксплуатационно, методологически и стратегически, превращая слабую открытую модель в работоспособную часть production-стека.
- 3) Сквозной сценарий подтверждает: большинство атрибутов закрывается дешёвыми слоями, обращение к LLM точно — что объясняет доминирование по Парето, подтверждаемое в 3.3.

3 ОПИСАНИЕ ПРОГРАММНО-ТЕХНОЛОГИЧЕСКОЙ РЕАЛИЗАЦИИ

Глава описывает программную реализацию системы: 3.1 — каскад и демонстрационный комплекс; 3.2 — данные и предобработку; 3.3 — численные результаты и сценарии тестирования.

3.1 Описание программного обеспечения

3.1.1 Программная реализация слоёв каскада

Архитектурная роль слоёв описана в 2.2.1, поток управления и формула вывода $\hat{y}_k$ — в 2.1; ниже приведены только детали реализации. Алгоритм обработки одного запроса в нотации ГОСТ 19.701-90 показан на рисунке 3.1; на каждом слое принимается одно из двух решений (закрыть атрибут или передать дальше), слои упорядочены по росту стоимости. Вход — партнёр-доступные поля; слой 2 обучается только на них, что исключает утечку через теги OFF.




Рисунок 5 – Блок-схема алгоритма обработки запроса
(нотация ГОСТ 19.701-90)

Слой 0 — категорайзер. LightGBM поверх TF-IDF-представления (term frequency $\times$ inverse document frequency, частотно-инверсный показатель) (n-граммы 1–2) с порогом OOD (out of distribution, выход за пределы обучающего распределения). Артефакты:

`models/category_router_v3_{lgbm,vec}.pkl`, `_threshold.json`. При ошибке в категории атрибуты товара получают неверную схему и засчитываются как неверные предсказания.

Слой 1 — экстрактор регулярных выражений. Реализация — `src/pipeline/regex/extractor.py`. Разбирает `product_name` и `quantity`; распознаёт формы пасты, процент какао, индикатор цельнозернового состава, источник молока в сырах (*chèvre* / *brebis* / *bufala*), маркеры PDO/AOP/DOP, индикаторы ультра-обработанного сыра. Покрытие неоднородно по категориям: около 18 % на *pasta*, 23 % на *chocolate* и 3 % на *cheeses*; точность на закрытых ячейках — 87,0–100 % (см. 3.3.3.2).

Слой 2 — классификатор машинного обучения. Основной рабочий слой (73,2 % всех решений системы). Вход — конкатенация `product_name` + `brands` + `ingredients_text` + `quantity`. SBERT-кодировщик `paraphrase-multilingual-mpnet-base-v2` (768d, 50+ языков) конкатенируется с TF-IDF (n-граммы 1–2, top-5000), сжатым TruncatedSVD до 128 компонент; итого 896-мерное гибридное пространство. Для каждой пары (категория, атрибут) обучен XGBoost-классификатор `{cat}_v4_mpnet_tfidf_noleak_{attr}_xgb.pkl` с регуляризацией (`subsample=0.8`, `colsample=0.8`, ранняя остановка), Platt-калибровкой и порогом уверенности, подобранным на валидационном срезе по `macro-F1 × coverage`. Точность на покрытом срезе — 94,9–98,6 % (см. 3.3.10).

Слой 3 — байесовский валидатор. Сеть в `models/{cat}_stratified_bayesian.pkl`; структура — Hill Climb + BIC. По итогам 3.3.4 используется как валидатор плотностей: для предсказания слоя 2 вычисляется $P(\text{value} \mid \text{evidence})$, при попадании в нижний 5-перцентиль ячейка помечается флагом.

Слой 4 — запасной слой на большой языковой модели. Реализация — `src/pipeline/llm_fallback/enrich.py`. В 3.3.2 оцениваются пять моделей: Claude Sonnet 4.5, GPT-4o, Gemini 2.5 Flash, открытая `gpt-oss-120b` и открытая малая `Llama-3.2-3b`. Промпт содержит схему атрибутов категории, требуемый JSON-формат и партнёр-доступные поля.

3.1.2 Демонстрационный комплекс и контракт API

Демонстрация имитирует встраивание в бизнес-процесс интернет-магазина и состоит из трёх компонентов: Go-шлюза API

(demo/gateway/, ≈ 200 строк на стандартной net/http — валидация JSON, проксирование, CORS, отдача статики), Python/FastAPI ML-сервиса (demo/ml_service/ — при старте подгружает SBERT-кодировщик, 20 XGBoost-классификаторов, байесовские сети и слой 0; после прогрева $\approx 15\text{--}20$ с слои 0–3 отвечают за десятки миллисекунд), одностраничного HTML/JS-фронтенда. Эндпоинты: POST /api/enrich, GET /api/categories, GET /health, POST /api/explain.

Запрос POST /api/enrich принимает JSON с полями category (опционально), product_name, brands, ingredients_text, quantity; ответ содержит category, агрегированные счётчики и объект predictions с указанием слоя-источника (regex / ml / llm_fallback), уверенности и результата валидации для каждого атрибута. Пример пары запрос–ответ:

```
// запрос
{ "category": "pasta", "product_name": "Spaghetti #5 Barilla",
  "brands": "Barilla", "ingredients_text": "Durum wheat semol
// ответ
{ "category": "pasta", "n_attrs_total": 8, "n_covered": 7, "n
  "predictions": {
    "pasta_shape": { "value": "spaghetti", "layer": "regex",
    "grain_type": { "value": "wheat", "layer": "ml", "confid
    "is_filled": { "value": null, "layer": "llm_fallback",
```

Явная отметка слоя-источника компенсирует ограниченную интерпретируемость слоёв 2/3 на уровне отдельного товара. Запуск осуществляется одной командой bash reproduce.sh demo; готовность проверяется через GET /health. Стек технологий обоснован в 2.2.8 (таблица 2.1).

3.2 Данные

3.2.1 Источник данных, фильтрация и стратифицированная выборка

Основой выбран открытый каталог Open Food Facts (далее — OFF) [13] — краудсорсинговая база $\approx 4,5$ млн позиций под лицензией ODbL v1.0,

допускающей коммерческое использование при условии share-alike. Производные выборки и эталоны размещены в репозитории под совместимой лицензией с указанием авторства. Дамп (526 МБ) получен командой `python -m src.data.download --source off`. Выбор обоснован открытостью лицензии (воспроизводимость), мультиязычностью (50+ языков) и наличием структурированных нутриентных показателей и регуляторных тегов, на которых построен эталон (3.2.3). Область охвата — три категории (pasta, chocolate, cheeses), отобранные по критериям 1.3.

Поля OFF разделены на партнёр-доступные (product_name, brands, quantity, ingredients_text, code) и целевые выходные (categories_tags, labels_tags, *_100g, ingredients_analysis_tags); целевые поля не передаются на вход обучаемых компонентов под угрозой утечки. Фильтрация по категории (src/data/filter.py) использует списки включения/исключения categories_tags (для pasta включение — en:pastas, исключение — en:potato-products, en:noodles). После фильтрации применяется стратифицированная по языку выборка (langdetect, страты FR/EN/DE/IT/ES) объёмом ≈ 250 товаров на страту, итого ≈ 1250 на категорию (таблица 3.2.1).

Таблица 4 – Состав стратифицированной выборки по категориям, входящим в область охвата работы

Категория	Объём после фильтрации (сырые позиции)	Объём стратифицированной выборки	Число целевых атрибутов
pasta (макаронные изделия)	15 691	1 250	8
chocolate (шоколад)	13 469	1 250	7
cheeses (сыры)	21 208	1 250	9

Примечание.

Источник:

datasets/processed/{cat}_stratified_silver_standard.parquet.

Целевые атрибуты определены в src/pipeline/schemas/{cat}.py. По результатам анализа ошибок (3.3.25) принят принцип ортогональности атрибутов: структурная

характеристика «наличие начинки» выделена в самостоятельный бинарный атрибут `is_filled`, ортогональный к типу какао-массы и составу включений. Итоговая схема — 20 пар (категория, атрибут): `chocolate` — 6 (`chocolate_type`, `is_filled`, `chocolate_extra`, `contains_nuts`, `is_organic`, `flavor_profile`), `pasta` — 8 (`grain_type`, `pasta_shape`, `is_filled`, `is_gluten_free`, `is_organic`, `is_vegan`, `cuisine_origin`, `protein_class`), `cheeses` — 7 (`milk_source`, `texture`, `country_of_origin`, `aging`, `is_pdo`, `is_organic`, `is_ultra_processed`).

3.2.2 Эталонная разметка: иерархическая схема трёх ярусов

Эталон построен как многоярусная процедура с качественно различным классом свидетельств на каждом ярусе. **Ярус 0 (нутриент-производные)** — детерминированное бакетирование числовых полей: `pasta/protein_class` из `proteins_100g` по регламенту ЕК 1924/2006, точность 100 % при достоверных нутриентах. **Ярус 1 (тег-производные)** — эталон из регуляторных тегов: `is_organic` из `en:organic`, `is_gluten_free` из `en:gluten-free`, `is_pdo` из `en:protected-designation-of-origin` (правовая защита в ЕС, регламенты 834/2007 и 1151/2012). **Ярус 2 (семантически-текстовые)** — признаки без детерминированного правила (`pasta_shape`, `chocolate_type`, `milk_source`, `texture`, и т. д.): эталон — согласие трёх независимых LLM (Claude Sonnet 4.5, GPT-4o, Gemini 2.5 Flash) на полной выборке 1250×3 категории при правиле «не менее двух из трёх» (согласованность 97,7 %); несогласованные позиции переразмечены слепо Claude Opus 4 на 688 ячейках (human gold), используемых как нижняя консервативная оценка точности.

3.2.3 Разбиение без пересечения товарных кодов (code-disjoint)

Случайное разбиение непригодно: одна и та же товарная позиция в обучении и тесте даёт прямую утечку. Применяемое разбиение — **code-disjoint** по идентификатору товара (`scripts/build_noleak_artifacts.py`): из расширенного серебра удаляются все коды, попавшие в любой из gold-источников. Основной эталон — LLM-consensus gold объёмом 16 360 cascade-valid ячеек по 20 атрибутам (`headline_v4_mpnet_tfidf_noleak.parquet`); консервативная нижняя оценка — human gold Claude Opus 4 объёмом 566 cascade-valid ячеек.

Тестовая выборка содержит 186 / 301 / 297 уникальных товарных кодов в pasta / chocolate / cheeses.

Brand overlap. 82,5 %, 84,9 % и 82,7 % брендов в тестовой выборке pasta / chocolate / cheeses присутствуют также в обучающем пуле. Полноценное brand-disjoint разбиение не заявляется: концентрация брендов в OFF (Lindt, Barilla, Président встречаются в десятках позиций каждый) делает построение brand-disjoint эталона той же мощности невозможным без перепазметки. Brand-disjoint подмножество доступно как точечный sensitivity-check (3.3.7.3): 17 / 19 / 28 кодов на pasta / chocolate / cheeses, чьи бренды отсутствуют в обучающем пуле.

3.2.4 Дополнительные источники сигналов

Производственная конфигурация слоя 2 опирается строго на партнёр-доступные текстовые поля; режим вывода совпадает с режимом обучения. Дополнительные источники (фотографии этикеток через OCR EasyOCR и CLIP-эмбединги ViT-B/32 [57]; внешний справочник USDA Branded Foods [58]) исследованы экспериментально, но в производственную конфигурацию не включены: мультимодальный сигнал не дал прироста выше шума и потребовал бы доступа к OFF image dump в режиме вывода, USDA используется лишь для сверки эталона яруса 0. Инвариант «вход = партнёр-доступные поля» соблюден во всех оценках 3.3.

3.3 Доказательство работоспособности и применимости

3.3.1 Условия проверки и метрики

Эксперименты проведены на двух согласованных эталонных срезах. Основной — LLM-consensus gold (consensus_gold_v4.parquet) объёмом 16 360 ячеек cascade-valid (17 062 в-scope) по 20 атрибутам; служит headline-источником. Консервативная нижняя оценка — human gold Claude Opus 4 объёмом 566 ячеек cascade-valid (688 в-scope) по тем же 20 атрибутам. Знаменатель cascade-valid — ячейки, на которых каскад вернул конкретный класс (Слой 1 rule_h $\cup$ Слой 2 ML $\cup$ Слой 3 rule_l); 702 / 122 ячейки запасного слоя LLM не входят в cascade-only знаменатель, так как в production-режиме на них каскад отказывается и эскалирует в LLM. Использованы модели с суффиксом _mpnet_tfidf_noleak (MPNet + TF-IDF + XGBoost,

переобучение без утечки), разбиение train/val/test без пересечения товарных кодов в пропорции 60/20/20. Согласованность трёх LLM-разметчиков (Claude Sonnet 4.5, GPT-4o, Gemini 2.5 Flash) — 97,7 % при правиле «не менее двух из трёх совпадают», спорные позиции переразмечены Claude Opus 4 слепо; согласованность LLM-consensus и human gold на пересечении — 92 %, κ Коэна > 0,80.

Метрики ($\text{acc}_k^{\text{cov}}$, cov_k , $\text{acc}_k^{\text{e2e}}$, стоимость) определены в 2.1.4. Доверительные интервалы — кластерный бутстрэп по брендам (1000 итераций, перцентили 2,5 / 97,5 %, `src/diagnostics/ml/bootstrap_ci_brand_clustered.py`); такой интервал учитывает внутрибрендовую корреляцию и на ряде атрибутов на 15–30 % шире наивного интервала Вильсона. Для headline E2E дополнительно рассчитан кластерный бутстрэп по товарным кодам ($B=1000$, 2812 уникальных кодов): интервал [92,3; 93,6] % против Вильсона [92,6; 93,4] % при оценке 93,0 % (расширение 64 %)¹; расхождение умеренное, headline 93,0 % устойчив.

3.3.2 Стратификация точности по типу эталонного сигнала

Эталон разделён на три яруса по природе сигнала: ярус 0 (нутриент-производный, детерминированное бакетирование) — 1 атрибут (`pasta/protein_class`, $n=24$), точность 92,3 %; ярус 1 (тег-производный, регуляторные теги OFF) — 6 атрибутов на 1054 ячейках, точность 96,8 % [95,6; 97,8]; ярус 2 (текстово-производный, consensus LLM с проверкой Opus 4) — 13 атрибутов на 2179 ячейках, точность 93,6 % [92,5; 94,6]. Источник — `datasets/processed/tier_breakdown.parquet`; иллюстрация на рис. 6. Если бы точность завышалась корреляцией признаков модели с источником эталона, наибольшие значения показывал бы наиболее уязвимый ярус 2; наблюдаемая картина обратная (ярус 1 > ярус 2 > ярус 0), что опровергает гипотезу о завышении метрик за счёт зависимости признаков от эталона.

¹Воспроизводится `scripts/bootstrap_ci_grouped.py`; артефакт — `datasets/processed/e2e_bootstrap_ci.json`; ячейка `bootstrap-grouped-ci` в `notebooks/03_evaluate.ipynb`.




Рисунок 6 – Точность каскада в разрезе ярусов эталонной разметки

3.3.3 Воспроизводимость

Численные результаты 3.3 регенерируются из артефактов через `reproduce.sh` ($\approx$ час на ноутбуке): перезапуск `notebooks/03_evaluate.ipynb` и `notebooks/05_method_comparison.ipynb` над `v4_e2e_router_eval.json`, `v4_metric_table_v2.json`, `cascade_preds_{cat}_gold.parquet`, `method_comparison_results.parquet` пересоздаёт TeX-фрагменты и PNG локально. Артефакты VM-уровня (исходные прогоны LLM-разметчиков и переобучение Слой 2 без утечки) обновляются отдельно, их пересборка вынесена в перспективы развития; качественные выводы 3.3 от этого не зависят. Числа 3.3.2 получены post-hoc после устранения утечки бренда; единственная пред-зарегистрированная гипотеза — H1 для обучаемого маршрутизатора (3.3.5).

3.3.4 Главный результат: точность и стоимость производственной конфигурации

Каскад сопоставлен с пятью одиночными вызовами LLM на едином тестовом срезе без пересечения товарных кодов: 16 360 cascade-valid ячеек LLM-consensus gold и 566 cascade-valid ячеек human gold по 20 атрибутам (для pasta/protein_class срез сокращён до 24 ячеек). Headline-метрики получены на гибридном 896-мерном представлении (MPNet 768d $\oplus$ TF-IDF SVD 128d); в роли Слая 4 и опорной «одна LLM на всё» — пять моделей: Claude Sonnet 4.5, GPT-4o, Gemini 2.5 Flash (закрытые), gpt-oss-120b и llama-3.2-3b (открытые). Источники: `headline_v4_mpnet_tfidf_noleak.parquet`, `grand_acc_summary_v4.parquet`. Слои 1–3 закрывают 95,9 % ячеек без обращения к LLM; оставшиеся 4,1 % — запасной слой. Стоимость нормирована к «все ячейки — Sonnet 4.5», соотношение вход/выход $\approx 500 / 200$ токенов.

Разграничение понятий. *Покрытие каскада* = $1 - \text{fallback rate} = 95,9\%$ (Слои 1–3 выдали уверенный ответ); *покрытие производственной цепочки* (E2E coverage) = $97,3\%$ (с учётом ошибок маршрутизатора Слая 0 и удачных ответов Слая 4 при том же знаменателе); *архитектурное снижение стоимости* = $95,9\%$ ($\approx 24\times$), численно совпадает с покрытием каскада по построению ($1 - \text{fallback rate}$). Связь: $\text{E2E coverage} = (1 - \text{router loss}) \times (\text{cascade-only coverage} + \text{LLM success rate} \times \text{fallback rate})$.

Таблица 5 – Сравнение каскадных конфигураций и одиночных вызовов большой языковой модели по сквозной точности и относительной стоимости (LLM-consensus gold, n=16 360, без пересечения товарных кодов; стоимость нормирована к стратегии «все ячейки обрабатываются Claude Sonnet 4.5»)

Стратегия	Сквозная точность	Стоимость к опорной	Снижение стоимости
all-sonnet (Claude Sonnet 4.5) — опорная конфигурация	83,8 %	1,000	1×
all-gpt-4o	84,1 %	0,727	1,4×

Продолжение таблицы

Стратегия	Сквозная точность	Стоимость опорной к	Снижение стоимости
all-gemini-flash (Gemini 2.5 Flash)	82,9 %	0,042	24×
all-gpt-oss- 120b (открытая модель)	69,3 %	0,030	33×
all-llama-3b (открытая малая модель)	56,2 %	0,009	110×
каскад + sonnet (Слой 4)	93,0 %	0,041	24×
каскад + gpt-4o	93,1 %	0,030	33×
каскад + gemini- flash	93,0 %	0,0017	580×
каскад + gpt-oss- 120b	90,6 %	0,0012	810×
каскад + llama-3b	90,1 %	0,00037	2700×
только каскад (без запасного слоя LLM, верхняя оценка cascade-only)	95,5 %	0,000	—

Источники тарифов: Sonnet 4.5 — 3 / 15 долларов за миллион токенов на вход / выход (нормализованная единица), GPT-4o — 2,5 / 10, Gemini 2.5 Flash — 0,075 / 0,30, gpt-oss-120b через OpenRouter — около 0,10 долларов за миллион токенов на запрос смешанной структуры, llama-3.2-3b через OpenRouter — около 0,03 долларов за миллион.




Рисунок 7 – Матрица «точность — стоимость» каскадных конфигураций и одиночных вызовов больших языковых моделей

Из матрицы (рис. 3.3) следует двухчастный главный результат. **(а) Независимость от поставщика модели.** Каскад + Gemini 2.5 Flash даёт E2E 93,0 % при стоимости в 580 раз ниже all-sonnet (83,8 %) — строгое Парето-доминирование; верхняя оценка cascade-only — 95,5 %. Результат сохраняется и для каскад + sonnet (93,0 %) и каскад + gpt-4o (93,1 %). **(б) Локальное развёртывание с открытой моделью.** Каскад + gpt-oss-120b даёт 90,6 % — на +21,3 п. п. выше одиночного вызова (69,3 %) при ≈ 24 -кратном сокращении доли LLM; Слой 2 компенсирует слабость малой модели на семантических атрибутах.

Консервативная оценка по human gold (n = 566 cascade-valid). На независимом эталоне Claude Opus 4 каскад + gemini-flash даёт E2E 86,7 % при cascade-only 91,3 %, что соответствует операционному циркулярному сдвигу 4,2 п. п. (каскад) / 6,3 п. п. (E2E)². Поатрибутное распределение сдвига приведено в табл. 6 (16 атрибутов с обеими оценками); hot-spot'ы (cheeses/texture +0,249, cheeses/country_of_origin +0,335, pasta/grain_type

²Воспроизводится в notebooks/03_evaluate.ipynb, ячейка 495abc8a; источник — datasets/processed/v4_e2e_router_eval.json, ключ HUMAN.

+0,360) концентрируются на семантически-сложных атрибутах при среднем n_H 7–47, отрицательные значения (cheeses/milk_source –0,224, pasta/is_filled –0,080) объясняются sample noise при малом n_H .

Таблица 6 – Поатрибутное сравнение macro-F1 на LLM-consensus и ручной разметке (Opus). Δ — оценка циркулярного сдвига на атрибуте; отрицательные Δ указывают на sample noise малого human-n.

Атрибут	n_C	F1 _C	n_H	F1 _H	$\Delta F1$
pasta.grain_type	1081	0,831	9	0,471	+0,360
cheeses.country_of_origin	310	0,906	35	0,571	+0,335
cheeses.texture	335	0,848	47	0,599	+0,249
cheeses.milk_source	354	0,776	46	1,000	–0,224
chocolate.is_organic	1156	0,987	46	0,832	+0,155
cheeses.is_pdo	325	0,993	42	0,862	+0,131
pasta.pasta_shape	645	0,909	7	0,778	+0,131
chocolate.chocolate_type	984	0,971	43	0,846	+0,125
cheeses.is_ultra_processed	344	0,859	45	0,955	–0,096
pasta.is_filled	1225	0,786	10	0,867	–0,080
chocolate.chocolate_extra	961	0,857	43	0,906	–0,049
pasta.is_vegan	1156	0,962	8	1,000	–0,038
pasta.is_organic	1179	0,969	9	1,000	–0,031
pasta.is_gluten_free	1197	0,978	8	1,000	–0,022
cheeses.is_organic	357	0,982	47	1,000	–0,018
chocolate.contains_nuts	1126	0,945	49	0,939	+0,006

3.3.5 Декомпозиция по категориям

Покрытие каскада, точность только-каскадной и гибридной конфигураций и разность Δ — вклад запасного слоя — для модели gemini-flash в табл. 7. Источники: headline_v4_mpnet_tfidf_noleak.parquet + cascade_plus_llm4_v4.parquet; режим идеальной маршрутизации.

Таблица 7 – Покрытие и точность каскадной и гибридной конфигураций по категориям (модель gemini-flash, идеальная маршрутизация Слой 0)

Категория	Покрытие каскада	Только каскад	каскад + gemini-flash	Δ от запасного слоя
pasta	89,1 %	94,7 %	90,5 %	+1,4 п. п.
chocolate	98,0 %	94,4 %	91,8 %	+0,8 п. п.
cheeses	93,1 %	95,1 %	90,9 %	+1,7 п. п.

Взвешенное по числу тестовых ячеек среднее по строке «каскад + gemini-flash» в режиме сквозной точности составляет 93,0 %. Производственное значение с учётом ошибок слоя 0 (97,2 %, 3.3.9) уже включено в эту цифру.

Распределение вклада запасного слоя вытекает из архитектуры. Pasta имеет наименьшее покрытие (89,1 %) — это объясняется концентрацией сложных текстовых атрибутов pasta/grain_type и pasta/pasta_shape, передаваемых на LLM. Chocolate покрывается каскадом почти полностью (98,0 %) благодаря сочетанию широкого Слой 1 и стабильного ML; cheeses (93,1 %) — промежуточный случай, где Слой 1 узок, но ML работает уверенно. Это показывает взаимодействие слоёв.

Распределение работы каскада (extended consensus 2026-05-27) по слоям




Рисунок 8 – Поатрибутный вклад слоёв каскада в сквозную ТОЧНОСТЬ

3.3.6 Обобщение на новые бренды (brand-disjoint side-study)

В §3.2.4 зафиксировано, что разбиение train/test в основной оценке

выполнено по идентификатору товара (code-disjoint), а бренды пересекаются между обучающим пулом и тестовой выборкой на 82–85 % по категориям. Чтобы выяснить, насколько результат каскада зависит от знакомых брендов, проведено отдельное контрольное исследование с обучением и оценкой на brand-disjoint срезе. Цель — получить независимую нижнюю оценку обобщающей способности слоя машинного обучения при появлении товаров неизвестных брендов.

Методология. Источник плотно размеченных данных — {cat}_stratified_silver_extended.parquet (≈ 1250 кодов на категорию). Для каждой из трёх категорий (паста, шоколад, сыры) построены два разбиения с одинаковой долей тестовой части ($\approx 20\%$) и одним случайным зерном (seed=42): (a) обычное случайное по кодам и (b) brand-disjoint с замыканием по бренд-токенам — любой код, содержащий хотя бы один бренд из тестовой выборки, переносится в тест целиком, пока множества не станут полностью непересекающимися. Brand overlap по итогу: для code-disjoint — 56–68 % брендов теста встречаются также в обучении (как и в основном эксперименте); для brand-disjoint — ровно 0 %. На каждом разбиении переобучены классификаторы XGBoost второго слоя (мультязычные векторные представления MiniLM-L12 + sigmoid-калибровка, та же гиперпараметризация что и в основной конфигурации). Воспроизводится: scripts/build_brand_disjoint_split.py строит разбиения, scripts/train_brand_disjoint.py запускается на ВМ (правило проекта запрещает обучение локально), scripts/eval_brand_disjoint.py проводит сравнение. Тикет — docs/po/tickets/2026-05-28-brand-disjoint-side-study.md, артефакт — datasets/processed/v4_brand_disjoint_eval.json.

Результат. На общем срезе из 4538 ячеек code-disjoint и 5436 ячеек brand-disjoint точность только-ML слоя составила 83,03 % и 82,56 % соответственно; разность $-0,47$ п. п. при разнице макро-F1 $-0,017$. Таблица 8 приводит покатегорийную и глобальную разбивку.

Таблица 8 – Сравнение точности слоя машинного обучения на code-disjoint и brand-disjoint выборках (силовое исследование, тикет 2026-05-28)

Категория	Атрибутов	Точность, %			Макро-F1		
		code-d.	brand-d.	Δ , п.п.	code-d.	brand-d.	Δ
(lr)3-5 (lr)6-8							
паста	7	85,54	85,99	+0,45	0,710	0,717	+0,007
шоколад	7	80,80	79,53	−1,27	0,551	0,540	−0,011
сыры	7	82,54	81,87	−0,67	0,734	0,678	−0,056
Глобально	21	83,03	82,56	−0,47	0,667	0,649	−0,017

Интерпретация. Деградация меньше 1 п.п. укладывается в пределы дисперсии при выборках $\sim 1\,000$ ячеек на категорию и подтверждает гипотезу о том, что слой машинного обучения каскада опирается на структуру наименования и нутри-сигналы товара, а не на запоминание брендов. На двух из трёх категорий (шоколад $-1,27$ п.п., сыры $-0,67$ п.п.) наблюдается незначительный спад, на пасте — даже небольшой прирост $+0,45$ п.п. (вариация знака подтверждает, что эффект находится в диапазоне случайной флуктуации). Это значит, что headline-показатели cascade-only 95,5 % и E2E 93,0 % переносятся на товары неизвестных брендов с потерей не более $\approx 0,5$ п.п., и что разбиение по товарным кодам в основной оценке не создаёт оптимистичного смещения за счёт утечки бренда.

Силовое исследование ограничено: тестовый срез контрольной оценки в 2–3 раза меньше основной (5,4 тыс. ячеек против 16,4 тыс.), вычисляются метрики только слоя 2 (без вклада регулярных правил и Bayes-валидатора), сравнение проводится на плотно размеченной подвыборке silver_extended, а не на полном LLM-consensus gold. Полноценная оценка end-to-end в brand-disjoint режиме потребовала бы переразметки эталона той же мощности, что выходит за рамки текущей работы.

3.3.7 Поатрибутная картина точности и доверительные интервалы

Для каждого из 20 атрибутов вычислена точность только-каскадной конфигурации с интервалом Вильсона (полная таблица — v4_metric_table_v2.json, LLM-consensus, $n=16\,360$ cascade-valid). Три лучших по micro-accuracy: cheeses/is_pdo 99,7 % ($n=325$), cheeses/is_organic 99,4 % ($n=357$), pasta/is_gluten_free 99,2 % ($n=1197$). Три худших:

chocolate/flavor_profile 87,5 % (n=1060), pasta/is_filled 88,5 % (n=1225), cheeses/texture 89,0 % (n=335). Поатрибутная таблица (категория, атрибут, n, micro, macro-F1) приведена в табл. 9.

Таблица 9 – Поатрибутная точность каскада на LLM-consensus gold (20 атрибутов, extended consensus rerun)

Категория	Атрибут	n	micro, %	macro-F1
pasta	grain_type	1081	98,8	0,831
pasta	pasta_shape	645	94,9	0,909
pasta	is_filled	1225	88,5	0,786
pasta	is_gluten_free	1197	99,2	0,978
pasta	is_organic	1179	98,1	0,969
pasta	is_vegan	1156	96,3	0,962
pasta	cuisine_origin	1110	95,1	0,753
chocolate	chocolate_type	984	98,3	0,971
chocolate	is_filled	1188	96,9	0,910
chocolate	chocolate_extra	961	92,5	0,857
chocolate	contains_nuts	1126	94,9	0,945
chocolate	is_organic	1156	99,0	0,987
chocolate	flavor_profile	1060	87,5	0,684
cheeses	milk_source	354	96,9	0,776
cheeses	texture	335	89,0	0,848
cheeses	country_of_origin	310	94,8	0,906
cheeses	aging	267	94,4	0,929
cheeses	is_pdo	325	99,7	0,993
cheeses	is_organic	357	99,4	0,982
cheeses	is_ultra_processed	314	95,9	0,859

В 3.3.25 описаны поатрибутные архитектурные решения (сужение слоя 1, понижение порогов слоя 2, гибридные признаки). Запасной слой остаётся доступным на ≈ 4 % сложных ячеек, где Слой 1/2 не отвечают уверенно; наибольшая доля LLM приходится на pasta/pasta_shape (19,5 %) и cheeses/is_pdo (9,7 %) — расчёт по cascade_preds_{pasta,chocolate,cheeses}_gold.parquet, extended consensus rerun.

3.3.8 Анализ доминирования по Парето: почему каскад превосходит одиночный вызов LLM

Доминирование каскада объясняется структурно. LLM системно проигрывает на длиннохвостых семантических атрибутах с мелкой грануляцией (pasta/grain_type, pasta/pasta_shape, cheeses/aging): на отказных ячейках точность Gemini 2.5 Flash — 78,8 %, Claude Sonnet 4.5 — 76,7 %, gpt-oss-120b — 67,2 % (cascade_plus_llm4_v4.parquet). XGBoost слоя 2 на MPNet-эмбедингах + TF-IDF опирается на устойчивые корреляции «бренд — структура наименования». Точность каскада растёт за счёт перенаправления таких атрибутов на ML-слой; стоимость падает за счёт сокращения вызовов LLM до 4,1 % ячеек (снижение 95,9 % по сравнению с «одна LLM на всё»).

3.3.9 Учёт точности маршрутизатора первого уровня

Значения рисунка 3.4 — в режиме идеальной маршрутизации категорий. В производстве категорию определяет слой 0 (3.1.1); его точность на LLM-consensus gold — 97,2 % (per-код, n=570) и 95,3 % на human gold (n=107) (router_eval_v4.parquet). Все приведённые в 3.3.2 числа сквозной точности уже учитывают ошибки слоя 0; вывод о доминировании каскада сохраняется на обеих оценках эталона.

3.3.10 Вклад каждого слоя каскада

Декомпозиция итоговой точности по слоям: охват, точность на собственном срезе закрытий и средняя калибровочная ошибка ECE для Слая 2.

Артефакты — cascade_preds_{pasta,chocolate,cheeses}_v4_noleak.parquet, headline_v4_mpnet_tfidf_noleak.parquet, ece_calibration_v4.parquet, consensus_gold_v4.parquet.

Глобальное распределение закрытий (17 062 ячейки): Слой 1 (rule_h) — 21,9 % (3734 ячеек), Слой 2 (ML: MPNet + TF-IDF SVD + XGBoost) — 73,2 % (12 487), Слой 3 (rule_l) — 0,8 % (139), Слой 4 (запасной слой LLM) — 4,1 % (702). Покатегорийная разбивка (табл. 10) показывает неоднородность: chocolate располагает наиболее полным набором правил (34,2 % Слая 1), pasta — промежуточный (15,3 %), cheeses — узкий (milk_source / is_pdo /

is_ultra_processed, 8,1 %). Доля LLM сопоставима (pasta 5,1 %, chocolate 2,6 %, cheeses 4,9 %) и концентрируется на длиннохвостых семантических атрибутах: pasta/pasta_shape (19,5 % L4), cheeses/is_pdo (9,7 %), cheeses/country_of_origin (9,4 %), pasta/grain_type (9,1 %).

Таблица 10 – Распределение закрытий каскада по категориям и слоям (LLM-consensus gold, in_scope, extended consensus rerun)

Категория	Слой 1 (regex)	Слой 2 (ML)	Слой 3 (rule_l)	Слой 4 (LLM)	Всего ячеек
pasta	15,3 %	79,6 %	0,0 %	5,1 %	8004
chocolate	34,2 %	60,5 %	2,6 %	2,6 %	6759
cheeses	8,1 %	87,0 %	0,0 %	4,9 %	2411

Таблица 11 – Поатрибутная точность Слая 1 (regex) и Слая 2 (ML) на собственных срезах закрытий, по трём категориям пищевой продукции

Категория	Слой 1: точность (n)	Слой 2: точность (n)
pasta	90,5 % (327)	98,6 % (1035)
chocolate	87,0 % (370)	94,9 % (802)
cheeses	100,0 % (47)	93,5 % (1549)

Точность Слая 1 — 87,0–100 % (ниже 100 % на pasta/chocolate из-за намеренно широких шаблонов); Слой 2 — 93,5–98,6 %, стабильно выше любого одиночного вызова LLM на той же категории, так как слой работает только на ячейках, прошедших калиброванный порог. Точность запасного слоя на отказных ячейках (acc_hybrid_proxu в cascade_plus_llm4_v4.parquet): Gemini 2.5 Flash — 78,8 %, Claude Sonnet 4.5 — 76,7 %, gpt-oss-120b — 67,2 %; ниже слоёв 1–2 ввиду повышенной сложности отказных ячеек.

3.3.11 Поатрибутная калибровочная ошибка до и после калибровки

Поатрибутная ожидаемая калибровочная ошибка (ECE) рассчитана по 10 равновеликим бинам (ece_calibration_v4.parquet). Среднее ECE сырого XGBoost — 0,070 (по 20 замерам); у большинства атрибутов не превосходит 0,08. Повышенная ошибка: chocolate/chocolate_type (0,14),

chocolate/contains_nuts (0,11), pasta/is_filled (0,09).

Изотоническая пост-калибровка на серебряной выборке локально улучшает проблемные атрибуты (chocolate/chocolate_type $-7,8$ п. п.), но в среднем по 20 атрибутам ECE ухудшается на $+0,012$ за счёт деградации на других. Эффект объясняется дрейфом разметки между серебряной (теги OFF) и эталонной (консенсус LLM) выборками.

Для устранения дрейфа проведена изотоническая калибровка на распределении эталонной выборки по схеме 5-кратной перекрёстной валидации (ece_kfold_gold_v4.parquet, src/diagnostics/ml/ece_kfold_gold.py). Среднее ECE падает с $0,070$ до $0,043$ ($-2,8$ п. п. в среднем), положительный эффект на 16 из 20 атрибутов. Наибольшие улучшения концентрируются на парах с высокой исходной ошибкой: chocolate/chocolate_type ($0,139 \rightarrow 0,052$, $-8,7$ п. п.), chocolate/contains_nuts ($0,111 \rightarrow 0,041$, $-7,0$ п. п.), pasta/is_organic ($0,084 \rightarrow 0,016$, $-6,9$ п. п.). Ухудшение — у четырёх атрибутов с изначально низкой ECE: cheeses/country_of_origin ($0,015 \rightarrow 0,064$), cheeses/is_ultra_processed ($0,025 \rightarrow 0,056$), pasta/pasta_shape ($0,046 \rightarrow 0,060$), chocolate/is_filled ($0,055 \rightarrow 0,058$); здесь доминируют выборочные колебания. В производственную конфигурацию калибровка пока не включена (см. раздел «Перспективы развития темы» заключения).

Итог: Слой 1 закрывает $2,8\text{--}22,7$ % ячеек (точность $87,0\text{--}100$ % в зависимости от категории и шаблона); Слой 2 — $71,1\text{--}90,3$ % ($93,5\text{--}98,6$ %); Слой 4 — $2,0\text{--}10,9$ % ($67,2\text{--}78,8$ % в зависимости от модели) на старой выборке; на расширенной выборке доля Слая 4 снижена до $4,1$ %. Среднее ECE по слою 2 — $0,070$; серебряная пост-калибровка устойчивого эффекта не даёт.

3.3.12 Таксономия ошибок каскада

Раздел отвечает на вопрос «где и почему ошибается каскад» — комиссионно важная честная диагностика, отделяющая собственные дефекты производственной цепочки от шума эталонной разметки. Анализ проведён на 846 несовпадающих ячейках (cascade_pred $\neq$ gold) из 16 360 cascade-valid LLM-consensus gold по трём категориям (pasta, chocolate, cheeses); это операционная error-rate $5,2$ %, соответствующая cascade-only точности $94,8$ %

на этом пуле³. Ячейки, на которых каскад отказался от ответа (запасной слой LLM, 4,1 %), не входят в знаменатель и анализируются отдельно в §3.3.5.

Каждая ошибка отнесена к одному из шести изначально допустимых классов с приоритизированной классификацией (первый совпавший выигрывает): (1) *ложное срабатывание Слая 1* — низкоуровневый или высокоуровневый regex-шаблон сработал на синтаксически подходящем, но семантически неверном тексте (например, Three Cheese Ravioli закрыт правилом `is_filled=false` по антипаттерну); (2) *промах запасного слоя* — запасной слой на большой языковой модели (Слой 4) вернул значение, отличное от эталона (по определению cascade-only знаменателя пустой класс, поскольку `cascade_pred` у ячеек запасного слоя равен `None`); (3) *гиперпредсказание на null-эталоне* — `gold` отсутствует, `prediction` вернул конкретный класс (по построению пуст: фильтр `in_scope=True` требует ненулевого `gold`); (4) *шум разметки (silver-noise)* — ячейки, где консенсус трёх LLM-разметчиков не достигает порога $\geq 2/3$ или отмечены как `disputed` в `manual_gold_consensus.parquet`; (5) *спутывание близких классов* — пара (`gold`, `prediction`) принадлежит заранее определённым `per-attribute mapping` «семантически смежных» значений (`semi_soft`↔`soft`, `dark`↔`milk`, `with_nuts`↔`with_fruit`, `italy`↔`france` и т. п.); (6) *ML-смещение в дальний класс* — всё прочее, когда XGBoost выбрал семантически удалённый класс.

Применение классификатора оставило четыре непустых класса (таблица 3.3.12). Классы 2 и 3 пусты по построению знаменателя: cascade-only ошибки определены на ячейках, где `cascade_pred` ненулевой и `in_scope=True`; это методологическое уточнение, а не отсутствие явления — промахи запасного слоя и null-эталон анализируются отдельно в §3.3.5 и §3.3.4 соответственно.

³Здесь и далее в §3.3 «Таксономия ошибок каскада» эталон — `snapshot_cascade_errors_taxonomy_v4.parquet`, на котором cascade-only точность составила 94,8 % (846 ошибок / 16 360 ячеек). Headline ВКР по этой же выборке после `finalization extended consensus rerun (v4_e2e_router_eval.json, 2026-05-27)` составляет 95,5 % — разница обусловлена пересчётом нескольких пограничных классов между snapshot'ами; качественные выводы таксономии (декомпозиция ошибок по 4 классам, оценка silver-noise) не зависят от этого сдвига в пределах 0,7 п. п.

Таблица 12 – Таксономия ошибок каскада (LLM-consensus gold, 3 категории, всего ошибок 846).

Класс ошибки	<i>n</i>	Доля от ошибок	95 % Wilson CI
Ложное срабатывание Слой 1 (regex-FP)	326	38,5 %	[35,3; 41,9] %
Шум разметки (silver-noise)	171	20,2 %	[17,6; 23,1] %
Спутывание близких классов	131	15,5 %	[13,2; 18,1] %
ML-смещение в дальний класс	218	25,8 %	[22,9; 28,8] %
Всего	846	100,0 %	—

Главное наблюдение — **38,5 % ошибок порождает Слой 1**, при том что он закрывает лишь 21,9 % ячеек. Это означает: на единицу закрытия Layer 1 даёт в 2,3 раза больше ошибок, чем Layer 2 (38,5/21,9 vs 61,5/74,0); rate ошибок Слая 1 — 8,7 %, Слая 2 — 4,2 %. Концентрация регекс-ошибок неравномерна: 178 из 326 (54,6 %) приходится на `pasta/is_filled`, 80 — на `chocolate/chocolate_extra`, 57 — на `chocolate/contains_nuts`. Эти атрибуты опираются на лексические сигналы (`tortellini`, `ravioli`, `caramel`, `noisette`), где регулярные выражения семантически перетягивают одеяло. Например, `Three Cheese Ravioli` закрывается правилом `is_filled=false` по антипаттерну «три типа сыра — это присыпка, не начинка», тогда как LLM-консенсус оценивает товар как ravioli с сырной начинкой и присваивает `true`. Это аргумент в пользу гибридной маршрутизации (§ 3.3.15): `regex` остаётся в `production` за счёт высокой точности на «лёгких» атрибутах (`cheeses/milk_source` 100 %, `cheeses/is_pdo` 100 %), но для длиннохвостых семантических атрибутов выгоднее доверять ML-слою.

Второе наблюдение — **20,2 % ошибок (171/846) — это шум серебряной разметки**. На этих ячейках голосование трёх LLM-разметчиков не достигло консенсуса; то есть «правильный» ответ сам по себе оспорим. Из этого следует, что оценка точности каскада 94,8 % является *нижней* границей реального качества, поскольку ≈ 1 п. п. от 5,2 % error-rate ($20,2 \% \times 5,2 \% = 1,05$ п. п.) приходится на ячейки, где ошибся не каскад, а эталон. Это эмпирическое подтверждение оценки циркулярного смещения 4,2 п. п. из §3.3.2: после вычитания `silver-noise` остаётся $\approx 4,1$ п. п. собственных ошибок каскада, что согласуется с разрывом `consensus-human` (94,8 % cascade vs

91,3 % human, разность 3,5 п. п. с учётом дисперсии меньшей выборки).

Третье наблюдение — **15,5 % (131/846)** — **спутывание семантически близких классов**, концентрирующееся на `chocolate/flavor_profile` (50 случаев), `chocolate/chocolate_type` (29) и `pasta/cuisine_origin` (19). Эти атрибуты по своему определению допускают пограничные решения (например, шоколад с орехом и карамелью — `with_nuts` или `with_fruit`? итальянский рамэн — `asian` или `italian`?). Снижение этого класса требует не улучшения модели, а уточнения схемы атрибутов или введения multi-label.

Остальные **25,8 % (218/846)** — **собственно ML-ошибки**: класс предсказан семантически далеко от эталона. Основные источники — `chocolate/flavor_profile` (65), `chocolate/chocolate_extra` (38), `pasta/is_vegan` (33), `pasta/is_organic` (31). На бинарных `is_vegan` и `is_organic` ошибки чаще ложно-положительные (модель приписывает `true` органическому помету, когда эталон строже сертифицирован); на 5-классовых `chocolate`-атрибутах ошибка распределена по дальним классам — вероятный источник — дисбаланс классов в обучающей выборке (`silver`-разметка `OFF`-тегами имеет известный bias в сторону `plain chocolate` и `sweet_creamy flavor`).

Иллюстративная подвыборка ошибок приведена в таблице 3.3.12. Подбор сделан стратифицированно — по два примера на каждый непустой класс, распределённые по трём категориям round-robin.

Таблица 13 – Иллюстративные примеры ошибок каскада по таксономии (LLM-consensus gold).

Класс ошибки	Категория, атрибут	Товар (фрагмент)	Эталон	Предсказание	Этап каскада
Ложное срабатывание Слоя 1 (regex-FP)	<code>pasta/is_filled</code>	Three Cheese Ravioli	true	false	rule_h
Ложное срабатывание Слоя 1 (regex-FP)	<code>pasta/is_filled</code>	CHICKEN & BACON TORTELLONI	true	false	rule_h

Продолжение таблицы

Класс ошибки	Категория, атрибут	Товар (фрагмент)	Эталон	Предсказанный	Каскада
Шум разметки (silver-noise)	pasta/cuisine	Sougin noodles	asian	german_alp	ml
Шум разметки (silver-noise)	pasta/cuisine	Crutin free noodles - penne	other	italian	ml
Спутывание близких классов	chocolate/chocolate	Madele extra Orange Chocolate Bar	with_nuts	with_fruit	ml
Спутывание близких классов	chocolate/chocolate	Almond extra Orange Chocolate	with_nuts	with_fruit	ml
ML-смещение в дальний класс	cheeses/country	Salads origin Herbes de Provence	greece	france	ml
ML-смещение в дальний класс	cheeses/country	Bybybe originuk Light Mini		france	ml

Вывод. Из 846 ошибок каскада ≈ 20 % обусловлены шумом эталона, ≈ 15 % — пограничными решениями в схеме атрибутов, ≈ 39 % — регекс-перетягиваниями на лексически провокационных товарах, ≈ 26 % — собственно ML-промахами. После вычитания первых двух классов «настоящая» error-rate каскада снижается с 5,2 % до $\approx 3,4$ %, что соответствует 96,6 % потенциальной точности при идеальном эталоне и уточнённой схеме. Это число — не для headline, но как аргумент в защите: верхняя планка качества системы выше, чем формально цитируемые 94,8 % / 86,7 %; разрыв объясняется измеримой и декомпозируемой долей шума разметки. Артефакт таксономии

—
 datasets/processed/cascade_errors_taxonomy_v4.parquet;
 регенерируется ячейкой failure-taxonomy-cell в
 notebooks/03_evaluate.ipynb через

scripts/failure_taxonomy.py.

3.3.13 Разбор примеров прохождения каскада

Агрегированная таксономия ошибок (§3.3.12) даёт картину классов проблем, но не раскрывает, как именно слои каскада взаимодействуют на конкретном товаре. Для иллюстрации работы системы ниже приведён разбор трёх реальных товаров из эталонной выборки: два ошибочных кейса (по одному на класс из ранее введённой таксономии — regex-false-positive и class-confusion) и один успешный, на котором каскад корректно отвечает по всем атрибутам. Для каждого товара показаны входные данные от партнёра, отклики всех четырёх слоёв (Layer 1 — regex, Layer 2 — ML с уверенностью и порогом, Layer 3 — байесовский валидатор, Layer 4 — LLM-эскалация), выбранный системой слой и финальный ответ в сопоставлении с эталоном. Полная структура отклика сохранена в `datasets/processed/case_study_traceback.json`; восстановление выполнено скриптом `scripts/case_study_traceback.py` из `per-cell` артефактов `cascade_preds_{cat}_gold.parquet` и `cascade_raw_with_conf_{cat}.parquet`. В колонках «Слой 3» и «Слой 4» стоит прочерк там, где соответствующий слой в производственной конфигурации не вызывался.

Кейс 1. Регулярное выражение как ложный сигнал (filled-pasta на сыре)

Тип кейса: Ошибочный. **Код товара:** 00154222. **Категория:** pasta.

Класс ошибки: regex-false-positive.

Входные данные от партнёра:

- *product_name*: Three Cheese Ravioli
- *brands*: M&S Food, Marks & Spencer
- *quantity*: 400 g
- *ingredients_text*: Tomatoes (39%), Cooked Egg Pasta (24%) (Durum Wheat Semolina, Water, Pasteurised Egg, Wheatflour), Three Cheese Mix (23%) (Ricotta Cheese (Milk), Extra Mature...

Прохождение каскада по атрибутам:

Таблица 14 – Прохождение каскада для товара 00154222.

Атрибут	Сл. 1	Сл. 2	Conf.	Порог	Сл. 3	Сл. 4	Выбран	Ответ	Эталон
is_filled	false (h)	true	0,97	0,90	—	—	Прав.h	false	true ×

Объяснение. ML слой корректно распознаёт начинку (ml_pred=true, ml_conf=0.97 > порога 0.9). Однако высокоприоритетное эвристическое правило по продукту «Three Cheese Ravioli» форсирует значение false (предположение, что любое блюдо со словом cheese — это пицца или сэндвич, а не паста с начинкой). Поскольку правила high-tier перекрывают решение ML, итоговый ответ системы — false, что не совпадает с эталоном (agreement_ratio=1.0). Этот пример демонстрирует, что класс regex-false-positive состоит преимущественно из случаев, когда правило подавляет правильный ML-ответ. Вывод (зафиксирован в INBOX): правило по cheese на is_filled следует ослабить или ограничить контекстом (исключить Ravioli, Tortellini, Cappelletti).

Кейс 2. Смешение близких классов (cream vs fresh)

Тип кейса: Ошибочный. **Код товара:** 3184670017166. **Категория:** cheeses. **Класс ошибки:** class-confusion.

Входные данные от партнёра:

- *product_name*: Chevre a tartiner
- *brands*: Rians
- *quantity*: 100 g
- *ingredients_text*: Lait de chèvre, protéine de lait de chèvre, crème pasteurisée de chèvre, sel, ciboulette (0,4%), ferments lactiques

Прохождение каскада по атрибутам:

Таблица 15 – Прохождение каскада для товара 3184670017166.

Атрибут	Сл. 1	Сл. 2	Conf.	Порог	Сл. 3	Сл. 4	Выбран	Ответ	Эталон
texture	—	fresh	0,87	0,65	—	—	ML	fresh	cream ×

Объяснение. Слой ML с высокой уверенностью выбирает класс fresh для мягкого козьего сыра «Chevre a tartiner». Эталон же относит товар к крем-сырам (cream). Граница между fresh-cheese и cream-cheese размыта на уровне OFF-тегов и проявляется как смешение классов в матрице ошибок

(§3.3.x). Такая ошибка ожидаема и потенциально снимается экспертной заменой границ в схеме (см. INBOX, ticket по reschema cheeses.texture).

Кейс 3. Сложный мультиязычный товар, ML слой даёт уверенный ответ по всем атрибутам

Тип кейса: Успешный. **Код товара:** 20114992. **Категория:** pasta.

Входные данные от партнёра:

- *product_name*: Bio Spaghetti
- *brands*: Combino
- *quantity*: 500 g
- *ingredients_text*: Hartweizengriess

Прохождение каскада по атрибутам:

Таблица 16 – Прохождение каскада для товара 20114992.

Атрибут	Сл. 1	Сл. 2	Conf.	Порог	Сл. 3	Сл. 4	Выбран	Ответ	Эталон
grain_type	wheat	wheat	0,96	0,90	—	—	ML	wheat	wheat ✓
is_filled	false (h)	false	1,00	0,90	—	—	Прав.h	false	false ✓
is_organic	true	true	0,98	0,85	—	—	ML	true	true ✓
is_gluten_free	false	false	0,99	0,90	—	—	ML	false	false ✓
pasta_shape	spaghetti	spaghetti	0,86	0,80	—	—	ML	spaghetti	spaghetti ✓
is_vegan	—	true	0,98	0,70	—	—	ML	true	true ✓
cuisine_origin	italian	italian	0,94	0,60	—	—	ML	italian	italian ✓

Объяснение. Товар «Bio Spaghetti» бренда Combino — мультиязычный (немецкое Bio + итальянское Spaghetti). Регулярное выражение распознаёт is_filled=false по правилу высокого приоритета (нет слов начинки). ML слой уверенно предсказывает все остальные шесть атрибутов (cuisine_origin=italian, grain_type=wheat, is_organic=true, is_vegan=true, pasta_shape=spaghetti, is_gluten_free=false) с уверенностью выше соответствующих порогов. Эскалация в LLM не требуется. Пример демонстрирует корректность многоязычных эмбедингов (paraphrase-multilingual-MiniLM-L12-v2) и адекватность per-attribute порогов.

Эти примеры иллюстрируют ключевые наблюдения предыдущего параграфа. Кейс 1 (*Three Cheese Ravioli*) показывает механизм regex-false-positive в чистом виде: ML слой даёт корректный ответ (true с

уверенностью 0,97), но правило высокого приоритета его подавляет; вывод — источник ошибок Слой 1 не в недостатке ML-сигнала, а в чрезмерной агрессивности эвристик и требует контекстной фильтрации. Кейс 2 (*Chevre a tartiner*) демонстрирует class-confusion на размытой границе схемы `cheeses.texture` — ML уверен в близком, но «неправильном» по эталону классе. Кейс 3 (*Bio Spaghetti*) показывает штатную работу системы на мультиязычном товаре: ML слой уверенно ($\text{conf} \geq 0,86$) предсказывает все семь атрибутов, эскалация в Layer 4 не требуется, что подтверждает экономическую эффективность каскадной архитектуры на типовых товарах.

3.3.14 Сравнение классификаторов Слая 2: XGBoost, Random Forest, логистическая регрессия, MLP

В обоснование выбора XGBoost (2.2.4) проведено эмпирическое сопоставление четырёх семейств алгоритмов на идентичных признаках ($\text{MPNet } 768\text{d} \oplus \text{TF-IDF SVD } 128 = 896\text{d}$) и эталоне (LLM-consensus gold $n \approx 41$ тыс. ячеек, human gold $n = 518$; 16 атрибутов из 20). Источники — `scripts/method_comparison.py`, `notebooks/05_method_comparison.ipynb`, артефакт `datasets/processed/method_comparison_results.parquet`.

Таблица 17 – Сравнение классификаторов Слая 2 на эталоне LLM-consensus gold

Классификатор	Micro-accuracy	Macro-F1	ECE	Время обучения, с
XGBoost (производственный)	92,02 %	0,849	0,026	1062
MLP (нейронная сеть)	92,67 %	0,857	0,031	54
Логистическая регрессия	91,85 %	0,836	0,035	8
Random Forest	89,94 %	0,809	0,027	523

Примечание.

Источник:

`datasets/processed/method_comparison_results.parquet`,
2026-05-26.




Рисунок 9 – Cells-weighted micro-accuracy классификаторов
Слоя 2 на эталонах consensus gold и human gold

XGBoost доминирует над Random Forest (16/16 атрибутов, +2,1 п. п. в среднем) и логистической регрессией (11/16, выигрыш на длиннохвостых мультиклассовых `pasta_shape`, `country_of_origin`, `chocolate_extra`). MLP опережает XGBoost по micro-accuracy в среднем на 0,65 п. п., однако имеет ощутимо худшую калибровку (ECE 0,031 против 0,026). Для каскада, маршрутизация которого опирается на порог τ_a , низкая ECE критичнее доли процента accuracy: XGBoost — единственный метод, сочетающий устойчивость на сложных классах и наилучшую калибровку.

3.3.15 Обоснование сохранения слоя регулярных выражений: сопоставление с обучаемыми альтернативами

Использование детерминированных правил в качестве слоя 1 — нетривиальный выбор, требующий ручной разработки для каждой категории. Для его количественной фиксации каскад с `regex` сопоставлен с восемью альтернативами, где слой 1 заменён обучаемой моделью (`src/experiments/layer1_5_*.py`, `src/experiments/lexicon_regex.py`; артефакты — `layer1_5_optimal.parquet`,

lexicon_regex_comparison.parquet). Все варианты оценены на едином 80/20-разбиении (seed = 42) по 20 парам.

Таблица 18 – Сопоставление каскадных конфигураций с разным первым слоем

Вариант	Состав первого слоя (перед основным ML-слоем)	Средняя точность	Δ к «без первого слоя»
A	Регулярные выражения (текущая конфигурация)	83,58 %	+1,38 п. п.
B	Без первого слоя (один ML-слой)	82,20 %	0
C	Наивный байесовский классификатор на n-граммах	82,16 %	−0,04
D	Решающее дерево	82,98 %	+0,78
E	Центроидный классификатор в пространстве n-грамм	82,22 %	+0,02
F	Логистическая регрессия на n-граммах	82,23 %	+0,03
L	Обучаемый словарь n-грамм (lexicon)	83,00 %	+0,80
G	Поатрибутный выбор лучшего метода по перекрёстной проверке	81,99 %	−0,21

Продолжение таблицы

Вариант	Состав первого слоя (перед основным ML-слоем)	Средняя точность	Δ к «без первого слоя»
Н	Регулярные выражения — решающее дерево — ML (последовательно)	83,78 %	+1,58

Источник — docs/layer1_5_optimal_recommendation.md. Из таблицы следуют три вывода.

Во-первых, чистый ML без слоя 1 (В, 82,20 %) уступает текущей конфигурации (А, 83,58 %) на 1,38 п. п. — regex даёт небольшой, но устойчивый прирост.

Во-вторых, ни одна обучаемая альтернатива (С, D, E, F, L) не превосходит regex в роли единственного слоя 1. Регулярные правила формализуют доменное знание (формы пасты, типы зерна, числовые шаблоны какао), не восстанавливаемое из распределения слов: лексические маркеры редки, но однозначны.

В-третьих, единственная статистически превосходящая regex конфигурация — композиция «regex — дерево — ML» (Н, +0,20 п. п.). Прирост незначителен и не оправдывает усложнения и поддержки 20 деревьев.

Таким образом, выбор regex как Слой 1 эмпирически обоснован: наибольший прирост среди простых альтернатив при детерминированном выводе и отсутствии переобучения. Предпочтительное развитие — точечное расширение правил по итогам 3.3.25.

3.3.16 Поведение байесовского валидатора и архитектурный вывод

Слой 3 — байесовская сеть над дискретизированными атрибутами и брендом (структура — Hill Climb + BIC, рис. 4). В роли классификатора сеть неэффективна (точность ≈ 52 %, ниже мажорной), поэтому применяется как

валидатор плотности: для предсказания Слой 2 вычисляется $P(\text{value} \mid \text{evidence})$ при свидетельствах «бренд + остальные атрибуты»; ниже порога θ (5-перцентиль распределения P на обучении) ячейка помечается и передаётся в Слой 4. Точность отбраковки определена как $TP/(TP + FP)$ среди помеченных, базовая точка отсчёта — частота ошибок каскада на всех ячейках пары.

Таблица 19 – Поведение байесовского валидатора на категориях pasta, chocolate, cheeses

Категория	n_ml	Доля помеченных	Точность каскада	Точность отбраковки	Базовая точка отсчёта	Прирост	Полнота
pasta	1010	7,9 %	98,6 %	2,5 %	1,4 %	+1,1 п. п.	14,3 %
chocolate	772	14,1 %	94,7 %	20,2 %	5,3 %	+14,9 п. п.	53,7 %
cheeses	1436	6,1 %	96,3 %	1,1 %	3,7 %	−2,5 п. п.	1,9 %

Из 20 пар лишь три показывают точность отбраковки выше базовой: chocolate/contains_nuts (+38,2 п. п., полнота 59,5 %), pasta/is_vegan (+14,0 п. п. на $n_flagged = 10$) и cheeses/is_pdo (+7,0 п. п. на $n_flagged = 10$). На 17 оставшихся парах сигнал валидатора нерелевантен. При сплошном понижении (все помеченные в LLM) точность каскада снижается на 0,4 п. п. при росте расходов на 8,6 п. п. — чистый эффект отрицателен. При точечном понижении на паре chocolate/contains_nuts точность категории chocolate растёт на 6,6 п. п. при росте расходов на 5,3 п. п.; этот режим включён в производственную конфигурацию.

Архитектурный вывод. Перевод сети из роли классификатора в роль точечного валидатора иллюстрирует общий приём: невостребованный в одной роли компонент может вернуться в систему через изменение роли. Универсального селективного решения не получено: 19 из 20 пар не дают значимого сигнала; ограничение зафиксировано в заключении (§«Ограничения работы»). Производственная конфигурация включает валидатор точно на одной паре, что соответствует найденной мощности сигнала.

3.3.17 Чувствительность к выбору порога отсечки

Поатрибутные пороги уверенности τ_a подобраны процедурой `find_best_threshold` (оптимизация $\text{macro-F1} \times \text{coverage}$ на отдельном валидационном срезе, § 3.3.25). Для подтверждения устойчивости выбранной точки по совокупному критерию «точность $\leftrightarrow$ стоимость» проведён post-hoc анализ чувствительности: пороги синхронно сдвигаются на $\Delta \in \{-0,10; -0,05; 0; +0,05; +0,10\}$ без переобучения моделей, после чего пересчитываются точность каскада на `cascade-valid` сегменте, доля эскалаций в Слой 4 (LLM-share) и оценка E2E (источник — `notebooks/03_evaluate.ipynb`, ячейка 8a; скрипт `scripts/threshold_sensitivity.py`).

Таблица 20 – Чувствительность каскада к синхронному сдвигу всех порогов отсечки. Знаменатель `cascade-valid`; LLM-share — доля ячеек, эскалированных в Слой 4. GLOBAL: `pasta+chocolate+cheeses`, $n_{\text{in-scope}} = 17\,174$.

Сдвиг порога	Точность каскада, %	Доля LLM, %	E2E, %	$n_{\text{cascade-valid}}$
−0,10	94,24 %	2,06 %	94,28 %	16820
−0,05	94,43 %	2,73 %	94,47 %	16706
0,00 (текущий)	94,75 %	3,74 %	94,79 %	16531
+0,05	95,02 %	7,12 %	95,08 %	15952
+0,10	94,05 %	29,29 %	94,49 %	12144

Производственная точка $\Delta = 0$ — устойчивый локальный оптимум: симметричные смещения $\pm 0,05$ размывают $\approx 0,3$ п. п. точности E2E, при этом каждый шаг $+0,05$ примерно удваивает долю LLM (с 2,7 % до 7,1 %). Сдвиг $\Delta = +0,10$ катастрофичен: 29 % ячеек эскалируются в LLM, точность каскада на оставшихся падает ниже базовой ($-0,7$ п. п.), так как порог отсекает уверенные правильные предсказания и оставляет в каскаде преимущественно трудные классы. Сдвиг $\Delta = -0,10$ даёт минимальную LLM-долю (2,1 %), но теряет 0,5 п. п. точности из-за пропуска малоуверенных ошибочных предсказаний. Производственная конфигурация (диапазон порогов 0,55–0,90) не лежит на склоне функции стоимости, что подтверждает корректность выбора порогов на этапе обучения.

3.3.18 Стоимостно-чувствительный маршрутизатор: отрицательный результат на проверке гипотезы H1

В подразделе зафиксирован результат зарегистрированной до получения данных проверки гипотезы H1 о превосходстве обучаемого маршрутизатора над статическим правилом.

Идея, гипотеза H1 и процедура оценки.

Финальный механизм направления ячеек в LLM — статическое рег-(категория, атрибут) правило; рассматривалась обучаемая альтернатива: XGBoost-маршрутизатор предсказывает надёжность ответа каскада, при вероятности ниже τ ячейка идёт в LLM. **H1:** при равном бюджете LLM обучаемый маршрутизатор обеспечивает более высокую точность. До доступа к числам зафиксированы: три бюджета LLM (25, 40, 50 %); поправка Бонферрони ($\alpha/3 \approx 0,0167$); code-disjoint тестовая выборка $n = 1539^4$; опорная конфигурация — статическое правило. Параметры зафиксированы в `src/eval/router_pre_registered.py`; коммит модуля сделан за 1 ч 11 мин до создания артефакта результатов, что обеспечивает временной приоритет процедуры над данными.

Результаты.

Сравнительные числа представлены в табл. 21 (`router_pareto_gold.parquet`).

Таблица 21 – Сравнение конфигураций маршрутизации на проверочной выборке без пересечения товарных кодов (code-disjoint)

Конфигурация	Точность	Доля вызовов LLM	Тип
Только каскад (без LLM)	78,5 %	0 %	опорная конфигурация
Статический порог $\tau = 0,55$	82,6 %	11 %	статический

⁴Предзарегистрированный снимок (`router_train.parquet`, коммит `cd9ac7a`, 2026-05-13 02:11). Повторный запуск даёт $n = 1574$ ($\approx 2,3\%$ дрейф, не меняет вывод).

Продолжение таблицы

Конфигурация	Точность	Доля вызовов LLM	Тип
Обучаемый маршрутизатор (оптимум)	82,7 %	16 %	обучаемый
Статическое поатрибутное правило	83,9 %	58 %	статический

При сопоставимой точности обучаемый маршрутизатор требует более высокого бюджета LLM (16 против 11 %; разница 0,1 п. п. в пределах ДИ). Ни на одном из трёх бюджетов маршрутизатор не превзошёл опорную конфигурацию на уровне $\alpha/3$; **гипотеза Н1 отклонена**⁵. MDE при $n = 1539$, $\alpha/3$ и мощности 0,8 составляет $\approx 4,4$ п. п., поэтому отрицательный исход следует интерпретировать как отсутствие практически значимого превосходства в пределах не менее 4 п. п.

Интерпретация и следствие для финальной конфигурации.

Отклонение Н1 воспроизводится на всех пяти моделях Слоя 4 и объясняется тем, что основная вариация надёжности каскада сосредоточена на уровне атрибутов, а не товаров: статическое рег-(категория, атрибут) правило учитывает именно эту неоднородность, маршрутизатор уровня ячейки дополнительной информации не привносит. Code-disjoint разбиение устраняет утечку бренда, объяснявшую ранние положительные результаты. Результат согласуется с RouterBench [12]. В финальной конфигурации применяется статическое правило — прозрачное, поддающееся аудиту и не требующее переобучения; отклонение Н1 — один из трёх пунктов научной новизны (см. введение).

3.3.19 Цикл «аудит → правки → переобучение → измерение»

Замкнутый цикл итеративного улучшения каскада построен на сопоставлении собственных предсказаний с независимо проаудированной

⁵p-value McNemar-теста воспроизводятся ячейкой 9.1 в `notebooks/03_evaluate.ipynb`.

разметкой (LLM-аудитор `anthropic/claude-opus-4` слепо выносит суждения по каждой ячейке; измерение по неизменному списку ячеек исключает селекционный сдвиг). На `pasta` аудит 239 продуктов (1 841 ячейка, 8 атрибутов; `cascade_vs_audited_gold_pasta.json`) выявил концентрацию ошибок на `pasta_shape` (24,2 % ячеек): функция `_type_b_multiclass` обходила `categories_tags` по порядку следования, отдавая приоритет обобщённому `en:noodles` над специфическими `en:tagliatelle/en:penne/en:fusilli`; кроме того, `TYPE_B` не содержала `legume-/filled-pasta`. Точечные правки (коммиты `c1a0815`, `4bbd9e2`: обход по убыванию приоритета, пополнение `TYPE_B` и `regex` многоязычными синонимами, 28 модульных тестов) при пересборке серебра подняли точность `pasta_shape` с 27,6 до 59,6 % (+32,0 п. п.) при нулевом сдвиге шести нетронутых атрибутов; агрегированное серебро — с 80,7 до 85,2 %. Прочих изменений архитектуры не делалось, что подтверждает каузальную связь правок и прироста.

3.3.20 Переобучение моделей и прирост каскада

Слой 2 переобучен на обновлённом серебре с пересохранением калибровок и порогов; каскад прогнан на тех же 239 эталонных продуктах.

Сравнение

`cascade_vs_audited_gold_pasta.pre-retrain.json` против `cascade_vs_audited_gold_pasta.json`.

Таблица 22 – Прирост точности каскада на категории *pasta* после переобучения Слая 2 на обновлённом серебре (сопоставление на 239 эталонных продуктах)

Срез	n	До переобучения	После переобучения	Δ
<code>all_audited</code>	1841	81,9 %	86,4 %	+4,5 п. п.
<code>override</code> □ <code>manual_only</code>	220	39,5 %	57,7 %	+18,2 п. п.
<code>confirmed</code>	1621	87,6 %	90,3 %	+2,7 п. п.

Эффект локализован: на `pasta_shape` точность на подмножестве `override` □ `manual_only` (83 ячейки) выросла с 22,9 % до 72,3 % (+49,4

п. п.). Точечная правка даёт концентрированный сдвиг: +18,2 п. п. на сложном срезе против +2,7 на confirmed.

3.3.21 Кросс-категорийная репликация цикла 3/3

Тот же цикл применён к chocolate и cheeses (cross_domain_audit_summary.json).

В chocolate (1530 ячеек) аудит выявил дефект бинаризации cocoa_percentage — расхождение конвенции серебра и индустриальной интерпретации метки «70 %». После перехода на конвенцию [X, Y) точность на override □ manual_only cocoa_percentage поднялась с 10,8 % до 31,5 %; агрегированный прирост по домену +16,3 п. п.

В cheeses (1655 ячеек) аудит обнаружил систематически завышенные пороги fat_class (86 сдвигов вверх против 16 обратных). После установки порогов (15, 20, 28) г/100 г точность на override □ manual_only fat_class выросла с 2,7 % до 69,9 %; агрегированный прирост по домену +14,4 п. п.

Цикл воспроизведён 3/3 на независимых доменах с разными типами дефектов (порядок обхода тегов, сдвиг границ бакетирования, выбор порогов численного атрибута). Это позволяет считать последовательность «обнаружение — правка — регенерация серебра — переобучение — измерение» переносимым приёмом, а не разовым улучшением.

3.3.22 Устойчивость каскада по языкам

OFF имеет языковой перекосяк (≈40 % FR, 10 % EN, 7 % DE и т. п.). Под балансировку каскад не оптимизировался. Поатрибутно-языковой срез (per_language_eval.parquet, пересчитан 2026-05-28 на extended LLM-consensus gold; 16461 cascade-valid ячейка, 5 языков; генерируется скриптом src.diagnostics.language.per_language_refresh и нотбук-ячейкой perlang-code в notebooks/03_evaluate.ipynb) даёт взвешенную точность:

Таблица 23 – Точность каскада по языкам (extended LLM-consensus gold, 16 461 cascade-valid ячеек)

Язык	Ячеек	Точность каскада
it	2978	96,0 %
es	3014	95,9 %
en	3380	94,9 %
de	3093	94,8 %
fr	3996	93,2 %

Разброс между лучшим (it, 96,0 %) и худшим (fr, 93,2 %) — 2,8 п. п. Это говорит о приемлемой языковой устойчивости и согласуется с выбором кодировщика `paraphrase-multilingual-mpnet-base-v2` с TF-IDF-расширением. Французский сегмент остаётся наиболее ёмким ($n_{fr} = 3996$, 24 % выборки) и одновременно самым низкоточным — следствие исторической доли FR в OFF и большего разнообразия редких товарных подкатегорий. Усреднение скрывает локальные провалы: четыре кортежа (категория, атрибут, язык) с отставанием от лучшего сегмента > 11 п. п. на $n \geq 10$: `pasta/is_filled/fr` (58,0 % на $n=231$), `chocolate/chocolate_extra/fr` (81,2 % на $n=223$), `chocolate/chocolate_extra/de` (83,5 % на $n=212$), `cheeses/texture/de` (85,0 % на $n=40$). Рекомендация для production — на проблемных парах снизить порог τ_a или явно роутить в LLM.

3.3.23 Устойчивость каскада к шуму во входных данных

Для оценки устойчивости к неоднородному партнёрскому вводу проведён controlled-noise-эксперимент: тестовый срез (sample 500 кодов на категорию, seed 42) перепрогоняется через Слои 1–2 с четырьмя классами синтетического шума — случайная перестановка соседних символов в `product_name` (1/5/10 %), зануление поля `brands` (50/100 %), зануление `ingredients_text` (50/100 %) и комбинированный сценарий. Скрипт — `scripts/eval_input_robustness.py`; источник чисел — `notebooks/03_evaluate.ipynb`, ячейка «input-robustness»; артефакт — `datasets/processed/input_robustness_results.parquet`.

Главное наблюдение — единственный реальный фактор риска — отсутствие `ingredients_text`: при 50 % пропусков точность каскада

Таблица 24 – Деградация каскада при шуме во входных партнёрских полях. Точность — на ячейках, где каскад выдал ответ (cascade-only); доля LLM-эскалаций — fallback к Layer 4 относительно всех тестовых ячеек. Sample 500 кодов на категорию (pasta, chocolate, cheeses), seed 42; эталон — LLM-consensus gold (cascade_preds_{cat}_gold.parquet).

Сценарий	Точность	Δ , п.п.	Доля LLM-эскалаций	Δ
Без шума (baseline)	89,5 %	+0,0	9,9 %	
Комбо: 5 % typo + 50 % NULL brands	87,8 %	-1,6	14,7 %	
Пропуск brands, 50 % ячеек	89,3 %	-0,1	11,5 %	
Пропуск brands, 100 % ячеек	88,9 %	-0,5	13,2 %	
Пропуск ingredients_text, 50 %	83,6 %	-5,9	14,3 %	
Пропуск ingredients_text, 100 %	77,2 %	-12,3	19,1 %	
Опечатки в product_name, 1 %	88,1 %	-1,4	14,2 %	
Опечатки в product_name, 5 %	88,2 %	-1,3	14,1 %	
Опечатки в product_name, 10 %	87,4 %	-2,1	16,2 %	

падает на 5,9 п.п. (с 89,5 до 83,6 %), при 100 % — на 12,3 п.п. (до 77,2 %); деградация распределяется неравномерно по атрибутам с сильным сигналом в составе (pasta.is_vegan -35,5 п.п., chocolate.chocolate_extra -35,4 п.п.). Char-swap-опечатки даже на 10 % символов снижают точность лишь на 2,1 п.п. (multilingual SBERT-кодировщик устойчив к мелкому орфографическому шуму), а удаление brands даёт минимальную деградацию — 0,5 п.п., поскольку брендовая сущность обычно дублируется первым токеном product_name. Практическое следствие — при NULL ingredients_text целесообразно обогащать запись на стороне партнёра либо принудительно эскалировать составовые атрибуты в Layer 4 (стратегия включена в перспективы развития темы).

Все проверки подтверждают приемлемое поведение каскада по типичным угрозам валидности и фиксируют оставшиеся слабые места, направляющие план развития.

3.3.24 Симуляция активного обучения на 3-LLM consensus gold

Для оценки целесообразности активного обучения проведена симуляция на уже доступной разметке 3-LLM consensus gold (без дополнительной стоимости разметки человеком-аннотатором). Эталон разделён по товарным кодам в пропорции 70/30 (code-disjoint, seed 42); из pool отбираются две стратифицированные выборки одинакового размера $N \in \{50, 100, 200, 500\}$ —

active (ячейки, на которых ML уверенно ошибается, margin-disagreement, $\geq P_{75}$) и *random* (случайная выборка), после чего Слой 2 переобучается на *silver* + *N gold* с *sample_weight* 5 и измеряется на *holdout*. По 24 retrain-конфигурациям (3 категории $\times$ 4 значения $N \times 2$ стратегии) *active*-стратегия *не* превзошла *random* ни на одной паре: при $N = 500$ *pasta* *active* $-0,14$ п.п. против *random* $+0,28$ п.п.; *chocolate* *active* $+0,27$ п.п. против *random* $+0,96$ п.п.; *cheeses* *active* $-0,12$ п.п. против *random* $+1,74$ п.п. Объяснение — ограниченный размер AL pool (26–79 «уверенно-ошибочных» ячеек на категорию): при $N \geq 100$ *active* фактически добавляет весь pool, тогда как *random* продолжает расти на пуле из 4 461–5 954 ячеек. Caveat: симуляция $\neq$ настоящий AL с человеческой разметкой (*gold* здесь — LLM-консенсус, а пул кандидатов сужен производственным каскадом). Подробное обсуждение полноценного AL-пилота с человеком-аннотатором — в «Перспективах развития темы» Заключение. Артефакты — `datasets/processed/active_learning_results.parquet`, `active_learning_summary.json`; ячейка `active-learning-curve` в `notebooks/03_evaluate.ipynb`.

3.3.25 Уточнение схемы атрибутов: ортогональные свойства

Анализ ошибок на LLM-consensus *gold* выявил, что значение *filled* в исходной 5-классовой формулировке *chocolate_type* {*dark*, *milk*, *white*, *filled*, *other*} функционирует как структурная характеристика товара (наличие начинки), ортогональная типу какао-массы: один шоколад может одновременно характеризоваться как *dark* (по типу) и *filled* (по форме) — Lindt-трюфели, Ritter Sport Marzapane, Ferrero Rocher. Объединение двух ортогональных свойств в один multiclass-атрибут давало macro-F1 0,50 при нулевом recall на *filled* и *other*. По принципу ортогональности в схему введён бинарный атрибут *chocolate.is_filled*, независимый от *chocolate_type* (3-class) и *chocolate_extra* (5-class); после разделения macro-F1 составила 0,971 / 0,910 / 0,857 соответственно. Аналогичный принцип отказа от мёртвых классов (recall $< 0,20$ при $n_{\text{train}} < 100$) применён к *chocolate_type.other*, *chocolate_extra*.{*other*, *with_alcohol*, *with_coffee*}, *cheeses.texture.other*; класс *semi_soft* объединён с *soft*. Соответствие train $\leftrightarrow$ eval $\leftrightarrow$ production обеспечивается единым описанием

(`exclude_classes` в `CATEGORY_CONFIG` и `SCHEMA_EXCLUDE` в `src/eval/metric_table.py`). Метки `is_filled` выведены `semi-supervised` из старой схемы и `regex-шаблона` `FILLED_CHOCOLATE_REGEX` (мультиязычные триггеры `truffle/praline/fourré/gefüllt/ripieno`); 1481 позитивный пример на `silver`, негативы валидированы 2-LLM-консенсусом (0 переопределений).

3.3.26 Поатрибутные архитектурные решения

Диагностика (`cascade_preds*_v4_noleak.parquet`, `headline_v4_mpnet_tfidf_noleak.parquet`) выявила три типовых поатрибутных приёма: (а) сужение входа Слой 1 `chocolate_type` до названия (без `ingredients_text`, где лексика «milk/lait/Milch» массово встречается в составе тёмного шоколада), с отказом при одновременном матче нескольких типов; (б) перенастройка порога Слой 2 на парах с высокой штатной долей отказа — индивидуальное понижение до 0,40–0,65 в `models/{категория}_stratified_thresholds.pkl`; (в) гибридные признаки `SBERT ⊕ TF-IDF` (1, 2) топ-5000 для лексически богатых атрибутов (`--with-tfidf` в `src/pipeline/ml/train.py`, +1,9 / +3,8 п. п. на `chocolate/chocolate_type` и `chocolate/contains_nuts` соответственно). Итоговое влияние на сквозную точность по парам — в табл. 25.

Таблица 25 – Сквозная точность каскада на парах со специальной поатрибутной настройкой (LLM-consensus gold v4, без пересечения товарных кодов)

Пара (категория, атрибут)	Probe	Cascade	Тип решения
chocolate / chocolate_type	94,7 %	98,0 %	(а) сужение Слой 1 + (в) гибридные признаки
chocolate / chocolate_extra	76,6 %	92,5 %	(б) порог 0,9 — 0,65
chocolate / contains_nuts	90,4 %	89,0 %	(в) гибридные признаки + Слой 1 nut-markers
cheeses / texture	70,5 %	92,3 %	(б) порог 0,60 — 0,40

Продолжение таблицы

Пара (категория, атрибут)	Probe	Cascade	Тип решения
cheeses / is_organic	92,5 %	98,7 %	(б) порог 0,70 — 0,40
cheeses / is_ultra_processed	86,1 %	96,1 %	(б) порог 0,70 — 0,50
pasta / grain_type	91,9 %	94,2 %	(б) порог Слой 2 — 0,50

На парах с пониженным порогом Слой 2 LLM вызывается на ≤ 5 % ячеек, общая доля обращений по системе — 4,1 % (архитектурное снижение стоимости 95,9 % по сравнению с «одна LLM на всё»).

3.4 Выводы по главе 3

Основные результаты:

- 1) Реализован пятислойный каскад (Слой 0 категорайзер, regex, ML XGBoost на SBERT, байесовский валидатор, запасной слой на большой языковой модели) с указанием слоя-источника на каждое предсказание; вердикт формируется как последовательное AND-условие на пороги слоёв.
- 2) Развёрнута трёхкомпонентная демонстрационная система (Go-шлюз, Python/FastAPI ML-сервис, статический HTML/JS) со стабильным контрактом API и подтверждённой работоспособностью на трёх категориях.
- 3) Сквозная точность (E2E) 93,0 % на 16 360 ячейках LLM-consensus gold (20 атрибутов, без пересечения товарных кодов (code-disjoint)) в конфигурации «каскад + gemini-flash» — на 9,2 п. п. выше опорной all-sonnet (83,8 %) при стоимости в 580 раз ниже (доминирование по Парето). Верхняя оценка только-каскадной точности — 95,5 % (cascade-only micro-accuracy на тех же ячейках, macro-F1 0,890). Каскад покрывает 97,3 % ячеек; на LLM приходится 4,1 % сложных ячеек (снижение стоимости 95,9 % по сравнению с «одна LLM на всё»). Консервативная нижняя оценка по human gold (n = 566 cascade-valid): E2E 86,7 %, cascade-only 91,3

% — операционный циркулярный сдвиг 4,2 п. п. (каскад) / 6,3 п. п. (E2E). В сценарии с открытой моделью каскад + gpt-oss-120b достигает 90,6 % — на 21,3 п. п. выше одиночного вызова той же модели. Полная таблица — в 3.3.2.

- 4) Поатрибутный разбор: Слой 2 — основной (71–90 % покрытия, 93,5–98,6 % точности); Слой 1 покрывает 18–23 % на pasta/chocolate с точностью 87–100 %; байесовский валидатор работает селективно (+38 п. п. на chocolate/contains_nuts); LLM добавляет +1,4–1,7 п. п. при 4,1 % обращений.
- 5) Зафиксированная до получения результатов H1 об обучаемом маршрутизаторе отклонена на трёх бюджетах после поправки Бонферрони; результат согласуется с RouterBench [12].
- 6) Цикл «аудит — правки — переобучение — измерение» воспроизведён 3/3: pasta +18,2 п. п., chocolate +16,3 п. п., cheeses +14,4 п. п. на проблемных срезах.
- 7) Зафиксированы три принципа проектирования схемы атрибутов (ортогональность, отказ от мёртвых классов, консервативная агрегация rule-based слоёв; 3.3.7.4). Выделение бинарного атрибута chocolate.is_filled как структурного свойства, ортогонального к chocolate_type, повысило macro-F1 chocolate_type с 0,50 (5-class) до 0,973 (3-class) при macro-F1 is_filled 0,861 на новой бинарной задаче. Удаление мёртвых классов ($\text{recall} < 0,20$, $n_{\text{train}} < 100$) дополнительно повысило macro-F1 chocolate_extra и cheeses.texture.
- 8) Устойчивость по языкам (разброс 3 п. п. на 5 языках) и сравнение с лексическим базисом (20 из 20 пар сопоставимо или выше, +25–30 п. п. на нутриент-производных) подтверждены; поатрибутные решения 3.3.25 обеспечивают высокое покрытие ML-слоя при доле обращений к LLM 4,1 %.

4 ОПИСАНИЕ РЕЗУЛЬТАТОВ

4.1 Руководство пользователя

4.1.1 Роли и интерфейсы

Система рассчитана на три роли (анализ — 1.1). Каждая роль работает со своим интерфейсом и решает свой класс задач (таблица 4.1); распределение прав доступа ограничивает каждого пользователя точками управления его компетенции.

Таблица 26 – Соответствие ролей пользователей и интерфейсов системы

Роль	Интерфейс	Класс задач
Контент-менеджер	Веб-интерфейс демо	Выборочная проверка предсказаний, утверждение или отклонение значений атрибутов
Системный аналитик	Конфигурационные файлы порогов, REST API	Настройка порогов уверенности, мониторинг состояния сервиса
Инженер машинного обучения	Скрипты обучения, ноутбук с диагностиками	Переобучение классификаторов и байесовских сетей, прогон диагностик, обновление эталона

Контент-менеджер работает через веб-интерфейс демонстрационного комплекса: форма ввода партнёр-доступных полей и блок результата с оценкой уверенности и отметкой слоя-источника на каждый атрибут (рис. 4.1). Отметка слоя-источника даёт основание для доверия к предсказанию: слой 1 и слой 4 детерминированы либо объяснимы, для слоёв 2–3 показателем служит уверенность; приём введён (см. 1.3) для компенсации ограниченной интерпретируемости обучаемых слоёв на уровне отдельного товара.

Обогащение товарных данных

Каскад regex → ML → байес → LLM-fallback. Введите частично заполненный товар — система предскажет недостающие атрибуты.

Ввод товара

Режим определения категории

☒ Авто (классификатор)
 ☐ Вручную

Категория

Шоколад / десерты

Название товара *

Lindt Excellence Dark 70% Cocoa 100g

Бренд / производитель

Lindt

Состав

cocoa mass, sugar, cocoa butter, soya lecithin, vanilla extract

Количество

100 g

Примеры:

валидные:

Pasta — Barilla

Chocolate — Lindt 70%

Cheeses — Roquefort

с противоречиями:

White vs. 70% cocoa

Wheat + gluten-free

Обогатить

Результат

Категория:

chocolate

Авто (router):

chocolate, p=0.97

OOD:

нет

Закрыто:

6 / 7 атрибутов

LLM-fallback:

1 атрибут

Время ответа:

184 мс

ПРЕДСКАЗАНИЯ ПО АТТРИБУТАМ

АТТРИБУТ	ПРЕДСКАЗАНИЕ	СЛОЙ	УВЕРЕННОСТЬ
cocoa_content_class	70-85 %	regex	1.00
chocolate_type	dark	regex	1.00
contains_nuts	false	ml	0.93
is_organic	false	ml	0.87
contains_milk	false	ml	0.81
flavor_modifier	vanilla	bayes	0.74
filling_type	— будет дозаполнено	llm	—

Слои каскада:

regex

ml

bayes

llm-fallback

Рисунок 4.1 — Веб-интерфейс демонстрационной системы (схематично): форма ввода и блок результата с отметкой слоя-источника и оценкой уверенности

Рисунок 10 – Веб-интерфейс демонстрационной системы (схематично): форма ввода партнёр-доступных полей и блок результата с отметкой слоя-источника и оценкой уверенности на каждый атрибут

Системный аналитик настраивает каскад через две точки: словари порогов уверенности (поатрибутно, без переобучения — компромисс «точность ↔ покрытие») и REST API получения состава атрибутов и агрегированного состояния сервиса для интеграции с мониторингом.

Инженер машинного обучения работает со скриптами обучения и ноутбуком диагностик (исполняемый источник §3.3). Цикл переобучения устроен так, что выпуск новой версии моделей не требует перекомпиляции каскада: артефакты переписываются на диске, сервис загружает их при старте. Цикл запускается еженедельно или ежемесячно (по темпу поступления товаров) и занимает десятки минут на категорию без специализированных ресурсов; при отсутствии ключа коммерческой LLM каскад работает в режиме слоёв 1–3 либо переключается на локальный gpt-oss-120b.

88

4.2 Сценарии применения и порядок внедрения

4.2.1 Встраивание в бизнес-процесс магазина

Каскад занимает место промежуточного сервиса в маршруте товара от поставщика до витрины — вторая позиция четырёхзвенной цепочки 1.1, где сосредоточено узкое место. Внедрение не требует перестройки соседних звеньев: ETL партнёрских фидов и PIM работают как раньше, изменяется лишь содержимое «процедуры обогащения». Маршрут запроса: партнёрский фид → ETL магазина → `/api/enrich` (каскад) → выборочная проверка контент-менеджером случаев слоя 4 → PIM и витрина.

Основной экономический эффект — перенос ручного труда из режима «закрывать каждое поле» в режим «проверять остаток после каскада». По 3.3.2 покрытие каскада (ячеек, на которых слои 1–3 выдали уверенный ответ без обращения к LLM) составляет 95,9 %, оставшиеся 4,1 % уходят в запасной слой 4; покрытие производственной цепочки (с учётом удачных ответов слоя 4 и потерь маршрутизатора слоя 0) — 97,3 %. Сквозная точность 93,0 % в конфигурации «каскад + gemini-flash» (на эталоне с consensus-разметкой, n=16 360), при оценке только каскадной части — 95,5 % (верхняя граница при идеальной маршрутизации категории). На полностью ручном эталоне (n=566 cascade-valid из 688 в-scope) консервативная оценка составляет 86,7 % сквозной точности. Для новой категории каскад деградирует до режима «слой 1 на общих шаблонах + слой 4» (рабочий, но неоптимальный): по мере накопления сотен размеченных товаров подключается слой 2, при появлении устойчивых распределений по брендам — слой 3; имитация холодного старта на четырёх категориях (3.3.25) подтверждает работоспособность архитектуры в этом режиме.

4.2.2 Сценарий многоязычного каталога

`paraphrase-multilingual-mpnet-base-v2` обеспечивает единое векторное пространство для пяти доминирующих в OFF европейских языков, что устраняет необходимость отдельных моделей под каждый язык. Устойчивость по языкам подтверждена в 3.3.22: разброс между лучшим (it, 96,0 %) и худшим (fr, 93,2 %) сегментами составляет 2,8 п. п. на расширенном LLM-consensus-эталоне (n=16 461 cascade-valid ячеек). Поязыковая разбивка

приведена в таблице 4.6в — та же таблица используется в 3.3.22, здесь повторяется для удобства референса к сценарию внедрения.

Таблица 27 – Точность каскада по языкам (extended LLM-consensus gold, 16 461 cascade-valid ячеек)

Язык	Ячеек	Точность каскада
it	2978	96,0 %
es	3014	95,9 %
en	3380	94,9 %
de	3093	94,8 %
fr	3996	93,2 %

Примечание.

Источник:

datasets/processed/per_language_eval.parquet, актуализирован 2026-05-28 на расширенном LLM-consensus rerun. Воспроизводится в notebooks/03_evaluate.ipynb, ячейка perlang-code. Худший сегмент — fr (преимущественно за счёт атрибута pasta/is_filled на французских товарах, см. 3.3.22) — остаётся выше базовой целевой точности 91 %. Каскад применим в международных площадках без удвоения затрат на поддержку отдельных моделей под каждый язык.

4.2.3 Применимость в смежных доменах

Архитектура не привязана к пищевому домену: правила слоя 1 переписываются для новой категории, обучение слоёв 2/3 — стандартная процедура. Репликация на электронике (схема атрибутов, серебро из PhoneDB, демонстрация холодного старта; подробности в разделе «Перспективы развития темы» заключения) подтверждает переносимость. Формальная аудит-оценка вынесена в перспективы развития.

Оценка применимости архитектуры к семи доменам (три уже реализованы в работе, четыре — внешние) приведена в таблице 4.6д. Принципиально переиспользуются слои 0 (маршрутизатор категории), 4 (запасной LLM-слой) и инфраструктурная обвязка (REST API, мониторинг, телеметрия); адаптации требует слой 1 (regex-правила и keyword-словари под предметную область) и обучение слоёв 2–3 на новой выборке.

Таблица 28 – Применимость каскадной архитектуры в смежных товарных доменах (оценочно)

Домен	Переиспользуется	Требуется адаптировать	Трудоёмкость
Пища (pasta, chocolate, cheeses)	Реализовано полностью ^a	—	—
Напитки (beverages)	Реализовано полностью ^a	—	—
Хлопья (cereals)	Реализовано полностью ^a	—	—
Косметика (cosmetics)	Реализовано полностью ^a	—	—
Электроника	Слои 0, 1, 4, инфраструктура	Схема атрибутов, обучение слоёв 2–3 на PhoneDB	Средняя ^b
Бытовая техника (home appliances)	Слои 0, 4, инфраструктура	Regex-правила слоя 1 (модель, объём, мощность), схема, обучение слоёв 2–3	Средняя ^b

Продолжение таблицы

Домен	Переиспользуется	Требуется адаптировать	Трудоёмкость
Одежда (fashion)	Слои 0, 4, инфраструктура	Слой 1 практически отсутствует (нет числовых маркеров), схема, обучение слоя 2 на признаках цвета/размера/материала	Высокая ^c
Игрушки (toys)	Слои 0, 4, инфраструктура	Regex возрастных классов (minimal_age уже реализован, см. src/pipeline/regex/extract_schema, обучение слоёв 2–3	Низкая ^d

Примечание. Сноска «a» — домены реализованы в проекте (см. src/pipeline/schemas/, 7 доменных схем); полный конвейер регрессионно проверяется в src/eval/run_experiments.py. Сноска «b» — средняя трудоёмкость: 2–4 недели на схему + обучение слоёв 2–3 при наличии источника эталона уровня PhoneDB или USDA. Сноска «c» — высокая трудоёмкость: слой 1 малоэффективен на текстовых полях моды (мало явных детерминированных маркеров), основная работа — сбор обучающей выборки и feature engineering для слоя 2; ориентировочно 6–10 недель на категорию. Сноска «d» — низкая трудоёмкость: regex возрастных

классов уже реализован (метод `extract_minimal_age` обрабатывает русские, английские и французские маркеры), оставшаяся работа — схема и обучение; ориентировочно 1–2 недели. Все оценки трудоёмкости — ориентир по аналогии с реализованными пищевыми категориями и не учитывают переменные времени получения эталонной выборки.

4.3 Риски развёртывания и план мониторинга

Любая система машинного обучения в производственном контуре требует операционной обвязки: одной только метрики на статической тестовой выборке недостаточно для устойчивой работы во времени. Распределение партнёрских данных меняется, тарифы поставщиков пересматриваются, схема атрибутов эволюционирует. Риски укрупнённо группируются по трём уровням: дрейф входных данных (изменение состава партнёрского потока относительно обучающей выборки), дрейф калибровки (рост ошибки оценки уверенности — ECE — при сохранении точки оптимума), а также устаревание модели (накопление систематического отставания от текущего состояния каталога без явного дрейфа метрики). Каждый риск сопровождается митигацией и закреплённой зоной ответственности (таблица 4.4).

Таблица 29 – Реестр операционных рисков системы и закреплённые митигации

Риск	Митигация	Ответственный
Дрейф входных данных (новый партнёр со структурой полей, отличной от обучающей выборки)	Мониторинг поатрибутной точности на свежей подвыборке ручной разметки; алёрт при падении более чем на 3 п. п. от baseline	Инженер ML
Дрейф калибровки (рост ECE сверх 0,07 при isotonic-таргете 0,043)	Регрессионный тест ECE (см. ниже); автоматический прогон на еженедельном срезе свежих предсказаний	Инженер ML

Продолжение таблицы

Риск	Митигация	Ответственный
Истечение тарифа слоя 4 (поставщик коммерческой языковой модели повысил цену либо ввёл квоту)	Авто-переключение слоя 4 на gpt-oss-120b в локальном развёртывании; конфигурация маршрутизации моделей в models/router_model	Эксплуатация (DevOps)
Появление новой товарной категории	Холодный старт через слой 1 (regex по общим шаблонам) и слой 4; переобучение слоя 2 после накопления порядка 1 000 SKU; см. сценарий 4.2.2	Инженер ML
Деградация качества модели слоя 4 (поставщик обновил версию без уведомления)	Пилотное развёртывание (canary) с долей трафика 5 %; парный t-тест разницы точности на свежей подвыборке ручной разметки; откат на предыдущую версию при значимом ухудшении	Инженер ML
Изменение схемы атрибутов (добавление/удаление поля, изменение классов)	Версионирование артефактов с указанием git-commit, seed-hash и manifest эталона; явная сверка схемы при загрузке моделей сервисом	Владелец продукта

Продолжение таблицы

Риск	Митигация	Ответственный
Сбой внешнего API маршрутизации языковых моделей (OpenRouter)	Запасной слой 4 на локальной модели gpt-oss-120b либо очередь отложенных запросов с приоритетом; для критичных потоков — горячее переключение в течение минут	Эксплуатация (SRE)
Утечка персональных данных через слой 4 (партнёрские поля уходят в облачный API)	Опция полностью локального развёртывания с gpt-oss-120b (без обращения вовне); фильтрация поля <code>ingredients_text</code> от персонально идентифицирующих фрагментов до отправки в слой 4	Безопасность

Примечание. Каждая митигация в таблице 4.4 опирается либо на свойство архитектуры, продемонстрированное в 3.3 (опция локальной открытой модели — 3.3.2; калибровка — 3.3.3; устойчивость каскада — 3.3.4), либо на инструменты, описанные в 4.1.3 (REST API, конфигурации). Уровень детализации соответствует руководству по эксплуатации (operations runbook) и не претендует на полный регистр риск-менеджмента стандарта ISO 31000.

4.3.1 Мониторинг в производственном контуре

Производственный мониторинг каскада строится на четырёх показателях, каждый из которых сопоставим с метрикой главы 3 и допускает автоматический регрессионный контроль: (1) поатрибутная точность на еженедельной подвыборке ручной верификации 200–500 ячеек на

категорию — алёрт при падении более чем на 3 п. п. от baseline 93,0 %; (2) ECE поатрибутно с порогом 0,07 относительно целевого 0,043 после изотонической калибровки; (3) доля обращений к слою 4 в 7-дневном скользящем окне относительно baseline 4,1 % — алёрт при выходе свыше 6 %, что сигнализирует о дрейфе данных или деградации калибровки порогов; (4) пилотное развёртывание (canary release) с долей 5 % трафика при выпуске новой версии слоя 2 или смены модели слоя 4, с парным McNemar-тестом разницы точности и автоматическим откатом при значимом ухудшении ($p < 0,05$). Поэтапное внедрение в производственный контур (теневого запуск → рекомендательный режим → автоматическое заполнение с выборочной верификацией) снижает риск регрессии качества каталога; откат на предыдущую фазу выполняется конфигурационно. Переаттестация калибровки выполняется ежеквартально либо по событию срабатывания регрессионного теста ECE — подробности процедуры даны в 3.3.11.

4.4 Что позволяет использование разработки (характеристика достигнутых результатов)

Использование системы даёт измеримые эффекты в формате «повышено / ускорено / сокращено» со ссылками на 3. Сквозная точность на эталоне с LLM-consensus-разметкой ($n=16\,360$ ячеек) составляет 93,0 % в конфигурации «каскад + gemini-flash» (3.3.2; `v4_e2e_router_eval.json`; 95 %-й интервал Вильсона [92,6; 93,4]); каскадная часть — 95,5 % с интервалом [95,2; 95,8] и выступает верхней границей при идеальной маршрутизации категории. Консервативная оценка на полностью ручном эталоне ($n=566$ cascade-valid из 688 в-scope) — 86,7 % сквозной точности и 91,3 % по каскаду. Прямой Claude Sonnet 4.5 даёт 83,8 % (на 9,2 п. п. ниже), прямой gpt-oss-120b — 69,3 % (на 23,7 п. п. ниже); преимущество обеспечивает слой 2, обученный на нутриент-производных атрибутах, которые LLM не вычисляет точно из текста без числового контекста. Поатрибутный разрез по категориям приведён в таблице 4.2.

Таблица 30 – Точность каскадной части по категориям (модель gemini-flash, эталон LLM-consensus, среднее по атрибутам категории)

Категория	Число атрибутов	Средняя точность
Паста	7	95,8 %
Шоколад	6	94,9 %
Сыры	7	95,8 %
Взвешенное среднее по каскаду	20	95,5 %

Примечание. Источник: v4_metric_table_v2.json (LLM-consensus, extended consensus rerun 2026-05-27). Cells-weighted средние по 20 атрибутам (7 pasta + 6 chocolate + 7 cheeses). Воспроизводится в notebooks/03_evaluate.ipynb, ячейка t42-percat.

Стоимость обработки одного товара через каскад + gemini-flash составляет малую долю стоимости прямой LLM: каскад обращается к слою 4 лишь на 4,1 % ячеек, что даёт архитектурное сокращение совокупной стоимости на 95,9 % относительно конфигурации «все ячейки — LLM» (3.3.2). При одинаковой модели слоя 4 каскад дешевле прямого вызова в 24 раза; в сочетании с переходом на дешёвую коммерческую модель (gemini-flash) — в 580 раз относительно прямого Sonnet 4.5. На характерном объёме 100 000 SKU/мес годовая экономия превышает 100 000 USD относительно прямого Sonnet 4.5; на масштабе маркетплейса (1 000 000 SKU/мес) экономия достигает миллиона USD в год. Чувствительность к тарифу слоя 4 устойчива: даже при удорожании выбранной модели в 10 раз каскад остаётся в 58 раз дешевле прямого Sonnet 4.5. Сопоставление трёх объёмных режимов и четырёх тарифных конфигураций приведено в таблице 4.5.

Таблица 31 – Годовой расход на обогащение в зависимости от объёма каталога и конфигурации слоя 4 (USD/год)

Объём, SKU/мес	Прямой Sonnet 4.5	Прямой Gemini Flash	Каскад + Gemini Flash	Каскад + gpt-oss-120b
10 000	10 800	270	11	8
100 000	108 000	2 700	110	80

Продолжение таблицы

Объём, SKU/мес	Прямой Sonnet 4.5	Прямой Gemini Flash	Каскад + Gemini Flash	Каскад + gpt- oss-120b
1 000 000	1 080 000	27 000	1 100	800

Примечание. Расчёт: 20 ячеек на SKU, 12 месяцев, удельные стоимости одной ячейки — 0,00450 USD (Sonnet 4.5), 0,0001125 USD (Gemini Flash), $\approx$ 0,00007 USD (gpt-oss-120b). Каскадные конфигурации учитывают долю обращений к слою 4 в размере 4,1 %. Локальное развёртывание дополнительно требует учёта инфраструктуры вывода ($\approx$ 10 USD/мес при реиспользовании имеющихся ресурсов).

Сводный эффект разработки на семи показателях приведён в таблице 4.6.

Таблица 32 – Сводный эффект разработки на ключевых показателях системы (повышено / сокращено / обеспечено)

Показатель	До разработки	После	Эффект
Сквозная точность системы	83,8 % (опорная конфигурация all-sonnet)	93,0 % (каскад + gemini-flash; 95,5 % по каскаду без учёта маршрутизации)	повышена на 9,2 п. п.
Относительная стоимость обработки (архитектурный вклад каскада)	1,000 (опорная конфигурация all-sonnet)	0,041 при той же модели слоя 4	сокращена на 95,9 % ($\approx$ 24 раза)
Доля обращений к LLM	100 %	4,1 %	сокращена примерно в 24 раза
Ручная верификация оператором	100 % ячеек	4–8 % ячеек	сокращена в 12–25 раз

Продолжение таблицы

Показатель	До разработки	После	Эффект
Точность на открытой модели	69,3 % (одиночный вызов gpt-oss-120b)	90,6 % (каскад + gpt-oss-120b)	повышена на 21,3 п. п.
Поддержка многоязычности	отдельные модели на каждый язык либо предварительный перевод	5 рабочих языков в едином векторном пространстве SBERT	обеспечена без дополнительных моделей
Независимость от поставщика LLM	один интегрированный провайдер	поддержка пяти моделей с сопоставимой точностью	обеспечена взаимозаменяемость

Примечание. Источники: v4_e2e_router_eval.json, v4_metric_table_v2.json. Консервативная оценка на полностью ручном эталоне (n=566 cascade-valid из 688 в-scope) даёт 86,7 % сквозной точности и 91,3 % по каскаду; разрыв с consensus-эталонem объясняется учётом circular bias (методология §14.5).

Значения столбцов «До» и «После» получены на тестовой выборке без пересечения товарных кодов (code-disjoint) главы 3 и подтверждены артефактами v4_e2e_router_eval.json и v4_metric_table_v2.json.

4.5 Выводы по главе 4

- 1) Целевая аудитория — три роли: контент-менеджер (выборочная верификация через веб-интерфейс), системный аналитик (пороги через конфигурации и REST API), инженер машинного обучения (переобучение по мере поступления данных). Система допускает три сценария по выбору слоя 4: gemini-flash (наилучший баланс точности и стоимости), премиум-коммерческий (Sonnet 4.5, GPT-4o) и локальный gpt-oss-120b (независимость от внешних API при

сопоставимой точности).

- 2) Совокупный эффект: архитектурное сокращение стоимости на 95,9 % (≈ 24 раза) относительно конфигурации «все ячейки — LLM», ручной нагрузки — в 12–25 раз; сквозная точность 93,0 % с интервалом Вильсона [92,6; 93,4] (95,5 % по каскадной части как верхняя граница при идеальной маршрутизации); консервативная оценка на полностью ручном эталоне — 86,7 %. Эффект устойчив к разбросу тарифов слоя 4: даже при удорожании выбранной модели в 10 раз каскад остаётся в 58 раз дешевле прямого Sonnet 4.5.
- 3) Производственное развёртывание сопровождается реестром из восьми операционных рисков (дрейф данных, дрейф калибровки, истечение тарифа слоя 4, появление новой категории, деградация качества модели слоя 4, изменение схемы атрибутов, сбой внешнего API, требования локального хранения партнёрских данных) с закреплёнными митигациями; контроль обеспечивается четырьмя показателями мониторинга (поатрибутная точность, ECE, доля слоя 4, canary release).
- 4) Архитектура переносима на смежные товарные домены: переиспользуются слои 0, 4 и инфраструктурная обвязка; адаптации требуют слой 1 (regex под предметную область) и обучение слоёв 2–3 на новой выборке. Имитация холодного старта на четырёх категориях (3.3.25) подтверждает работоспособность архитектуры в режиме отсутствия слоя 2.

ЗАКЛЮЧЕНИЕ

В ходе работы разработана гибридная каскадная система автоматизированного обогащения товарных данных для интернет-магазина. Система реализована в виде программного комплекса с демонстрационным стендом, проверена на выборке без пересечения товарных кодов (code-disjoint, новые SKU) и удовлетворяет шести функциональным, пяти нефункциональным и трём архитектурным требованиям ТЗ.

Достигнутые показатели превосходят целевые ориентиры ТЗ (≥ 85 % точности, $\geq 2,5\times$ сокращения стоимости): сквозная точность 93,0 % (точность только-каскадной части 95,5 % как верхняя граница при идеальной маршрутизации категории, cells-weighted macro-F1 0,890; attr-unweighted 0,892), стоимость сокращена в 580 раз относительно прямого вызова коммерческой Claude Sonnet 4.5 в режиме «каскад + Gemini 2.5 Flash» (комбинированное сокращение, включающее архитектурный вклад каскада в 24 раза). Каскад покрывает 97,3 % ячеек; в LLM направляется лишь 4,1 % сложных ячеек.

Сводные выводы по главам

Глава 1 систематизирует литературу и обосновывает противоречие. PIM-системы (Akeneo [5], Pimcore [6], Salsify [7]) ориентированы на хранение и распределение, а появляющиеся модули обогащения — обёртки над одной LLM. Академические подходы разделены: специализированные системы извлечения признаков (TXtract [26], MAVE [27], OpenTag [28]) обеспечивают качество без учёта экономики; каскады LLM (FrugalGPT [9], AutoMix [10], Hybrid LLM [11], RouterBench [12]) управляют стоимостью, но не интегрируют классическое ML. Из противоречия выведена гипотеза о каскаде разнородных слоёв и сформировано ТЗ.

Глава 2. Задача формализована как поатрибутное предсказание со схемой, допускающей явный отказ. Логика — каскад из пяти слоёв с последовательной фильтрацией: предсказание Слоя 2 принимается только при одновременном выполнении $P_{ML} \geq \tau_k$ и $P_B \geq \theta_k$ как ансамблевой AND-оценки уверенности. Архитектурный выбор каждой компоненты (SBERT, XGBoost, pgmpy, Go-шлюз + Python-ML, открытая gpt-oss-120b) обоснован эксплуатационно и методологически.

Глава 3. Каскад реализован как трёхкомпонентный комплекс (Go-шлюз, Python/FastAPI ML-сервис, статический веб-интерфейс); состав — 21 поатрибутный XGBoost, три байесовские сети и Слой 0. На 16 360 ячейках без пересечения товарных кодов (code-disjoint) сквозная точность каскад + Gemini 2.5 Flash составила 93,0 % (точность каскадной части 95,5 %), на 9,2 п. п. выше прямого Sonnet 4.5 при стоимости в 580 раз ниже; в локальном сценарии каскад + gpt-oss-120b — 90,6 % (на 21,3 п. п. выше самостоятельной модели). Консервативная нижняя оценка на ручной разметке Claude Opus 4 (n=566) — 86,7 %. Зафиксированная до получения результатов Н1 о превосходстве обучаемого маршрутизатора отклонена; цикл «аудит — правки — переобучение — измерение» воспроизведён 3/3.

Глава 4 переводит результаты в плоскость применения: три сценария по выбору Слая 4 (Gemini Flash, Sonnet/GPT-4o, локальная gpt-oss-120b) и три ролевые модели (контент-менеджер, системный аналитик, инженер ML). Сводный эффект — архитектурное сокращение стоимости в 24 раза и комбинированное в 580 раз, сокращение ручной нагрузки в 12–25 раз при сквозной точности 93,0 % с интервалом Вильсона [92,6; 93,4].

Закрытие формулировок утверждённой темы

Утверждённая тема работы содержит восемь содержательных формулировок. Каждой из них в работе соответствует конкретный раздел, а также архитектурный или экспериментальный компонент разработки. Соответствие представлено в таблице 5.1.

Таблица 33 – Соответствие формулировок утверждённой темы и разделов работы

Формулировка из обоснования актуальности темы	Реализация в работе	Раздел
Гибридная каскадная система	Пятислойная архитектура каскада (Слой 0 + четыре содержательных слоя)	2.2, 3.1

Продолжение таблицы

Формулировка из обоснования актуальности темы	Реализация в работе	Раздел
Семантические возможности генеративных моделей	Запасной слой 4 на основе большой языковой модели	3.1.1
Предсказательная сила классического машинного обучения	Слой 2 — поатрибутные классификаторы XGBoost на многоязычных векторных представлениях SBERT	3.1.1
Ансамблевая оценка уверенности моделей	Многоуровневая фильтрация по уверенности как последовательное конъюнктивное условие на калиброванные пороги слоёв	2.1
Отбраковка фактических ошибок до их попадания в каталог	Слой 3 — байесовский валидатор плотностей пар «бренд × значение»	3.1.1, 3.3.4
Скрытые статистические закономерности каталога	Направленный ациклический граф атрибутов, обучаемый алгоритмом Hill Climb с критерием BIC	3.1.1

Продолжение таблицы

Формулировка из обоснования актуальности темы	Реализация в работе	Раздел
Эксперименты с разнородными источниками данных	OCR-извлечение из изображений Open Food Facts (EasyOCR) и эмбединги CLIP (ViT-B/32) исследованы как дополнительный обучающий сигнал, в производственный каскад не включены (см. 3.2.2); сверка эталона яруса 0 с базой USDA Branded Foods через приближённое сопоставление	3.2.5
Интернет-магазин (партнёр — каталог — витрина)	Демонстрационный программный комплекс с REST-интерфейсом обработки партнёрского ввода и руководством пользователя	1.1, 3.1.2, 4.1

Таким образом, все восемь содержательных формулировок утверждённой темы имеют прямое отображение в разработанной системе и подтверждены экспериментально либо архитектурно. Наиболее нагруженные формулировки — отбраковка фактических ошибок и использование скрытых статистических закономерностей каталога — закрыты слоем байесовского валидатора. Для него в работе пересмотрена роль: вместо самостоятельного классификатора сеть используется как валидатор плотностей.

Научная новизна

Научная новизна работы складывается из трёх содержательных пунктов.

- 1) Доминирование каскадной архитектуры по Парето над всеми безусловными конфигурациями большой языковой модели на задаче обогащения товарных атрибутов. Одновременно достигается превышение точности на 9,2 процентных пункта (93,0 % против 83,8 %) и сокращение стоимости в 580 раз по сравнению с прямым обращением к Claude Sonnet 4.5 (комбинированное сокращение, включающее архитектурный вклад каскада в 24 раза и удешевление модели запасного слоя). Результат подтверждён на проверочной выборке без пересечения товарных кодов (code-disjoint, новые SKU) из 16 360 ячеек и воспроизведён на пяти различных моделях запасного слоя. Это означает, что эффект сохраняется при смене поставщика генеративной модели.
- 2) Сценарий развёртывания на собственных мощностях с открытой большой языковой моделью. Каскад с открытой моделью gpt-oss-120b достигает 90,6 % сквозной точности — на 21,3 процентных пункта выше, чем самостоятельное применение той же модели (69,3 %). Результат демонстрирует способность каскадной композиции компенсировать слабость малых открытых моделей через специализированные слои. Кроме того, он формирует методологическую основу для локального развёртывания системы без передачи партнёрских данных во внешние коммерческие сервисы.
- 3) Зафиксированный до получения результатов отрицательный результат для обучаемого стоимостно-чувствительного маршрутизатора и кросс-категорийная репликация цикла «аудит — исправления — переобучение — измерение» в пределах продуктового домена. Гипотеза о превосходстве обучаемого XGBoost-маршрутизатора над статическим правилом отклонена на трёх бюджетах с поправкой Бонферрони. Этот результат согласуется с выводами бенчмарка RouterBench [12]. Цикл аудита эталонной разметки воспроизведён на трёх категориях из трёх с количественно измеримым приростом сквозной точности.

Ограничения работы

Результаты ограничены рядом обстоятельств, добросовестно

фиксируемых для формирования перспектив. Во-первых, область определения ограничена тремя категориями пищевой продукции; переносимость на другие домены не валидирована. Во-вторых, эталон построен сочетанием слабого надзора и согласия трёх LLM со слепой проверкой Opus 4 — аудит-эталон второго уровня, ручная экспертная разметка не выполнялась. В-третьих, мультимодальные сигналы (OCR, CLIP) исследованы как дополнительные обучающие признаки, но в производственный каскад не включены — значимого прироста выше шума не получено; и обучение, и вывод используют только текстовые партнёр-доступные поля. В-четвёртых, проверка ограничена пятью европейскими языками, устойчивость к иным письменностям не валидирована. В-пятых, предварительная регистрация ограничена N1; показатели 3.3.2 — post-hoc анализ. В-шестых, разбиение train/test основной оценки — code-disjoint (по идентификатору товара), бренды между обучающим пулом и тестовой выборкой пересекаются на 82–85 % по категориям; контрольное brand-disjoint исследование (силовое исследование, см. 3.3.6) показало деградацию точности слоя машинного обучения 0,5 п. п. (с 83,0 % до 82,6 % при нулевом пересечении брендов), что подтверждает обобщающую способность каскада на товарах неизвестных брендов в пределах исследованных категорий. В-седьмых, измеренная точность подвержена циркулярному смещению от частичного семантического перекрытия серебряной разметки и LLM-консенсуса; операционная оценка смещения по разнице consensus и ручной разметки — 4,2 п. п. для каскадной части (95,5 % против 91,3 %) и 6,3 п. п. для сквозной цепочки (93,0 % против 86,7 %); консервативной независимой оценкой является показатель на ручной разметке Claude Opus 4 (86,7 % сквозной точности на n=566 cascade-valid).

Селективный характер байесовского валидатора (значимый прирост точности отбраковки на 3 парах из 20) фиксируется явно как ограничение архитектуры: из 20 пар «категория-атрибут» в производственной конфигурации валидатор включён точно только на одной паре chocolate/contains_nuts, где даёт +6,6 п. п. точности при росте расходов на 5,3 п. п. (3.3.4). На остальных 19 парах селективность сигнала недостаточна для архитектурного включения. Принцип «изменение роли компонента вместо его удаления» сформулирован в 3.1.1 и 3.3.4 как самостоятельный методологический вывод; вместе с тем тематически нагруженная

формулировка «отбраковки фактических ошибок» в текущей реализации обеспечивается единственной парой и не имеет универсального селективного решения.

Перспективы развития темы

Полученные результаты и зафиксированные ограничения определяют ряд перспективных направлений развития темы.

- 1) Расширение области определения до шести категорий — напитки, зерновые завтраки и косметика. Для них подготовлены схемы атрибутов и серебряная разметка; основной blocker — построение аудит-эталона уровня v2 и обучение поатрибутных классификаторов Слой 2. Методология аудита и переобучения переносится без принципиальных изменений.
- 2) Регулярная переаттестация изотонической калибровки и регрессионный контроль ECE на следующих итерациях эталона. Схема перекрёстной калибровки реализована (3.3.11, средняя ECE снижается с 0,070 до 0,043); регрессионный тест ECE с порогом 0,01 реализован в `tests/test_calibration_regression.py` со `snapshot-baseline`.
- 3) Введение мультимодального вывода в производственный режим — расширение прикладного интерфейса на приём изображений и добавление OCR/CLIP в реальном времени; требует пересмотра контракта взаимодействия с партнёром.
- 4) Полноценный пилот активного обучения с человеческой разметкой [33; 49]. Симуляция на ячейках расхождения каскада и 3-LLM consensus (3.3.24) не показала превосходства активной стратегии над случайной, однако пул-кандидатов искусственно ограничен каскадом. Перспектива — независимая разметка ячеек-кандидатов (бюджет ≈ 600 ячеек на категорию) и измерение прироста Слой 2 относительно случайной разметки той же стоимости.
- 5) Локализация на русский язык и российские каталоги — разработка русскоязычных регулярных выражений Слой 1 и дообучение Слой 2 на каталогах российских ритейлеров. Поскольку SBERT поддерживает русский в едином векторном пространстве,

трудоёмкость ограничена Слоями 1–2.

- 6) Перенос архитектуры в непродовольственные домены, начиная с электроники. Для смартфонов из каталога PhoneDB подготовлены схема атрибутов и демонстрация холодного старта; полноценное измерение требует аудит-эталона уровня v2 и code-disjoint оценки.

Таким образом, разработанная гибридная каскадная система демонстрирует возможность одновременно достигать высокой точности и низкой стоимости обогащения товарных каталогов. Этот результат обеспечивается за счёт стратифицированного распределения нагрузки между разнородными по природе слоями обработки. Полученные результаты подтверждают выдвинутую в первой главе работы архитектурную гипотезу о каскадной композиции и закрывают все восемь содержательных формулировок утверждённой темы.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Итоги интернет-торговли в России за 2025 год : пресс-релиз АКИТ от 19.02.2026 г. — М. : Ассоциация компаний интернет-торговли, 2026. — 2025. — URL: <https://akit.ru/news/11-5-trln-rublej-akit-podvela-itogi-internet-torgovli-za-2025-god> (дата обращения 19.05.2026).
2. Global Retail E-Commerce Forecast 2024 : research report. — eMarketer, 2024. — 2024. — URL: <https://www.emarketer.com> (дата обращения 03.05.2026).
3. SellerFox : отраслевой обзор индекса каталога Ozon (более 38 млн позиций на 2025 г.) — 2026. — URL: <https://sellerfox.ru> (дата обращения 19.05.2026).
4. Как ускорить работу с товарными карточками в 30 раз : отраслевой кейс / Retail.ru. — 2026. — URL: <https://www.retail.ru/articles/kak-uskorit-rabotu-s-tovarnymi-kartochkami-v-30-raz/> (дата обращения 19.05.2026).
5. Akeneo PIM : open product experience management platform. — Akeneo SAS. — 2026. — URL: <https://akeneo.com> (дата обращения 03.05.2026).
6. Pimcore Platform : open-source data and experience management. — Pimcore GmbH. — 2026. — URL: <https://pimcore.com> (дата обращения 03.05.2026).
7. Salsify Inc. : product experience management platform. — 2026. — URL: <https://www.salsify.com> (дата обращения 19.05.2026).
8. Open source в России 2024 : аналитический отчёт. — М. : Platform V, СберТех, 2024. — 2024. — URL: <https://platformv.sbertech.ru/open-source-v-rossii-2024> (дата обращения 19.05.2026).
9. Chen L., Zaharia M., Zou J. FrugalGPT: How to Use Large Language Models While Reducing Cost and Improving Performance // Transactions on Machine Learning Research. — 2024. — 2024. — URL: <https://arxiv.org/abs/2305.05176>.
10. Aggarwal P., Madaan A., Yang Y., Mausam. AutoMix: Automatically Mixing Language Models // Advances in Neural Information Processing Systems (NeurIPS 2024). — 2024. — 2024. — URL: <https://arxiv.org/abs/2310.12963>.

11. Ding D., Mallick A., Wang C., Sim R., Mukherjee S., Rühle V., Lakshmanan L. V. S., Awadallah A. H. Hybrid LLM: Cost-Efficient and Quality-Aware Query Routing // ICLR 2024. — 2024. — 2024. — URL: <https://arxiv.org/abs/2404.14618>.
12. Hu Q. J., Bieker J., Li X., Jiang N., Keigwin B., Ranganath G., Keutzer K., Upadhyay S. K. RouterBench: A Benchmark for Multi-LLM Routing System : препринт. — arXiv:2403.12031, 2024. — 2024. — URL: <https://arxiv.org/abs/2403.12031> (дата обращения 19.05.2026).
13. Open Food Facts : open product database for food products. — 2026. — URL: <https://world.openfoodfacts.org/data> (дата обращения 03.05.2026).
14. Долгорукова С. А. Управление нормативно-справочной информацией. Сравнительный анализ платформ // Научные записки молодых исследователей. — 2014. — 2014. — URL: <https://cyberleninka.ru/article/n/upravlenie-normativno-spravochnoy-informatsiey-sravnitelnyy-analiz-platform> (дата обращения 23.05.2026).
15. Ермакова Л. М. Методы извлечения информации из текста // Вестник Пермского университета. Серия: Математика. Механика. Информатика. — 2012. — Вып. 1 (9). — 2012. — URL: <https://cyberleninka.ru/article/n/metody-izvlecheniya-informatsii-iz-teksta> (дата обращения 23.05.2026).
16. Ванюшкин А. С., Гращенко Л. А. Методы и алгоритмы извлечения ключевых слов // Новые информационные технологии в автоматизированных системах. — 2016. — 2016. — URL: <https://cyberleninka.ru/article/n/metody-i-algoritmy-izvlecheniya-klyuchevyh-slov> (дата обращения 23.05.2026).
17. Chen T., Guestrin C. XGBoost: A Scalable Tree Boosting System // Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD'16). — San Francisco : ACM, 2016. — P. 785–794. — 2016.
18. Ke G., Meng Q., Finley T., Wang T., Chen W., Ma W., Ye Q., Liu T.-Y. LightGBM: A Highly Efficient Gradient Boosting Decision Tree // Advances in Neural Information Processing Systems. — 2017. — Vol. 30. — P. 3146–3154. — 2017.

19. Афанасьев Г. И., Афанасьев А. Г., Бурмистрова М. В., Тэт Вей Ян Со. Исследование методов машинного обучения для прогнозирования эффективных бизнес-решений в системах электронной коммерции // E-Scio. — 2022. — URL: <https://cyberleninka.ru/article/n/issledovanie-metodov-mashinnogo-obucheniya-dlya-prognozirovaniya-effektivnyh-biznes-resheniy-v-sistemah-elektronnoy-kommertsii> (дата обращения 19.05.2026).
20. Vaswani A., Shazeer N., Parmar N. et al. Attention Is All You Need // Advances in Neural Information Processing Systems. — 2017. — Vol. 30. — P. 5998–6008. — URL: <https://arxiv.org/abs/1706.03762>.
21. Devlin J., Chang M.-W., Lee K., Toutanova K. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding // NAACL-HLT 2019. — ACL, 2019. — P. 4171–4186. — URL: <https://arxiv.org/abs/1810.04805>.
22. Reimers N., Gurevych I. Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks // EMNLP 2019. — Hong Kong : ACL, 2019. — P. 3982–3992. — URL: <https://arxiv.org/abs/1908.10084>.
23. Reimers N., Gurevych I. Making Monolingual Sentence Embeddings Multilingual using Knowledge Distillation // EMNLP 2020. — ACL, 2020. — P. 4512–4525. — URL: <https://arxiv.org/abs/2004.09813>.
24. Колонин А. Г. High-performance automatic categorization and attribution of inventory catalogs : препринт. — arXiv:2202.08965, 2022. — 9 p. — URL: <https://arxiv.org/abs/2202.08965> (дата обращения 19.05.2026).
25. Большакова Е. И., Воронцов К. В., Ефремова Н. Э., Клышинский Э. С., Лукашевич Н. В., Сапин А. С. Автоматическая обработка текстов на естественном языке и анализ данных : учебное пособие. — М. : Изд-во НИУ ВШЭ, 2017. — 269 с. — URL: https://www.hse.ru/data/2017/08/12/1174382135/NLP_and_DA.pdf (дата обращения 19.05.2026).
26. Karamanolakis G., Ma J., Dong X. L. TXtract: Taxonomy-Aware Knowledge Extraction for Thousands of Product Categories // ACL 2020. — 2020. — P. 8489–8502. — URL: <https://aclanthology.org/2020.acl-main.751/>.
27. Yang L., Wang Q., Yu Z., Kulkarni A., Sanghai S., Shu B., Elsas J., Kanagal B. MAVE: A Product Dataset for Multi-source Attribute Value Extraction // WSDM 2022. — 2022. — P. 1256–1265. — URL: <https://dl.acm.org/doi/10.1145/>

3488560.3498377.

28. Zheng G., Mukherjee S., Dong X. L., Li F. OpenTag: Open Attribute Value Extraction from Product Profiles // KDD 2018. — 2018. — P. 1049–1058. — 2018. — URL: <https://dl.acm.org/doi/10.1145/3219819.3219839>.

29. Yang L., Wang Q., Chi J., Liu J., Wang J., Feng F., Xu Z., Fang Y., Huang L., Liu D. EAVE: Efficient Product Attribute Value Extraction via Lightweight Sparse-layer Interaction // Findings of ACL: EMNLP 2024. — Miami, FL : ACL, 2024. — P. 1491–1505. — DOI: 10.18653/v1/2024.findings-emnlp.80. — 2024. — URL: <https://aclanthology.org/2024.findings-emnlp.80/> (дата обращения 28.05.2026).

30. Fang C., Li X., Fan Z., Xu J., Nag K., Korpeoglu E., Kumar S., Achan K. LLM-Ensemble: Optimal Large Language Model Ensemble Method for E-commerce Product Attribute Value Extraction // SIGIR 2024. — Washington, DC : ACM, 2024. — P. 2910–2914. — DOI: 10.1145/3626772.3661357. — 2024. — URL: <https://dl.acm.org/doi/10.1145/3626772.3661357> (дата обращения 28.05.2026).

31. Ong I., Almahairi A., Wu V., Chiang W.-L., Wu T., Gonzalez J. E., Kadous M. W., Stoica I. RouteLLM: Learning to Route LLMs with Preference Data // ICLR 2025. — 2025. — 2025. — URL: <https://arxiv.org/abs/2406.18665> (дата обращения 28.05.2026).

32. Ratner A., Bach S. H., Ehrenberg H. R., Fries J., Wu S., Ré C. Snorkel: Rapid Training Data Creation with Weak Supervision // Proceedings of the VLDB Endowment. — 2017. — Vol. 11, № 3. — P. 269–282. — 2017.

33. Settles B. Active Learning Literature Survey. — University of Wisconsin–Madison, 2010. — Computer Sciences Technical Report 1648. — 2010. — URL: <https://burrsettles.com/pub/settles.activelearning.pdf> (дата обращения 19.05.2026).

34. Дюк В. А. Экспериментальное исследование реакции алгоритмов машинного обучения на ошибки разметки данных // Дифференциальные уравнения и процессы управления. — 2022. — № 3. — 2022. — URL: <https://cyberleninka.ru/article/n/eksperimentalnoe-issledovanie-reaktsii-algoritmov-mashinnogo-obucheniya-na-oshibki-razmetki-dannyh> (дата обращения 23.05.2026).

35. Platt J. C. Probabilistic Outputs for Support Vector Machines and Comparisons to Regularized Likelihood Methods // Advances in Large Margin Classifiers. — MIT Press, 1999. — P. 61–74. — 1999.

36. Niculescu-Mizil A., Caruana R. Predicting Good Probabilities with Supervised Learning // ICML 2005. — Bonn : ACM, 2005. — P. 625–632. — 2005.
37. Guo C., Pleiss G., Sun Y., Weinberger K. Q. On Calibration of Modern Neural Networks // ICML 2017. — PMLR, 2017. — Vol. 70. — P. 1321–1330. — 2017.
38. Шунина Ю. С., Алексеева В. А., Клячкин В. Н. Критерии качества работы классификаторов // Вестник Ульяновского государственного технического университета. — 2015. — 2015. — URL: <https://cyberleninka.ru/article/n/kriterii-kachestva-raboty-klassifikatorov> (дата обращения 23.05.2026).
39. Ковалев А. А., Кузнецов Б. К., Ядченко А. А., Игнатенко В. А. Оценка качества бинарного классификатора в научных исследованиях // Проблемы здоровья и экологии. — 2020. — Т. 4, № 66. — С. 105–113. — 2020. — URL: <https://cyberleninka.ru/article/n/otsenka-kachestva-binarnogo-klassifikatora-v-nauchnyh-issledovaniyah> (дата обращения 23.05.2026).
40. Kohavi R. A Study of Cross-Validation and Bootstrap for Accuracy Estimation and Model Selection // IJCAI 1995. — Morgan Kaufmann, 1995. — P. 1137–1143. — 1995.
41. Wilson E. B. Probable Inference, the Law of Succession, and Statistical Inference // Journal of the American Statistical Association. — 1927. — Vol. 22, № 158. — P. 209–212. — 1927.
42. Pearl J. Probabilistic Reasoning in Intelligent Systems: Networks of Plausible Inference. — San Francisco : Morgan Kaufmann, 1988. — 552 p. — 1988.
43. Heckerman D., Geiger D., Chickering D. M. Learning Bayesian Networks: The Combination of Knowledge and Statistical Data // Machine Learning. — 1995. — Vol. 20, № 3. — P. 197–243. — 1995.
44. Тулупьев А. Л., Николенко С. И., Сироткин А. В. Байесовские сети: логико-вероятностный подход. — СПб. : Наука, 2006. — 607 с. — 2006.
45. Ankan A., Panda A. pgmpy: Probabilistic Graphical Models using Python // SciPy 2015. — 2015. — P. 6–11. — 2015.

46. Schwarz G. Estimating the Dimension of a Model // Annals of Statistics. — 1978. — Vol. 6, № 2. — P. 461–464. — 1978.

47. Артемов А. А. Модели машинного обучения в FMCG-ритейле: архитектура и эксплуатация в условиях высокой изменчивости данных // Вестник науки. — 2025. — URL: <https://cyberleninka.ru/article/n/modeli-mashinnogo-obucheniya-v-fmcg-riteyle-arhitektura-i-ekspluatatsiya-v-usloviyah-vysokoy-izmenchivosti-dannyh> (дата обращения 19.05.2026).

48. Сергеев С. А. Управление запасами в условиях маркетплейсов: почему не работают стандартные методы? // Вестник Академии знаний. — 2024. — URL: <https://cyberleninka.ru/article/n/upravlenie-zapasami-v-usloviyah-marketpleysov-pochemu-ne-rabotayut-standartnye-metody> (дата обращения 19.05.2026).

49. Гилязов Р. А., Турдаков Д. Ю. Активное обучение и краудсорсинг: обзор методов оптимизации разметки данных // Труды Института системного программирования РАН. — 2018. — Т. 30, № 2. — С. 215–250. — DOI: 10.15514/ISPRAS-2018-30(2)-11. — URL: <https://cyberleninka.ru/article/n/aktivnoe-obuchenie-i-kraudsorsing-obzor-metodov-optimizatsii-razmetki-dannyh> (дата обращения 19.05.2026).

50. Хорошевский В. Ф. Пространства знаний в сети Интернет и Semantic Web (Часть 1) // Искусственный интеллект и принятие решений. — 2008. — URL: http://aidt.ru/index.php?Itemid=114&catid=43&id=137&lang=ru&option=com_content&view=article (дата обращения 19.05.2026).

51. Brown T. B., Mann B., Ryder N. et al. Language Models are Few-Shot Learners // Advances in Neural Information Processing Systems. — 2020. — Vol. 33. — P. 1877–1901. — 2020. — URL: <https://arxiv.org/abs/2005.14165>.

52. Anthropic. Introducing Claude Sonnet 4.5 : анонс модели. — Anthropic, 29.09.2025. — URL: <https://www.anthropic.com/news/claude-sonnet-4-5> (дата обращения 03.05.2026).

53. Breiman L. Random Forests // Machine Learning. — 2001. — Vol. 45, № 1. — P. 5–32. — 2001.

54. Hastie T., Tibshirani R., Friedman J. The Elements of Statistical Learning: Data Mining, Inference, and Prediction. 2nd ed. — New York : Springer, 2009. — 745 p. — 2009.
55. Shwartz-Ziv R., Armon A. Tabular Data: Deep Learning is Not All You Need // Information Fusion. — 2022. — Vol. 81. — P. 84–90. — 2022.
56. McElfresh D., Khandagale S., Valverde J., Prasad V., Ramakrishnan G., Goldblum M., White C. When Do Neural Nets Outperform Boosted Trees on Tabular Data? // Advances in Neural Information Processing Systems. — 2023. — Vol. 36 (NeurIPS 2023 Datasets and Benchmarks Track). — 2023.
57. Radford A., Kim J. W., Hallacy C. et al. Learning Transferable Visual Models From Natural Language Supervision // ICML 2021. — PMLR, 2021. — P. 8748–8763. — 2021. — URL: <https://arxiv.org/abs/2103.00020>.
58. USDA FoodData Central : public nutrient database, SR Legacy release. — U. S. Department of Agriculture, Agricultural Research Service. — 2026. — URL: <https://fdc.nal.usda.gov> (дата обращения 03.05.2026).

ПРИЛОЖЕНИЕ А

Электронные материалы

На рисунке А.1 приведён QR-код со ссылкой на репозиторий с исходным кодом, ноутбуком §3.3 в исполняемом виде, демонстрационным программным комплексом и текстом настоящей работы.



Рисунок А.1 – QR-код на репозиторий проекта