



МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ
(национальный исследовательский университет)»

Институт (Филиал) № 8 «Компьютерные науки и прикладная математика»

Образовательный центр Института № 8

Группа М8О-206СВ-24 Направление подготовки 01.04.02 «Прикладная математика и информатика»

Магистерская программа Прикладная математика и информатика

Квалификация: студент специализированного высшего образования

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА СПЕЦИАЛИСТА

На тему: Система автоматизированного обогащения товарных данных для интернет-магазина

Автор ВКР: Фролов Михаил Александрович ()

Научный руководитель: Судаков Владимир Анатольевич, д. т. н., профессор ()

Консультант: ()

Консультант: ()

Рецензент: ()

К защите допустить

Заведующий кафедрой Института № 8 «Компьютерные науки и прикладная математика»

Крылов Сергей Сергеевич ()

_____ 2026 года

Москва 2026

РЕФЕРАТ

Выпускная квалификационная работа специалиста состоит из 105 страниц, 11 рисунков, 31 таблицы, 58 использованных источников, 1 приложения. **ОБОГАЩЕНИЕ ТОВАРНЫХ ДАННЫХ, КАСКАДНАЯ АРХИТЕКТУРА, СЛАБЫЙ НАДЗОР, БАЙЕСОВСКАЯ СЕТЬ, БОЛЬШАЯ ЯЗЫКОВАЯ МОДЕЛЬ, КАЛИБРОВКА, ИЗВЛЕЧЕНИЕ ПРИЗНАКОВ, ДОМИНИРОВАНИЕ ПО ПАРЕТО, ВЕКТОРНЫЕ ПРЕДСТАВЛЕНИЯ**

Объект. Процесс автоматизированного обогащения товарных каталогов интернет-магазинов на открытых источниках данных.

Предмет. Гибридная каскадная архитектура с ансамблевой оценкой уверенности классификаторов и выборочным обращением к большой языковой модели как запасному слою.

Цель. Разработать каскадную систему обогащения товарных данных, превосходящую прямой вызов большой языковой модели по точности и стоимости и допускающую локальное развёртывание.

Методы. Многоязычные векторные представления SBERT; XGBoost с поатрибутными порогами уверенности; байесовская сеть (Hill Climb + BIC); согласие трёх больших языковых моделей со слепой проверкой; проверка гипотезы по предзаявленному протоколу с поправкой Бонфферрони.

Результаты. Реализована пятислойная каскадная архитектура на трёх категориях Open Food Facts. На тестовой выборке без пересечения товарных кодов (16 360 ячеек, 20 пар «категория-атрибут») сквозная точность 93,0 %, каскадной части 95,5 %; на ручном эталоне Claude Opus 4 (n=566) консервативная оценка 86,7 %. С открытой моделью gpt-oss-120b сквозная точность 90,6 % (+21,3 п. п. над прямым вызовом). Каскад покрывает 97,3 % ячеек; доминирует по Парето над прямым Claude Sonnet 4.5 (+9,2 п. п. при сокращении стоимости в 580 раз). Гипотеза о превосходстве обучаемого маршрутизатора отклонена. Разработана демонстрационная система: шлюз API на Go, ML-сервис на Python/FastAPI, веб-интерфейс.

Использование. Архитектура применима в системах управления товарной информацией интернет-магазинов: точность 93,0 %, сокращение стоимости обработки в 580 раз, ручной нагрузки оператора в 12–25 раз, локальное развёртывание без передачи данных во внешние API.

СОДЕРЖАНИЕ

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ	6
ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ	8
ВВЕДЕНИЕ	10
1 РАЗВЁРНУТАЯ АКТУАЛЬНОСТЬ ТЕМЫ	18
1.1 Проблема обогащения товарных каталогов интернет-магазина .	18
1.1.1 Роль товарных данных и неоднородность партнёрского ввода	18
1.1.2 Эффекты неполной карточки на пользовательский опыт . .	20
1.1.3 Существующие системы управления товарной информацией не решают задачу	21
1.1.4 Противоречие и постановка задачи	21
1.2 Литературный обзор	21
1.2.1 Извлечение признаков из текстовых описаний товаров . . .	22
1.2.2 Стоимостно-чувствительные каскады больших языковых моделей	23
1.2.3 Существующие промышленные РІМ-системы и анализ аналогов	24
1.2.4 Слабый надзор, калибровка и сопутствующая методология	25
1.3 Техническое задание на разрабатываемую систему	25
1.3.1 Функциональные требования	26
1.3.2 Нефункциональные требования	26
1.3.3 Архитектурные требования	27
1.3.4 Соотношение технического задания и решаемых задач работы	27
1.4 Выводы по главе 1	28
2 ТЕОРЕТИЧЕСКОЕ ОБОСНОВАНИЕ РЕШЕНИЯ	30
2.1 Логика работы разрабатываемого программного обеспечения .	30
2.1.1 Формальная постановка задачи обогащения	30
2.1.2 Каскадная схема принятия решения	30
2.1.3 Поведение системы при выходе категории за пределы поддерживаемых	31
2.1.4 Метрики качества и стоимости	32
2.2 Архитектура и стек технологий	32
2.2.1 Архитектура системы	33

2.2.2	Обоснование выбора компонентов стека	35
2.2.3	Стек технологий — сводная таблица	36
2.3	Сценарий работы программного обеспечения	37
2.3.1	Сквозной пример прохождения запроса	37
2.4	Выводы по главе 2	38
3	ОПИСАНИЕ ПРОГРАММНО-ТЕХНОЛОГИЧЕСКОЙ РЕАЛИЗАЦИИ	39
3.1	Описание программного обеспечения	39
3.1.1	Программная реализация слоёв каскада	39
3.1.2	Демонстрационный комплекс и контракт API	42
3.2	Данные	43
3.2.1	Источник данных, фильтрация и стратифицированная выборка	43
3.2.2	Эталонная разметка: иерархическая схема трёх ярусов . .	44
3.2.3	Разбиение без пересечения товарных кодов	45
3.2.4	Дополнительные источники сигналов	45
3.3	Доказательство работоспособности и применимости	46
3.3.1	Условия проверки и метрики	46
3.3.2	Стратификация точности по типу эталонного сигнала . . .	46
3.3.3	Воспроизводимость	47
3.3.4	Главный результат: точность и стоимость производственной конфигурации	48
3.3.5	Декомпозиция по категориям	51
3.3.6	Обобщение на новые бренды (точечная проверка без пересечения брендов)	52
3.3.7	Поатрибутная картина точности и доверительные интервалы	54
3.3.8	Анализ доминирования по Парето: почему каскад превосходит одиночный вызов LLM	55
3.3.9	Учёт точности маршрутизатора первого уровня	56
3.3.10	Вклад каждого слоя каскада	56
3.3.11	Поатрибутная калибровочная ошибка до и после калибровки	57
3.3.12	Таксономия ошибок каскада	58
3.3.13	Разбор примеров прохождения каскада	61
3.3.14	Сравнение классификаторов Слой 2: XGBoost, Random Forest, логистическая регрессия, MLP	63

3.3.15	Обоснование сохранения слоя регулярных выражений: сопоставление с обучаемыми альтернативами	65
3.3.16	Поведение байесовского валидатора и архитектурный вывод	66
3.3.17	Чувствительность к выбору порога отсечки	67
3.3.18	Стоимостно-чувствительный маршрутизатор: отрицательный результат на проверке гипотезы H1	68
3.3.19	Цикл «аудит → правки → переобучение → измерение» . .	70
3.3.20	Переобучение моделей и прирост каскада	70
3.3.21	Кросс-категорийная репликация цикла 3/3	71
3.3.22	Устойчивость каскада по языкам	71
3.3.23	Устойчивость каскада к шуму во входных данных	72
3.3.24	Симуляция активного обучения на эталон согласия трёх больших языковых моделей	74
3.3.25	Уточнение схемы атрибутов: независимые свойства	75
3.3.26	Поатрибутные архитектурные решения	76
3.4	Выводы по главе 3	77
4	ОПИСАНИЕ РЕЗУЛЬТАТОВ	79
4.1	Руководство пользователя	79
4.1.1	Роли и интерфейсы	79
4.2	Сценарии применения и порядок внедрения	81
4.2.1	Встраивание в бизнес-процесс магазина	81
4.2.2	Сценарий многоязычного каталога	81
4.2.3	Применимость в смежных доменах	82
4.3	Риски развёртывания и план мониторинга	83
4.3.1	Мониторинг в производственном контуре	86
4.4	Что позволяет использование разработки (характеристика достигнутых результатов)	86
4.5	Выводы по главе 4	89
	ЗАКЛЮЧЕНИЕ	91
	СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	97
	ПРИЛОЖЕНИЕ А Электронные материалы	104

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ

В настоящей выпускной квалификационной работе специалиста применяют следующие термины с соответствующими определениями:

Серебряная разметка — набор пар «товар — целевое значение атрибута», полученный автоматически из открытых источников данных (теги Open Food Facts) и используемый для обучения моделей. Содержит шум и неполноту; противопоставляется эталонной разметке

Эталонная разметка — пары «товар — целевое значение», прошедшие верификацию согласованным мнением нескольких языковых моделей и/или слепой разметкой более сильной языковой модели; используется как опорная истина при оценке каскада

Слабый надзор — режим обучения с использованием неполной или зашумлённой разметки, формируемой автоматически из доступных источников вместо ручной разметки экспертом

Каскадная архитектура — последовательность алгоритмических слоёв, каждый из которых обрабатывает только те объекты или атрибуты, которые не были закрыты предыдущими слоями с заданной уверенностью

Многоуровневая фильтрация по уверенности — формализация поведения каскада как последовательного конъюнктивного условия на прохождение калиброванных порогов уверенности на каждом слое. Реализует требование утверждённой темы об «ансамблевой оценке уверенности моделей»

Покрытие — доля ячеек «товар, атрибут» в тестовой выборке, для которых каскад дал предсказание выше порога уверенности на слоях 1–3 (без обращения к запасному слою)

Точность на покрытом срезе — доля верных предсказаний среди тех ячеек, для которых каскад дал ответ без обращения к запасному слою

Сквозная точность — точность системы на полной тестовой выборке, при которой отказы каскада засчитываются как неверные ответы (либо заменяются ответом запасного слоя при включённом Слое 4)

Разбиение без пересечения товарных кодов — построение разбиения выборки на обучающую и тестовую части, при котором ни один товарный код не встречается одновременно в обеих частях. Обеспечивает оценку качества системы на новых товарных позициях

Цикл «аудит — правки — переобучение — измерение» — методологический

приём улучшения системы, при котором обнаружение конкретных дефектов эталонной разметки через аудит приводит к правкам экстрактора, затем к переобучению моделей и измерению прироста точности на той же аудит-выборке

ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ

В настоящей выпускной квалификационной работе специалиста применяют следующие сокращения и обозначения:

OFF — Open Food Facts, открытый краудсорсинговый каталог продовольственных товаров под лицензией ODbL

SBERT — Sentence-BERT, многоязычная модель векторного представления предложений

XGBoost — Extreme Gradient Boosting, библиотека градиентного бустинга деревьев решений

ECE — Expected Calibration Error, ожидаемая ошибка калибровки вероятностей классификатора

CPD — Conditional Probability Distribution, условное распределение вероятности

DAG — Directed Acyclic Graph, направленный ациклический граф

BIC — Bayesian Information Criterion, критерий выбора структуры байесовской сети

PDO — Protected Designation of Origin, защищённое наименование товара

AOP — Appellation d'Origine Protégée, защищённое наименование товара (фр.)

LLM — large language model, большая языковая модель

TF-IDF — term frequency $\times$ inverse document frequency, частотно-инверсный показатель

OOD — out of distribution, выход за пределы обучающего распределения

AUROC — area under the ROC curve, площадь под кривой ошибок

ТЗ — техническое задание

BPMN — Business Process Model and Notation, модель и нотация бизнес-процессов

PIM — product information management, управление информацией о товарах

CJM — customer journey map, карта пути клиента

СМ — контент-менеджер

ML — machine learning, машинное обучение

API — application programming interface, программный интерфейс приложения

REST — representational state transfer, архитектурный стиль программного интерфейса

JSON — JavaScript Object Notation, текстовый формат обмена данными

CSV — comma-separated values, текстовый формат табличных данных с разделителями

DOCX — Office Open XML Document, формат текстового документа

E2E — end-to-end, сквозной — точность системы с учётом маршрутизации и отказа от ответа (None=wrong); production-realistic метрика (см. 2.1.4)

MPNet — Masked and Permuted Pre-training, архитектура трансформера, использованная в paraphrase-multilingual-mpnet-base-v2 для 768-мерных эмбедингов

NBSP — non-breaking space, неразрывный пробел; используется в LaTeX между числом и единицей

ODbL — Open Database License v1.0, лицензия share-alike для открытых баз данных (применяется к Open Food Facts)

TCO — total cost of ownership, совокупная стоимость владения системой за период

CI — confidence interval, доверительный интервал (95 % если не указано иное)

RF — Random Forest, ансамбль деревьев решений с bagging

MLP — multi-layer perceptron, многослойный перцептрон (полносвязная нейросеть)

ВВЕДЕНИЕ

Актуальность темы исследования.

Годовой объём российского сегмента электронной коммерции в 2025 году составил 11,5 трлн руб. [1], мировой рынок также растёт [2]. Каталоги крупных интернет-магазинов содержат десятки миллионов товарных позиций: индексируемая часть каталога Ozon в открытых аналитических базах превышает 38 млн позиций [3]. Ежедневно туда добавляются тысячи новых записей от партнёров-поставщиков.

Карточка товара — центральный элемент цифровой витрины. От её полноты зависят фасетный поиск, релевантность ранжирования и рекомендаций, корректность аналитики и в итоге конверсия в покупки. Партнёрский ввод при этом неоднородный: для одного товара поставщик передаёт только название и бренд, для другого — расширенный набор полей с фотографиями, для третьего — состав на иностранном языке. Образующиеся пробелы исторически закрывают контент-менеджеры вручную: каждую карточку приходится открывать, проверять и дописывать десятки атрибутов. На каталоге в миллионы позиций и тысячах новых записей в сутки это уже не работает ни по затратам, ни по доступности знаний иностранных языков [4].

Системы управления товарной информацией (Product Information Management) — Akeneo, Pimcore, Salsify и аналогичные [5; 6; 7] — сложились из задачи хранить уже сформированную товарную информацию. Задачу извлечения этой информации из неструктурированного партнёрского ввода они системно не решают. Появляющиеся в них модули автоматического обогащения — надстройка над одной публичной большой языковой моделью с прямым вызовом на каждый товар. Подробное сопоставление приведено в 1.2.3. Такой вызов экономически приемлем только для каталогов небольшого и среднего размера и не даёт гарантий фактической корректности. На числовых полях большие языковые модели регулярно ошибаются (3.3.12). Рост ставок коммерческих API, ужесточение требований к локализации данных и отраслевой тренд на открытые модели в локальном развёртывании [8] дополнительно усиливают запрос на архитектурные решения, которые не сводятся к прямому вызову одной модели.

Отсюда противоречие: автоматизация наполнения карточек — инженерная необходимость, но ни одна отдельная технология не покрывает

все типы целевых атрибутов с приемлемой точностью и стоимостью. Правила надёжны на числовых атрибутах, классические классификаторы требуют большой размеченной выборки, большие языковые модели универсальны, но дорогие и ошибаются на числовых полях.

Разрешением противоречия выступает гибридная каскадная архитектура — последовательность слоёв, в которой каждый следующий подключается к остатку, не закрытому предыдущими с нужной уверенностью. Такая композиция совмещает семантические возможности генерирующих моделей, предсказательную силу классического машинного обучения и автоматическую отбраковку недостоверных значений. Научная актуальность — проверка эффективности такого каскада на типовой задаче обогащения; практическая — готовый к производству комплекс с контролируемой стоимостью и локальным развёртыванием.

Цель работы.

Цель работы — разработать гибридную каскадную систему обогащения товарных данных интернет-магазина, которая выигрывает у прямого вызова большой языковой модели одновременно по точности и стоимости и допускает локальное развёртывание на открытых моделях.

Задачи работы.

Для достижения поставленной цели сформулированы и решены пять задач:

- 1) разработать архитектуру гибридного каскадного конвейера обработки товарных данных с пошаговой фильтрацией по уверенности и явным разделением слоёв. Слои каскада: предкаскадный классификатор категории, экстрактор регулярных выражений, классификатор машинного обучения на векторных представлениях, байесовский валидатор плотностей, запасной слой большой языковой модели. Пошаговая фильтрация формализует требование утверждённой темы об ансамблевой оценке уверенности моделей как последовательное конъюнктивное условие на калиброванные пороги слоёв;
- 2) реализовать каждый слой каскада в виде отдельного программного

компонента: экстрактор регулярных выражений; классификатор машинного обучения на многоязычных векторных представлениях партнёр-доступных полей; байесовский валидатор, который использует обученную сеть атрибутов как фильтр статистически маловероятных пар «бренд × значение»; запасной слой на основе большой языковой модели с поддержкой нескольких поставщиков, включая открытые модели для локального развёртывания;

- 3) построить эталонную разметку и проверочную выборку без пересечения товарных кодов между обучением и тестом для оценки качества системы на трёх категориях: паста, шоколад, сыры. Разметка сочетает слабый надзор от тегов открытого каталога, поатрибутное согласие трёх независимых больших языковых моделей и слепую разметку референсной моделью;
- 4) провести экспериментальную оценку разработанной системы: измерить точность сквозного прохождения каскада, поатрибутное покрытие и стоимость обработки на эталонной тестовой выборке; сопоставить полученные показатели с прямым использованием большой языковой модели; оценить вклад каждого слоя каскада, устойчивость к смещению по языкам входных данных и поведение байесовского валидатора как селективной валидации плотностей;
- 5) разработать демонстрационный программный комплекс. Комплекс должен обеспечивать работу оператора каталога с каскадом через веб-интерфейс и стабильный программный интерфейс. Поддерживаются три производственных сценария развёртывания: с премиум-коммерческой большой языковой моделью, с бюджетной коммерческой и с открытой моделью в локальном развёртывании.

Объект и предмет исследования.

Объектом исследования является процесс автоматизированного обогащения товарных каталогов интернет-магазинов на основе открытых источников данных. На вход подаётся минимальный набор партнёр-доступных полей, на выходе требуется получить структурированный набор целевых атрибутов.

Предметом исследования является гибридная каскадная архитектура обработки товарных данных с ансамблевой оценкой уверенности

классификаторов и выборочным обращением к большой языковой модели в роли запасного слоя. Рассматриваются её точность, стоимость, устойчивость к смещению входного распределения, а также вычислительные и эксплуатационные свойства, существенные для производственного применения.

Теоретические и методические основы работы.

Работа опирается на следующие методы и инструменты:

- 1) извлечение признаков из неструктурированного текста — регулярные выражения и многоязычный кодировщик `paraphrase-multilingual-mpnet-base-v2`;
- 2) классификатор уровня машинного обучения — градиентный бустинг `XGBoost` поверх векторных представлений;
- 3) валидатор атрибутов реализован вероятностной графической моделью на библиотеке `pgmpy`; структура сети строится алгоритмом `Hill Climb` по критерию `BIC`;
- 4) обучающая выборка формируется слабым надзором по тегам открытого каталога `Open Food Facts`;
- 5) эталонная разметка строится из трёх ярусов: детерминированные правила для нутриент-производных атрибутов, регуляторные теги и поатрибутное согласие трёх независимых больших языковых моделей со слепой проверкой референсной моделью; процедура подробно описана в 3.2.3;
- 6) качество измеряется на отложенной выборке без пересечения товарных кодов; доверительные интервалы — кластерным бутстрэпом с группировкой по брендам;
- 7) гипотезы о превосходстве каскада над одиночной языковой моделью проверяются по заранее объявленному протоколу с поправкой Бонферрони на трёх бюджетах вызовов запасного слоя.

Архитектурный подход к выбору модели по соотношению цена/качество опирается на работы L. Chen и соавторов `FrugalGPT` [9], P. Aggarwal и соавторов `AutoMix` [10], D. Ding и соавторов `Hybrid LLM` [11], а также на бенчмарк Q. J. Hu и соавторов `RouterBench` [12].

Новизна и основные результаты.

По задаче 1 — проектирование архитектуры каскада, разделы 2.1, 3.1.1. Спроектирован гибридный каскад из пяти последовательных слоёв; решение слоя принимается при одновременном выполнении калиброванных порогов уверенности предыдущих слоёв. Формальная постановка задачи допускает явный отказ системы от ответа и явно указывает слой-источник каждого предсказания.

По задаче 2 — реализация слоёв, раздел 3.1.2. Каскад реализован как набор независимо обновляемых программных компонентов. Разработана демонстрационная система: шлюз API на Go — ML-сервис на Python/FastAPI — статический веб-интерфейс. Система запускается одной командой и проходит проверку готовности всех слоёв через диагностический интерфейс.

По задаче 3 — построение эталонной разметки, раздел 3.2. Построена многоисточниковая эталонная разметка для трёх категорий товаров: теги открытого каталога, правила на нутриентах, поатрибутное согласие трёх независимых больших языковых моделей и слепая разметка референсной моделью. Разбиение на обучающую, валидационную и тестовую части выполнено без пересечения товарных кодов между обучением и тестом.

По задаче 4 — экспериментальная оценка, разделы 3.3.2, 3.3.3, 3.3.4, 3.3.7. Получена сквозная точность 93,0 % (точность только-каскадной части 95,5 %, макро-F1 0,890) на тестовой выборке без пересечения товарных кодов между обучением и тестом из 16 360 ячеек по 20 парам «категория-атрибут» при 580-кратном сокращении стоимости в режиме «каскад + Gemini 2.5 Flash» относительно прямого вызова Claude Sonnet 4.5 (сюда входит архитектурный вклад каскада в 24 раза и удешевление модели). На независимом эталоне ручной разметки Claude Opus 4 (n=566 ячеек в области применимости каскада из 688 проверенных) сквозная точность — 86,7 %. Выигрыш каскада по точности и стоимости одновременно подтверждён на пяти моделях запасного слоя. Вклад каждого слоя измерен количественно, включая точечный вклад байесовского валидатора. Каскад покрывает 97,3 % ячеек.

По задаче 5 — разработка демонстрационного программного комплекса, разделы 4.1, 4.2. Реализована поддержка трёх производственных сценариев развёртывания: премиум-коммерческий, бюджетный коммерческий, локальный с открытой моделью. Поддерживаются три роли

пользователей: контент-менеджер, системный аналитик, инженер машинного обучения.

На основании результатов сформулированы три пункта научной новизны. Их общая особенность относительно известных стоимостно-ориентированных каскадов для языковых задач — FrugalGPT [9], AutoMix [10], Hybrid LLM [11], RouterBench [12] — разнородность слоёв. Перечисленные работы комбинируют однотипные генеративные модели разной мощности; в настоящей работе исследован разнородный каскад «правила (регулярные выражения) — дискриминативная модель машинного обучения — генеративная большая языковая модель» с явным правилом маршрутизации на уровне пары «категория-атрибут». Подобной комбинации трёх парадигм для задачи обогащения товарных каталогов в литературе не зафиксировано.

Первый пункт научной новизны. Количественно установлено доминирование по Парето разработанной гибридной каскадной системы над прямым использованием большой языковой модели на задаче обогащения товарных каталогов. На тестовой выборке без пересечения товарных кодов размером 16 360 ячеек одновременно достигаются: превышение точности на 9,2 процентных пункта (93,0 % против 83,8 %) и сокращение стоимости обработки в 580 раз. Архитектурный вклад каскада в этот выигрыш — 24 раза, остальное даёт удешевление модели запасного слоя.

Второй пункт научной новизны. Эмпирически установлено: в сценарии локального развёртывания с открытой большой языковой моделью gpt-oss-120b в роли запасного слоя каскад компенсирует слабость малой открытой модели на сложных атрибутах за счёт специализированного слоя машинного обучения. Прирост сквозной точности — 21,3 процентных пункта над прямым использованием той же открытой модели (90,6 % против 69,3 %) при сокращении стоимости в 810 раз относительно опорного прямого вызова Claude Sonnet 4.5. Архитектура устойчива к смене поставщика большой языковой модели, что подтверждено на пяти проверенных моделях запасного слоя.

Третий пункт научной новизны объединяет два самостоятельных результата. Первый — **заранее объявленный отрицательный исход проверки гипотезы H1**: на задаче обогащения товарных каталогов по заранее объявленной (до сбора экспериментальных данных) процедуре с поправкой

Бонферрони эмпирически установлено, что статическое правило маршрутизации, определённое отдельно для каждой пары «категория-атрибут», не уступает обучаемому XGBoost-маршрутизатору с учётом стоимости по сквозной точности при равных бюджетах вызовов запасного слоя. Результат уточняет применимость обучаемой маршрутизации к этому классу задач и согласуется с выводами бенчмарка RouterBench [12]. Второй — **перенос замкнутого цикла «аудит эталонной разметки — правка экстрактора признаков — переобучение моделей — повторное измерение» на категории внутри продуктового домена.** Цикл воспроизведён на трёх категориях из трёх с приростом сквозной точности на подвыборке проверенных проблемных ячеек +18,2, +16,3 и +14,4 процентных пункта для пасты, шоколада и сыров соответственно.

Апробация и внедрение результатов.

Разработка велась по практическим требованиям, типичным для крупных интернет-магазинов (российских и международных). Архитектура и эксплуатационные характеристики системы ориентированы на встраивание в производственный процесс обогащения товарного каталога без перестройки соседних звеньев (см. 4.2.1 — описание точки встраивания в маршрут «партнёрский фид — каталог — витрина»). Поддерживаются три производственных сценария развёртывания: с премиум-коммерческой большой языковой моделью (Claude Sonnet 4.5 / GPT-4o), с бюджетной коммерческой (Gemini 2.5 Flash) и с открытой моделью в полностью локальном развёртывании (gpt-oss-120b). Последний сценарий критичен для требований локализации обработки партнёрских данных.

Апробация выполнена в виде демонстрационного программного комплекса. Комплекс запускается одной командой и проверяется на работоспособность через диагностический программный интерфейс. Демонстрация подтверждает, что все слои каскада работают на трёх категориях: паста, шоколад, сыры. Воспроизводимость численных показателей обеспечена сценарием `reproduce.sh`, который пересоздаёт основные результаты из артефактов в каталоге `datasets/processed/` репозитория. Разработанный комплекс архитектурно приспособлен к интеграции в системы управления товарной информацией розничной торговли; типовая схема встраивания приведена в 4.2.1.

Структура и объём работы.

Выпускная квалификационная работа состоит из введения, четырёх глав, заключения, списка использованных источников и приложения. Общий объём работы — 107 страниц, основная часть (от введения до заключения включительно) — 89 страниц. Список использованных источников включает 58 наименований: 18 российских источников, индексируемых в РИНЦ и доступных в открытых российских репозиториях, и 40 зарубежных публикаций, отраслевых отчётов и стандартов.

Первая глава содержит обоснование актуальности темы, литературный обзор по трём направлениям и техническое задание (ТЗ) на разрабатываемую систему. Вторая глава посвящена теоретическому обоснованию решения. В ней приводятся формальная постановка задачи, обоснование архитектуры и стека технологий, а также сценарии прохождения запроса через каскад. Третья глава содержит описание программной реализации, использованных данных и доказательство работоспособности каскада на эталонной тестовой выборке без пересечения товарных кодов между обучением и тестом. Четвёртая глава представляет порядок применения системы, сценарии её развёртывания и характеристику достигнутых результатов в формате «повышено / ускорено / сокращено». В заключении собраны выводы по главам, научная новизна и перспективы развития темы.

1 РАЗВЁРНУТАЯ АКТУАЛЬНОСТЬ ТЕМЫ

В главе обосновывается тема работы, систематизируются существующие подходы к автоматическому обогащению товарных данных и формулируется техническое задание на разрабатываемую систему.

1.1 Проблема обогащения товарных каталогов интернет-магазина

1.1.1 Роль товарных данных и неоднородность партнёрского ввода

Карточка товара — центральный элемент цифровой витрины: от её атрибутов (тип, состав, маркировки качества, страна происхождения) зависят фасетный поиск, релевантность ранжирования и конверсия. В каталогах крупных площадок десятки миллионов позиций [3] и тысячи новых записей в сутки — объёмы, на которых ручное заполнение перестаёт работать. Место разрабатываемой системы в типовой инфраструктуре интернет-магазина показано на рисунке 1.



Рисунок 1 — Место системы автоматизированного обогащения в инфраструктуре интернет-магазина

Партнёрские данные сильно неоднородны: для одного товара поставщик передаёт только название и бренд, для другого — расширенный набор полей с фотографиями, для третьего — состав на иностранном языке, для четвёртого доступен только штрихкод. Анализ Open Food Facts [13] показывает, что

заполненность нутриентных полей в среднем ниже, чем у базовых. Пробелы исторически закрываются контент-менеджерами вручную; при каталоге в миллионы позиций и тысячах новых записей в сутки такой путь экономически не подходит [4] и плохо масштабируется по языкам (FR, DE, IT, ES в категориях импортной пищевой продукции).

Типовая работа контент-менеджера сводится к шагам «приём — поиск аналогов — заполнение — внутренняя проверка — публикация» (рисунок 2, а). Гибридный каскад заменяет ручное заполнение автоматическим выводом системы, а ручной труд сосредотачивается на выборочной проверке и периодическом аудите ошибок (рисунок 2, б).




Рисунок 2 — Процесс работы контент-менеджера: (а) текущий, (б) целевой с интеграцией гибридного каскада обогащения

Примечание. Этапы текущего процесса реконструированы по материалам публичной документации Akeneo [5], Pimcore [6] и Salsify [7]; целевой процесс — авторская конструкция.

1.1.2 Эффекты неполной карточки на пользовательский опыт

Неполная карточка выпадает из фасетных подборок при применении фильтров; растёт доля возвратов и негативной обратной связи по атрибутам

правового и диетического значения (органика, глютен, аллергены); удлиняется цикл выхода товара на витрину.

1.1.3 Существующие системы управления товарной информацией не решают задачу

Системы управления информацией о товарах (PIM, product information management) — Akeneo, Pimcore, Salsify, Riversand, inRiver [5; 6; 7] — выросли из корпоративной потребности хранить и публиковать товарную информацию в едином каталоге. Их функциональность сосредоточена на управлении уже сформированной информацией, не на её извлечении. Сравнительный анализ платформ управления нормативно-справочной информацией с учётом MDM/PIM-функциональности проведён С. А. Долгоруковой [14]. Появляющиеся модули автоматического обогащения — это обёртки над одной публичной большой языковой моделью (LLM, large language model) с прямым вызовом на каждый товар. Они экономически приемлемы только для каталогов небольшого и среднего размера и не дают гарантий корректности. Альтернатива в виде агрегаторов готовых описаний задачу извлечения атрибутов из произвольного партнёрского текста не решает и ограничена крупными брендами.

1.1.4 Противоречие и постановка задачи

Ни одна отдельная технология не покрывает все типы целевых атрибутов с приемлемой точностью и стоимостью: правила слабы на семантических полях, классические классификаторы требуют разметки и плохо переносятся между языками, большие языковые модели дорогие [9] и ошибаются на числовых полях (см. 3.3.12). Рабочая гипотеза — каскадная композиция, в которой каждый следующий слой подключается к остатку, не закрытому предыдущими с нужной уверенностью.

1.2 Литературный обзор

Литературный обзор охватывает три направления:

- извлечение признаков из текстовых описаний товаров;
- каскады больших языковых моделей с учётом стоимости вызовов;
- существующие промышленные системы управления товарной

информацией.

1.2.1 Извлечение признаков из текстовых описаний товаров

Задача восполнения пропущенных атрибутов — это частный случай извлечения признаков из неструктурированного текста (information extraction, IE). Систематизация методов IE приведена в обзоре Л. М. Ермаковой [15]; гибридная природа практических решений по русскоязычным текстам отмечена в работе А. С. Ванюшкина и Л. А. Гращенко [16]. Подходы делятся на три группы — формальные правила, классические статистические модели и нейросетевые трансформеры — и их сочетание лежит в основе каскадных архитектур.

Правила и регулярные выражения надёжно извлекают атрибуты с устойчивой лексической разметкой при околонулевой стоимости, но ограничены низким покрытием на полях со сложным смыслом. *Статистические модели* над TF-IDF и градиентный бустинг (XGBoost [17], LightGBM [18]) работают при достаточной выборке и одноязычном входе (применение к электронной коммерции — Г. И. Афанасьев и соавторы [19]). *Векторные представления* на основе трансформеров [20] и BERT [21], в частности Sentence-BERT [22] и многоязычные дистиллированные варианты [23], дают фиксированные представления предложений; категоризация товарных каталогов рассмотрена А. Г. Колониным [24], систематическое изложение IE — в учебнике Е. И. Большаковой и соавторов [25].

Специализированные системы извлечения атрибутов товаров. В индустриальной литературе выделяются три эталонные системы: TXtract [26] (Karamanolakis et al., ACL 2020, Amazon) — многозадачный кодировщик с условием на таксономию; MAVI [27] (Yang et al., WSDM 2022, Google) — BERT с кросс-вниманием по нескольким полям карточки; OpenTag [28] (Zheng et al., KDD 2018) — BiLSTM-CRF с механизмом внимания. Эти системы дают 85–92 % F1 на специализированных корпусах. Сравнения с каскадными архитектурами, в которых LLM работает запасным слоем, в открытой литературе системно нет; настоящая работа частично закрывает этот пробел.

Поколение 2024 года. Свежие работы идут по двум линиям. L. Yang и соавторы предложили EAVE [29] — лёгкий энкодер со sparse-layer-интеракцией, который даёт сопоставимое качество дешевле на выводе. С. Fang и соавторы предложили LLM-Ensemble [30] — взвешенный

ансамбль коммерческих LLM с итеративной коррекцией; показали, что ни одна модель не выигрывает на всех типах атрибутов. В отличие от обеих линий, настоящая работа не заменяет специализированный экстрактор более компактным трансформером и не наращивает число параллельных вызовов LLM. Предлагается перпендикулярная композиция: большая языковая модель вызывается выборочно — только для тех (товар, атрибут), на которых классические слои не вышли на калиброванный порог уверенности.

1.2.2 Стоимостно-чувствительные каскады больших языковых моделей

С появлением спектра больших языковых моделей разной мощности оформилась подобласть маршрутизации с учётом стоимости (англ. *cost-aware LLM routing*). *FrugalGPT* [9] (L. Chen, M. Zaharia, J. Zou) предложил каскад LLM по возрастанию стоимости с прерыванием на первом уверенном ответе; настоящая работа опирается на идеи последовательного прерывания и калибровки. *AutoMix* [10] (P. Aggarwal, A. Madaan и соавторы) основан на самопроверке ответа малой моделью; в разрабатываемой системе роли валидатора и предсказателя, наоборот, разнесены по разным слоям. *Hybrid LLM* [11] (D. Ding, A. Mallick и соавторы) рассматривает маршрутизацию между моделью на пограничном устройстве и облачной — постановка прямо соответствует сценарию «локальная gpt-oss-120b + коммерческое API как запасной слой». *RouterBench* [12] (Q. J. Hu, J. Bieker и соавторы) показал, что обучаемые маршрутизаторы не выигрывают у простых политик, когда ошибки локализованы по доменам; настоящая работа подтверждает это на задаче обогащения каталогов по заранее объявленному протоколу.

RouteLLM [31] (I. Ong, A. Almahairi и соавторы, ICLR 2025) обучил маршрутизатор поверх пользовательских предпочтений Chatbot Arena и снизил стоимость диалога общего назначения в два раза. Но подход опирается на парные предпочтения и сводится к выбору одной из двух моделей на запрос. В задаче обогащения каталога такого сигнала нет в принципе, а маршрутизация ведётся на уровне пары (товар, атрибут), а не запроса. Это обосновывает переход от обучаемого маршрутизатора к статической политике.

1.2.3 Существующие промышленные PIM-системы и анализ аналогов

Для позиционирования разработки отобраны три коммерческие PIM-системы — Akeneo, Pimcore и Salsify — и построена сравнительная таблица по семи функциональным критериям (таблица 1). Источники — документация вендоров [5; 6; 7].

Таблица 1 — Сравнение существующих PIM-систем и разрабатываемой системы

№	Критерий	Akeneo	Pimcore	Salsify	Новая система
1	Централизованное хранение каталога	да	да	да	не в задаче
2	Распределение по каналам сбыта	да	да	да	не в задаче
3	Автоматическое обогащение атрибутов	частично ^a	частично ^b	частично ^c	да ^d
4	Извлечение признаков из текста произвольной структуры	нет	нет	нет	да ^e
5	Поддержка многоязычного входа	через переводы	через переводы	через переводы	встроенная ^f
6	Открытый исходный код	частично ^g	да	нет	да ^h
7	Стоимостно-чувствительная обработка	нет	нет	нет	да ⁱ

Примечание. ^a Akeneo AI / GenAI (с 2023 г.) — надстройка над сторонней большой языковой моделью; ^b встроенные правила обогащения и сторонние плагины; ^c Salsify AI Suite — надстройка над сторонней большой языковой моделью; ^d каскадная архитектура с многоуровневой фильтрацией по уверенности; ^e слои машинного обучения и большой языковой модели; ^f многоязычные векторные представления (50+ языков); ^g Akeneo Community Edition (с ограничениями функциональности); ^h включая локальное развёртывание большой языковой модели; ⁱ каскадная композиция, доминирующая по Парето над одиночным вызовом большой языковой модели.

Из таблицы 1 видно, что коммерческие PIM-системы покрывают

хранение и распределение уже сформированной информации, а функция автоматического обогащения у всех трёх (Akeneo с 2023 года, Salsify через AI Suite, Pimcore через плагины) функционально сводится к проксированию запросов к одной коммерческой большой языковой модели. Без учёта стоимости массовых вызовов, без поатрибутной маршрутизации, без гарантий локального развёртывания. Ни одно из решений не закрывает весь набор критериев интернет-магазина целиком — отсюда смысл самостоятельной разработки.

1.2.4 Слабый надзор, калибровка и сопутствующая методология

Главная сложность задачи — отсутствие достаточной ручной разметки (слабый надзор, англ. *weak supervision*); инструментарий систематизирован А. Ratner и соавторами в системе Snorkel [32], обзор активного обучения и слабого надзора — В. Settles [33]. Источником слабого эталона выступает Open Food Facts [13]. Устойчивость классических алгоритмов (метод k -ближайших соседей, метод опорных векторов) к шуму разметки измерена В. А. Дюком [34], что обосновывает применимость серебряной разметки.

Для корректной работы каскада выходы классификаторов калибруются: масштабирование Платта [35], изотоническая регрессия [36], анализ ECE — С. Guo и соавторы [37]. Критерии качества классификаторов, включая ROC и выбор порога, систематизированы Ю. С. Шуниной и соавторами [38] и А. А. Ковалевым и соавторами [39]. Оценка точности — кросс-валидация и бутстрэп [40], интервалы пропорций — формула Вильсона [41]. Аппарат байесовских сетей опирается на J. Pearl [42], D. Heckerman et al. [43], А. Л. Тулупьева и соавторов [44], библиотеку pgmpy [45], поиск структуры — Hill Climb + BIC [46]. Прикладные вопросы устойчивости ML-моделей к дрейфу в каталогах — А. А. Артемов [47], масштабируемость на маркетплейсах — С. А. Сергеев [48], краудсорсинг — Р. А. Гилязов и Д. Ю. Турдаков [49], семантические пространства — В. Ф. Хорошевский [50].

1.3 Техническое задание на разрабатываемую систему

В разделе формулируется техническое задание (ТЗ) на разрабатываемую систему. Оно подразделяется на три группы требований: функциональные (что система должна делать), нефункциональные (с какими

характеристиками) и архитектурные (каким способом она организована).

1.3.1 Функциональные требования

Ф-1. Входные данные. Система принимает товар, описанный партнёрскими полями: `product_name` (обязательное), `brands`, `ingredients_text`, `quantity`, `category` (опционально).

Ф-2. Возврат значений целевых атрибутов. Для каждого атрибута возвращается предсказанное значение, оценка уверенности и идентификатор слоя-источника, что обеспечивает отслеживаемость и возможность ручной верификации.

Ф-3. Покрывание категорий. Поддерживается заполнение атрибутов для трёх категорий пищевой продукции — паста, шоколад и шоколадные изделия, сыры. Выбор обоснован достаточным объёмом данных в OFF, доступностью аудит-эталона (согласие трёх LLM + слепая разметка Opus) и репрезентативностью по типам атрибутов (числовые, бинарные, мультиклассовые семантические).

Ф-4. Автоматическое определение категории. Если категория не указана, она определяется автоматически предкасадным слоем 0.

Ф-5. Запасной слой на основе LLM. Когда слои 1–3 не дают уверенного ответа на конкретный атрибут, система обращается к LLM селективно — только по тем атрибутам товара, где предыдущие слои отказались.

Ф-6. Диагностический вывод. Возвращается результат работы валидатора, агрегированные оценки уверенности по слоям и маршрут запроса по каскаду — для отладки, аудита и накопления операционных данных.

1.3.2 Нефункциональные требования

НФ-1. Точность. Целевая сквозная точность на тестовой выборке без пересечения товарных кодов — не менее 85 %; в конфигурации с коммерческой LLM в запасном слое — не менее 90 %.

НФ-2. Стоимость. Стоимость обработки одного товара каскадом не менее чем в 2,5 раза ниже прямого вызова большой языковой модели; фактически достижимое значение фиксируется в 3.3.4.

НФ-3. Производительность. Время отклика на один товар без запасного слоя — не более 500 мс на потребительском ноутбуке без

ускорителя; с запасным слоем — не более 5 с (определяется временем ответа внешнего API).

НФ-4. Многоязычность. Поддерживаются пять рабочих языков европейского рынка пищевой продукции (FR, EN, DE, IT, ES), наиболее представленных в OFF.

НФ-5. Локальное развёртывание. Поддерживается сценарий полностью локального развёртывания через открытую модель gpt-oss-120b в запасном слое — требование вендорной независимости.

1.3.3 Архитектурные требования

А-1. Каскадная архитектура с отдельными слоями. Последовательность слоёв по принципу «передачи остатка»: каждый последующий обрабатывает только атрибуты, не закрытые предыдущими с уверенностью выше калиброванного порога.

А-2. Независимое обновление слоёв. Изменение или переобучение любого отдельного слоя (правил, классификаторов слоя 2, LLM в запасном слое) не должно требовать перезапуска остальных слоёв и API-шлюза.

А-3. Демонстрационный комплекс с веб-интерфейсом. Система сопровождается комплексом из трёх компонентов: API-шлюза на Go, ML-сервиса на Python/FastAPI и одностраничного веб-интерфейса — для верификации работоспособности и наглядного представления результатов контент-менеджеру.

1.3.4 Соотношение технического задания и решаемых задач работы

Сформулированные требования полностью покрываются задачами, поставленными во введении (таблица 2).

Таблица 2 — Соответствие требований технического задания и задач работы

№ задачи	Краткая формулировка задачи	Покрываемые требования ТЗ
1	Разработать архитектуру гибридного каскадного конвейера	Ф-1, Ф-2, Ф-4, Ф-5, А-1

Продолжение таблицы 2

№ задачи	Краткая формулировка задачи	Покрываемые требования ТЗ
2	Реализовать каждый слой каскада как самостоятельный программный компонент	Ф-6, А-2
3	Построить эталонную разметку и проверочную выборку без пересечения товарных кодов между обучением и тестом	Ф-3 (в части обеспечения данных для оценки на трёх категориях)
4	Провести экспериментальную оценку точности, покрытия и стоимости	НФ-1, НФ-2, НФ-3, НФ-4, НФ-5
5	Разработать демонстрационный программный комплекс	А-3

Установленное соответствие подтверждает, что выполнение пяти задач работы влечёт за собой выполнение технического задания в полном объёме.

1.4 Выводы по главе 1

В главе проведён анализ предметной области, систематизировано состояние литературы и обосновано техническое задание. По результатам анализа можно сформулировать следующие выводы.

- 1) Проблема автоматического обогащения остаётся открытой. Промышленные PIM-системы — Akeneo [5], Pimcore [6], Salsify [7] — нацелены на хранение и распределение уже сформированной информации. Появляющиеся модули автоматического обогащения — обёртки над одной коммерческой большой языковой моделью; для обработки больших каталогов с учётом стоимости они не годятся.
- 2) Научные подходы делятся на две группы, и ни одна из них не покрывает задачу полностью. Специализированные системы извлечения атрибутов — TXtract [26], MAVe [27], OpenTag [28] — решают задачу качественно, но требуют большой размеченной выборки и не учитывают экономики обращения к моделям. Каскады больших языковых моделей с учётом стоимости — FrugalGPT,

AutoMix, Hybrid LLM — дают инструменты управления стоимостью (сопоставление есть в бенчмарке RouterBench), но рассматривают композицию из однородных моделей и не интегрируют классическое машинное обучение.

- 3) Разрабатываемая система объединяет оба подхода в гибридный каскад. Каскад совмещает специализированные слои извлечения признаков — правила, машинное обучение на многоязычных векторных представлениях, байесовский валидатор — и запасной слой LLM с учётом стоимости. Шесть функциональных, пять нефункциональных и три архитектурных требования ТЗ образуют обязательство, выполнение которого проверяется в экспериментальной части работы.

2 ТЕОРЕТИЧЕСКОЕ ОБОСНОВАНИЕ РЕШЕНИЯ

В главе формализуется задача обогащения и обосновываются принятые архитектурные решения.

2.1 Логика работы разрабатываемого программного обеспечения

2.1.1 Формальная постановка задачи обогащения

Пусть товарная позиция, поступающая в систему от партнёра, представлена кортежем партнёр-доступных полей

$$x = (x^{\text{name}}, x^{\text{brand}}, x^{\text{ingr}}, x^{\text{qty}}), \quad (1)$$

где компоненты — название, бренд, состав и количество соответственно; пустым может быть любое поле, кроме названия. Каждому товару ставится в соответствие категория $c \in \mathcal{C} = \{c_1, \dots, c_M\} \cup \{\text{OOD}\}$ ($M = 3$: паста, шоколад, сыры; OOD — выход за пределы поддерживаемых доменов), определяемая отдельной моделью

$$c = f_0(x), \quad (2)$$

(Слой 0, см. 2.2). Для каждой категории задана схема $\mathcal{A}_c = \{a_1, \dots, a_{K_c}\}$ с областями $\mathcal{Y}_k$; система строит

$$\hat{y} = (\hat{y}_1, \dots, \hat{y}_{K_c}) \in (\mathcal{Y}_1 \cup \{\text{null}\}) \times \dots \times (\mathcal{Y}_{K_c} \cup \{\text{null}\}), \quad (3)$$

где $\hat{y}_k = \text{null}$ — явный отказ от ответа: повторное обращение к оператору дешевле ошибки на витрине.

2.1.2 Каскадная схема принятия решения

Логика обогащения реализована как каскад из четырёх содержательных слоёв; ему предшествует определение категории. Для каждого атрибута k итоговое предсказание формируется по правилу

$$\hat{y}_k = \begin{cases} f_k^{\text{regex}}(x), & f_k^{\text{regex}}(x) \neq \emptyset; \\ f_k^{\text{ML}}(x), & f_k^{\text{regex}}(x) = \emptyset, P_{\text{ML}}(\hat{y}_k | x) \geq \tau_k, P_B(\hat{y}_k | \mathbf{e}) \geq \theta_k; \\ f_k^{\text{LLM}}(x), & \text{otherwise.} \end{cases} \quad (4)$$

Здесь f_k^{regex} — детерминированный экстрактор регулярных выражений (Слой 1); f_k^{ML} — классификатор машинного обучения (Слой 2) над многоязычным векторным представлением партнёр-доступных полей с калиброванной апостериорной вероятностью P_{ML} и поатрибутным порогом τ_k ; $P_B(\hat{y}_k | \mathbf{e})$ — оценка байесовской сети при свидетельствах $\mathbf{e} = (x^{\text{brand}}, \hat{y}_{j \neq k})$ с порогом θ_k , заданным как пятый перцентиль распределения P_B по верно размеченным обучающим примерам; f_k^{LLM} — запасной слой на большой языковой модели (LLM, large language model), возвращающий значение из $\mathcal{Y}_k$ или null. Предсказание Слоя 2 принимается тогда и только тогда, когда одновременно выполнены

$$[P_{\text{ML}}(\hat{y}_k | x) \geq \tau_k] \wedge [P_B(\hat{y}_k | \mathbf{e}) \geq \theta_k]. \quad (5)$$

Это конъюнктивное условие формализует требование темы об ансамблевой оценке уверенности: не параллельное голосование, а последовательная фильтрация с правом каждого слоя отказаться. По итогам 3.3.10 валидатор включён точно — только на парах «категория — атрибут» с неотрицательным приростом. Схема даёт ступенчатое распределение нагрузки (дешёвый Слой 1 — массовые случаи, дорогой Слой 4 — трудный остаток), отбраковку статистически маловероятных пар «бренд × значение» и архитектурную объяснимость: для каждой ячейки известно, какой слой принял решение.

2.1.3 Поведение системы при выходе категории за пределы поддерживаемых

Слой 0 определяет $c = f_0(x)$ до запуска каскада. Если уверенность ниже порога OOD-детектора, товару присваивается метка OOD и система возвращает «категория не поддерживается»: $f_0(x) \in \mathcal{C} \setminus \{\text{OOD}\} \Rightarrow$ запуск per-category каскада со схемой $\mathcal{A}_{f_0(x)}$; $f_0(x) = \text{OOD} \Rightarrow \hat{y} = \emptyset$. Явный отказ

выбран по соображениям эксплуатационной безопасности: если товар ошибочно отнести к чужой категории, всем атрибутам достанется неверная схема.

2.1.4 Метрики качества и стоимости

Каскад поддерживает явный отказ от ответа; используются две согласованные метрики качества и одна сводная по стоимости.

$$\text{acc}_k^{\text{cov}} = \frac{|\{i : \hat{y}_k^{(i)} = y_k^{(i)} \wedge \hat{y}_k^{(i)} \neq \text{null}\}|}{|\{i : \hat{y}_k^{(i)} \neq \text{null}\}|}. \quad (6)$$

Точность на покрытой части $\text{acc}_k^{\text{cov}}$ — доля верных предсказаний среди ячеек с непустым ответом.

$$\text{cov}_k = \frac{|\{i : \hat{y}_k^{(i)} \neq \text{null}\}|}{N}, \quad (7)$$

Покрытие cov_k — доля ячеек, на которых система решилась дать ответ (где N — мощность проверочной выборки).

$$\text{acc}_k^{\text{e2e}} = \text{acc}_k^{\text{cov}} \cdot \text{cov}_k. \quad (8)$$

Сквозная точность $\text{acc}_k^{\text{e2e}}$ — основная метрика и заголовочное число (3.3.4); ячейки с $\hat{y}_k^{(i)} = \text{null}$ засчитываются как неверные, что не даёт системе зависеть качество за счёт молчания.

$$\text{cost}_{\text{LLM}} = \frac{1000}{N \cdot K_c} \sum_{i=1}^N \sum_{k=1}^{K_c} \mathbb{I}[\hat{y}_k^{(i)} \text{ получен через } f_k^{\text{LLM}}]. \quad (9)$$

Стоимость cost_{LLM} — ожидаемая доля вызовов запасного слоя на 1000 ячеек; метрика инвариантна к выбору модели Слая 4 и характеризует структуру каскада. Совместный анализ $(\text{acc}^{\text{e2e}}, \text{cost}_{\text{LLM}})$ даёт матрицу «точность — стоимость», на которой строится заголовочный результат (3.3.4).

2.2 Архитектура и стек технологий

В разделе описывается архитектурное решение, реализующее формальную постановку 2.1, и обосновывается выбор каждой компоненты

стека.

2.2.1 Архитектура системы

Функциональная модель системы в виде диаграммы потоков данных приведена на рисунке 3. Внешние акторы (партнёр-продавец и витрина каталога интернет-магазина) обмениваются данными со шлюзом API и ML-сервисом, который содержит каскад из пяти слоёв и обращается к хранилищам моделей XGBoost, байесовских сетей и внешнему API большой языковой модели.




Рисунок 3 — Функциональная модель системы обогащения товарных данных

Система реализована как пятислойный конвейер (Слой 0 + четыре содержательных слоя). Состав и роль каждого слоя:

- **Слой 0 — классификатор категории.** LightGBM поверх TF-IDF-представления (term frequency $\times$ inverse document frequency, частотно-инверсный показатель) названия и бренда с порогом отнесения к выходу за пределы обучающего распределения; определяет $c \in C$ либо относит товар к выходу за пределы поддерживаемых категорий.
- **Слой 1 — экстрактор регулярных выражений.** Извлекает значения, явно присутствующие в тексте (форма пасты, % какао, цельнозерновой, шаблоны количества). Применяется только к шаблонам с высокой точностью совпадения.

- **Слой 2 — классификатор машинного обучения.** Основной слой: партнёр-доступные поля конкатенируются и кодируются SBERT в 768-мерный вектор (модель `paraphrase-multilingual-mpnet-base-v2`, архитектура MPNet); поатрибутный XGBoost с порогом τ_k на отложенной выборке. Изотоническая пост-калибровка исследована в двух режимах (3.3.11): серебряная деградирует на эталоне из-за дрейфа; перекрёстная на эталонной выборке даёт улучшение ожидаемой ошибки калибровки с 0,070 до 0,043 (в производственную конфигурацию не включена).
- **Слой 3 — байесовский валидатор.** Сеть (структура — Hill Climb + BIC) вычисляет $P_B(\hat{y}_k \mid \mathbf{e})$; ниже порога θ_k — флаг и передача дальше. Роль пересмотрена (3.3.10): не классификатор, а валидатор плотностей.
- **Слой 4 — запасной слой на большой языковой модели.** Несколько равнозначных моделей семейств GPT [51] и Claude [52]: Sonnet 4.5, GPT-4o, Gemini 2.5 Flash, открытая `gpt-oss-120b`, малая `Llama-3.2-3b` (сопоставление — 3.3.4). Структурированный запрос со схемой и партнёр-доступными полями; возвращает значение или честный отказ.

Слои упорядочены по росту удельной стоимости решения: регулярные выражения → машинное обучение на уже вычисленном векторном представлении → байесовский вывод → запасной слой.

Структура обученной байесовской сети для категории `chocolate` приведена на рисунке 4. Узлы графа — целевые атрибуты и бренд; направленные рёбра показывают условные зависимости, найденные алгоритмом Hill Climb на серебряной выборке. Бренд — корневой узел; через производный признак `brand_has_organic_marker` он влияет на `chocolate_type` и `is_organic`. Тип шоколада задаёт процент какао и подтип `chocolate_extra`, от которого расходятся рёбра к `contains_nuts`, `nutri_score_grade`, `protein_class` и повторно к `is_organic` — это согласуется с интуицией о связи органичности, бренда и подтипа. Эмпирическая роль сети как точечного валидатора и количественные характеристики приведены в 3.3.10.




Рисунок 4 — Структура байесовской сети категории *chocolate* (направленный ациклический граф; алгоритм Hill Climb с критерием BIC, библиотека pgmpy 1.1.2)

2.2.2 Обоснование выбора компонентов стека

Каскад вместо сквозного решения. Сквозное применение одной большой языковой модели даёт 56–84 % точности (3.3.4), но стоимость линейно растёт с числом ячеек; каскад при равной или большей точности экономит порядка двух порядков за счёт ступенчатого распределения нагрузки. Сквозной all-ML не подходит — у части атрибутов значения вычисляются из данных за пределами товарного описания, к тому же есть сценарий холодного старта новых категорий.

SBERT *paraphrase-multilingual-mpnet-base-v2* [23] выбран за бесплатную многоязычность (50+ языков в едином пространстве без дообучения), умеренную 768-мерную размерность и готовность к работе без доменной адаптации. Архитектура MPNet объединяет преимущества маскированного и перестановочного языкового моделирования и устойчиво обгоняет дистиллированные MiniLM-варианты на задачах семантической близости.

XGBoost [17] с регуляризацией (*subsample=0.8*, *colsample=0.8*, ранняя остановка, *gamma=0.1*) выбран как Слой 2 за устойчивость на плотных

векторных признаках при ограниченной разметке ($n \approx 1250$ на категорию), калибруемость вероятностей (изотоническая регрессия [36]) и миллисекундный вывод на CPU. Поэтапная оптимизация по остаткам и явные L1/L2/ γ -штрафы дают более тонкие нелинейные границы и более прямой контроль переобучения, чем у Random Forest [53; 54]; на независимых табличных стендах [55; 56] градиентный бустинг устойчиво обходит Random Forest и нейросетевые архитектуры в характерной для Слой 2 размерности. Эмпирическое сравнение (§ 3.3.14) подтверждает выбор: при сопоставимой точности XGBoost даёт наименьшую ECE (0,026 против 0,031 у MLP и 0,035 у LogReg).

Байесовская сеть на pgmpy [45] 1.1.2. По сравнению с MRF и автоэнкодерами дискретная байесовская сеть допускает построение структуры графа (Hill Climb + BIC [46]) с интерпретируемым ориентированным графом, дешёвый вывод через Variable Elimination и явное выражение условных зависимостей; pgmpy поддерживает и построение структуры, и оценку параметров через BayesianEstimator.

Шлюз API на Go при ML-сервисе на Python. Демо-система — два сервиса: шлюз на Go (:8080) и ML-сервис на Python/FastAPI (:8001). Go подходит для сетевого ввода-вывода (малое потребление памяти, быстрый запуск, конкурентный I/O); Python-экосистема (PyTorch, sentence-transformers, XGBoost, pgmpy) безальтернативна для ML-инференса. Разделение соответствует типовой производственной архитектуре и позволяет масштабировать компоненты независимо.

Открытая LLM как запасной слой. Конфигурация многомодельна через OpenRouter (Claude Sonnet 4.5, GPT-4o, Gemini 2.5 Flash, открытая gpt-oss-120b, малая llama-3.2-3b). Открытую gpt-oss-120b можно запустить в инфраструктуре заказчика без передачи данных вовне; коммерческие LLM могут заменяться одна на другую, что снижает зависимость от провайдера; каскад компенсирует слабость малой модели — при самостоятельном применении gpt-oss-120b проигрывает Sonnet 14–15 п. п., но в составе каскада превосходит её безусловное использование на 21,3 п. п. (3.3.4).

2.2.3 Стек технологий — сводная таблица

Сводное представление принятых решений приведено в таблице 3.

Таблица 3 — Сводная таблица стека технологий с обоснованием выбора

Компонент	Технология	Ключевое обоснование
Шлюз API	Go, стандартная библиотека net/http	Малое потребление ресурсов, быстрый запуск, отсутствие внешних зависимостей
ML-сервис	Python 3.14, FastAPI, Uvicorn	Доступ к ML-экосистеме, автоматическая валидация через Pydantic, поддержка OpenAPI
Векторное представление	SBERT paraphrase-multilingual-mpnet-base-v2	Многоязычность (50+ языков), 768-мерный вектор (архитектура MPNet), отсутствие необходимости в дообучении
Классификатор слоя 2	XGBoost с регуляризацией	Устойчивость на плотных признаках, калибруемые вероятности, дешёвый вывод
Байесовская сеть	pgmpy 1.1.2, Discrete BayesianNetwork	Структурное обучение Hill Climb + BIC, дешёвый вывод (Variable Elimination), интерпретируемый граф
Классификатор категории слоя 0	LightGBM (поверх TF-IDF-представления) + порог отнесения к выходу за пределы обучающего распределения	Многоклассовая классификация с вероятностями + явный отказ при низкой уверенности
Запасной слой	OpenRouter API: Claude Sonnet 4.5, GPT-4o, Gemini 2.5 Flash, gpt-oss-120b, llama-3.2-3b	Единый интерфейс, возможность локального развёртывания, независимость от поставщика
Фронтенд	HTML/CSS/JavaScript без сборочной системы	Минимальные требования к окружению, прозрачность демонстрации

2.3 Сценарий работы программного обеспечения

2.3.1 Сквозной пример прохождения запроса

Рассмотрим прохождение на примере «Spaghetti #5 Barilla» (повторяется в 3.1.2). Партнёр шлёт POST /api/enrich с полями category=null,

product_name=«Spaghetti #5 Barilla», brands=«Barilla», ingredients_text=«Durum wheat semolina, water», quantity=«500g». Поле category пустое — категоризация выполняется системой.

Шаг 1. Определение категории (Слой 0). Возвращает $c = \text{pasta}$ с уверенностью 0,97; детектор выхода за пределы поддерживаемых категорий не сработал, выбрана схема $\mathcal{A}_{\text{pasta}}$ (8 атрибутов).

Шаг 2. Поочерёдная обработка атрибутов. Каскад обходит атрибуты по схеме. Для pasta_shape срабатывает шаблон Слая 1 на «spaghetti» с уверенностью 1,0 — следующие слои не вызываются. Для grain_type Слой 1 не даёт совпадения; Слой 2 выдаёт "wheat" с $P_{\text{ML}} = 0,99 \geq \tau = 0,5$, валидатор подтверждает ($P_B = 0,85 \geq \theta = 0,04$) — отметка ml. Для nutri_score_grade — класс "A", $P_{\text{ML}} = 0,83$, валидатор подтверждает. Для is_filled $P_{\text{ML}} = 0,45 < \tau$ — ячейка идёт в Слой 4.

Шаг 3. Формирование ответа. ML-сервис собирает поатрибутный ответ с агрегированными счётчиками и возвращает JSON шлюзу (формат — 3.1.2). В этом сценарии 7 из 8 атрибутов закрыты дешёвыми слоями (1 regex + 6 ML), 1 — Слосом 4. Именно такое распределение и даёт каскаду выигрыш в матрице «точность — стоимость» (3.3.4).

2.4 Выводы по главе 2

- 1) Задача обогащения формализована как поатрибутное предсказание $\hat{y}_k$ с явным отказом ($\hat{y}_k = \text{null}$); каскадная логика — последовательная фильтрация по уверенности с конъюнктивным условием $P_{\text{ML}} \geq \tau_k \wedge P_B \geq \theta_k$ для принятия предсказания Слая 2 как ансамблевая оценка уверенности.
- 2) Архитектурный выбор каждой компоненты (каскад вместо сквозного решения; SBERT, XGBoost, pgmpy; Go-шлюз + Python-ML; открытая gpt-oss-120b) обоснован эксплуатационно и методологически.
- 3) Сквозной сценарий подтверждает: большинство атрибутов закрывается дешёвыми слоями, обращение к большой языковой модели точно — отсюда и доминирование каскада по Парето над одиночным вызовом большой языковой модели (подтверждается в 3.3.4).

3 ОПИСАНИЕ ПРОГРАММНО-ТЕХНОЛОГИЧЕСКОЙ РЕАЛИЗАЦИИ

Глава описывает программную реализацию системы: 3.1 — каскад и демонстрационный комплекс; 3.2 — данные и предобработку; 3.3 — численные результаты и сценарии проверки.

3.1 Описание программного обеспечения

3.1.1 Программная реализация слоёв каскада

Архитектурная роль слоёв описана в 2.2, поток управления и формула вывода $\hat{y}_k$ — в 2.1; ниже приведены только детали реализации. Алгоритм обработки одного запроса в нотации ГОСТ 19.701-90 показан на рисунке 5; на каждом слое принимается одно из двух решений (закрыть атрибут или передать дальше), слои упорядочены по росту стоимости. Вход — партнёр-доступные поля; слой 2 обучается только на них, что исключает утечку через теги Open Food Facts.




Рисунок 5 — Блок-схема алгоритма обработки запроса
(нотация ГОСТ 19.701-90)

Слой 0 — классификатор категории. LightGBM поверх TF-IDF-представления (term frequency $\times$ inverse document frequency, частотно-инверсный показатель), n-граммы 1–2, с порогом отнесения к выходу за пределы обучающего распределения (out-of-distribution).

Артефакты: `models/category_router_v3_{lgbm,vec}.pkl`. При ошибке в категории атрибуты товара получают неверную схему и засчитываются как неверные предсказания.

Слой 1 — экстрактор регулярных выражений. Реализация — `src/pipeline/regex/extractor.py`. Разбирает `product_name` и `quantity`; распознаёт формы пасты, процент какао, маркер цельнозернового состава, источник молока в сырах (*chèvre* / *brebis* / *bufala*), маркеры PDO/AOP/DOP, маркеры ультра-обработанного сыра. Покрытие неравно по категориям: около 18 % на пасте, 23 % на шоколаде и 3 % на сырах; точность на закрытых ячейках — 87,0–100 % (см. 3.3.15).

Слой 2 — классификатор машинного обучения. Основной рабочий слой (73,2 % всех решений системы). Вход — конкатенация `product_name` + `brands` + `ingredients_text` + `quantity`. SBERT-кодировщик `paraphrase-multilingual-mpnet-base-v2` (768d, 50+ языков) конкатенируется с TF-IDF (n-граммы 1–2, верхние 5000 признаков), сжатым TruncatedSVD до 128 компонент; итого 896-мерное гибридное пространство. Для каждой пары (категория, атрибут) обучен XGBoost-классификатор `{cat}_v4_mpnet_tfidf_noleak_{attr}_xgb.pkl` с регуляризацией (`subsample=0.8`, `colsample=0.8`, ранняя остановка), Platt-калибровкой и порогом уверенности, подобранным на валидационном срезе по произведению макро-F1 на долю покрытия. Точность на покрытом срезе — 94,9–98,6 % (см. 3.3.10).

Слой 3 — байесовский валидатор. Сеть в `models/{cat}_stratified_bayesian.pkl`; структура — Hill Climb + BIC. По итогам 3.3.10 используется как валидатор плотностей: для предсказания слоя 2 вычисляется $P(\text{value} \mid \text{evidence})$, при попадании в нижний 5-перцентиль ячейка помечается флагом.

Слой 4 — запасной слой на большой языковой модели. Реализация — `src/pipeline/llm_fallback/enrich.py`. В 3.3.4 оцениваются пять моделей: Claude Sonnet 4.5, GPT-4o, Gemini 2.5 Flash, открытая `gpt-oss-120b` и открытая малая `Llama-3.2-3b`¹. Промпт содержит схему атрибутов категории, требуемый JSON-формат и партнёр-доступные поля.

¹Состав моделей зафиксирован на момент проведения экспериментов (первое полугодие 2026 года). Архитектура каскада не привязана к конкретному поставщику, и при появлении новых поколений моделей Слой 4 заменяется без переобучения остальных слоёв; переоценка на актуальных моделях вынесена в перспективы развития темы (Заключение).

3.1.2 Демонстрационный комплекс и контракт API

Демонстрация имитирует встраивание в бизнес-процесс интернет-магазина и состоит из трёх компонентов: Go-шлюза API (demo/gateway/, ≈ 200 строк на стандартной net/http — валидация JSON, передача запросов ML-сервису, межсайтовый доступ, выдача статических файлов фронтенда), Python/FastAPI ML-сервиса (demo/ml_service/ — при старте подгружает SBERT-кодировщик, 20 XGBoost-классификаторов, байесовские сети и слой 0; после прогрева $\approx 15\text{--}20$ с слои 0–3 отвечают за десятки миллисекунд), одностраничного HTML/JS-фронтенда. Эндпоинты: POST /api/enrich, GET /api/categories, GET /health, POST /api/explain.

Запрос POST /api/enrich принимает JSON с полями category (опционально), product_name, brands, ingredients_text, quantity; ответ содержит category, агрегированные счётчики и объект predictions с указанием слоя-источника (regex / ml / llm_fallback), уверенности и результата валидации для каждого атрибута. Пример пары запрос–ответ:

```
1 // запрос
2 { "category": "pasta",
3   "product_name": "Spaghetti #5 Barilla",
4   "brands": "Barilla",
5   "ingredients_text": "Durum wheat semolina",
6   "quantity": "500g" }
7 // ответ
8 { "category": "pasta",
9   "n_attrs_total": 8,
10  "n_covered": 7,
11  "n_llm_fallback": 1,
12  "predictions": {
13    "pasta_shape": { "value": "spaghetti", "layer": "regex",
14                     "confidence": 1.00 },
15    "grain_type": { "value": "wheat", "layer": "ml",
16                   "confidence": 0.99 },
17    "is_filled": { "value": null, "layer": "llm_fallback",
18                  "confidence": 0.0 } } }
```

Явная отметка слоя-источника компенсирует ограниченную интерпретируемость слоёв 2/3 на уровне отдельного товара. Запуск — одной командой `bash reproduce.sh demo`; готовность проверяется через `GET /health`. Стек технологий обоснован в 2.2 (таблица 3).

3.2 Данные

3.2.1 Источник данных, фильтрация и стратифицированная выборка

Основой выбран открытый каталог Open Food Facts (далее — OFF) [13] — краудсорсинговая база $\approx 4,5$ млн позиций под лицензией ODbL v1.0, допускающей коммерческое использование при условии share-alike. Производные выборки и эталоны размещены в репозитории под совместимой лицензией с указанием авторства. Дамп (526 МБ) получен командой `python -m src.data.download --source off`. Выбор обусловлен открытостью лицензии (воспроизводимость), мультиязычностью (50+ языков) и наличием структурированных нутриентных показателей и регуляторных тегов, на которых построен эталон (см. §3.2.2). Область охвата — три категории (паста, шоколад, сыры), отобранные по критериям §1.3.

Поля OFF разделены на партнёр-доступные (`product_name`, `brands`, `quantity`, `ingredients_text`, `code`) и целевые выходные (`categories_tags`, `labels_tags`, `*_100g`, `ingredients_analysis_tags`); целевые поля не передаются на вход обучаемых компонентов под угрозой утечки. Фильтрация по категории (`src/data/filter.py`) использует списки включения/исключения `categories_tags` (для паста включение — `en:pastas`, исключение — `en:potato-products`, `en:noodles`). После фильтрации применяется стратифицированная по языку выборка (`langdetect`, страты FR/EN/DE/IT/ES) объёмом ≈ 250 товаров на страту, итого ≈ 1250 на категорию (таблица 4).

Таблица 4 — Состав выборки после стратификации

Категория	Объём после фильтрации	Объём выборки	Атрибутов
Паста (макаронные изделия)	15 691	1 250	8

Продолжение таблицы 4

Категория	Объём после фильтрации	Объём выборки	Атрибутов
Шоколад	13 469	1 250	7
Сыры	21 208	1 250	9

Примечание. Источник: datasets/processed/.

Целевые атрибуты определены в `src/pipeline/schemas/{cat}.py`. По результатам анализа ошибок (3.3.25) принят принцип независимости атрибутов: структурная характеристика «наличие начинки» выделена в отдельный бинарный атрибут `is_filled`, не зависящий от типа какао-массы и состава включений. Итоговая схема — 20 пар (категория, атрибут): шоколад — 6 (`chocolate_type`, `is_filled`, `chocolate_extra`, `contains_nuts`, `is_organic`, `flavor_profile`), паста — 8 (`grain_type`, `pasta_shape`, `is_filled`, `is_gluten_free`, `is_organic`, `is_vegan`, `cuisine_origin`, `protein_class`), сыры — 7 (`milk_source`, `texture`, `country_of_origin`, `aging`, `is_pdo`, `is_organic`, `is_ultra_processed`).

3.2.2 Эталонная разметка: иерархическая схема трёх ярусов

Эталон построен как процедура из трёх ярусов с качественно разным классом свидетельств на каждом ярусе. **Ярус 0 (нутриент-производные)** — детерминированное багетирование числовых полей: `pasta/protein_class` из `proteins_100g` по регламенту ЕК 1924/2006, точность 100 % при достоверных нутриентах. **Ярус 1 (тег-производные)** — эталон из регуляторных тегов: `is_organic` из `en:organic`, `is_gluten_free` из `en:gluten-free`, `is_pdo` из `en:protected-designation-of-origin` (правовая защита в ЕС, регламенты 834/2007 и 1151/2012). **Ярус 2 (семантически-текстовые)** — признаки без детерминированного правила (`pasta_shape`, `chocolate_type`, `milk_source`, `texture` и т. д.): эталон — согласие трёх независимых LLM (Claude Sonnet 4.5, GPT-4o, Gemini 2.5 Flash) на полной выборке 1250×3 категории при правиле «не менее двух из трёх» (согласованность 97,7 %); несогласованные позиции переразмечены слепо Claude Opus 4 на 688 ячейках (ручной эталон) — это нижняя консервативная оценка точности.

3.2.3 Разбиение без пересечения товарных кодов

Случайное разбиение не подходит: одна и та же товарная позиция в обучении и тесте даёт прямую утечку. Применяемое разбиение — **без пересечения товарных кодов** (по идентификатору товара `code`; реализация в `scripts/build_noleak_artifacts.py`): из расширенной серебряной разметки удаляются все коды, попавшие в любой из эталонных источников. Основной эталон — эталон согласия трёх больших языковых моделей объёмом 16 360 ячеек в области применимости каскада по 20 атрибутам; консервативная нижняя оценка — ручная эталонная разметка моделью Claude Opus 4 объёмом 566 ячеек в области применимости каскада. Тестовая выборка содержит 186 / 301 / 297 уникальных товарных кодов в паста / шоколад / сыры.

Пересечение брендов между обучением и тестом. 82,5 %, 84,9 % и 82,7 % брендов в тестовой выборке паста / шоколад / сыры встречаются и в обучающем пуле. Полноценное разбиение без пересечения брендов не заявляется: концентрация брендов в Open Food Facts (Lindt, Barilla, Président встречаются в десятках позиций каждый) делает построение эталона той же мощности без пересечения брендов невозможным без переразметки. Подмножество без пересечения брендов доступно как точечная проверка устойчивости (см. 3.3.6): 17 / 19 / 28 кодов на пасте / шоколад / сыры, чьи бренды отсутствуют в обучающем пуле.

3.2.4 Дополнительные источники сигналов

Производственная конфигурация слоя 2 опирается строго на партнёр-доступные текстовые поля; режим вывода совпадает с режимом обучения. Дополнительные источники (фотографии этикеток через OCR EasyOCR и CLIP-эмбединги ViT-B/32 [57]; внешний справоник USDA Branded Foods [58]) проверены экспериментально, но в производственную конфигурацию не включены: мультимодальный сигнал не дал прироста выше шума и потребовал бы доступа к OFF image dump в режиме вывода, USDA используется только для сверки эталона яруса 0. Правило «вход = партнёр-доступные поля» соблюдено во всех оценках 3.3.

3.3 Доказательство работоспособности и применимости

3.3.1 Условия проверки и метрики

Эксперименты проведены на двух согласованных эталонных срезах. Основной — эталон согласия больших языковых моделей объёмом 16 360 ячеек в области применимости каскада (17 062 проверенных) по 20 атрибутам; служит источником главного показателя. Консервативная нижняя оценка — ручной эталон Claude Opus 4 объёмом 566 ячеек в области применимости каскада (688 проверенных) по тем же 20 атрибутам. Знаменатель в области применимости каскада — ячейки, на которых каскад вернул конкретный класс (правило высокого приоритета Слая 1, ML Слая 2 или правило низкого приоритета Слая 3); 702 / 122 ячейки запасного слоя LLM не входят в только-каскадного знаменатель, так как в производственном режиме на них каскад отказывается и эскалирует в LLM. Использованы модели с суффиксом `_mpnet_tfidf_noleak` (MPNet + TF-IDF + XGBoost, переобучение без утечки), разбиение train/val/test без пересечения товарных кодов в пропорции 60/20/20. Согласованность трёх LLM-разметчиков (Claude Sonnet 4.5, GPT-4o, Gemini 2.5 Flash) — 97,7 % при правиле «не менее двух из трёх совпадают», спорные позиции переразмечены Claude Opus 4 слепо; согласованность эталон согласия больших языковых моделей и ручной эталон на пересечении — 92 %, κ Коэна $> 0,80$.

Метрики ($\text{acc}_k^{\text{cov}}$, cov_k , $\text{acc}_k^{\text{e2e}}$, стоимость) определены в 2.1. Доверительные интервалы строятся кластерным бутстрэпом по брендам (1000 итераций, перцентили 2,5 / 97,5 %); такой интервал учитывает внутрибрендовую корреляцию и на ряде атрибутов на 15–30 % шире наивного интервала Вильсона. Для опорной сквозной оценки дополнительно рассчитан кластерный бутстрэп по товарным кодам ($B = 1000$, 2 812 уникальных кодов): интервал [92,3; 93,6] % против Вильсона [92,6; 93,4] % при оценке 93,0 % — расхождение умеренное, опорное значение 93,0 % устойчиво.

3.3.2 Стратификация точности по типу эталонного сигнала

Эталон разделён на три яруса по природе сигнала: ярус 0 (нутриент-производный, детерминированное бакетирование) — 1 атрибут (`pasta/protein_class`, $n=24$), точность 92,3 %; ярус 1 (тег-производный,

регуляторные теги OFF) — 6 атрибутов на 1054 ячейках, точность 96,8 % [95,6; 97,8]; ярус 2 (текстово-производный, согласие трёх больших языковых моделей с проверкой Claude Opus 4) — 13 атрибутов на 2179 ячейках, точность 93,6 % [92,5; 94,6]. Иллюстрация на рисунке 6. Если бы точность завышалась за счёт корреляции признаков модели с источником эталона, наибольшие значения показывал бы самый уязвимый ярус 2. На практике картина обратная (ярус 1 > ярус 2 > ярус 0), и это опровергает гипотезу о завышении метрик за счёт связи признаков с эталоном.




Рисунок 6 — Точность каскада в разрезе ярусов эталонной разметки

3.3.3 Воспроизводимость

Численные результаты §3.3 пересоздаются из артефактов скриптом `reproduce.sh` ($\approx$ час на ноутбуке) перезапуск ноутбуков оценки и сравнения методов. Артефакты, требующие выполнения на удалённой машине (исходные прогоны разметчиков на больших языковых моделях и переобучение слоя 2 без утечки), обновляются отдельно, их пересборка вынесена в перспективы развития; качественные выводы §3.3 от этого не

зависят. Числа 3.3.4 получены апостериорным анализом после устранения утечки бренда; единственная заранее объявленная гипотеза — H1 для обучаемого маршрутизатора (см. 3.3.9).

3.3.4 Главный результат: точность и стоимость производственной конфигурации

Каскад сопоставлен с пятью одиночными вызовами LLM на едином тестовом срезе без пересечения товарных кодов: 16 360 в области применимости каскада ячеек эталон согласия больших языковых моделей и 566 в области применимости каскада ячеек ручной эталон по 20 атрибутам (для `pasta/protein_class` срез сокращён до 24 ячеек). Заголовочные метрики получены на гибридном 896-мерном представлении (MPNet 768d $\oplus$ TF-IDF SVD 128d); в роли Слоя 4 и опорной «одна LLM на всё» — пять моделей: Claude Sonnet 4.5, GPT-4o, Gemini 2.5 Flash (закрытые), gpt-oss-120b и Llama-3.2-3b (открытые). Слои 1–3 закрывают 95,9 % ячеек без обращения к LLM; оставшиеся 4,1 % — запасной слой. Стоимость нормирована к «все ячейки — Claude Sonnet 4.5», соотношение вход/выход $\approx 500 / 200$ токенов. Сводка по конфигурациям с их точностью и относительной стоимостью приведена в таблице 5.

Разграничение понятий. *Покрытие каскада* = 1 — доля обращений к запасному слою = 95,9 % (Слои 1–3 выдали уверенный ответ); *покрытие производственной цепочки* (сквозное покрытие) = 97,3 % (с учётом ошибок маршрутизатора Слоя 0 и удачных ответов Слоя 4 при том же знаменателе); *архитектурное снижение стоимости* = 95,9 % ($\approx 24\times$) — это то же число, то и покрытие каскада, по построению (1 — доля обращений к запасному слою). Связь между метриками: $\text{сквозное покрытие} = (1 - p_{\text{ош. марш.}}) \times (\text{покрытие каскада} + p_{\text{усп. LLM}} \times \text{доля обращений к запасному слою})$, где $p_{\text{ош. марш.}}$ — доля ошибок маршрутизатора Слоя 0, $p_{\text{усп. LLM}}$ — доля успешных ответов запасного слоя на отказных ячейках.

Таблица 5 — Сравнение каскадных конфигураций и одиночных вызовов большой языковой модели по сквозной точности и относительной стоимости (эталон согласия больших языковых моделей, $n = 16\,360$, без пересечения товарных кодов; стоимость нормирована к стратегии «все ячейки обрабатываются Claude Sonnet 4.5»)

Стратегия	Точность, %	Стоимость к опорной	Снижение стоимости
Прямой Claude Sonnet 4.5 (опорная)	83,8	1,000	1×
Прямой GPT-4o	84,1	0,727	1,4×
Прямой Gemini 2.5 Flash	82,9	0,042	24×
Прямой gpt-oss-120b (открытая модель)	69,3	0,030	33×
Прямой llama-3.2-3b (открытая малая модель)	56,2	0,009	110×
Каскад + Claude Sonnet 4.5 (Слой 4)	93,0	0,041	24×
Каскад + GPT-4o	93,1	0,030	33×
Каскад + Gemini 2.5 Flash	93,0	0,0017	580×
Каскад + gpt-oss-120b	90,6	0,0012	810×
Каскад + llama-3.2-3b	90,1	0,00037	2700×
Только каскад (без запасного слоя; верхняя оценка)	95,5	0,000	—

Источники тарифов: Claude Sonnet 4.5 — 3 / 15 долларов за миллион токенов на вход / выход (нормализованная единица), GPT-4o — 2,5 / 10, Gemini 2.5 Flash — 0,075 / 0,30, gpt-oss-120b через OpenRouter — около 0,10 долларов за миллион токенов на запрос смешанной структуры, llama-3.2-3b через OpenRouter — около 0,03 долларов за миллион.




Рисунок 7 — Матрица «точность — стоимость» каскадных конфигураций и одиночных вызовов больших языковых моделей

Из матрицы (рисунок 7) следует двухчастный главный результат. **(а) Независимость от поставщика модели.** Каскад + Gemini 2.5 Flash даёт сквозная 93,0 % при стоимости в 580 раз ниже прямой Claude Sonnet 4.5 (83,8 %) — строгое доминирование по Парето; верхняя оценка только-каскадная — 95,5 %. Результат сохраняется и для каскад + Claude Sonnet 4.5 (93,0 %), и для каскад + GPT-4o (93,1 %). **(б) Локальное развёртывание с открытой моделью.** Каскад + gpt-oss-120b даёт 90,6 % — на +21,3 п. п. выше одиночного вызова (69,3 %) при ≈ 24 -кратном сокращении доли LLM; Слой 2 компенсирует слабость малой модели на семантических атрибутах.

Консервативная оценка по ручной эталон (n = 566 в области применимости каскада). На независимом эталоне Claude Opus 4 каскад + Gemini 2.5 Flash даёт сквозная 86,7 % при только-каскадная 91,3 %; это соответствует операционному циркулярному сдвигу 4,2 п. п. (каскад) / 6,3 п. п. (E2E)². Поатрибутное распределение сдвига приведено в табл. 6 (16

²Воспроизводится в notebooks/03_evaluate.ipynb; источник — ключ HUMAN.

атрибутов с обеими оценками); точки концентрации (cheeses/texture +0,249, cheeses/country_of_origin +0,335, pasta/grain_type +0,360) приходятся на сложные по смыслу атрибуты при среднем n_H 7–47, отрицательные значения (cheeses/milk_source –0,224, pasta/is_filled –0,080) объясняются шумом выборки при малом n_H .

Таблица 6 — Поатрибутное сравнение макро-F1 на эталоне согласия и ручной разметке

Атрибут	n_C	$F1_C$	n_H	$F1_H$	$\Delta F1$
паста, тип зерна	1081	0,831	9	0,471	+0,360
сыры, страна происхождения	310	0,906	35	0,571	+0,335
сыры, текстура	335	0,848	47	0,599	+0,249
сыры, вид молока	354	0,776	46	1,000	–0,224
шоколад, органический	1156	0,987	46	0,832	+0,155
сыры, защищ. наименование	325	0,993	42	0,862	+0,131
паста, форма	645	0,909	7	0,778	+0,131
шоколад, тип	984	0,971	43	0,846	+0,125
сыры, ультра-обработанные	344	0,859	45	0,955	–0,096
паста, с начинкой	1225	0,786	10	0,867	–0,080
шоколад, доп. ингредиенты	961	0,857	43	0,906	–0,049
паста, веганская	1156	0,962	8	1,000	–0,038
паста, органическая	1179	0,969	9	1,000	–0,031
паста, без глютена	1197	0,978	8	1,000	–0,022
сыры, органические	357	0,982	47	1,000	–0,018
шоколад, с орехами	1126	0,945	49	0,939	+0,006

Примечание. Δ — циркулярный сдвиг макро-F1 (ручной эталон минус эталон согласия); отрицательные значения объясняются шумом выборки при малом n_H . C — эталон согласия, H — ручной эталон.

3.3.5 Декомпозиция по категориям

Покрывание каскада, точность только-каскадной и гибридной конфигураций и разность Δ — вклад запасного слоя — для модели Gemini 2.5 Flash в табл. 7. Режим оценки — идеальная маршрутизация категории.

Таблица 7 — Покрытие и точность каскадной и гибридной конфигураций по категориям (модель Gemini 2.5 Flash, идеальная маршрутизация Слоя 0)

Категория	Покрытие, %	Только каскад, %	Каскад + LLM, %	Δ , п. п.
паста	89,1	94,7	90,5	+1,4
шоколад	98,0	94,4	91,8	+0,8
сыры	93,1	95,1	90,9	+1,7

Взвешенное по числу тестовых ячеек среднее по строке «каскад + Gemini 2.5 Flash» в режиме сквозной точности составляет 93,0 %. Производственное значение с учётом ошибок слоя 0 (97,2 %, 3.3.9) уже включено в эту цифру.

Распределение вклада запасного слоя следует из архитектуры. У пасты наименьшее покрытие (89,1 %) — там много сложных текстовых атрибутов `pasta/grain_type` и `pasta/pasta_shape`, которые уходят на LLM. Шоколад покрывается каскадом почти полностью (98,0 %) за счёт сочетания широкого Слоя 1 и стабильного ML; сыры (93,1 %) — промежуточный случай, где Слой 1 узкий, но ML работает уверенно. Поатрибутная разбивка вклада слоёв приведена на рисунке 8.

Распределение работы каскада (extended consensus 2026-05-27) по слоям




Рисунок 8 — Поатрибутный вклад слоёв каскада в сквозную точность

3.3.6 Обобщение на новые бренды (точечная проверка без пересечения брендов)

В 3.2.3 зафиксировано, что разбиение на обучающую и тестовую части в основной оценке выполнено по идентификатору товара, а бренды пересекаются между обучающим пулом и тестовой выборкой на 82–85 % по

категориям. Чтобы выяснить, насколько результат каскада зависит от знакомых брендов, проведено отдельное контрольное исследование с обучением и оценкой на срезе без пересечения брендов. Цель — получить независимую нижнюю оценку обобщающей способности слоя машинного обучения, когда появляются товары неизвестных брендов.

Методология. Для каждой из трёх категорий (паста, шоколад, сыры) на расширенной серебряной разметке ($\approx 1\,250$ кодов) построены два разбиения с одинаковой долей тестовой части ($\approx 20\%$) и одним случайным зерном: (а) случайное по товарным кодам и (б) без пересечения брендов — с замыканием по бренд-токенам, при котором любой код, содержащий хотя бы один бренд из тестовой выборки, переносится в тест целиком, пока множества не станут полностью непересекающимися. Пересечение брендов теста и обучения в первом разбиении — 56–68 % (как и в основном эксперименте), во втором — 0 %. На каждом разбиении переобучены классификаторы XGBoost Слой 2 с той же гиперпараметризацией, что и в основной конфигурации.

Результат. На общем срезе из 4 538 ячеек на разбиении без пересечения товарных кодов и 5 436 ячеек без пересечения брендов точность только-ML слоя составила 83,03 % и 82,56 % соответственно; разность $-0,47$ п. п. при разнице макро-F1 $-0,017$. Таблица 8 приводит покатегорийную и глобальную разбивку.

Таблица 8 — Сравнение точности слоя машинного обучения на выборках без пересечения товарных кодов и без пересечения брендов между обучением и тестом

Категория	Атрибутов	Точность, %			Макро-F1		
		разд. тов.	разд. бр.	Δ , п. п.	разд. тов.	разд. бр.	Δ
паста	7	85,54	85,99	+0,45	0,710	0,717	+0,007
шоколад	7	80,80	79,53	$-1,27$	0,551	0,540	$-0,011$
сыры	7	82,54	81,87	$-0,67$	0,734	0,678	$-0,056$
Глобально	21	83,03	82,56	$-0,47$	0,667	0,649	$-0,017$

Примечание. разд. тов. — разбиение по товарным кодам; разд. бр. — разбиение по брендам без пересечения между обучением и тестом.

Интерпретация. Деграция меньше 1 п. п. укладывается в пределы дисперсии при выборках $\sim 1\,000$ ячеек на категорию. Это значит, что слой машинного обучения каскада опирается на структуру наименования и нутри-сигналы товара, а не на запоминание брендов. На двух из трёх категорий (шоколад $-1,27$ п. п., сыры $-0,67$ п. п.) виден незначительный спад,

на пасте — даже небольшой прирост +0,45 п.п. (то, что знак прыгает, говорит, что эффект в диапазоне случайной флуктуации). Следовательно, заголовочные показатели только-каскадная 95,5 % и сквозная 93,0 % переносятся на товары неизвестных брендов с потерей не больше $\approx 0,5$ п.п., и разбиение по товарным кодам в основной оценке не создаёт оптимистичного смещения за счёт утечки бренда.

Контрольное исследование ограничено: тестовый срез контрольной оценки в 2–3 раза меньше основной (5,4 тыс. ячеек против 16,4 тыс.), считаются метрики только слоя 2 (без вклада регулярных правил и Bayes-валидатора), сравнение проводится на плотно размеченной подвыборке `silver_extended`, а не на полном эталон согласия больших языковых моделей. Полноценная оценка end-to-end в режиме без пересечения брендов потребовала бы переразметки эталона той же мощности, что выходит за рамки текущей работы.

3.3.7 Поатрибутная картина точности и доверительные интервалы

Для каждого из 20 атрибутов вычислена точность только-каскадной конфигурации с интервалом Вильсона (полная таблица — по эталону согласия больших языковых моделей, $n=16\,360$ ячеек в области применимости каскада). Три лучших по микро-усреднённая точность: `cheeses/is_pdo` 99,7 % ($n=325$), `cheeses/is_organic` 99,4 % ($n=357$), `pasta/is_gluten_free` 99,2 % ($n=1197$). Три худших: `chocolate/flavor_profile` 87,5 % ($n=1060$), `pasta/is_filled` 88,5 % ($n=1225$), `cheeses/texture` 89,0 % ($n=335$). Поатрибутная таблица (категория, атрибут, n , микро, макро-F1) приведена в табл. 9.

Таблица 9 — Поатрибутная точность каскада на эталоне согласия трёх больших языковых моделей (20 атрибутов)

Категория	Атрибут	n	Точн., %	Макро-F1
паста	тип зерна	1081	98,8	0,831
паста	форма	645	94,9	0,909
паста	с начинкой	1225	88,5	0,786
паста	без глютена	1197	99,2	0,978
паста	органическая	1179	98,1	0,969

Продолжение таблицы 9

Категория	Атрибут	<i>n</i>	Точн., %	Макро-F1
паста	веганская	1156	96,3	0,962
паста	кухня	1110	95,1	0,753
шоколад	тип	984	98,3	0,971
шоколад	с начинкой	1188	96,9	0,910
шоколад	доп. ингредиенты	961	92,5	0,857
шоколад	с орехами	1126	94,9	0,945
шоколад	органический	1156	99,0	0,987
шоколад	вкусовой профиль	1060	87,5	0,684
сыры	вид молока	354	96,9	0,776
сыры	текстура	335	89,0	0,848
сыры	страна происхождения	310	94,8	0,906
сыры	выдержка	267	94,4	0,929
сыры	защит. наименование	325	99,7	0,993
сыры	органические	357	99,4	0,982
сыры	ультра-обработанные	344	95,9	0,859

В 3.3.25 описаны поатрибутные архитектурные решения (сужение слоя 1, понижение порогов слоя 2, гибридные признаки). Запасной слой остаётся доступным на ≈ 4 % сложных ячеек, где Слой 1 и Слой 2 не отвечают уверенно; наибольшая доля LLM приходится на `pasta/pasta_shape` (19,5 %) и `cheeses/is_pdo` (9,7 %)³.

3.3.8 Анализ доминирования по Парето: почему каскад превосходит одиночный вызов LLM

Выигрыш каскада объясняется структурно. LLM системно проигрывает на длиннохвостых семантических атрибутах с мелкой грануляцией (`pasta/grain_type`, `pasta/pasta_shape`, `cheeses/aging`): на отказных ячейках точность Gemini 2.5 Flash — 78,8 %, Claude Sonnet 4.5 — 76,7 %, gpt-oss-120b — 67,2 %. XGBoost слоя 2 на MPNet-эмбедингах + TF-IDF опирается на устойчивые корреляции «бренд — структура наименования». Точность каскада растёт за счёт перенаправления таких

³Расчёт по поатрибутным предсказаниям каскада на расширенном эталоне согласия трёх больших языковых моделей (повторный прогон 2026-05-27); воспроизводится в `notebooks/03_evaluate.ipynb`.

атрибутов на ML-слой; стоимость падает за счёт сокращения вызовов LLM до 4,1 % ячеек (снижение 95,9 % по сравнению с «одна LLM на всё»).

3.3.9 Учёт точности маршрутизатора первого уровня

Значения рисунка 7 — в режиме идеальной маршрутизации категорий. В производстве категорию определяет слой 0 (3.1.1); его точность на эталоне согласия трёх больших языковых моделей — 97,2 % (на уровне товарных кодов, $n=570$) и 95,3 % на ручном эталоне ($n=107$). Все приведённые в 3.3.4 числа сквозной точности уже учитывают ошибки слоя 0; вывод о выигрыше каскада сохраняется на обеих оценках эталона.

3.3.10 Вклад каждого слоя каскада

Декомпозиция итоговой точности по слоям: охват, точность на собственном срезе закрытий и средняя калибровочная ошибка ECE для Слоя 2. Глобальное распределение закрытий (17 062 ячейки): Слой 1 (правила высокого приоритета) — 21,9 % (3734 ячейки), Слой 2 (ML: MPNet + TF-IDF SVD + XGBoost) — 73,2 % (12 487), Слой 3 (правила низкого приоритета) — 0,8 % (139), Слой 4 (запасной слой LLM) — 4,1 % (702). Покатегорийная разбивка (табл. 10) показывает неоднородность: шоколад располагает наиболее полным набором правил (34,2 % Слоя 1), паста — промежуточный (15,3 %), сыры — узкий (milk_source / is_pdo / is_ultra_processed, 8,1 %). Доля LLM сопоставима (паста 5,1 %, шоколад 2,6 %, сыры 4,9 %) и концентрируется на длиннохвостых семантических атрибутах: pasta/pasta_shape (19,5 % L4), cheeses/is_pdo (9,7 %), cheeses/country_of_origin (9,4 %), pasta/grain_type (9,1 %).

Таблица 10 — Распределение закрытий каскада по категориям и слоям

Категория	Слой 1	Слой 2	Слой 3	Слой 4	Ячеек
паста	15,3 %	79,6 %	0,0 %	5,1 %	8004
шоколад	34,2 %	60,5 %	2,6 %	2,6 %	6759
сыры	8,1 %	87,0 %	0,0 %	4,9 %	2411

Примечание. Слой 1 — правила; Слой 2 — ML; Слой 3 — валидатор; Слой 4 — запасной слой (LLM). Эталон — согласие трёх больших языковых моделей; область применимости каскада; расширенный повторный прогон.

Таблица 11 — Поатрибутная точность Слая 1 (regex) и Слая 2 (ML) на собственных срезах закрытий, по трём категориям пищевой продукции

Категория	Слой 1, %	n_1	Слой 2, %	n_2
паста	90,5	327	98,6	1035
шоколад	87,0	370	94,9	802
сыры	100,0	47	93,5	1549

Поатрибутная точность Слоёв 1 и 2 на собственных срезах закрытий приведена в таблице 11. Точность Слая 1 — 87,0–100 % (ниже 100 % для категорий «паста» и «шоколад» из-за намеренно широких шаблонов); Слой 2 — 93,5–98,6 %, стабильно выше любого одиночного вызова LLM на той же категории, поскольку слой работает только на ячейках, прошедших калиброванный порог. Точность запасного слоя на отказных ячейках: Gemini 2.5 Flash — 78,8 %, Claude Sonnet 4.5 — 76,7 %, gpt-oss-120b — 67,2 %; ниже слоёв 1–2, потому что отказные ячейки сложнее.

3.3.11 Поатрибутная калибровочная ошибка до и после калибровки

Поатрибутная ожидаемая калибровочная ошибка (ECE) рассчитана по 10 равновеликим бином. Среднее ECE сырого XGBoost — 0,070 (по 20 замерам); у большинства атрибутов не превосходит 0,08. Повышенная ошибка: chocolate/chocolate_type (0,14), chocolate/contains_nuts (0,11), pasta/is_filled (0,09).

Изотоническая пост-калибровка на серебряной выборке локально улучшает проблемные атрибуты (chocolate/chocolate_type –7,8 п. п.), но в среднем по 20 атрибутам ECE ухудшается на +0,012 за счёт деградации на других. Эффект объясняется дрейфом разметки между серебряной (теги OFF) и эталонной (консенсус LLM) выборками.

Для устранения дрейфа проведена изотоническая калибровка на распределении эталонной выборки по схеме 5-кратной перекрёстной валидации. Среднее ECE падает с 0,070 до 0,043 (–2,8 п. п. в среднем), эффект положительный на 16 из 20 атрибутов. Самые сильные улучшения — на парах с высокой исходной ошибкой: chocolate/chocolate_type (0,139 → 0,052, –8,7 п. п.), chocolate/contains_nuts (0,111 → 0,041, –7,0 п. п.), pasta/is_organic (0,084 → 0,016, –6,9 п. п.). Ухудшение — у четырёх

атрибутов с изначально низкой ECE: `cheeses/country_of_origin` (0,015 → 0,064), `cheeses/is_ultra_processed` (0,025 → 0,056), `pasta/pasta_shape` (0,046 → 0,060), `chocolate/is_filled` (0,055 → 0,058); тут главную роль играют выборочные колебания. В производственную конфигурацию калибровка пока не включена (см. раздел «Перспективы развития темы» заключения).

Итог: Слой 1 закрывает 2,8–22,7 % ячеек (точность 87,0–100 % в зависимости от категории и шаблона); Слой 2 — 71,1–90,3 % (93,5–98,6 %); Слой 4 — 2,0–10,9 % (67,2–78,8 % в зависимости от модели) на старой выборке; на расширенной выборке доля Слая 4 снижена до 4,1 %. Среднее ECE по слою 2 — 0,070; серебряная пост-калибровка устойчивого эффекта не даёт.

3.3.12 Таксономия ошибок каскада

Раздел отвечает на вопрос «где и почему ошибается каскад» — честная диагностика, важная для защиты: она отделяет собственные дефекты производственной цепочки от шума эталонной разметки. Анализ проведён на 846 несовпадающих ячейках (несовпадения с эталоном) из 16 360 в области применимости каскада эталон согласия больших языковых моделей по трём категориям (*паста*, *шоколад*, *сыры*); это операционная частота ошибок 5,2 %, соответствующая только-каскадная точности 94,8 % на этом пуле⁴. Ячейки, на которых каскад отказался от ответа (запасной слой большой языковой модели, 4,1 %), не входят в знаменатель и анализируются отдельно в 3.3.9.

Каждая ошибка отнесена к одному из шести изначально допустимых классов с приоритизированной классификацией (первый совпавший выигрывает): (1) *ложное срабатывание Слая 1* — низкоуровневый или высокоуровневый regex-шаблон сработал на синтаксически подходящем, но семантически неверном тексте (например, *Three Cheese Ravioli* закрыт правилом `is_filled=false` по антипаттерну); (2) *промах запасного слоя* — запасной слой на большой языковой модели (Слой 4) вернул значение,

⁴Здесь и далее в §3.3 «Таксономия ошибок каскада» эталон — моментальный снимок таксономии, на котором только-каскадная точность составила 94,8 % (846 ошибок / 16 360 ячеек). Заголовочное число ВКР по этой же выборке после расширенного перезапуска консенсуса (2026-05-27) составляет 95,5 % — разница обусловлена пересчётом нескольких пограничных классов между моментальными снимками; качественные выводы таксономии (декомпозиция ошибок по 4 классам, оценка шум серебряной разметки) не зависят от этого сдвига в пределах 0,7 п. п.

отличное от эталона (по определению только-каскадного знаменателя пустой класс, поскольку предсказание каскада на ячейках запасного слоя пусто); (3) *гиперпредсказание на null-эталоне* — gold отсутствует, prediction вернул конкретный класс (по построению пуст: фильтр требует ненулевого эталонного значения); (4) *шум разметки (шум серебряной разметки)* — ячейки, где консенсус трёх LLM-разметчиков не достигает порога $\geq 2/3$ или отмечены как спорные; (5) *спутывание близких классов* — пара (gold, prediction) принадлежит заранее определённом поатрибутный словарь «семантически смежных» значений (semi_soft $\leftrightarrow$ soft, dark $\leftrightarrow$ milk, with_nuts $\leftrightarrow$ with_fruit, italy $\leftrightarrow$ france и т. п.); (6) *ML-смещение в дальний класс* — всё прочее, когда XGBoost выбрал семантически удалённый класс.

Применение классификатора оставило четыре непустых класса (таблица 12). Классы 2 и 3 пусты по построению знаменателя: ошибки только-каскадной части определены на ячейках, где предсказание каскада ненулевое и атрибут входит в область применимости каскада; это методологическое уточнение, а не отсутствие явления — промахи запасного слоя и пустые эталонные значения анализируются отдельно в 3.3.9 и 3.3.10 соответственно.

Таблица 12 — Таксономия ошибок каскада (3 категории, всего 846 ошибок)

Класс ошибки	<i>n</i>	Доля от ошибок	95 % Wilson CI
Ложное срабатывание Слоя 1 (ложное срабатывание регулярного выражения)	326	38,5 %	[35,3; 41,9] %
Шум серебряной разметки	171	20,2 %	[17,6; 23,1] %
Спутывание близких классов	131	15,5 %	[13,2; 18,1] %
ML-смещение в дальний класс	218	25,8 %	[22,9; 28,8] %
Всего	846	100,0 %	—

Главное наблюдение — **38,5 % ошибок порождает Слой 1**, при том что он закрывает лишь 21,9 % ячеек. Это означает: на единицу закрытия Слой 1 даёт в 2,3 раза больше ошибок, чем Слой 2 (38,5/21,9 vs 61,5/74,0); частота ошибок Слоя 1 — 8,7 %, Слоя 2 — 4,2 %. Концентрация ошибок Слоя 1 неравномерна: 178 из 326 (54,6 %) приходится на pasta/is_filled, 80 — на chocolate/chocolate_extra, 57 — на chocolate/contains_nuts. Эти атрибуты опираются на лексические сигналы (tortellini, ravioli, caramel, noisette), где регулярные выражения семантически доминируют над семантически правильным

сигналом. Например, `Three Cheese Ravioli` закрывается правилом `is_filled=false` по антипаттерну «три типа сыра — это присыпка, не начинка», тогда как LLM-консенсус оценивает товар как равиоли с сырной начинкой и присваивает `true`. Это аргумент в пользу гибридной маршрутизации (§ 3.3.15): `regex` остаётся в `production` за счёт высокой точности на «лёгких» атрибутах (`cheeses/milk_source` 100 %, `cheeses/is_pdo` 100 %), но для длиннохвостых семантических атрибутов выгоднее доверять ML-слою.

Второе наблюдение — **20,2 % ошибок (171/846)** — это шум **серебряной разметки**. На этих ячейках голосование трёх LLM-разметчиков не достигло консенсуса; то есть «правильный» ответ сам по себе оспорим. Следовательно, оценка точности каскада 94,8 % является *нижней* границей реального качества, поскольку ≈ 1 п. п. от 5,2 % доли ошибок ($20,2 \% \times 5,2 \% = 1,05$ п. п.) приходится на ячейки, где ошибся не каскад, а эталон. Это эмпирическое подтверждение оценки циркулярного смещения 4,2 п. п. из 3.3.4: после вычитания шума серебряной разметки остаётся $\approx 4,1$ п. п. собственных ошибок каскада, что согласуется с разрывом между эталоном согласия больших языковых моделей и ручным эталоном (94,8 % каскада против 91,3 % по ручному эталону, разность 3,5 п. п. с учётом дисперсии меньшей выборки).

Третье наблюдение — **15,5 % (131/846)** — **спутывание семантически близких классов**, концентрирующееся на `chocolate/flavor_profile` (50 случаев), `chocolate/chocolate_type` (29) и `pasta/cuisine_origin` (19). Эти атрибуты по своему определению допускают пограничные решения (например, шоколад с орехом и карамелью — `with_nuts` или `with_fruit`? итальянский рамэн — `asian` или `italian`?). Снижение этого класса требует не улучшения модели, а уточнения схемы атрибутов или введения множественные метки.

Остальные **25,8 % (218/846)** — **собственно ML-ошибки**: класс предсказан семантически далеко от эталона. Основные источники — `chocolate/flavor_profile` (65), `chocolate/chocolate_extra` (38), `pasta/is_vegan` (33), `pasta/is_organic` (31). На бинарных `is_vegan` и `is_organic` ошибки чаще ложно-положительные (модель приписывает `true` органическому помету, когда эталон строже сертифицирован); на 5-классовых шоколад-атрибутах ошибка распределена

по дальним классам — вероятный источник — дисбаланс классов в обучающей выборке (серебряная разметка OFF-тегами имеет известный смещение в сторону `plain` шоколад и `sweet_creamy flavor`).

Качественные примеры ошибок каждого класса — ложное срабатывание Слоя 1 на «Three Cheese Ravioli» (антипаттерн правила подавил корректный прогноз слоя 2), спутывание близких классов на «Mandel Orange Шоколад Bar» (*с орехами* против *с фруктами*), смещение в дальний класс ML на «Babybel Light Mini» (Соединённое Королевство против Франции) — разобраны в составе кейс-анализа 3.3.13 (таблица 13).

Вывод. Из 846 ошибок каскада $\approx 20\%$ — шум эталона, $\approx 15\%$ — пограничные решения в схеме атрибутов, $\approx 39\%$ — regex-перетягивания на лексически провокационных товарах, $\approx 26\%$ — собственно ML-промахи. Если вычесть первые два класса, «настоящая» частота ошибок каскада снижается с $5,2\%$ до $\approx 3,4\%$; это соответствует $96,6\%$ потенциальной точности при идеальном эталоне и уточнённой схеме. Это число — не для заголовочного результата, но как аргумент в защите: верхняя планка качества системы выше, чем цитируемые $94,8\%$ / $86,7\%$; разрыв объясняется измеримой и декомпозируемой долей шума разметки. Артефакт таксономии; регенерируется ячейкой `failure-taxonomy-cell` в `notebooks/03_evaluate.ipynb` через `scripts/failure_taxonomy.py`.

3.3.13 Разбор примеров прохождения каскада

Агрегированная таксономия ошибок (§3.3.12) даёт картину классов проблем, но не раскрывает, как именно слои каскада взаимодействуют на конкретном товаре. Для иллюстрации работы системы ниже приведён разбор трёх реальных товаров из эталонной выборки: два ошибочных кейса (по одному на класс из ранее введённой таксономии — ложное срабатывание регулярного выражения и спутывание близких классов) и один успешный, на котором каскад корректно отвечает по всем атрибутам. Для каждого товара показаны входные данные от партнёра, отклики всех четырёх слоёв (Слой 1 — regex, Слой 2 — ML с уверенностью и порогом, Слой 3 — байесовский валидатор, Слой 4 — LLM-эскалация), выбранный системой слой и финальный ответ в сопоставлении с эталоном. В колонках «Слой 3» и «Слой 4» стоит прочерк там, где соответствующий слой в производственной

конфигурации не вызывался.

Кейс 1. Ложное срабатывание регулярного выражения (*Three Cheese Ravioli*).

Вход: product_name=«Three Cheese Ravioli», brands=«M&S Food», quantity=400 g. **Атрибут:** is_filled. **Эталон:** true (ravioli с сырной начинкой). **Ответ системы:** false.

Слой машинного обучения корректно предсказал true с уверенностью 0,97 (выше порога 0,90), но высокоприоритетное правило Слая 1 форсировало false по антипаттерну «блюдо со словом cheese — это пицца или сэндвич, не паста с начинкой». Класс ошибок — ложное срабатывание регулярного выражения, преимущественно из-за подавления правильного ответа слоя 2. Правило подлежит сужению контекстом (исключить Ravioli, Tortellini, Cappelletti).

Кейс 2. Спутывание близких классов (*Chevre a tartiner*).

Вход: product_name=«Chevre a tartiner», brands=«Rians», состав с пастеризованными сливками козьего молока. **Атрибут:** cheeses.texture. **Эталон:** cream. **Ответ системы:** fresh.

Слой машинного обучения уверенно (0,87 при пороге 0,65) выбирает класс fresh для мягкого козьего сыра. Эталон относит товар к крем-сырам. Граница между fresh и cream размыта на уровне тегов Open Food Facts и проявляется как смешение классов в матрице ошибок. Такая ошибка ожидаема и снимается экспертной заменой границ в схеме.

Кейс 3. Штатный мультиязычный режим (*Bio Spaghetti*).

Вход: product_name=«Bio Spaghetti» (немецкое *Bio* + итальянское *Spaghetti*), brands=«Combino», состав *Hartweizengriess* (нем. твёрдая пшеница). Прохождение каскада приведено в таблице 13.

Таблица 13 — Прохождение каскада для мультиязычного товара «Bio Spaghetti»

Атрибут	Слой 1	Слой 2	Увер.	Порог	Источник	Ответ	Эталон
Тип зерна	—	пшеница	0,96	0,90	Слой 2	пшеница	пшеница

Продолжение таблицы 13

Атрибут	Слой 1	Слой 2	Увер.	Порог	Источник	Ответ	Эталон
С начинкой	нет	нет	1,00	0,90	Слой 1	нет	нет
Органический	—	да	0,98	0,85	Слой 2	да	да
Без глютена	—	нет	0,99	0,90	Слой 2	нет	нет
Форма пасты	—	спагетти	0,86	0,80	Слой 2	спагетти	спагетти
Веганский	—	да	0,98	0,70	Слой 2	да	да
Кухня	—	итал.	0,94	0,60	Слой 2	итал.	итал.

Правило Слоя 1 распознаёт отсутствие начинки по антипаттерну (нет слов наполнителей в названии), слой 2 уверенно предсказывает остальные шесть атрибутов с уверенностью выше соответствующих порогов. Эскалация в запасной слой не требуется. Пример демонстрирует корректность многоязычных векторных представлений и адекватность поатрибутных порогов.

Эти примеры иллюстрируют ключевые наблюдения предыдущего параграфа. Кейс 1 («Three Cheese Ravioli») показывает механизм ложного срабатывания регулярного выражения в чистом виде: ML-слой даёт корректный ответ (`true` с уверенностью 0,97), но правило высокого приоритета его подавляет; вывод — источник ошибок Слоя 1 не в недостатке ML-сигнала, а в чрезмерной агрессивности эвристик, требует контекстной фильтрации. Кейс 2 («Chevre a tartiner») демонстрирует спутывание близких классов на размытой границе схемы `cheeses.texture` — ML уверен в близком, но «неправильном» по эталону классе. Кейс 3 («Bio Spaghetti») показывает штатную работу системы на мультиязычном товаре: ML-слой уверенно (уверенность $\geq 0,86$) предсказывает все семь атрибутов, эскалация в Слой 4 не требуется, что подтверждает экономическую эффективность каскадной архитектуры на типовых товарах.

3.3.14 Сравнение классификаторов Слоя 2: XGBoost, Random Forest, логистическая регрессия, MLP

В обоснование выбора XGBoost (см. 2.2) проведено эмпирическое сопоставление четырёх семейств алгоритмов. Все модели обучены и оценены на одинаковых признаках — конкатенированном векторе из 768-мерного представления MPNet и 128-мерного TF-IDF-представления, сжатого TruncatedSVD (итого 896 измерений). Эталон: согласие трёх больших

языковых моделей ($n \approx 41$ тыс. ячеек) и ручной эталон ($n = 518$); 16 атрибутов из 20. Результаты сведены в таблице 14 и визуализированы на рисунке 9.

Таблица 14 — Сравнение классификаторов Слой 2 на эталоне согласия трёх больших языковых моделей

Классификатор	Точность, %	Макро-F1	ECE	Время обуч., с
XGBoost (производств.)	92,02	0,849	0,026	1062
MLP (нейронная сеть)	92,67	0,857	0,031	54
Логистическая регрессия	91,85	0,836	0,035	8
Случайный лес	89,94	0,809	0,027	523




Рисунок 9 — Точность только-каскадной части классификаторов Слой 2 на эталонах эталон согласия трёх больших языковых моделей и ручной эталон

XGBoost выигрывает у Random Forest (16/16 атрибутов, +2,1 п. п. в среднем) и логистической регрессии (11/16, выигрыш на длиннохвостых мультиклассовых `pasta_shape`, `country_of_origin`, `chocolate_extra`). MLP опережает XGBoost по микро-усреднённой точности в среднем на 0,65 п. п., но у него заметно хуже калибровка (ECE 0,031 против 0,026). Для каскада, Чья маршрутизация опирается на порог τ_a , низкая ECE важнее доли процента accuracy: XGBoost — единственный метод, который сочетает устойчивость на сложных классах и наилучшую калибровку.

3.3.15 Обоснование сохранения слоя регулярных выражений: сопоставление с обучаемыми альтернативами

Использование детерминированных правил в качестве слоя 1 — нетривиальный выбор: их приходится писать руками для каждой категории. Чтобы это количественно зафиксировать, каскад с regex сопоставлен с восемью альтернативами, где слой 1 заменён обучаемой моделью. Все варианты оценены на едином 80/20-разбиении (seed = 42) по 20 парам. Сравнение конфигураций приведено в таблице 15.

Таблица 15 — Сопоставление каскадных конфигураций с разным первым слоем

Вариант	Состав первого слоя (перед основным ML-слоем)	Точн., %	Δ , п. п.
A	Регулярные выражения (текущая конфигурация)	83,58	+1,38
B	Без первого слоя (один ML-слой)	82,20	0,00
C	Наивный байесовский классификатор на n-граммах	82,16	−0,04
D	Решающее дерево	82,98	+0,78
E	Центроидный классификатор в пространстве n-грамм	82,22	+0,02
F	Логистическая регрессия на n-граммах	82,23	+0,03
L	Обучаемый словарь n-грамм (lexicon)	83,00	+0,80
G	Поатрибутный выбор лучшего метода по перекрёстной проверке	81,99	−0,21
H	Регулярные выражения — решающее дерево — ML (последовательно)	83,78	+1,58

Примечание. Δ — отклонение средней точности от варианта B («без первого слоя»).

Из таблицы следуют три вывода:

- 1) Чистый ML без слоя 1 (вариант B, 82,20 %) уступает текущей конфигурации (A, 83,58 %) на 1,38 п. п.; регулярные выражения дают небольшой, но устойчивый прирост.
- 2) Ни одна обучаемая альтернатива (C, D, E, F, L) не обходит регулярные выражения в роли единственного слоя 1. Правила фиксируют доменное знание (формы пасты, типы зерна, числовые шаблоны какао), которое из распределения слов не восстанавливается: лексические маркеры редкие, но однозначные.

- 3) Единственная значимо превосходящая регулярные выражения конфигурация — композиция «правила — решающее дерево — ML» (Н, +0,20 п. п.). Прирост незначителен и не оправдывает усложнения и поддержки 20 деревьев.

Итог: выбор regex как Слоя 1 эмпирически обоснован — наибольший прирост среди простых альтернатив при детерминированном выводе и без переобучения. Предпочтительное развитие — точечное расширение правил по итогам 3.3.25.

3.3.16 Поведение байесовского валидатора и архитектурный вывод

Слой 3 — байесовская сеть над дискретизированными атрибутами и брендом (структура — Hill Climb + BIC, рис. 4). В роли классификатора сеть работает плохо (точность $\approx 52\%$, ниже мажорной), поэтому используется как валидатор плотности: для предсказания Слоя 2 вычисляется $P(\text{value} \mid \text{evidence})$ при свидетельствах «бренд + остальные атрибуты»; ниже порога θ (5-перцентиль распределения P на обучении) ячейка помечается и передаётся в Слой 4. Точность отбраковки определена как $TP/(TP + FP)$ среди помеченных, базовая точка отсчёта — частота ошибок каскада на всех ячейках пары. Поведение валидатора по категориям сведено в таблице 16.

Таблица 16 — Поведение байесовского валидатора по категориям

Категория	n	Помечено, %	Точность каскада, %	Точность отбраковки, %	Базовая ошибка, %	Δ , п. п.	Полнота, %
паста	1010	7,9	98,6	2,5	1,4	+1,1	14,3
шоколад	772	14,1	94,7	20,2	5,3	+14,9	53,7
сыры	1436	6,1	96,3	1,1	3,7	-2,5	1,9

Примечание. Доля помеченных — ячейки, у которых $P_B < \theta$ и которые передаются в запасной слой; точность отбраковки — $TP/(TP + FP)$ среди помеченных; базовая ошибка — доля ошибок каскада среди всех ячеек пары; Δ — прирост точности на помеченных в процентных пунктах относительно базовой; полнота — покрытие реальных ошибок каскада среди помеченных.

Из 20 пар только три показывают точность отбраковки выше базовой: chocolate/contains_nuts (+38,2 п. п., полнота 59,5 %),

pasta/is_vegan (+14,0 п. п. на `n_flagged = 10`) и `cheeses/is_pdo` (+7,0 п. п. на `n_flagged = 10`). На 17 оставшихся парах сигнал валидатора не работает. При сплошном понижении (все помеченные в LLM) точность каскада снижается на 0,4 п. п. при росте расходов на 8,6 п. п. — чистый эффект отрицательный. При точечном понижении на паре `chocolate/contains_nuts` точность категории шоколад растёт на 6,6 п. п. при росте расходов на 5,3 п. п.; этот режим включён в производственную конфигурацию.

Архитектурный вывод. Перевод сети из классификатора в точечный валидатор показывает общий приём: невостребованный в одной роли компонент можно вернуть в систему, поменяв его роль. Универсального решения не получено: 19 из 20 пар не дают значимого сигнала; ограничение зафиксировано в заключении (§«Ограничения работы»). Производственная конфигурация включает валидатор точно на одной паре, что соответствует найденной мощности сигнала.

3.3.17 Чувствительность к выбору порога отсечки

Поатрибутные пороги уверенности τ_a подобраны процедурой `find_best_threshold` (оптимизация произведения макро-F1 на долю покрытия на отдельном валидационном срезе, § 3.3.25). Чтобы убедиться, что выбранная точка устойчива по совокупному критерию «точность $\leftrightarrow$ стоимость», проведён post-hoc анализ чувствительности: пороги синхронно сдвигаются на $\Delta \in \{-0,10; -0,05; 0; +0,05; +0,10\}$ без переобучения моделей. Затем пересчитываются точность каскада на ячейках в области его применимости, доля эскалаций в Слой 4 (доля обращений к большой языковой модели) и оценка сквозной точности (источник — `notebooks/03_evaluate.ipynb`, ячейка 8a; скрипт `scripts/threshold_sensitivity.py`). Результаты приведены в таблице 17.

Производственная точка $\Delta = 0$ — устойчивый локальный оптимум: симметричные смещения $\pm 0,05$ размывают $\approx 0,3$ п. п. точности E2E, при этом каждый шаг $+0,05$ примерно удваивает долю LLM (с 2,7 % до 7,1 %). Сдвиг $\Delta = +0,10$ катастрофичен: 29 % ячеек эскалируются в LLM, точность каскада на оставшихся падает ниже базовой ($-0,7$ п. п.), так как порог отсекает уверенные правильные предсказания и оставляет в каскаде преимущественно

Таблица 17 — Чувствительность каскада к синхронному сдвигу всех порогов отсечки. Знаменатель — ячейки в области применимости каскада; доля обращений к большой языковой модели — доля ячеек, эскалированных в Слой 4. GLOBAL: паста+шоколад+сыры, $n = 17\,174$.

Сдвиг порога	Точн. каскада, %	Доля LLM, %	E2E, %	n ячеек
−0,10	94,24	2,06	94,28	16820
−0,05	94,43	2,73	94,47	16706
0,00 (текущий)	94,75	3,74	94,79	16531
+0,05	95,02	7,12	95,08	15952
+0,10	94,05	29,29	94,49	12144

трудные классы. Сдвиг $\Delta = -0,10$ даёт минимальную LLM-долю (2,1 %), но теряет 0,5 п. п. точности из-за пропуска малоуверенных ошибочных предсказаний. Производственная конфигурация (диапазон порогов 0,55–0,90) не лежит на склоне функции стоимости, что подтверждает корректность выбора порогов на этапе обучения.

3.3.18 Стоимостно-чувствительный маршрутизатор: отрицательный результат на проверке гипотезы Н1

В подразделе зафиксирован результат заранее объявленной проверки гипотезы Н1 о превосходстве обучаемого маршрутизатора над статическим правилом.

Идея, гипотеза Н1 и процедура оценки.

Финальный механизм направления ячеек в LLM — статическое рег-(категория, атрибут) правило. Рассматривалась обучаемая альтернатива: XGBoost-маршрутизатор предсказывает надёжность ответа каскада, при вероятности ниже τ ячейка идёт в LLM. **Н1:** при равном бюджете LLM обучаемый маршрутизатор даёт более высокую точность. До доступа к числам зафиксированы: три бюджета вызовов запасного слоя (25, 40, 50 %); поправка Бонферрони ($\alpha/3 \approx 0,0167$); тестовая выборка без пересечения товарных кодов между обучением и тестом, $n = 1539^5$; опорная конфигурация

⁵Заранее зафиксированный снимок (от 2026-05-13). Повторный запуск даёт $n = 1574$ ($\approx$

— статическое правило. Параметры зафиксированы в `src/eval/router_pre_registered.py`.

Результаты.

Сравнительные числа представлены в табл. 18.

Таблица 18 — Сравнение конфигураций маршрутизации на проверочной выборке без пересечения товарных кодов между обучением и тестом

Конфигурация	Точн., %	Доля LLM, %	Тип
Только каскад (без LLM)	78,5	0	опорная конфигурация
Статический порог $\tau = 0,55$	82,6	11	статический
Обучаемый маршрутизатор (оптимум)	82,7	16	обучаемый
Статическое поатрибутное правило	83,9	58	статический

При сопоставимой точности обучаемый маршрутизатор требует большего бюджета LLM (16 против 11 %; разница 0,1 п. п. в пределах ДИ). Ни на одном из трёх бюджетов маршрутизатор не превзошёл опорную конфигурацию на уровне $\alpha/3$; **гипотеза Н1 отклонена**⁶. MDE при $n = 1539$, $\alpha/3$ и мощности 0,8 — $\approx 4,4$ п. п., поэтому отрицательный исход надо понимать как отсутствие практически значимого превосходства в пределах не менее 4 п. п.

Интерпретация и следствие для финальной конфигурации.

Отклонение Н1 воспроизводится на всех пяти моделях Слоя 4. Причина: основная вариация надёжности каскада сосредоточена на уровне атрибутов, а не товаров. Статическое рег-(категория, атрибут) правило ловит именно эту неоднородность, маршрутизатор уровня ячейки дополнительной информации не приносит. Без пересечения товарных кодов между обучением и тестом разбиение устраняет утечку бренда, которая объясняла ранние положительные результаты. Результат согласуется с RouterBench [12]. В финальной конфигурации применяется статическое правило — прозрачное,

2,3% дрейф, не меняет вывод).

⁶p-value McNemar-теста воспроизводятся ячейкой 9.1 в `notebooks/03_evaluate.ipynb`.

поддающееся аудиту и не требующее переобучения; отклонение Н1 — один из трёх пунктов научной новизны (см. введение).

3.3.19 Цикл «аудит → правки → переобучение → измерение»

Замкнутый цикл итеративного улучшения каскада построен на сопоставлении собственных предсказаний с независимо проаудированной разметкой: модель-аудитор (Claude Opus 4) слепо выносит суждения по каждой ячейке, измерение по неизменному списку ячеек исключает селекционный сдвиг. На пасте аудит 239 продуктов (1 841 ячейка, 8 атрибутов) выявил концентрацию ошибок на атрибуте `pasta_shape` (24,2 % ячеек). Источник — порядок обхода тегов категории в правиле многоклассового извлечения формы: общий тег `en:noodles` имел приоритет над специфическими `en:tagliatelle/en:penne/en:fusilli`, а в словаре форм отсутствовали зернобобовые и фаршированные виды. После исправления порядка обхода и расширения словаря многоязычными синонимами точность `pasta_shape` выросла с 27,6 до 59,6 % (+32,0 п. п.) при нулевом сдвиге шести нетронутых атрибутов; агрегированное серебро — с 80,7 до 85,2 %. Других изменений архитектуры не делалось — это подтверждает причинную связь правок и прироста.

3.3.20 Переобучение моделей и прирост каскада

Слой 2 переобучен на обновлённой серебряной разметке с пересохранением калибровок и порогов; каскад прогнан на тех же 239 эталонных продуктах. Сравнение до и после переобучения сведено в таблице 19.

Таблица 19 — Прирост точности каскада на категории паста после переобучения Слой 2 на обновлённой серебряной разметке (сопоставление на 239 эталонных продуктах)

Срез	<i>n</i>	До	После	Δ
Все проверенные	1841	81,9 %	86,4 %	+4,5 п. п.
Переопределённые аудитом	220	39,5 %	57,7 %	+18,2 п. п.
Подтверждённые аудитом	1621	87,6 %	90,3 %	+2,7 п. п.

Эффект локализован: на атрибуте `pasta_shape` точность на подмножестве переопределённых аудитом ячеек (83 ячейки) выросла с 22,9 %

до 72,3 % (+49,4 п. п.). Точечная правка даёт концентрированный сдвиг: +18,2 п. п. на сложном срезе против +2,7 п. п. на подтверждённом.

3.3.21 Кросс-категорийная репликация цикла 3/3

Тот же цикл применён к шоколаду и сырам.

Для категории «шоколад» (1530 ячеек) аудит выявил дефект бинаризации `cocoa_percentage` — расхождение конвенции серебра и индустриальной интерпретации метки «70 %». После перехода на конвенцию $[X, Y)$ точность на пересечении переразмеченных и исходно эталонных ячеек `cocoa_percentage` поднялась с 10,8 % до 31,5 %; агрегированный прирост по домену +16,3 п. п.

Для категории «сыры» (1655 ячеек) аудит обнаружил систематически завышенные пороги `fat_class` (86 сдвигов вверх против 16 обратных). После установки порогов (15, 20, 28) г/100 г точность на пересечении переразмеченных и исходно эталонных ячеек `fat_class` выросла с 2,7 % до 69,9 %; агрегированный прирост по домену +14,4 п. п.

Цикл воспроизведён 3/3 на независимых категориях с разными типами дефектов (порядок обхода тегов, сдвиг границ бакетирования, выбор порогов численного атрибута). Значит, последовательность «обнаружение — правка — пересборка серебряной разметки — переобучение — измерение» можно считать переносимым приёмом, а не разовым улучшением.

3.3.22 Устойчивость каскада по языкам

OFF имеет языковой перекосяк (≈ 40 % FR, 10 % EN, 7 % DE и т. д.). Под балансировку каскад не оптимизировался. Поатрибутно-поязыковой срез на расширенном эталоне (16 461 ячейка в области применимости каскада, 5 языков) даёт взвешенную точность (таблица 20):

Таблица 20 — Точность каскада по языкам (расширенный эталон согласия трёх больших языковых моделей, 16 461 ячейка в области применимости каскада)

Язык	Ячеек	Точн., %
Итальянский	2978	96,0
Испанский	3014	95,9
Английский	3380	94,9

Продолжение таблицы 20

Язык	Ячеек	Точн., %
Немецкий	3093	94,8
Французский	3996	93,2

Разброс между лучшим (it, 96,0 %) и худшим (fr, 93,2 %) — 2,8 п. п. Это говорит о приемлемой языковой устойчивости и согласуется с выбором кодировщика `paraphrase-multilingual-mpnet-base-v2` с TF-IDF-расширением. Французский сегмент остаётся самым ёмким ($n_{fr} = 3996$, 24 % выборки) и одновременно самым низкоточным — это следствие исторической доли FR в OFF и большего разнообразия редких товарных подкатегорий. Усреднение скрывает локальные провалы: четыре кортежа (категория, атрибут, язык) с отставанием от лучшего сегмента > 11 п. п. на $n \geq 10$: `pasta/is_filled/fr` (58,0 % на $n=231$), `chocolate/chocolate_extra/fr` (81,2 % на $n=223$), `chocolate/chocolate_extra/de` (83,5 % на $n=212$), `cheeses/texture/de` (85,0 % на $n=40$). Рекомендация для production — на проблемных парах снизить порог τ_a или явно роутить в LLM.

3.3.23 Устойчивость каскада к шуму во входных данных

Для оценки устойчивости к неоднородному партнёрскому вводу проведён controlled-noise-эксперимент: тестовый срез (sample 500 кодов на категорию, seed 42) перепрогоняется через Слои 1–2 с четырьмя классами синтетического шума — случайная перестановка соседних символов в `product_name` (1/5/10 %), зануление поля `brands` (50/100 %), зануление `ingredients_text` (50/100 %) и комбинированный сценарий. Скрипт — `scripts/eval_input_robustness.py`; источник чисел — `notebooks/03_evaluate.ipynb`, ячейка «input-robustness»; артефакт. Результаты сведены в таблице 21.

Таблица 21 — Деградация каскада при шуме во входных партнёрских полях. Точность — на ячейках, где каскад выдал ответ; доля эскалаций в запасной слой — относительно всех тестовых ячеек. Выборка 500 кодов на категорию (паста, шоколад, сыры), seed 42; эталон — согласие трёх больших языковых моделей.

Сценарий	Точн., %	Δ, п. п.	Доля LLM, %	Δ, п. п.
Без шума (опорная)	89,5	+0,0	9,9	+0,0
Комбо: опечатки 5 % + пропуск бренда 50 %	87,8	−1,6	14,7	+4,8
Пропуск поля бренда, 50 % ячеек	89,3	−0,1	11,5	+1,6
Пропуск поля бренда, 100 % ячеек	88,9	−0,5	13,2	+3,3
Пропуск поля состава, 50 % ячеек	83,6	−5,9	14,3	+4,4
Пропуск поля состава, 100 % ячеек	77,2	−12,3	19,1	+9,2
Опечатки в названии товара, 1 %	88,1	−1,4	14,2	+4,3
Опечатки в названии товара, 5 %	88,2	−1,3	14,1	+4,2
Опечатки в названии товара, 10 %	87,4	−2,1	16,2	+6,3

Главное наблюдение: единственный реальный фактор риска — отсутствие `ingredients_text`. При 50 % пропусков точность каскада падает на 5,9 п. п. (с 89,5 до 83,6 %), при 100 % — на 12,3 п. п. (до 77,2 %); деградация неравномерна, сильнее всего бьёт по атрибутам с сильным сигналом в составе (`pasta.is_vegan` −35,5 п. п., `chocolate.chocolate_extra` −35,4 п. п.). Char-swap-опечатки даже на 10 % символов снижают точность всего на 2,1 п. п. (multilingual SBERT-кодировщик устойчив к мелкому орфографическому шуму), а удаление `brands` даёт минимальную деградацию — 0,5 п. п., потому что бренд обычно дублируется первым токеном `product_name`. Практическое следствие: при NULL `ingredients_text` стоит обогащать запись на стороне партнёра либо принудительно эскалировать составные атрибуты в Слой 4 (стратегия включена в перспективы развития темы).

Все проверки показывают приемлемое поведение каскада по типичным угрозам валидности и фиксируют оставшиеся слабые места, которые задают план развития.

3.3.24 Симуляция активного обучения на эталон согласия трёх больших языковых моделей

Для оценки целесообразности активного обучения проведена симуляция на уже доступной разметке эталон согласия трёх больших языковых моделей (без дополнительной стоимости разметки человеком-аннотатором). Эталон разделён по товарным кодам в пропорции 70/30 (без пересечения товарных кодов между обучением и тестом, seed 42); из пула отбираются две стратифицированные выборки одинакового размера $N \in \{50, 100, 200, 500\}$ — *active* (ячейки, на которых ML уверенно ошибается, расхождение вероятностей у границы, верхний квартиль) и *random* (случайная выборка), после чего Слой 2 переобучается на *silver* + N *gold* с пятикратным весом и измеряется на отложенной выборке. По 24 циклам переобучения (3 категории $\times$ 4 значения $N \times 2$ стратегии) *active*-стратегия *не* превзошла *random* ни на одной паре: при $N = 500$ паста *active* $-0,14$ п.п. против *random* $+0,28$ п.п.; шоколад *active* $+0,27$ п.п. против *random* $+0,96$ п.п.; сыры *active* $-0,12$ п.п. против *random* $+1,74$ п.п. Объяснение — ограниченный размер пула кандидатов активного обучения (26–79 «уверенно-ошибочных» ячеек на категорию): при $N \geq 100$ *active* фактически добавляет весь пул, тогда как *random* продолжает расти на пуле из 4 461–5 954 ячеек. Оговорка: симуляция $\neq$ настоящий AL с человеческой разметкой (*gold* здесь — LLM-консенсус, а пул кандидатов сужен производственным каскадом). Подробное обсуждение полноценного AL-пилота с человеком-аннотатором — в «Перспективах развития темы» [Заклучения](#). Артефакты в [notebooks/03_evaluate.ipynb](#). Численные значения по парам (категория, N) сведены в таблице 22.

Таблица 22 — Симуляция активного обучения на эталоне согласия трёх больших языковых моделей. Активная выборка — ячейки, на которых модель уверенно ошибается; случайная — равновеликая выборка из остального эталонного пула. Отложенная выборка: 30 % эталонных кодов без пересечения товарных кодов между обучением и тестом. Точность — на отложенной выборке, взвешенная по ячейкам.

Категория	N	Активн., %	Δ , п. п.	Случ., %	Δ , п. п.	A–C
паста	0 (опорная)	83,50	—	83,50	—	—
паста	50	83,45	$-0,05$	83,50	$+0,00$	$-0,05$

Продолжение таблицы 22

Категория	<i>N</i>	Активн., %	Δ , п. п.	Случ., %	Δ , п. п.	A–C
паста	100	83,36	–0,14	83,69	+0,19	–0,33
паста	200	83,36	–0,14	83,64	+0,14	–0,28
паста	500	83,36	–0,14	83,78	+0,28	–0,43
шоколад	0 (опорная)	75,34	—	75,34	—	—
шоколад	50	75,20	–0,14	75,96	+0,61	–0,75
шоколад	100	75,61	+0,27	75,61	+0,27	+0,00
шоколад	200	75,61	+0,27	76,50	+1,16	–0,89
шоколад	500	75,61	+0,27	76,30	+0,96	–0,68
сыры	0 (опорная)	76,31	—	76,31	—	—
сыры	50	76,19	–0,12	76,13	–0,18	+0,06
сыры	100	76,19	–0,12	76,31	+0,00	–0,12
сыры	200	76,19	–0,12	76,85	+0,54	–0,66
сыры	500	76,19	–0,12	78,05	+1,74	–1,86

Примечание. Δ — прирост точности в процентных пунктах относительно опорной конфигурации; A–C — разность точностей активной и случайной стратегий. Пул кандидатов активного обучения ограничен: паста 75 ячеек, шоколад 79, сыры 26, поэтому при $N \geq 100$ активная стратегия добавляет почти весь пул и кривая выходит на плато.

3.3.25 Уточнение схемы атрибутов: независимые свойства

Анализ ошибок показал, что значение «с начинкой» в исходной пятиклассовой формулировке `chocolate_type` {тёмный, молочный, белый, с начинкой, прочее} работает как структурная характеристика товара и не зависит от типа какао-массы: один шоколад может быть одновременно тёмным и с начинкой (Lindt-трюфели, Ritter Sport Marzapane, Ferrero Rocher). Объединение двух независимых свойств в один многоклассовый атрибут давало макро-F1 0,50 при нулевой полноте на классах «с начинкой» и «прочее».

По принципу независимости атрибутов в схему введён бинарный атрибут `chocolate.is_filled`, выделенный из `chocolate_type`. После разделения макро-F1 трёх получившихся атрибутов составила 0,971 (`chocolate_type` из трёх классов), 0,910 (`chocolate_extra` из пяти классов) и 0,857 (`is_filled`, бинарный) соответственно.

Аналогичный принцип отказа от классов с низкой полнотой и малой обучающей выборкой применён к нескольким редким классам категорий шоколада и сыров; класс «полутвёрдый» в `cheeses.texture` объединён с «мягкий» как близкий по семантике.

3.3.26 Поатрибутные архитектурные решения

Диагностика выявила три типовых поатрибутных приёма:

- (а) **Сужение входа Слая 1** для `chocolate_type`: разбор только по названию (без поля `ingredients_text`, где лексика «milk/lait/Milch» массово встречается в составе тёмного шоколада); правило отказывает при одновременном срабатывании нескольких типов.
- (б) **Перенастройка порога Слая 2** на парах с высокой систематически высокой долей отказа — индивидуальное понижение до 0,40–0,65.
- (в) **Гибридные признаки** SBERT $\oplus$ TF-IDF (1, 2) топ-5000 для лексически богатых атрибутов (+1,9 / +3,8 п. п. на `chocolate_type` и `contains_nuts` соответственно).

Итоговое влияние на сквозную точность приведено в таблице 23.

Таблица 23 — Сквозная точность каскада на парах со специальной поатрибутной настройкой

Пара (категория, атрибут)	Базовая модель	Каскад	Применённый приём
шоколад / <code>chocolate_type</code>	94,7 %	98,0 %	(а)+(в) сужение входа и гибридные признаки
шоколад / <code>chocolate_extra</code>	76,6 %	92,5 %	(б) порог 0,90 $\rightarrow$ 0,65
шоколад / <code>contains_nuts</code>	90,4 %	89,0 %	(в) гибридные признаки + правила маркеров орехов
сыры / <code>texture</code>	70,5 %	92,3 %	(б) порог 0,60 $\rightarrow$ 0,40
сыры / <code>is_organic</code>	92,5 %	98,7 %	(б) порог 0,70 $\rightarrow$ 0,40
сыры / <code>is_ultra_processed</code>	86,1 %	96,1 %	(б) порог 0,70 $\rightarrow$ 0,50
паста / <code>grain_type</code>	91,9 %	94,2 %	(б) порог Слая 2 0,50

Примечание. «Базовая модель» — точность одиночной модели Слой 2 без поатрибутной настройки и без каскадной композиции. «Каскад» — точность системы после применения соответствующего приёма. Эталон — согласие трёх больших языковых моделей на тестовой выборке без пересечения товарных кодов.

На парах с пониженным порогом Слой 2 запасная большая языковая модель вызывается на ≤ 5 % ячеек, общая доля обращений по системе — 4,1 % (архитектурное снижение стоимости 95,9 % по сравнению с конфигурацией «все ячейки — большая языковая модель»).

3.4 Выводы по главе 3

Основные результаты:

- 1) Реализован пятислойный каскад (Слой 0 классификатор категории, регулярные выражения, машинное обучение XGBoost на SBERT, байесовский валидатор, запасной слой на большой языковой модели) с указанием слоя-источника на каждое предсказание; вердикт формируется как последовательное конъюнктивное условие на пороги слоёв.
- 2) Развёрнута трёхкомпонентная демонстрационная система (Go-шлюз, Python/FastAPI ML-сервис, статический HTML/JS) со стабильным контрактом API и подтверждённой работоспособностью на трёх категориях.
- 3) Сквозная точность 93,0 % на 16 360 ячейках эталона согласия трёх больших языковых моделей (20 атрибутов, без пересечения товарных кодов между обучением и тестом) в конфигурации «каскад + Gemini 2.5 Flash» — на 9,2 п. п. выше опорной конфигурации с прямым вызовом Claude Sonnet 4.5 (83,8 %) при стоимости в 580 раз ниже (доминирование по Парето). Верхняя оценка только-каскадной точности — 95,5 % (точность только-каскадной части на тех же ячейках, макро-F1 0,890). Каскад покрывает 97,3 % ячеек; на запасной слой большой языковой модели приходится 4,1 % сложных ячеек (снижение стоимости 95,9 % по сравнению с конфигурацией «все ячейки — большая

языковая модель»). Консервативная нижняя оценка по ручному эталону ($n=566$ ячеек в области применимости каскада): сквозная точность 86,7 %, точность только-каскадной части 91,3 % — операционный циркулярный сдвиг 4,2 п. п. (каскад) и 6,3 п. п. (сквозная). В сценарии с открытой моделью «каскад + gpt-oss-120b» точность достигает 90,6 % — на 21,3 п. п. выше одиночного вызова той же модели. Полная таблица — в 3.3.4.

- 4) Поатрибутный разбор: Слой 2 — основной (71–90 % покрытия, 93,5–98,6 % точности по покрытым ячейкам); Слой 1 покрывает 18–34 % ячеек в категориях «паста» и «шоколад» с точностью 87–100 %; байесовский валидатор работает точно (+38 п. п. на `chocolate/contains_nuts`); большая языковая модель добавляет +1,4–1,7 п. п. при 4,1 % обращений.
- 5) Заранее объявленная гипотеза H1 об обучаемом маршрутизаторе отклонена на трёх бюджетах после поправки Бонферрони; результат согласуется с RouterBench [12].
- 6) Цикл «аудит — правки — переобучение — измерение» воспроизведён 3/3: паста +18,2 п. п., шоколад +16,3 п. п., сыры +14,4 п. п. на проблемных срезах.
- 7) Зафиксированы три принципа проектирования схемы атрибутов (независимость, отказ от мёртвых классов, консервативная агрегация слоёв на правилах; см. 3.3.25). Выделение бинарного атрибута `chocolate.is_filled` как структурного свойства, независимого от `chocolate_type`, повысило макро-F1 атрибута `chocolate_type` с 0,50 (5 классов) до 0,973 (3 класса) при макро-F1 атрибута `is_filled` 0,861 на новой бинарной задаче. Удаление мёртвых классов (полнота $< 0,20$, объём обучающих примеров < 100) дополнительно повысило макро-F1 атрибутов `chocolate_extra` и `cheeses.texture`.
- 8) Устойчивость по языкам (разброс 3 п. п. на 5 языках) и сравнение с лексическим базисом (20 из 20 пар сопоставимо или выше, +25–30 п. п. на нутриент-производных) подтверждены; поатрибутные решения 3.3.25 обеспечивают высокое покрытие слоя машинного обучения при доле обращений к запасному слою большой языковой модели 4,1 %.

4 ОПИСАНИЕ РЕЗУЛЬТАТОВ

4.1 Руководство пользователя

4.1.1 Роли и интерфейсы

Система рассчитана на три роли (анализ — §1.1). Каждая роль работает со своим интерфейсом и решает свой класс задач (таблица 24); права доступа ограничивают каждого пользователя точками управления его компетенции.

Таблица 24 — Соответствие ролей пользователей и интерфейсов системы

Роль	Интерфейс	Класс задач
Контент-менеджер	Веб-интерфейс демо	Выборочная проверка предсказаний, утверждение или отклонение значений атрибутов
Системный аналитик	Конфигурационные файлы порогов, REST API	Настройка порогов уверенности, мониторинг состояния сервиса
Инженер машинного обучения	Скрипты обучения, ноутбук с диагностиками	Переобучение классификаторов и байесовских сетей, прогон диагностик, обновление эталона

Контент-менеджер работает через веб-интерфейс демонстрационного комплекса (рисунок 10): слева — форма ввода партнёр-доступных полей с выбором категории и опциональным указанием ожидаемых значений атрибутов, справа — результат обогащения с агрегированными счётчиками («закрыто X из Y», «уйдут в запасной слой»), таблицей предсказаний и блоком валидации. Каждое значение сопровождается отметкой слоя-источника (правила, машинное обучение, большая языковая модель) и оценкой уверенности; отметка обоснует доверие к предсказанию — слой 1 и слой 4 детерминированы или объяснимы, для слоёв 2–3 показателем служит уверенность. Расхождения с пользовательскими ожиданиями подсвечиваются

отдельной колонкой «введено пользователем». Время ответа на типовом запросе — порядка 50 миллисекунд.

Ввод товара

Режим определения категории

☐ Авто — категорию определяет классификатор

☒ Вручную

Категория

Паста / макароны

Название товара *

Spaghetti #5 Barilla

Бренд / производитель

Barilla

Состав

Durum wheat semolina, water

Количество

500g

☒ brand: n/a (no brand node in validator network)

Ожидаемые значения (опционально)

Без глютена

Да

x

+ добавить атрибут

Примеры:

валидные:

Pasta — Barilla

Chocolate — Lindt 70%

Cheeses — Roquefort PDO

с противоречиями:

White vs. 70% cocoa

Wheat + gluten-free

Подозрительно: dark + contains_nuts

с невалидным вводом:

мусор → Layer -1

пустое название

☐ LLM-fallback при OOD (для эксперимента; в этой версии не активен)

Обогатить

Результат

Категория: **pasta**

Закрыто: 7 / 7 атрибутов

Уйдут в LLM-fallback: 0

Время ответа: 53 мс

ПРЕДСКАЗАНИЯ ПО АТТРИБУТАМ

Невалидных значений от пользователя: 1

АТТРИБУТ	ПРЕДСКАЗАНИЕ	ВВЕДЕНО ПОЛЬЗОВАТЕЛЕМ	СЛОЙ	ВАЛИДАЦИЯ
Тип зерна	wheat confidence 100%	—	ML	—
Форма пасты	spaghetti confidence 100%	—	REGEX	—
is_filled	Нет confidence 99%	—	ML	—
Органик	Нет confidence 97%	—	ML	—
Без глютена	Нет confidence 99%	Да значение не приводится к домену атрибута	ML	невалидный ввод
Веганский	Да confidence 98%	—	ML	—
cuisine_origin	italian confidence 94%	—	ML	—

▼ Валидация (подробно)

Нет флагов.

► Сырой JSON-ответ от gateway

Рисунок 10 — Веб-интерфейс демонстрационной системы (пример обогащения товара «Spaghetti #5 Barilla»)

Системный аналитик настраивает каскад через две точки: словари порогов уверенности (поатрибутно, без переобучения — компромисс «точность ↔ покрытие») и REST API получения состава атрибутов и агрегированного состояния сервиса для интеграции с мониторингом.

Инженер машинного обучения работает со скриптами обучения и

80

ноутбуком диагностик (исполняемый источник §3.3). Цикл переобучения устроен так, что выпуск новой версии моделей не требует перекомпиляции каскада: артефакты переписываются на диске, сервис загружает их при старте. Цикл запускается раз в неделю или раз в месяц (по темпу поступления товаров) и занимает десятки минут на категорию без специализированных ресурсов. Если ключа коммерческой LLM нет, каскад работает в режиме слоёв 1–3 либо переключается на локальный gpt-oss-120b.

4.2 Сценарии применения и порядок внедрения

4.2.1 Встраивание в бизнес-процесс магазина

Каскад занимает место промежуточного сервиса в маршруте товара от поставщика до витрины — вторая позиция четырёхзвенной цепочки §1.1, где сосредоточено узкое место. Внедрение не требует перестройки соседних звеньев: ETL партнёрских фидов и PIM-система работают как раньше, меняется только содержимое процедуры обогащения. Маршрут запроса: партнёрский фид → ETL магазина → /api/enrich (каскад) → выборочная проверка контент-менеджером случаев слоя 4 → PIM-система и витрина.

Главный экономический эффект — перенос ручного труда на выборочную проверку остатка после каскада. По 3.3.4 покрытие каскада (ячеек, на которых слои 1–3 выдали уверенный ответ без обращения к большой языковой модели) — 95,9 %, оставшиеся 4,1 % уходят в запасной слой 4; покрытие производственной цепочки (с учётом удачных ответов слоя 4 и потерь маршрутизатора слоя 0) — 97,3 %. Для новой категории каскад работает в усечённом режиме «слой 1 на общих шаблонах + слой 4» (рабочий, но неоптимальный). По мере накопления сотен размеченных товаров подключается слой 2, а при появлении устойчивых распределений по брендам — слой 3. Имитация холодного старта на четырёх категориях (3.3.25) подтверждает работоспособность архитектуры в этом режиме.

4.2.2 Сценарий многоязычного каталога

paraphrase-multilingual-mpnet-base-v2 даёт единое векторное пространство для пяти доминирующих в Open Food Facts европейских языков, и отдельные модели под каждый язык не нужны. Устойчивость по языкам подтверждена в 3.3.22: разброс между лучшим

(итальянский, 96,0 %) и худшим (французский, 93,2 %) сегментами — 2,8 п. п. на расширенном эталоне (16 461 ячейка в области применимости каскада). Худший сегмент остаётся выше базовой целевой точности 91 %; каскад применим в международных площадках без удвоения затрат на поддержку отдельных моделей под каждый язык.

4.2.3 Применимость в смежных доменах

Архитектура не привязана к пищевому домену: правила слоя 1 переписываются для новой категории, обучение слоёв 2/3 — стандартная процедура. Перенос на электронику (схема атрибутов, серебряная разметка по PhoneDB, демонстрация холодного старта; подробности в разделе «Перспективы развития темы» заключения) подтверждает переносимость. Формальная аудит-оценка вынесена в перспективы развития.

Оценка применимости архитектуры к семи доменам (три уже реализованы в работе, четыре — внешние) приведена в таблице 25. Без изменений переиспользуются слои 0 (маршрутизатор категории), 4 (запасной слой большой языковой модели) и инфраструктурная обвязка (REST API, мониторинг, телеметрия); адаптации требует слой 1 (правила и словари ключевых слов под предметную область) и обучение слоёв 2–3 на новой выборке.

Таблица 25 — Применимость каскадной архитектуры в смежных товарных доменах (оценочно)

Домен	Что переиспользуется	Что требуется адаптировать	Сложность адаптации
Пища (паста, шоколад, сыры)	Реализовано полностью ^a	—	—
Напитки	Реализовано полностью ^a	—	—
Хлопья	Реализовано полностью ^a	—	—
Косметика	Реализовано полностью ^a	—	—

Продолжение таблицы 25

Домен	Что переиспользуется	Что требуется адаптировать	Сложность адаптации
Электроника	Слои 0, 1, 4, инфраструктура	Схема атрибутов, обучение слоёв 2–3 на PhoneDB	Средняя ^b
Бытовая техника	Слои 0, 4, инфраструктура	Правила слоя 1 (модель, объём, мощность), схема, обучение слоёв 2–3	Средняя ^b
Одежда	Слои 0, 4, инфраструктура	Слой 1 фактически отсутствует (нет числовых маркеров), схема, обучение слоя 2 на признаках цвета/размера/материала	Высокая ^c
Игрушки	Слои 0, 4, инфраструктура	Правила возрастных классов (<code>minimal_age</code> уже реализован, см. правил Слой 1), схема, обучение слоёв 2–3	Низкая ^d

Примечание. Сноска «a» — домены реализованы в проекте (см. `src/pipeline/schemas/`, 7 доменных схем); полный конвейер регрессионно проверяется в `src/eval/run_experiments.py`. Сноска «b» — средняя трудоёмкость: 2–4 недели на схему + обучение слоёв 2–3 при наличии источника эталона уровня PhoneDB или USDA. Сноска «c» — высокая трудоёмкость: слой 1 малоэффективен на текстовых полях моды (мало явных детерминированных маркеров), основная работа — сбор обучающей выборки и формирование признаков для слоя 2; ориентировочно 6–10 недель на категорию. Сноска «d» — низкая трудоёмкость: `regex` возрастных классов уже реализован (реализованное правило поддерживает три языка), оставшаяся работа — схема и обучение; ориентировочно 1–2 недели. Все оценки трудоёмкости — ориентир по аналогии с реализованными пищевыми категориями и не учитывают переменные времени получения эталонной выборки.

4.3 Риски развёртывания и план мониторинга

Любой системе машинного обучения в производственном контуре нужна операционная обвязка: одной только метрики на статической тестовой выборке для устойчивой работы во времени мало. Распределение партнёрских

данных меняется, тарифы поставщиков пересматриваются, схема атрибутов эволюционирует. Риски группируются по трём уровням: дрейф входных данных (партнёрский поток отличается от обучающей выборки), дрейф калибровки (растёт ожидаемая ошибка калибровки ЕСЕ, хотя точка оптимума не сдвинулась), устаревание модели (накопилось отставание от текущего состояния каталога без явного дрейфа метрики). Каждый риск сопровождается митигацией и закреплённой зоной ответственности (таблица 26).

Таблица 26 — Реестр операционных рисков системы и закреплённые митигации

Риск	Митигация	Ответственный
Дрейф входных данных (новый партнёр со структурой полей, отличной от обучающей выборки)	Мониторинг поатрибутной точности на свежей подвыборке ручной разметки; сигнал тревоги при падении более чем на 3 п. п. от базового уровня	Инженер машинного обучения
Дрейф калибровки (рост ожидаемой ошибки калибровки сверх 0,07 при целевом значении 0,043 после изотонической калибровки)	Регрессионный тест ожидаемой ошибки калибровки (см. ниже); автоматический прогон на еженедельном срезе свежих предсказаний	Инженер машинного обучения
Истечение тарифа слоя 4 (поставщик коммерческой языковой модели повысил цену либо ввёл квоту)	Авто-переключение слоя 4 на gpt-oss-120b в локальном развёртывании через конфигурацию маршрутизации моделей	Эксплуатация (системный администратор)

Продолжение таблицы 26

Риск	Митигация	Ответственный
Появление новой товарной категории	Холодный старт через слой 1 (правила по общим шаблонам) и слой 4; переобучение слоя 2 после накопления порядка 1 000 учётных позиций товара; см. сценарий 4.2.2	Инженер машинного обучения
Деградация качества модели слоя 4 (поставщик обновил версию без уведомления)	Пилотное развёртывание с долей трафика 5 %; парный критерий Стьюдента для разницы точности на свежей подвыборке ручной разметки; откат на предыдущую версию при значимом ухудшении	Инженер машинного обучения
Изменение схемы атрибутов (добавление/удаление поля, изменение классов)	Версионирование артефактов с указанием идентификатора фиксации, инициализирующего значения генератора случайных чисел и манифеста эталона; явная сверка схемы при загрузке моделей сервисом	Владелец продукта
Сбой внешнего API маршрутизации языковых моделей (OpenRouter)	Запасной слой 4 на локальной модели gpt-oss-120b либо очередь отложенных запросов с приоритетом; для критичных потоков — горячее переключение в течение минут	Эксплуатация (системный администратор)
Утечка персональных данных через слой 4 (партнёрские поля уходят в облачный API)	Опция полностью локального развёртывания с gpt-oss-120b (без обращения вовне); фильтрация поля ingredients_text от персонально идентифицирующих фрагментов до отправки в слой 4	Безопасность

Примечание. Каждая митигация опирается либо на свойство архитектуры, продемонстрированное в §3.3, либо на инструменты, описанные в 3.1.2. Уровень детализации соответствует регламенту эксплуатации и не претендует на полный регистр риск-менеджмента стандарта ISO 31000.

4.3.1 Мониторинг в производственном контуре

Производственный мониторинг каскада строится на четырёх показателях, каждый из которых сопоставим с метрикой главы 3 и допускает автоматический регрессионный контроль: (1) поатрибутная точность на еженедельной подвыборке ручной проверки 200–500 ячеек на категорию — сигнал тревоги при падении больше чем на 3 п. п. от базового уровня 93,0 %; (2) ожидаемая ошибка калибровки поатрибутно с порогом 0,07 относительно целевого 0,043 после изотонической калибровки; (3) доля обращений к слою 4 в 7-дневном скользящем окне относительно базового уровня 4,1 % — сигнал тревоги при выходе свыше 6 %, это указывает на дрейф данных или деградацию калибровки порогов; (4) пилотное развёртывание с долей 5 % трафика при выпуске новой версии слоя 2 или смены модели слоя 4, с парным критерием Мак-Немара для разницы точности и автоматическим откатом при значимом ухудшении ($p < 0,05$). Поэтапное внедрение в производственный контур (теневого запуск → рекомендательный режим → автоматическое заполнение с выборочной проверкой) снижает риск регрессии качества каталога; откат на предыдущую фазу выполняется изменением конфигурации. Переаттестация калибровки делается ежеквартально или по событию срабатывания регрессионного теста ожидаемой ошибки калибровки — подробности процедуры даны в 3.3.11.

4.4 Что позволяет использование разработки (характеристика достигнутых результатов)

Использование системы даёт измеримые эффекты в формате «повышено / ускорено / сокращено». Числа в этом подразделе не пересчитываются заново: их источник — измерения раздела 3.3.4, которые здесь приводятся в форме итогового вывода для пользователя. Доверительные интервалы и методика измерения — в 3.3.4; разбивка по категориям — в таблице 27.

Таблица 27 — Точность каскадной части по категориям (модель Gemini 2.5 Flash, эталон согласия трёх больших языковых моделей, среднее по атрибутам категории)

Категория	Число атрибутов	Точн., %
Паста	7	95,8
Шоколад	6	94,9
Сыры	7	95,8
Взвешенное среднее по каскаду	20	95,5

Примечание. Эталон — согласие трёх больших языковых моделей. Средние по 20 атрибутам (7 паста + 6 шоколад + 7 сыры) рассчитаны с весами по числу ячеек.

Точность — повышена. Сквозная точность системы выросла с 83,8 % (прямой Claude Sonnet 4.5) до 93,0 % («каскад + Gemini 2.5 Flash»); на открытой модели — с 69,3 % (прямой gpt-oss-120b) до 90,6 % («каскад + gpt-oss-120b»). Консервативная нижняя оценка на ручной разметке Claude Opus 4 — 86,7 %. Прирост на нутриент-производных атрибутах даёт слой 2 — большая языковая модель без числового контекста их не вычисляет точно из текста.

Стоимость — сокращена. Каскад обращается к слою 4 только на 4,1 % ячеек: совокупная стоимость снижается на 95,9 % относительно конфигурации «все ячейки — большая языковая модель» (3.3.4). При одинаковой модели слоя 4 каскад дешевле прямого вызова в 24 раза; в сочетании с переходом на дешёвую коммерческую модель (Gemini 2.5 Flash) — в 580 раз относительно прямого Claude Sonnet 4.5. На объёме 100 000 учётных позиций товара в месяц годовая экономия превышает 100 000 долл. США относительно прямого Claude Sonnet 4.5; на масштабе маркетплейса (1 000 000) экономия достигает миллиона долл. США в год. Эффект устойчив к тарифу слоя 4: даже при удорожании выбранной модели в 10 раз каскад остаётся в 58 раз дешевле прямого Claude Sonnet 4.5. Расчёт годового расхода в зависимости от объёма каталога и конфигурации запасного слоя приведён в таблице 28.

Таблица 28 — Годовой расход на обогащение в зависимости от объёма каталога и конфигурации слоя 4 (долл. США в год)

Учётных позиций товара в месяц	Прямой Claude Sonnet 4.5	Прямой Gemini 2.5 Flash	Каскад + Gemini 2.5 Flash	Каскад + gpt-oss-120b
10 000	10 800	270	11	8
100 000	108 000	2 700	110	80
1 000 000	1 080 000	27 000	1 100	800

Примечание. Расчёт: 20 ячеек на одну учётную позицию товара, 12 месяцев, удельные стоимости одной ячейки — 0,00450 долл. США (Claude Sonnet 4.5), 0,0001125 долл. США (Gemini 2.5 Flash), $\approx$ 0,00007 долл. США (gpt-oss-120b). Каскадные конфигурации учитывают долю обращений к слою 4 в размере 4,1 %. Локальное развёртывание дополнительно требует учёта инфраструктуры вывода ($\approx$ 10 долл. США в месяц при реиспользовании имеющихся ресурсов).

Таблица 29 — Сводный эффект разработки на ключевых показателях системы (повышено / сокращено / обеспечено)

Показатель	До разработки	После	Эффект
Сквозная точность системы	83,8 % (опорная конфигурация — прямой Claude Sonnet 4.5)	93,0 % (каскад + Gemini 2.5 Flash; 95,5 % по каскадной части без учёта маршрутизации)	повышена на 9,2 п. п.
Относительная стоимость обработки (архитектурный вклад каскада)	1,000 (опорная конфигурация — прямой Claude Sonnet 4.5)	0,041 при той же модели слоя 4	сокращена на 95,9 % ($\approx$ 24 раза)
Доля обращений к большой языковой модели	100 %	4,1 %	сокращена примерно в 24 раза
Ручная проверка оператором	$\approx$ 100 % ячеек	$\approx$ 4–8 % ячеек	сокращена в 12–25 раз

Продолжение таблицы 29

Показатель	До разработки	После	Эффект
Точность на открытой модели	69,3 % (одиночный вызов gpt-oss-120b)	90,6 % (каскад + gpt-oss-120b)	повышена на 21,3 п. п.
Поддержка многоязычности	отдельные модели на каждый язык либо предварительный перевод	5 рабочих языков в едином векторном пространстве SBERT	обеспечена без дополнительных моделей
Независимость от поставщика большой языковой модели	один интегрированный провайдер	поддержка пяти моделей с сопоставимой точностью	модели можно менять одна на другую

Примечание. Консервативная оценка на полностью ручном эталоне (n=566 ячеек в области применимости каскада из 688 проверенных) даёт 86,7 % сквозной точности и 91,3 % по каскадной части; разрыв с эталоном согласия трёх больших языковых моделей объясняется учётом частичного семантического перекрытия серебряной разметки и эталона (методология 3.3.4).

Сводный эффект разработки по ключевым показателям сведён в таблице 29. Значения столбцов «До» и «После» получены на тестовой выборке без пересечения товарных кодов главы 3.

4.5 Выводы по главе 4

- 1) Целевая аудитория — три роли: контент-менеджер (выборочная проверка через веб-интерфейс), системный аналитик (пороги через конфигурации и REST API), инженер машинного обучения (переобучение по мере поступления данных). Система поддерживает три сценария по выбору слоя 4: Gemini 2.5 Flash (лучший баланс точности и стоимости), премиум-коммерческий (Claude Sonnet 4.5, GPT-4o) и локальный gpt-oss-120b (без зависимости от внешних API при сопоставимой точности).
- 2) Совокупный эффект: архитектурное сокращение стоимости на 95,9 % (≈ 24 раза) относительно конфигурации «все ячейки — большая языковая модель», ручной нагрузки — в 12–25 раз;

сквозная точность 93,0 % (см. 3.3.4); консервативная оценка на полностью ручном эталоне — 86,7 %. Эффект устойчив к разбросу тарифов слоя 4: даже при удорожании выбранной модели в 10 раз каскад остаётся в 58 раз дешевле прямого Claude Sonnet 4.5.

- 3) Производственное развёртывание сопровождается реестром из восьми операционных рисков (дрейф данных, дрейф калибровки, истечение тарифа слоя 4, появление новой категории, деградация качества модели слоя 4, изменение схемы атрибутов, сбой внешнего API, требование локального хранения партнёрских данных) с закреплёнными митигациями; контроль обеспечивают четыре показателя мониторинга (поатрибутная точность, ожидаемая ошибка калибровки, доля обращений к слою 4, пилотное развёртывание).
- 4) Архитектура переносима на смежные товарные домены: переиспользуются слои 0, 4 и инфраструктурная обвязка; адаптации требуют слой 1 (regex под предметную область) и обучение слоёв 2–3 на новой выборке. Имитация холодного старта на четырёх категориях (3.3.25) подтверждает работоспособность архитектуры в режиме без слоя 2.

ЗАКЛЮЧЕНИЕ

В ходе работы разработана гибридная каскадная система автоматизированного обогащения товарных данных для интернет-магазина. Система реализована как программный комплекс с демонстрационным стендом, проверена на выборке без пересечения товарных кодов между обучением и тестом и удовлетворяет шести функциональным, пяти нефункциональным и трём архитектурным требованиям ТЗ.

Достигнутые показатели превосходят целевые ориентиры ТЗ ($\geq 85\%$ точности, $\geq 2,5\times$ сокращения стоимости): сквозная точность $93,0\%$, стоимость сокращена в 580 раз относительно прямого Claude Sonnet 4.5 в режиме «каскад + Gemini 2.5 Flash». Каскад покрывает $97,3\%$ ячеек; в запасной слой уходит $4,1\%$.

Сводные выводы по главам

Глава 1 систематизирует литературу и обосновывает противоречие. PIM-системы (Akeneo [5], Pimcore [6], Salsify [7]) нацелены на хранение и распределение, а появляющиеся модули обогащения функционально сводятся к проксированию запросов к одной большой языковой модели. Академические подходы делятся надвое: специализированные системы извлечения признаков (TXtract [26], MAVe [27], OpenTag [28]) дают качество без учёта экономики; каскады больших языковых моделей с учётом стоимости (FrugalGPT [9], AutoMix [10], Hybrid LLM [11], RouterBench [12]) управляют стоимостью, но не интегрируют классическое машинное обучение. Из противоречия выведена гипотеза о каскаде разнородных слоёв и сформировано ТЗ.

Глава 2. Задача формализована как поатрибутное предсказание со схемой, допускающей явный отказ. Логика — каскад из пяти слоёв с последовательной фильтрацией: предсказание Слоя 2 принимается только при одновременном выполнении $P_{ML} \geq \tau_k$ и $P_B \geq \theta_k$ как конъюнктивное условие ансамблевой оценки уверенности. Архитектурный выбор каждой компоненты (SBERT, XGBoost, pgmpy, Go-шлюз + Python-ML, открытая gpt-oss-120b) обоснован эксплуатационно и методологически.

Глава 3. Каскад реализован как трёхкомпонентный комплекс (Go-шлюз, Python/FastAPI ML-сервис, статический веб-интерфейс); состав — 21

поатрибутный XGBoost, три байесовские сети и Слой 0. На локальном сценарии «каскад + gpt-oss-120b» точность 90,6 % (на 21,3 п. п. выше самостоятельной модели). Консервативная нижняя оценка на ручной разметке Claude Opus 4 (n=566) — 86,7 %. Заранее объявленная гипотеза H1 о превосходстве обучаемого маршрутизатора отклонена; цикл «аудит — правки — переобучение — измерение» воспроизведён на трёх категориях из трёх.

Глава 4 переводит результаты в плоскость применения: три сценария по выбору Слоя 4 (Gemini 2.5 Flash, Claude Sonnet 4.5 / GPT-4o, локальная gpt-oss-120b) и три ролевые модели (контент-менеджер, системный аналитик, инженер машинного обучения). Сокращение ручной нагрузки оператора каталога — в 12–25 раз.

Заккрытие формулировок утверждённой темы

Утверждённая тема работы содержит восемь содержательных формулировок. Каждой из них в работе соответствует конкретный раздел, а также архитектурный или экспериментальный компонент разработки. Соответствие приведено в таблице 30.

Таблица 30 — Соответствие формулировок утверждённой темы и разделов работы

Формулировка из обоснования актуальности темы	Реализация в работе	Раздел
Гибридная каскадная система	Пятислойная архитектура каскада (Слой 0 + четыре содержательных слоя)	2.2, 3.1
Семантические возможности генерирующих моделей	Запасной слой 4 на основе большой языковой модели	3.1.1
Предсказательная сила классического машинного обучения	Слой 2 — поатрибутные классификаторы XGBoost на многоязычных векторных представлениях SBERT	3.1.1
Ансамблевая оценка уверенности моделей	Пошаговая фильтрация по уверенности как последовательное конъюнктивное условие на калиброванные пороги слоёв	2.1

Продолжение таблицы 30

Формулировка из обоснования актуальности темы	Реализация в работе	Раздел
Отбраковка фактических ошибок до их попадания в каталог	Слой 3 — байесовский валидатор плотностей пар «бренд × значение»	3.1.1, 3.3.4
Скрытые статистические закономерности каталога	Направленный ациклический граф атрибутов, построенный алгоритмом Hill Climb с критерием BIC	3.1.1
Эксперименты с разнородными источниками данных	OCR-извлечение из изображений Open Food Facts (EasyOCR) и векторные представления CLIP (ViT-B/32) проверены как дополнительный обучающий сигнал, в производственный каскад не включены (см. 3.2.2); сверка эталона яруса 0 с базой USDA Branded Foods через приближённое сопоставление	3.2.5
Интернет-магазин (партнёр — каталог — витрина)	Демонстрационный программный комплекс с REST-интерфейсом обработки партнёрского ввода и руководством пользователя	1.1, 3.1.2, 4.1

Наиболее нагруженные формулировки темы — отбраковка фактических ошибок и использование скрытых статистических закономерностей каталога — закрыты байесовским валидатором с пересмотренной ролью: вместо самостоятельного классификатора сеть используется как валидатор плотностей.

Научная новизна

Научная новизна работы складывается из трёх содержательных пунктов.

- 1) Доминирование по Парето каскадной архитектуры над всеми безусловными конфигурациями большой языковой модели на задаче обогащения товарных атрибутов. Одновременно

достигаются: превышение точности на 9,2 процентных пункта (93,0 % против 83,8 %) и сокращение стоимости в 580 раз по сравнению с прямым обращением к Claude Sonnet 4.5 (сюда входит архитектурный вклад каскада в 24 раза и удешевление модели запасного слоя). Результат подтверждён на проверочной выборке без пересечения товарных кодов между обучением и тестом из 16 360 ячеек и воспроизведён на пяти разных моделях запасного слоя. Следовательно, эффект сохраняется при смене поставщика генеративной модели.

- 2) Сценарий развёртывания на собственных мощностях с открытой большой языковой моделью. Каскад с открытой моделью gpt-oss-120b достигает 90,6 % сквозной точности — на 21,3 процентных пункта выше, чем самостоятельное применение той же модели (69,3 %). Каскадная композиция компенсирует слабость малых открытых моделей через специализированные слои, обеспечивая локальное развёртывание без передачи партнёрских данных во внешние сервисы.
- 3) Заранее объявленный отрицательный результат для обучаемого стоимостно-чувствительного маршрутизатора и перенос цикла «аудит — исправления — переобучение — измерение» на категории внутри продуктового домена. Получено эмпирическое подтверждение, согласующееся с выводами бенчмарка RouterBench [12]: гипотеза о превосходстве обучаемого XGBoost-маршрутизатора над статическим правилом отклоняется на трёх бюджетах с поправкой Бонферрони. Цикл аудита эталонной разметки воспроизведён на трёх категориях из трёх с количественно измеримым приростом сквозной точности.

Ограничения работы

Зафиксированы следующие ограничения.

- 1) Область определения — три категории пищевой продукции; переносимость на другие домены не проверена.
- 2) Эталон — сочетание слабого надзора и согласия трёх больших языковых моделей со слепой проверкой Claude Opus 4. Это эталонная разметка яруса аудита, не ручная экспертная.

- 3) Мультимодальные сигналы (оптическое распознавание текста и векторные представления CLIP) проверены как дополнительные обучающие признаки, но в каскад не включены — прироста выше шума не получено.
- 4) Проверка велась на пяти европейских языках; устойчивость к другим письменностям не оценивалась.
- 5) Заранее объявлена только гипотеза H1; показатели 3.3.4 получены апостериорным анализом.
- 6) Разбиение на обучающую и тестовую части основной оценки — по товарным кодам, при этом бренды пересекаются на 82–85 %. Контрольное исследование без пересечения брендов (см. 3.3.6) даёт деградацию слоя машинного обучения 0,5 п. п. (83,0 % → 82,6 %) — обобщающая способность каскада на новых брендах сохраняется.
- 7) Измеренная точность подвержена циркулярному смещению из-за частичного семантического перекрытия серебряной разметки и эталона. Операционная оценка смещения — 4,2 п. п. для каскадной части и 6,3 п. п. для сквозной; консервативная независимая оценка — 86,7 % на ручной разметке Claude Opus 4.

Точечный характер байесовского валидатора (значимый прирост точности отбраковки на 3 парах из 20) фиксируется явно как ограничение архитектуры. Из 20 пар «категория-атрибут» в производственной конфигурации валидатор включён точно только на одной паре `chocolate/contains_nuts`, где даёт +6,6 п. п. точности при росте расходов на 5,3 п. п. (3.3.4). На остальных 19 парах сигнал слишком слабый, чтобы вернуть валидатор в архитектуру. Принцип «изменение роли компонента вместо его удаления» сформулирован в 3.1.1 и 3.3.4 как самостоятельный методологический вывод; при этом тематически нагруженная формулировка «отбраковки фактических ошибок» в текущей реализации обеспечивается одной парой и не имеет универсального решения.

Перспективы развития темы

Полученные результаты и зафиксированные ограничения задают ряд направлений развития темы.

- 1) Расширение области определения до шести категорий — напитки, зерновые завтраки и косметика. Для них подготовлены схемы

атрибутов и серебряная разметка; основной блок — построение эталонной разметки уровня v2 (ярус аудита) и обучение поатрибутных классификаторов Слоя 2. Методология аудита и переобучения переносится без принципиальных изменений.

- 2) Регулярная переаттестация изотонической калибровки и регрессионный контроль ECE на следующих итерациях эталона. Схема перекрёстной калибровки реализована (3.3.11, средняя ECE снижается с 0,070 до 0,043); регрессионный тест ECE с порогом 0,01 реализован в наборе модульных тестов системы.
- 3) Введение мультимодального вывода в производственный режим — расширение прикладного интерфейса на приём изображений и добавление OCR/CLIP в реальном времени; потребует пересмотра контракта взаимодействия с партнёром.
- 4) Полноценный пилот активного обучения с человеческой разметкой [33; 49]. Симуляция на ячейках расхождения каскада и согласия трёх больших языковых моделей (3.3.24) не показала превосходства активной стратегии над случайной, но пул кандидатов был искусственно ограничен каскадом. Перспектива — независимая разметка ячеек-кандидатов (бюджет ≈ 600 ячеек на категорию) и измерение прироста Слоя 2 относительно случайной разметки той же стоимости.
- 5) Локализация на русский язык и российские каталоги — разработка русскоязычных регулярных выражений Слоя 1 и дообучение Слоя 2 на каталогах российских ритейлеров. SBERT поддерживает русский в едином векторном пространстве, поэтому трудоёмкость ограничена Слоями 1–2.
- 6) Перенос архитектуры в непродовольственные домены, начиная с электроники. Для смартфонов из каталога PhoneDB подготовлены схема атрибутов и демонстрация холодного старта; полноценное измерение требует эталонной разметки уровня v2 (ярус аудита) и оценки на выборке без пересечения товарных кодов между обучением и тестом.

Полученные результаты подтверждают выдвинутую в первой главе архитектурную гипотезу о каскадной композиции и закрывают все восемь содержательных формулировок утверждённой темы.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Итоги интернет-торговли в России за 2025 год : пресс-релиз АКИТ от 19.02.2026 г. — М. : Ассоциация компаний интернет-торговли. — 2025. — URL: <https://akit.ru/news/11-5-trln-rublej-akit-podvela-itogi-internet-torgovli-za-2025-god> (дата обращения 19.05.2026).
2. Global Retail E-Commerce Forecast 2024 : research report. — eMarketer. — 2024. — URL: <https://www.emarketer.com> (дата обращения 03.05.2026).
3. SellerFox : отраслевой обзор индекса каталога Ozon (более 38 млн позиций на 2025 г.) — 2026. — URL: <https://sellerfox.ru> (дата обращения 19.05.2026).
4. Как ускорить работу с товарными карточками в 30 раз : отраслевой кейс / Retail.ru. — 2026. — URL: <https://www.retail.ru/articles/kak-uskorit-rabotu-s-tovarnymi-kartochkami-v-30-raz/> (дата обращения 19.05.2026).
5. Akeneo PIM : open product experience management platform. — Akeneo SAS. — 2026. — URL: <https://akeneo.com> (дата обращения 03.05.2026).
6. Pimcore Platform : open-source data and experience management. — Pimcore GmbH. — 2026. — URL: <https://pimcore.com> (дата обращения 03.05.2026).
7. Salsify Inc. : product experience management platform. — 2026. — URL: <https://www.salsify.com> (дата обращения 19.05.2026).
8. Open source в России 2024 : аналитический отчёт. — М. : Platform V, СберТех. — 2024. — URL: <https://platformv.sbertech.ru/open-source-v-rossii-2024> (дата обращения 19.05.2026).
9. Chen L., Zaharia M., Zou J. FrugalGPT: How to Use Large Language Models While Reducing Cost and Improving Performance // Transactions on Machine Learning Research. — 2024. — URL: <https://openreview.net/forum?id=cSimKw5p6R>.
10. Aggarwal P., Madaan A., Yang Y., Mausam. AutoMix: Automatically Mixing Language Models // Advances in Neural Information Processing Systems (NeurIPS 2024). — 2024. — URL: https://proceedings.neurips.cc/paper_files/paper/2024/hash/45046ce81d6b04432754dd62f8b27a36-Abstract-Conference.html.

11. Ding D., Mallick A., Wang C., Sim R., Mukherjee S., Rühle V., Lakshmanan L. V. S., Awadallah A. H. Hybrid LLM: Cost-Efficient and Quality-Aware Query Routing // ICLR 2024. — 2024. — URL: <https://openreview.net/forum?id=02f3mUtqnM>.
12. Hu Q. J., Bieker J., Li X., Jiang N., Keigwin B., Ranganath G., Keutzer K., Upadhyay S. K. RouterBench: A Benchmark for Multi-LLM Routing System : препринт. — arXiv:2403.12031. — 2024. — URL: <https://arxiv.org/abs/2403.12031> (дата обращения 19.05.2026).
13. Open Food Facts : open product database for food products. — 2026. — URL: <https://world.openfoodfacts.org/data> (дата обращения 03.05.2026).
14. Долгорукова С. А. Управление нормативно-справочной информацией. Сравнительный анализ платформ // Научные записки молодых исследователей. — 2014. — URL: [https://cyberleninka.ru/article/n/upravlenie-normativno - spravochnoy - informatsiy - sravnitelnyy - analiz - platform](https://cyberleninka.ru/article/n/upravlenie-normativno-spravochnoy-informatsiy-sravnitelnyy-analiz-platform) (дата обращения 23.05.2026).
15. Ермакова Л. М. Методы извлечения информации из текста // Вестник Пермского университета. Серия: Математика. Механика. Информатика. — Вып. 1 (9). — 2012. — URL: <https://cyberleninka.ru/article/n/metody-izvlecheniya-informatsii-iz-teksta> (дата обращения 23.05.2026).
16. Ванюшкин А. С., Гращенко Л. А. Методы и алгоритмы извлечения ключевых слов // Новые информационные технологии в автоматизированных системах. — 2016. — URL: <https://cyberleninka.ru/article/n/metody-i-algoritmy-izvlecheniya-klyuchevyh-slov> (дата обращения 23.05.2026).
17. Chen T., Guestrin C. XGBoost: A Scalable Tree Boosting System // Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD'16). — San Francisco : ACM. — P. 785–794. — 2016.
18. Ke G., Meng Q., Finley T., Wang T., Chen W., Ma W., Ye Q., Liu T.-Y. LightGBM: A Highly Efficient Gradient Boosting Decision Tree // Advances in Neural Information Processing Systems. — Vol. 30. — P. 3146–3154. — 2017.

19. Афанасьев Г. И., Афанасьев А. Г., Бурмистрова М. В., Тэт Вей Ян Со. Исследование методов машинного обучения для прогнозирования эффективных бизнес-решений в системах электронной коммерции // E-Scio. — 2022. — URL: <https://cyberleninka.ru/article/n/issledovanie-metodov-mashinnogo-obucheniya-dlya-prognozirovaniya-effektivnyh-biznes-resheniy-v-sistemah-elektronnoy-kommertsii> (дата обращения 19.05.2026).
20. Vaswani A., Shazeer N., Parmar N. et al. Attention Is All You Need // Advances in Neural Information Processing Systems. — Vol. 30. — P. 5998–6008. — 2017. — URL: <https://papers.nips.cc/paper/7181-attention-is-all-you-need>.
21. Devlin J., Chang M.-W., Lee K., Toutanova K. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding // NAACL-HLT 2019. — ACL. — P. 4171–4186. — 2019. — URL: <https://aclanthology.org/N19-1423/>.
22. Reimers N., Gurevych I. Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks // EMNLP 2019. — Hong Kong : ACL. — P. 3982–3992. — 2019. — URL: <https://aclanthology.org/D19-1410/>.
23. Reimers N., Gurevych I. Making Monolingual Sentence Embeddings Multilingual using Knowledge Distillation // EMNLP 2020. — ACL. — P. 4512–4525. — 2020. — URL: <https://aclanthology.org/2020.emnlp-main.365/>.
24. Колонин А. Г. High-performance automatic categorization and attribution of inventory catalogs : препринт. — arXiv:2202.08965. — 9 p. — 2022. — URL: <https://arxiv.org/abs/2202.08965> (дата обращения 19.05.2026).
25. Большакова Е. И., Воронцов К. В., Ефремова Н. Э., Клышинский Э. С., Лукашевич Н. В., Сапин А. С. Автоматическая обработка текстов на естественном языке и анализ данных : учебное пособие. — М. : Изд-во НИУ ВШЭ. — 269 с. — 2017. — URL: https://www.hse.ru/data/2017/08/12/1174382135/NLP_and_DA.pdf (дата обращения 19.05.2026).
26. Karamanolakis G., Ma J., Dong X. L. TXtract: Taxonomy-Aware Knowledge Extraction for Thousands of Product Categories // ACL 2020. — P. 8489–8502. — 2020. — URL: <https://aclanthology.org/2020.acl-main.751/>.
27. Yang L., Wang Q., Yu Z., Kulkarni A., Sanghai S., Shu B., Elsas J., Kanagal B. MAVe: A Product Dataset for Multi-source Attribute Value Extraction // WSDM 2022. — P. 1256–1265. — 2022. — URL: <https://dl.acm.org/doi/10.1145/3488560>.

28. Zheng G., Mukherjee S., Dong X. L., Li F. OpenTag: Open Attribute Value Extraction from Product Profiles // KDD 2018. — P. 1049–1058. — 2018. — URL: <https://dl.acm.org/doi/10.1145/3219819.3219839>.

29. Yang L., Wang Q., Chi J., Liu J., Wang J., Feng F., Xu Z., Fang Y., Huang L., Liu D. EAVE: Efficient Product Attribute Value Extraction via Lightweight Sparse-layer Interaction // Findings of ACL: EMNLP 2024. — Miami, FL : ACL. — P. 1491–1505. — DOI: 10.18653/v1/2024.findings-emnlp.80. — 2024. — URL: <https://aclanthology.org/2024.findings-emnlp.80/> (дата обращения 28.05.2026).

30. Fang C., Li X., Fan Z., Xu J., Nag K., Korpeoglu E., Kumar S., Achan K. LLM-Ensemble: Optimal Large Language Model Ensemble Method for E-commerce Product Attribute Value Extraction // SIGIR 2024. — Washington, DC : ACM. — P. 2910–2914. — DOI: 10.1145/3626772.3661357. — 2024. — URL: <https://dl.acm.org/doi/10.1145/3626772.3661357> (дата обращения 28.05.2026).

31. Ong I., Almahairi A., Wu V., Chiang W.-L., Wu T., Gonzalez J. E., Kadous M. W., Stoica I. RouteLLM: Learning to Route LLMs with Preference Data // ICLR 2025. — 2025. — URL: <https://openreview.net/forum?id=8sSqNntaMr> (дата обращения 28.05.2026).

32. Ratner A., Bach S. H., Ehrenberg H. R., Fries J., Wu S., Ré C. Snorkel: Rapid Training Data Creation with Weak Supervision // Proceedings of the VLDB Endowment. — Vol. 11, № 3. — P. 269–282. — 2017.

33. Settles B. Active Learning Literature Survey. — University of Wisconsin–Madison. — Computer Sciences Technical Report 1648. — 2010. — URL: <https://burrsettles.com/pub/settles.activelearning.pdf> (дата обращения 19.05.2026).

34. Дюк В. А. Экспериментальное исследование реакции алгоритмов машинного обучения на ошибки разметки данных // Дифференциальные уравнения и процессы управления. — № 3. — 2022. — URL: <https://cyberleninka.ru/article/n/eksperimentalnoe-issledovanie-reaktsii-algoritmov-mashinnogo-obucheniya-na-oshibki-razmetki-dannyh> (дата обращения 23.05.2026).

35. Platt J. C. Probabilistic Outputs for Support Vector Machines and Comparisons to Regularized Likelihood Methods // Advances in Large Margin Classifiers. — MIT Press. — P. 61–74. — 1999.

36. Niculescu-Mizil A., Caruana R. Predicting Good Probabilities with Supervised Learning // ICML 2005. — Bonn : ACM. — P. 625–632. — 2005.
37. Guo C., Pleiss G., Sun Y., Weinberger K. Q. On Calibration of Modern Neural Networks // ICML 2017. — PMLR. — Vol. 70. — P. 1321–1330. — 2017.
38. Шунина Ю. С., Алексеева В. А., Клячкин В. Н. Критерии качества работы классификаторов // Вестник Ульяновского государственного технического университета. — 2015. — URL: <https://cyberleninka.ru/article/n/kriterii-kachestva-raboty-klassifikatorov> (дата обращения 23.05.2026).
39. Ковалев А. А., Кузнецов Б. К., Ядченко А. А., Игнатенко В. А. Оценка качества бинарного классификатора в научных исследованиях // Проблемы здоровья и экологии. — Т. 4, № 66. — С. 105–113. — 2020. — URL: <https://cyberleninka.ru/article/n/otsenka-kachestva-binarnogo-klassifikatora-v-nauchnyh-issledovaniyah> (дата обращения 23.05.2026).
40. Kohavi R. A Study of Cross-Validation and Bootstrap for Accuracy Estimation and Model Selection // IJCAI 1995. — Morgan Kaufmann. — P. 1137–1143. — 1995.
41. Wilson E. B. Probable Inference, the Law of Succession, and Statistical Inference // Journal of the American Statistical Association. — Vol. 22, № 158. — P. 209–212. — 1927.
42. Pearl J. Probabilistic Reasoning in Intelligent Systems: Networks of Plausible Inference. — San Francisco : Morgan Kaufmann. — 552 p. — 1988.
43. Heckerman D., Geiger D., Chickering D. M. Learning Bayesian Networks: The Combination of Knowledge and Statistical Data // Machine Learning. — Vol. 20, № 3. — P. 197–243. — 1995.
44. Тулупьев А. Л., Николенко С. И., Сироткин А. В. Байесовские сети: логико-вероятностный подход. — СПб. : Наука. — 607 с. — 2006.
45. Ankan A., Panda A. pgmpy: Probabilistic Graphical Models using Python // SciPy 2015. — P. 6–11. — 2015.
46. Schwarz G. Estimating the Dimension of a Model // Annals of Statistics. — Vol. 6, № 2. — P. 461–464. — 1978.

47. Артемов А. А. Модели машинного обучения в FMCG-ритейле: архитектура и эксплуатация в условиях высокой изменчивости данных // Вестник науки. — 2025. — URL: <https://cyberleninka.ru/article/n/modeli-mashinnogo-obucheniya-v-fmcg-riteyle-arhitektura-i-ekspluatatsiya-v-usloviyah-vysokoy-izmenchivosti-dannyh> (дата обращения 19.05.2026).

48. Сергеев С. А. Управление запасами в условиях маркетплейсов: почему не работают стандартные методы? // Вестник Академии знаний. — 2024. — URL: <https://cyberleninka.ru/article/n/upravlenie-zapasami-v-usloviyah-marketpleysov-pochemu-ne-rabotayut-standartnye-metody> (дата обращения 19.05.2026).

49. Гилязов Р. А., Турдаков Д. Ю. Активное обучение и краудсорсинг: обзор методов оптимизации разметки данных // Труды Института системного программирования РАН. — Т. 30, № 2. — С. 215–250. — DOI: 10.15514/ISPRAS-2018-30(2)-11. — 2018. — URL: <https://cyberleninka.ru/article/n/aktivnoe-obuchenie-i-kraudsorsing-obzor-metodov-optimizatsii-razmetki-dannyh> (дата обращения 19.05.2026).

50. Хорошевский В. Ф. Пространства знаний в сети Интернет и Semantic Web (Часть 1) // Искусственный интеллект и принятие решений. — 2008. — 2008. — URL: http://aidt.ru/index.php?Itemid=114&catid=43&id=137&lang=ru&option=com_content&view=article (дата обращения 19.05.2026).

51. Brown T. B., Mann B., Ryder N. et al. Language Models are Few-Shot Learners // Advances in Neural Information Processing Systems. — Vol. 33. — P. 1877–1901. — 2020. — URL: <https://papers.nips.cc/paper/2020/hash/1457c0d6bfc4967418bfb8ac142f64a-Abstract.html>.

52. Anthropic. Introducing Claude Sonnet 4.5 : анонс модели. — Anthropic, 29.09.2025. — 2025. — URL: <https://www.anthropic.com/news/claude-sonnet-4-5> (дата обращения 03.05.2026).

53. Breiman L. Random Forests // Machine Learning. — Vol. 45, № 1. — P. 5–32. — 2001.

54. Hastie T., Tibshirani R., Friedman J. The Elements of Statistical Learning: Data Mining, Inference, and Prediction. 2nd ed. — New York : Springer. — 745 p. — 2009.
55. Shwartz-Ziv R., Armon A. Tabular Data: Deep Learning is Not All You Need // Information Fusion. — Vol. 81. — P. 84–90. — 2022.
56. McElfresh D., Khandagale S., Valverde J., Prasad V., Ramakrishnan G., Goldblum M., White C. When Do Neural Nets Outperform Boosted Trees on Tabular Data? // Advances in Neural Information Processing Systems. — Vol. 36 (NeurIPS 2023 Datasets and Benchmarks Track). — 2023.
57. Radford A., Kim J. W., Hallacy C. et al. Learning Transferable Visual Models From Natural Language Supervision // ICML 2021. — PMLR. — P. 8748–8763. — 2021. — URL: <https://proceedings.mlr.press/v139/radford21a.html>.
58. USDA FoodData Central : public nutrient database, SR Legacy release. — U. S. Department of Agriculture, Agricultural Research Service. — 2026. — URL: <https://fdc.nal.usda.gov> (дата обращения 03.05.2026).

ПРИЛОЖЕНИЕ А

Электронные материалы

На рисунке А.1 приведён QR-код со ссылкой на репозиторий с исходным кодом, ноутбуком §3.3 в исполняемом виде, демонстрационным программным комплексом и текстом настоящей работы.



Рисунок А.1 — QR-код на репозиторий проекта

Полная схема целевых атрибутов системы по трём категориям приведена в таблице А.1. Тип атрибута: *бинарная* — два класса; *классификация* — более двух категориальных классов; *упорядоченная* — классы с естественным порядком. Ярус эталона определён в §3.2.2.

Таблица А.1 — Полная схема целевых атрибутов системы

Атрибут	Тип	Классов	Ярус эталона
Паста (8 атрибутов)			
grain_type (тип зерна)	классификация	4	2
pasta_shape (форма пасты)	классификация	12	2
is_filled (с начинкой)	бинарная	2	2
is_gluten_free (без глютена)	бинарная	2	1
is_organic (органический)	бинарная	2	1
is_vegan (веганский)	бинарная	2	1
cuisine_origin (кухня)	классификация	6	2
protein_class (класс белка)	упорядоченная	4	0
Шоколад (6 атрибутов)			
chocolate_type (тип шоколада)	классификация	3	2
is_filled (с начинкой)	бинарная	2	2

Продолжение таблицы А.1

Атрибут	Тип	Классов	Ярус эталона
chocolate_extra (доп. ингредиенты)	классификация	5	2
contains_nuts (содержит орехи)	бинарная	2	2
is_organic (органический)	бинарная	2	1
flavor_profile (вкусовой профиль)	классификация	5	2
Сыры (7 атрибутов)			
milk_source (вид молока)	классификация	4	2
texture (текстура)	классификация	4	2
country_of_origin (страна происхождения)	классификация	8	2
aging (выдержка)	упорядоченная	4	2
is_pdo (защищённое наименование)	бинарная	2	1
is_organic (органический)	бинарная	2	1
is_ultra_processed (ультра-обработанный)	бинарная	2	2

Примечание. Ярус 0 эталона — детерминированное бакетирование числовых полей нутриентов; ярус 1 — регуляторные теги Open Food Facts; ярус 2 — согласие трёх больших языковых моделей со слепой проверкой Claude Opus 4 (см. §3.2.2). Ярус эталонной разметки — не то же самое, что слой каскада (Слои 0–4 описаны в §3.1.1).