

Система автоматизированного обогащения товарных данных для интернет-магазина

Фролов М. А.

Московский авиационный институт (национальный исследовательский университет)

Институт № 8 «Компьютерные науки и прикладная математика»

Образовательный центр Института № 8

Выпускная квалификационная работа

Программа «Продуктовая разработка и разработка программных систем»

Научный руководитель: Судаков В. А., д. т. н., профессор образовательного центра Института № 8

Москва, 2026

Проблемы практики обогащения товарных каталогов

- ▶ Каталоги интернет-магазинов — **десятки миллионов** карточек; качество атрибутов определяет поиск, фильтры и рекомендации.
- ▶ РИМ-системы **хранят** атрибуты, но не извлекают их из текста; партнёры присылают лишь базовые поля (название, бренд, состав) — **50–90 %** целевых атрибутов приходят пустыми.
- ▶ **Ручное** заполнение не масштабируется на 10^7 карточек × десятки атрибутов — новые товары выходят с задержкой.
- ▶ **Прямой вызов** большой языковой модели (БЯМ, англ. LLM) на каждую ячейку возможен технически, но экономически неприемлем.

Область и направление исследования


Область исследования.

Обогащение карточек товаров в системах управления каталогом (PIM) интернет-магазинов — заполнение целевых атрибутов из неструктурированных партнёрских полей.

Направление исследования.

Автоматизация поатрибутного заполнения гибридной каскадной системой с маршрутизацией между слоями разной стоимости.

Место и роль программного средства



Цель, задачи, объект, предмет

Цель. Разработать программное средство автоматизированного обогащения карточек товаров на основе гибридной каскадной архитектуры с поатрибутной маршрутизацией, обеспечивающее заданную точность при кратно меньшей стоимости, чем прямой вызов большой языковой модели.

Задачи

1. Спроектировать каскад с поатрибутной политикой.
2. Реализовать слои как независимо обновляемые компоненты.
3. Подготовить эталон и контроль без пересечения кодов.
4. Оценить точность и стоимость; сравнить с прямой БЯМ.
5. Реализовать программный комплекс (REST + Web-UI).

Объект. Процессы обогащения карточек товаров атрибутными значениями из неструктурированных партнёрских полей.

Предмет. Методы и алгоритмы автоматического заполнения атрибутов гибридными каскадными системами с поатрибутной маршрутизацией.

Данные и протокол оценки

Источник. Open Food Facts — 4,5 млн карточек на разных языках (~40 % фр., 10 % англ., 7 % нем., 43 % др.); отсюда выбор многоязычного векторного представления.

3 категории пищевых продуктов — **21 пара** «категория–атрибут» (разбивка справа).

Эталон. Два уровня: основной — консенсус трёх БЯМ ($n = 16\,360$); контрольный — независимая ручная разметка ($n = 566$, даёт нижнюю оценку точности).

Разбиение. Обучающая и тестовая выборки **не пересекаются по товарным кодам** — один товар не попадает в обе.

Одна многоязычная модель — новые языки без дообучения, разброс точности $\leq 2,8$ пп.

Категория	Атрибутов
Паста	8
Шоколад	6
Сыры	7
<i>Перенос:</i>	
Электроника	8

Научная и практическая значимость

Научная значимость.

- ▶ **Гетерогенный каскад** (правила, машинное обучение, большая языковая модель) с поатрибутной маршрутизацией — в отличие от однотипных БЯМ-каскадов (FrugalGPT, AutoMix): на задаче обогащения каталогов одновременный выигрыш по точности и стоимости над прямым вызовом БЯМ.
- ▶ **Методика** поатрибутной маршрутизации по **калиброванной уверенности**: каждый атрибут передаётся на следующий слой по своему порогу.

Практическая значимость.

- ▶ Кратное сокращение стоимости обработки и ручной нагрузки контент-менеджеров при автоматическом заполнении атрибутов каталога.

Состав требований к программному средству


Функциональные (ФР)

- ▶ **F1.** Возврат значения целевого атрибута либо явный отказ.
- ▶ **F2.** Слой-источник предсказания.
- ▶ **F3.** Калиброванная уверенность $c \in [0, 1]$.
- ▶ **F4.** Эскалация на запасной слой.
- ▶ **F5.** Байес-валидация подозрительных предсказаний.
- ▶ **F6.** Поатрибутная настройка через конфиг.

Нефункциональные (НФР)

- ▶ **N1.** Точность $\geq 85\%$ (каскад) / $\geq 90\%$ (+ БЯМ).
- ▶ **N2.** Стоимость снижена в $\geq 2,5\times$ раз vs прямой БЯМ.
- ▶ **N3.** Время отклика ≤ 500 мс (каскад) / ≤ 5 с (БЯМ).
- ▶ **N4.** Многоязычность (≥ 5 языков).
- ▶ **N5.** Локальное развёртывание (без внешних API).

Функциональное представление архитектуры



Назначение слоёв каскада

Слой	Что делает	Когда не справляется	Доля
L0 марш-рутизатор	XGBoost по векторному представлению определяет категорию либо помечает её неизвестной	Ни одна из известных категорий не выше порога $\Rightarrow$ сразу в L4	—
L1 regex	Прецизионные поатрибутные шаблоны	Нет устойчивого шаблона $\Rightarrow$ L2	21,9 %
L2 ML	XGBoost на 768-мерном векторном представлении	Уверенность ниже поатрибутного порога $\Rightarrow$ L3	73,2 %
L3 Bayes	Валидатор согласованности предсказаний L2 с другими атрибутами	Предсказание несовместимо с остальными атрибутами $\Rightarrow$ L4	0,8 %
L4 LLM	gpt-oss-120b / Sonnet 4.5 / Gemini Flash	Последний слой; null только при нарушении схемы ответа	4,1 %


Слой 2: выбор алгоритма классификации

Четыре алгоритма обучены на одном векторном представлении. XGBoost выбран не по максимуму точности, а по **качеству калибровки** (ошибка ECE): только у него уверенность модели соответствует реальной доле верных ответов — это нужно для корректных поатрибутных порогов. Сам классификатор сменяется через конфигурацию.

Метод	Точность	Макро-F1	ECE	Обучение
XGBoost	92,02 %	0,849	0,026	1062 с
MLP	92,67 %	0,857	0,031	54 с
Логистическая регрессия	91,85 %	0,836	0,035	8 с
Random Forest	89,94 %	0,809	0,027	523 с


Нейросеть точнее на 0,65 пп, но хуже калибрована (ECE **0,031** против **0,026**): при поатрибутных порогах важнее калибровка.

Какой слой заполняет какие атрибуты



Исключены 3 тривиальных атрибута (100 % Слой 1, правила): pasta.is_filled, chocolate.is_filled, chocolate.contains_nuts

Байесовская сеть: валидатор, а не классификатор



Что это.

Граф вероятностных связей между атрибутами. Рёбра выводятся из данных (Hill Climbing по критерию BIC), вероятности — частотной оценкой.

Роль — контролёр, не классификатор.

Сама предсказывает слабо ($\approx 52\%$), но отмечает маловероятные сочетания атрибутов как подозрительные.

Где помогает.

Один атрибут из 21 — орехи в шоколаде: **+6,6 пп** точности (важно для аллергиков) при **+5,3 пп** обращений к запасному слою.

Красным — единственная активная связь валидатора.

Байесовский контроль: орехи в шоколаде

Единственный атрибут из 21, где байесовский контроль меняет ответ. Качество каскада с включённым контролёром — точечный фильтр, а не общий классификатор.

		Предсказание	
		нет	да
Истина	нет	698	51
	да	6	371


Матрица ошибок, $n = 1126$ ячеек шоколада

Класс	точность	полнота	F1
нет (без орехов)	99,1 %	93,2 %	0,961
да (с орехами)	87,9 %	98,4 %	0,929
Итого	доля верных 94,9 %		0,945

Эффект байесовского контроля:

- ▶ перепроверяет 5,3 % подозрительных → **+6,6** пп точности,
- ▶ точность на «нет» **99,1 %** — важно для аллергиков,
- ▶ полнота на «да» **98,4 %** — все орехи отловлены.

Перенос архитектуры на электронику




Сплошные стрелки — устойчивые связи ($\geq 95\%$ повторяемости в выборках), пунктир — менее устойчивые (50–80 %).



Заполнение каталога электроники
— 300 моделей, 11 признаков, без единого обращения к языковой модели:

- ▶ восстановил **72 %** пропусков (100 из 139);
- ▶ точность восстановления **95,0 %**;
- ▶ байесовская сеть сама определяет ОС и форм-фактор — **29 %** решений каскада при точности **94,1 %**.

Распределение слоёв каскада по признакам (электроника)



Слой 4: вклад в каскад и качество на отказных ячейках



Результат применения методики

Гибридный каскад из пяти слоёв на тестовой выборке без пересечения товарных кодов ($n = 16\,360$ ячеек):

Показатель	Значение	n
Точность каскада	95,5 %	16 360
Точность всей цепочки	93,0 %	16 360
Макро-F1 каскада (взвеш. по ячейкам)	0,890	16 360
Макро-точность / макро-полнота	0,918 / 0,881	16 360
Точность маршрутизатора категории	97,2 %	570
Покрытие всей цепочки	97,3 %	16 360
Нижняя оценка (ручной эталон Orus 4)	86,7 %	566

Точность каскада по категориям и атрибутам

Эталон — консенсус БЯМ, $n = 16\,360$ ячеек; сводные метрики взвешены по числу ячеек.

Категория	Ячеек	Точность	Макро-F1	Макро-точн.	Макро-полн.
Паста (8 атр.)	7 593	95,8 %	0,883	0,930	0,869
Шоколад (6 атр.)	6 475	94,9 %	0,894	0,902	0,893
Сыры (7 атр.)	2 292	95,8 %	0,897	0,920	0,883
Всего	16 360	95,5 %	0,890	0,918	0,881

Диапазон по 21 атрибуту: лучший: `cheeses.is_pdo` 99,7 % / F1 0,993

- `pasta.is_gluten_free` 99,2 % / F1 0,978
- **наихудший:** `chocolate.flavor_profile` 87,5 % / F1 0,684
- `pasta.is_filled` 88,5 % / F1 0,786.

Каскад vs прямая БЯМ

«Прямая БЯМ» — одна модель на 100 % ячеек без L1/L2/L3 ($n = 16\,360$, без пересечения товарных кодов).

Конфигурация	Точность	Макро-F1	Дешевле в
Прямая Sonnet 4.5 (опорная)	83,8 %	0,725	1×
Прямая gpt-oss-120b (открытая)	69,3 %	0,561	33×
Каскад + Gemini 2.5 Flash	93,0 %	0,890	580×
Каскад + Sonnet 4.5	92,9 %	0,888	24×
Каскад + gpt-oss-120b	90,6 %	0,847	810×



chocolate авто · p=1.00

Lindt Excellence Dark 70% Cocoa

Бренд: Lindt Масса: 100 g SKU: LNDT-EXC-D70



Из карточки 3
Принято системой 4
На проверке 2

● На проверке: 2

● Расхождение с предложением: 1

Принять все

Дозаполнить

АТРИБУТ	ЗНАЧЕНИЕ	ИСТОЧНИК	УВЕРЕННОСТЬ	ПРОВЕРКА
Бренд brand	Lindt	из карточки	—	—
Масса нетто net_weight	100 g	из карточки	—	—
Состав composition	Cocoa mass, sugar, cocoa butter, soya lecithin, vanilla extract	из карточки	—	—
Категория category	Шоколад	ml	1.00	✓ принято авто
Тип шоколада chocolate_type	тёмный	regex	1.00	✓ принято авто
Содержит орехи contains_nuts	Нет	ml	0.97	✓ принято авто
Добавки chocolate_extra	с орехами * система предлагала: без добавок	ml	0.85	Сохранить ↗
Органик is_organic	Нет	ml	0.99	✓ принято авто
Вкусовой профиль flavor_profile	горький	ml	0.86	✓ Принять ✕

Выполнение требований к программному средству

Каждое НФР из ТЗ закрыто измеренным результатом на тестовой выборке.

Требование (НФР)	Целевое	Достигнуто
Н1. Точность каскадной части	$\geq 85 \%$	95,5 %
Н1. Точность всей цепочки (со слоем 4)	$\geq 90 \%$	93,0 %
Н2. Сокращение стоимости	$\geq 2,5\times$	580$\times$ (облако) / 810$\times$ (локально)
Н3. Время отклика каскада	$\leq 500 \text{ мс}$	~200 мс
Н3. Время отклика со слоем 4	$\leq 5 \text{ с}$	~3–4 с
Н4. Многоязычность	≥ 5 языков	7 (фр., англ., нем., ит., исп., порт., рус.)
Н5. Локальное развёртывание	да	gpt-oss-120b через Ollama

Заключение

Задача	Полученный результат
1. Спроектировать каскад с по- атрибутной политикой	5 слоёв с явным отказом по калиброванному порогу; иденти- фикация слоя-источника по каждому атрибуту.
2. Реализовать слои как незави- симо обновляемые компоненты	21 классификатор (3 категории, 8/6/7); конфиг τ_a поатрибутно; замена L2/L4 без правки ядра.
3. Подготовить эталон и кон- троль без пересечения кодов	Консенсус БЯМ $n=16\,360$ + контрольная ручная разметка $n=566$; без пересечения товарных кодов между обучением и контролем.
4. Оценить точность и стои- мость; сравнить с прямой БЯМ	Каскад 95,5 % / F1 0,890, вся цепочка 93,0 %, ручной контроль 86,7 %; стоимость снижена в $24\times / 580\times$ раз.
5. Реализовать программный комплекс (REST + Web-UI)	<code>docker-compose</code> : Go-шлюз + FastAPI + Web-UI; 3 сценария L4; локальный режим (Ollama).

Дополнительно: сформулированы методические рекомендации по построению, внедрению и развитию гибридного каскада.

Спасибо за внимание

**Готов ответить на
вопросы.**



github.com/Qworl/diploma