

Система автоматизированного обогащения товарных данных для интернет-магазина

Фролов М. А.

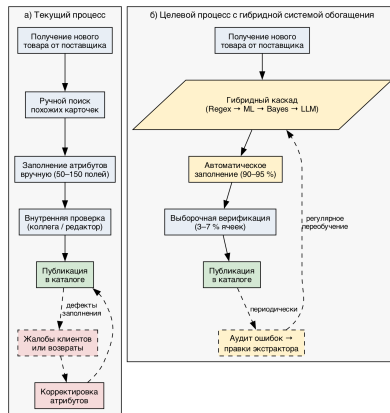
Московский авиационный институт
Институт № 8, кафедра 806 «Вычислительная математика и программирование»
Научный руководитель: Судаков В. А.

Москва, 2026

Проблемные вопросы практики обогащения карточек

- ▶ Каталоги маркетплейсов — **десятки миллионов SKU**.
- ▶ Партнёры присылают **лишь базовый набор** полей.
- ▶ PIM-системы **хранят, но не извлекают** атрибуты.
- ▶ Ручное заполнение — **узкое место** вывода ассортимента.

$\sim 10^7$ SKU · часы на карточку ·
линейная стоимость от объёма



Область и направление исследования

Область. Обогащение карточек товаров в интернет-магазинах: преобразование партнёрских полей в структурированные атрибуты.

Направление. Гибридная каскадная система извлечения атрибутов: регулярные выражения + ML с калиброванной уверенностью + LLM-fallback, интеграция рядом с PIM.

⇒ *перенос акцента с «одна большая LLM на всё» на поатрибутную маршрутизацию между слоями разной стоимости.*

Актуальность направления и задача ВКР

Противоречия

- ▶ **Процесс** — 10^7 + SKU vs пропускная способность контент-менеджеров.
- ▶ **Средства** — PIM хранит, но не извлекает атрибуты.
- ▶ **Технология** — точность LLM vs её **цена** на промышленных объёмах.

Что есть для разрешения

- ▶ Многоязычные эмбединги (sentence-transformers, 50+ языков).
- ▶ Калиброванные классификаторы (XGBoost + Platt/isotonic).
- ▶ Открытые LLM (gpt-oss-120b, Ollama) — локальное развёртывание.
- ▶ Открытый корпус Open Food Facts (4,5 млн SKU).

Задача ВКР. Программное средство обогащения товарных данных с заданной точностью при **кратном сокращении стоимости** vs прямой вызов LLM и локальным развёртыванием.

Аналоги: пробел в существующих подходах

Критерий	TXtract	MAVE	FrugalGPT	AutoMix	Наша система
Per-attribute policy	✓	✓	—	—	✓
Калиброванный отказ от ответа	—	—	—	✓	✓
Cost-aware routing	—	—	✓	✓	✓
Brand-disjoint evaluation	—	—	—	—	✓
Гибридный backend (regex+ML+LLM)	—	—	—	—	✓
Локальное развёртывание	✓	✓	—	—	✓

Ни одна из существующих систем не объединяет **per-attr policy**, **проверку на непересекающихся брендах** и **гибридный backend** одновременно.

Цель и задачи ВКР

Цель. Программное средство обогащения товарных данных на основе гибридной каскадной архитектуры.

Частные задачи

1. Анализ существующих подходов, выявление пробела.
2. Функциональные, нефункциональные, архитектурные требования; интегральный критерий качества.
3. Каскад из 4 слоёв + поатрибутная политика маршрутизации.
4. Реализация end-to-end демо-комплекса (REST API + Web-UI).
5. Pre-registered протокол оценки на выборке с непересекающимися брендами.
6. Рекомендации по внедрению и эксплуатации.

Объект, предмет и рабочее предположение

Объект. Процессы обогащения карточек товаров в интернет-магазинах.

Предмет. Методы и алгоритмы извлечения атрибутов, политики маршрутизации между слоями разной стоимости и протоколы их оценки.

Рабочее предположение.

Каскад из регулярных выражений, ML с калиброванной уверенностью, байесовской валидации и LLM-fallback с **поатрибутной политикой эскалации** обеспечивает заданную точность обогащения при **кратном сокращении стоимости** vs прямой вызов LLM и допускает локальное развёртывание.

Исходные посылки

1. Унаследованная инфраструктура

PIM (Akeneo, Pimcore, Salsify) хранит, но не извлекает атрибуты.

2. Теоретическая основа

Многоязычные эмбединги, калиброванная классификация (Platt + isotonic), байесовские сети, prompt-инженерия (few-shot, schema-constrained).

3. Технологический стек

Python / FastAPI / Go-gateway / React; Docker-compose; XGBoost, sentence-transformers, pgmpy; Ollama для локальной LLM.

4. Открытые данные

Open Food Facts (4,5 млн SKU, ~40 % FR / 10 % EN / 7 % DE) + открытые источники по электронике для cold-start.

Методы исследования

Системный анализ

Декомпозиция процесса, выявление противоречий.

Управление требованиями

ФР / НФР / А-требования, интегральный критерий Q.

Машинное обучение

Эмбединги + XGBoost, калибровка Platt + isotonic.

Промпт-инженерия

Few-shot со схемой ответа, селективная эскалация.

Pre-registered эксперимент

Brand-disjoint, McNemar + Бонферрони, Wilson 95 % CI.

Итеративная разработка

Цикл

аудит → правки → переобучение → измерение.

Основные результаты работы

1. **Требования и качество:** 6 ФР, 4 НФР, 3 А; критерий Q с 4 показателями.
2. **Методика:** 4-слойный каскад с поатрибутной политикой эскалации.
3. **Архитектура:** REST-микросервис, упакованный в `docker-compose`.
4. **Реализация:** ~15 тыс. строк Python, 22 пары «категория-атрибут», работающий e2e демо.
5. **Оценка** ($n=3257$): cascade-only **94,8 %** micro / **0,899** macro-F1; E2E production-realistic **91,1 %**; ÷14 стоимости vs all-LLM.

Формальная постановка задачи

Вход:

$x = (\text{product_name}, \text{brands}, \text{ingredients_text}, \text{quantity}, \text{code})$.

Политика обогащения:

$$\pi : x \longrightarrow (a, \hat{y}, c, \ell)$$

a — атрибут, $\hat{y}$ — значение, $c \in [0, 1]$ — **калиброванная** уверенность, ℓ — слой-источник.

Метрики:

- ▶ $\text{Ass}(\pi)$ на проверке с непересекающимися брендами.
- ▶ $\text{C}(\pi)$ — стоимость vs прямой вызов LLM.
- ▶ Покрытие каскадом без обращения к LLM.

ℓ и c позволяют верифицировать выборочно.

Состав требуемых функций программного средства

Функциональные требования

- ▶ **F1.** Предсказание значения каждого целевого атрибута.
- ▶ **F2.** Возврат *слоя-источника* ($L_1 / L_2 / L_3 / L_4$).
- ▶ **F3.** Возврат *калиброванной уверенности* $c \in [0, 1]$.
- ▶ **F4.** Селективная эскалация на LLM-fallback.
- ▶ **F5.** Bayes-валидация: флаг подозрительных решений.
- ▶ **F6.** Поатрибутная настройка через конфиги.

Нефункциональные требования

- ▶ **N1.** Доля LLM-вызовов $\leq 10\%$ решений.
- ▶ **N2.** **Локальное развёртывание** (без внешних API).
- ▶ **N3.** Brand-disjoint обобщение на новых брендах.
- ▶ **N4.** Воспроизводимость: `pre-reg + reproduce.sh`.

Архитектурные требования. **A1.** Контейнеризация (docker-compose). **A2.** Стабильный REST-контракт между слоями. **A3.** Cold-start: новая категория без правки ядра.

Система качества продукта и интегральный критерий

Качество описано **четырьмя показателями** (точность, стоимость, покрытие, калибровка), сведёнными в интегральный критерий Q :


$$Q = w_1 \cdot \text{Acc} + w_2 \cdot \left(1 - \frac{C_{\text{LLM}}}{C_{\text{max}}}\right) + w_3 \cdot \text{Cov} - w_4 \cdot \text{ECE}$$

Acc — точность на непересекающихся брендах; $C_{\text{LLM}}/C_{\text{max}}$ — доля LLM-вызовов; Cov — покрытие каскадом до LLM; ECE — ошибка калибровки.


Веса: $w_1 = 0,40$, $w_2 = 0,30$, $w_3 = 0,20$, $w_4 = 0,10$.

Показатель	Целевое	Достигнуто
Acc (cascade-only)	$\geq 90\%$	94,8 %
$C_{\text{LLM}}/C_{\text{max}}$	$\leq 0,10$	0,071
Cov (покрытие до LLM)	$\geq 0,90$	0,929
ECE (калибровка)	$\leq 0,05$	per-attr ниже целевого


Место и роль программного средства (контекст ГОСТ)



Функциональная модель системы



Ключевые алгоритмы каскада



Решение слоя: $\hat{y}$, если $p_{\max}(x) \geq \theta_{c,a}$ (поатрибутный порог, Platt + isotonic). Иначе — каскация. ИМ вызывается на 7.1 % ячеек

Данные и протокол оценки

Источник: Open Food Facts, 4,5 млн SKU (~40 % FR / 10 % EN / 7 % DE).

3 категории: паста (8 атр.), шоколад (7), сыры (7) — **22 пары** «категория-атрибут».

Эталон: два уровня — основной ($n = 3257$, majority vote 3 LLM) и HUMAN gold ($n = 615$, консервативная граница).

Протокол: проверка на непересекающихся брендах.
Pre-registration H1 (router): cd9ac7a (2026-05-13).


Категория	Атрибутов
Pasta	8
Chocolate	7
Cheeses	7
<i>Расширения:</i>	
Beverages	8
Cereals	8
Cosmetics	6
<i>Cold-start:</i>	
Electronics	8

Главный результат: точность и стоимость

Метрика	Значение	<i>n</i>
Cascade-only micro-accuracy	94,8 %	3257
Cascade-only macro-F1	0,899	3257
Router accuracy (per product code)	95,4 %	570
E2E coverage	96,0 %	3257
E2E (None=wrong) — production-realistic	91,1 %	3257
HUMAN gold (консервативная граница) — E2E	87,5 %	615

Проверка на непересекающихся брендах. **Доля LLM: 7,1 %** ячеек $\Rightarrow$ сокращение стоимости $\div 14$ vs all-LLM baseline.

За счёт чего: вклад слоёв по 22 атрибутам



Результаты разработки программного средства

1. **Соответствие требованиям.** Все 6 ФР, 4 НФР, 3 А реализованы; **4/4** показателя качества достигли целевых.
2. **Объём.** ~15 тыс. строк Python; 35+ модулей; 7 категориальных схем; 22 пары.
3. **Демо.** `docker-compose`: React + Go + FastAPI; 5 REST-эндпоинтов; ~200 мс на запрос.
4. **Воспроизводимость.** ~70 тестов; ноутбук как исполняемый §3.3; `reproduce.sh` восстанавливает headline-цифры.

Научная и практическая значимость

Научная значимость.

- ▶ Методика гибридного каскада с **поатрибутной калиброванной уверенностью** и **pre-registered** протоколом оценки.
- ▶ Cascade-only **94,8 % / 0,899** macro-F1, E2E **91,1 %** при **÷14** стоимости vs all-LLM.
- ▶ Pre-registered **отказ** от гипотезы об обучаемом router'е.
- ▶ Воспроизведено на cold-start (*electronics*).

Практическая значимость.

- ▶ Работающее ПО в `docker-compose` рядом с PIM.
- ▶ Кратное сокращение стоимости и ручной нагрузки.
- ▶ Локальное развёртывание — независимость от внешних API.

Достоверность и обоснованность результатов

Достоверность:

- ▶ проверка на непересекающихся брендах: основная $n=3257$ + HUMAN gold $n=615$ (две границы);
- ▶ **pre-registration** протокола H1 (router) в git `cd9ac7a` до создания артефакта;
- ▶ Wilson 95 % CI на всех headline-числах;
- ▶ McNemar + поправка Бонферрони ($\alpha/3$);
- ▶ воспроизведение через `reproduce.sh`.

Обоснованность. Признанные методы: sentence-transformers, XGBoost, байесовские сети, калибровка Platt + isotonic; сравнение с TXtract, MAVE, OpenTag, FrugalGPT, AutoMix.

Реализация. `docker-compose` stack с REST API и Web-UI; код и `reproduce.sh`

Демонстрационный комплекс — экранные формы

Обогащение товарных данных

Каскад: `regex` → `ML` → `байес` → `LLM-fallback`. Введите частично заполненный товар — система предложит недостающие атрибуты.

Ввод товара

Режим определения категории

☒ Авто (классификатор) ☐ Вручную

Категория

Название товара *

Бренд / производитель

Состав

Количество

Примеры:

включая:

с противоречиями:

Результат

Категория:	Авто (router):	OOD:
chocolate	chocolate, p=0.97	нет
Закрито:	LLM-fallback:	Время ответа:
6 / 7 атрибутов	1 атрибут	184 мс

ПРЕДСКАЗАНИЯ ПО АТТРИБУТАМ

АТТРИБУТ	ПРЕДСКАЗАНИЕ	СЛОЙ	УВЕРЕННОСТЬ
cocoa_content_class	70-85 %	regex	1.00
chocolate_type	dark	regex	1.00
contains_nuts	false	ml	0.93
is_organic	false	ml	0.87
contains_milk	false	ml	0.81
flavor_modifier	vanilla	bayes	0.74

fling_type — будет дозаполнено: **ml** —

Слов каскада: **regex** **ml** **bayes** **ml-fallback**

Рисунок 4.1 — Веб-интерфейс демонстрационной системы (схематично): форма ввода и блок результата с отметкой слов-источника и оценкой уверенности

Стек **frontend** (React) ↔ **gateway** (Go) ↔ **ml service** (FastAPI). Для каждой ячейки —

Рекомендации по внедрению, эксплуатации и развитию

Внедрение

- ▶ `docker-compose` up рядом с PIM.
- ▶ Стартовый silver-эталон из истории каталога.
- ▶ Per-attribute пороги через JSON-конфиги.
- ▶ LLM: внешний API или локальный Ollama.

Эксплуатация

- ▶ Мониторинг доли LLM ($\leq 10\%$).
- ▶ Точность на сэмпле $n \geq 200$ еженедельно.
- ▶ Аудит при росте Bayes-флагов $> 5\%$.
- ▶ Верификация только флажированных ячеек.

Развитие

- ▶ Cold-start на новые категории.
- ▶ Расширение схем атрибутов.
- ▶ Апгрейд backbone-эмбединга.
- ▶ Подключение более дешёвых LLM.

Оперативный эффект от внедрения

94,8 %

cascade-only acc
(consensus, $n=3257$)

91,1 %

E2E production-
realistic accuracy

7,1 %

доля ячеек,
эскалированных на
LLM

÷14

сокращение стоимости
vs all-LLM baseline

⇒ кратное сокращение ручной нагрузки и стоимости обогащения
при сохранении локального развёртывания.

Заключение: задачи и полученные результаты


Задача	Результат
1. Анализ подходов	Пробел: hybrid + per-attr + pre-registered eval.
2. Требования и качество	6 ФР, 4 НФР, 3 А; критерий Q — все цели достигнуты.
3. Каскад и маршрутизация	4 слоя, 22 пары $\times$ 3 категории, калиброванные пороги.
4. Реализация	<code>docker-compose</code> + REST + Web-UI; ~ 15 тыс. строк Python.
5. Pre-registered оценка	$n=3257$: cascade 94,8 % / 0,899 mF1, E2E 91,1 % , $\div 14$ cost; H1 отвергнута.
6. Рекомендации	Внедрение / эксплуатация / развитие; cold-start.

Итог: cascade-only **94,8 %** / 0,899 macro-F1, E2E **91,1 %** при $\div 14$ стоимости vs all-LLM.

Спасибо за внимание

Исходный код, ноутбук §3.3 в исполняемом виде, демонстрационный комплекс и текст работы доступны в репозитории проекта.

Вопросы?



github.com/Qworl/diploma

В1. Отрицательный результат: обучаемый router

Гипотеза H1: обучаемый


стоимостно-чувствительный маршрутизатор превосходит статическое правило хотя бы на одном из трёх бюджетов LLM (25 % / 40 % / 50 %).

Pre-registration: git cd9ac7a, 2026-05-13 02:11
(за 1 ч 11 мин до создания артефакта).

Поправка Бонферрони: $\alpha/3 \approx 0,0167$.

MDE на $n = 1539$: $\approx 4,4$ пп (парный McNemar).

Результат: $p > 0,3$ во всех трёх бюджетах.




B2. Селективное поведение Bayes-валидатора

Bayes-валидатор активен **селективно** — флаг ставится только при $q_{c,a}$ -калибровке плотностей, выбран per-attr пороги (см.

`*_validation_thresholds.json`).

Hybrid CPD-fit: структура DAG — Hill Climb + BIC на silver (15K с непересекающимися брендами vs test); CPD — на `CONCAT(silver, gold-train × 10)` с BDeu prior.

Production: 10 useful Bayes-пар, селективное флагирование на *chocolate/contains_nuts*, *cheeses/is_ultra_processed* и др.



B3. Silver vs Gold standard

Silver standard (consensus тегов OFF + 3 LLM + слепая Opus-разметка) служит **обучающим** сигналом. Gold-эталон (`consensus_gold_v2_expanded.parquet`) получен по аудит-циклу для холдаута.

Цикл «аудит — правки экстрактора — переобучение — измерение» воспроизведён 3 из 3 категорий с приростом **+18,2, +16,3, +14,4** пп.

Калибровка уверенности — комбинация Platt + isotonic per (категория, атрибут); ECE измеряется на отдельной выборке, артефакты сохраняются в `*_calibration.json`.

В4. Утечки и борьба с ними

Запрет утечки `categories_tags` в эмбединги.

Эмбединги Слой 2 строятся **только** из partner-available полей: `product_name` + `brands` + `ingredients_text` + `quantity.categories_tags` — это **выход** обогащения, не вход; использование как фичи привело бы к target leakage.

Brand-disjoint split (60/20/20). Бренды в train/val/test **не пересекаются** — гарантия обобщения на новых брендах.

k-NN ablation (§3.3.7.3): точность **не падает** на удалённых от обучающей выборки товарах — монотонный рост от Q1 (82,7 %) до Q4 (91,6 %).

B5. Мультиязычность

Языковой состав OFF: $\approx 40\%$ FR, 10% EN, 7% DE, остальное — прочие.

Эмбединг: `paraphrase-multilingual-MiniLM-L12-v2` (50+ языков, общее семантическое пространство).

Поатрибутно-поязыковой срез (`per_language_eval.parquet`, 132 записи на $n=3257$ ячейках): взвешенная точность стабильна по основным языкам.

Под балансировку каскад не оптимизировался — это естественный выигрыш многоязычного backbone'a.

B6. LLM-cost на 1M SKU

Каскад делегирует LLM лишь 7,1 % ячеек ($n = 3506$) — прямая прокси к стоимости.
Cost reduction **92,9 %** ($\div 14$) относительно «прямой LLM на всё».

Распределение по слоям: L1 (regex high-precision) — 18,4 %, L2 (ML) — **73,8 %**, L3 (regex low-precision) — 0,7 %, L4 (LLM) — 7,1 %.

Проекция на 1M SKU × 22 атрибута ($\sim 2,2 \cdot 10^7$ ячеек):

- ▶ Прямой LLM — оплачены все $\sim 2,2 \cdot 10^7$ вызовов.
- ▶ Каскад — оплачены лишь $\sim 1,6 \cdot 10^6$ вызовов (7,1 %).

Топ-3 LLM-затратных атрибутов: pasta.grain_type (32,9 %), pasta.pasta_shape (22,8 %), cheeses.is_pdo (13,6 %).

B7. Cold-start: electronics (§5 ноутбука)

Демонстрация переноса методологии на **новую категорию без regex-правил**.

Электроника (8 атрибутов): смартфоны — RAM, storage, screen size, has 5G, ...

Transfer: только Слой 2 (ML+эмбединги) и Слой 4 (LLM); Слой 1 пропускается; Слой 3 — по обучающим парам.

Результат: cold-start работает на small-shot, обоснованность расширения каскада за пределы food-доменов.

