

Система автоматизированного обогащения товарных данных для интернет-магазина

Фролов М. А.

Московский авиационный институт (национальный исследовательский университет)
Институт № 8, кафедра 806 «Вычислительная математика и программирование»

Выпускная квалификационная работа студента СпецВО

Научный руководитель: Судаков В. А., д. т. н., профессор кафедры 806

Москва, 2026

Проблемы практики обогащения товарных каталогов

- ▶ Интернет-магазины ведут каталоги из **десятков миллионов** карточек товаров; качество атрибутов (категория, тип молока, содержание какао, аллергены...) определяет работу поиска, фильтров и рекомендаций.
- ▶ Карточки хранятся и публикуются через системы управления товарными данными (PIM, *Product Information Management*), которые **хранят** атрибуты, но не извлекают их из неструктурированного текста.
- ▶ Партнёры-поставщики присылают только **базовые поля** (название, бренд, ингредиенты-текст, баркод); 50–90 % целевых атрибутов приходят пустыми и требуют отдельного обогащения.
- ▶ Заполнение атрибутов **вручную** контент-менеджерами не масштабируется на 10^7 карточек $\times$ 50–150 атрибутов; новые товары публикуются с задержкой.
- ▶ **Прямой вызов** большой языковой модели на каждую ячейку технически возможен, но при цене $\sim \$0,003$ за вызов проекция на $10^7 \times 20$ ячеек экономически неприемлема.

Область и направление исследования


Область исследования.

Деятельность по обогащению карточек товаров в системах управления товарным каталогом (PIM) интернет-магазинов: заполнение целевых атрибутов из неструктурированных партнёрских полей (название, бренд, ингредиенты) и поддержание атрибутного слоя в актуальном состоянии.

Направление исследования.

Совершенствование деятельности посредством автоматизации поатрибутного заполнения средствами гибридной каскадной системы с маршрутизацией между слоями разной стоимости и калиброванным отказом от ответа на нижних слоях.

Место и роль программного средства



Цель, задачи, объект, предмет, гипотеза

Цель. Разработать программное средство автоматизированного обогащения карточек товаров на основе гибридной каскадной архитектуры с поатрибутной маршрутизацией между слоями разной стоимости, обеспечивающее одновременное достижение заданной точности и кратное снижение стоимости относительно прямого вызова большой языковой модели.

Задачи

1. Спроектировать каскад с поатрибутной политикой.
2. Реализовать слои как независимо обновляемые компоненты.
3. Подготовить эталон и контроль без пересечения кодов.
4. Оценить точность и стоимость; сравнить с прямой БЯМ.
5. Реализовать программный комплекс (REST + Web-UI).

Объект. Процессы обогащения карточек товаров атрибутными значениями из неструктурированных партнёрских полей.

Предмет. Методы и алгоритмы автоматического заполнения атрибутов гибридными каскадными системами с поатрибутной маршрутизацией.

Рабочая гипотеза. Каскад `regex` → `ML` → `Bayes` → `LLM` с калиброванной эскалацией обеспечивает точность $\geq 90\%$ при сокращении стоимости относительно прямой БЯМ $\geq 5\times$.

Данные и протокол оценки

Источник. Open Food Facts, 4,5 млн карточек (~40 % FR / 10 % EN / 7 % DE / 43 % др.), поэтому необходимо многоязычное векторное представление.

3 категории. Паста (8 атр.), шоколад (6), сыры (7) — **21 пара** «категория-атрибут».

Эталон. Два уровня: основной консенсус БЯМ ($n = 16\,360$) + независимая контрольная ручная разметка ($n = 566$, нижняя оценка).

Протокол. Один товар не попадает одновременно в обучающую и тестовую выборки (разбиение без пересечения товарных кодов и брендов).

Категория	Атрибутов
Паста	8
Шоколад	6
Сыры	7
<i>Холодный старт:</i>	
Электроника	8

Научная и практическая значимость

Научная значимость.

- ▶ Методика построения гибридного каскада с **поатрибутной калиброванной уверенностью** и **предрегистрируемым** протоколом оценки.
- ▶ Воспроизводимость методики подтверждена на новой категории (электроника) в режиме холодного старта.

Практическая значимость.

- ▶ Работающее ПО в `docker-compose`, интегрируется рядом с каталогом.
- ▶ Кратное сокращение стоимости и ручной нагрузки контент-менеджеров.
- ▶ Локальный режим (`gpt-oss-120b` через `Ollama`, 810× дешевле прямой БЯМ) — для контуров без внешнего интернет-доступа.

Состав требований к программному средству


Функциональные (ФР)

- ▶ **F1.** Возврат значения целевого атрибута либо явный отказ.
- ▶ **F2.** Слой-источник предсказания.
- ▶ **F3.** Калиброванная уверенность $c \in [0, 1]$.
- ▶ **F4.** Эскалация на запасной слой.
- ▶ **F5.** Bayes-валидация подозрительных предсказаний.
- ▶ **F6.** Поатрибутная настройка через конфиг.

Нефункциональные (НФР)

- ▶ **N1.** Точность $\geq 85\%$ (каскад) / $\geq 90\%$ (+ БЯМ).
- ▶ **N2.** Стоимость снижена в $\geq 2,5\times$ раз vs прямой БЯМ.
- ▶ **N3.** Латентность ≤ 500 мс (каскад) / ≤ 5 с (БЯМ).
- ▶ **N4.** Многоязычность (≥ 5 языков).
- ▶ **N5.** Локальное развёртывание (без внешних API).

Функциональный вид архитектуры (ГОСТ Р 57100-2016)




Назначение слоёв каскада

Слой	Что делает	Когда не справляется	Доля
L0 router	XGBoost на эмбединге → категория + OOD-флаг	Уверенность ни по одной из 7 категорий не превышает порога: товар попадает в OOD и сразу обогащается через L4	—
L1 regex	Прецизионные поатрибутные шаблоны	Ни один шаблон не сматчился в названии или количестве — нет устойчивой лексической разметки ⇒ L2	21,9 %
L2 ML	XGBoost на 768-мерном эмбединге	Калиброванная уверенность ниже поатрибутного порога — модель не уверена в ответе ⇒ L3	73,2 %
L3 Bayes	Байесовский валидатор согласованности предсказаний L2 с контекстом атрибутов	Сеть атрибутивных связей считает предсказание L2 несовместимым с остальными атрибутами товара ⇒ L4	0,8 %
L4 LLM	gpt-oss-120b / Sonnet 4.5 / Gemini Flash	Последний слой каскада: ответ возвращается «как есть»; null только если LLM нарушила схему ответа	4,1 %

Слой 2: сравнение алгоритмов классификации

Четыре алгоритма на общем эмбединге; выбор XGBoost обоснован **калибровкой**, а не максимумом точности — система гибкая, классификатор сменяется конфигом.




Cells-weighted micro-асс: четыре метода в пределах ± 1 пп

Метод	Асс	F1	ECE	t , с
XGBoost	92,02 %	0,849	0,026	1062
MLP	92,67 %	0,857	0,031	54
LogPer	91,85 %	0,836	0,035	8
Random Forest	89,94 %	0,809	0,027	523

Почему XGBoost (а не MLP/RF/нейросеть):


- ▶ MLP: +0,65 пп асс, но ECE **0,031** $\Rightarrow$ сдвинутые $p_{\max}$,
- ▶ ЛогПер: ECE **0,035** — худшая калибровка,
- ▶ RF: точность — 2 пп (89,94 %),
- ▶ **XGBoost**: ECE **0,026** $\Rightarrow \tau_a$ корректно калиброваны.

Какой слой заполняет какие атрибуты



Исключены 3 тривиальных атрибута (100 % L1 regex): pasta.is_filled, chocolate.is_filled, chocolate.contains_nuts

Bayes — валидатор, не классификатор



1. Что построено.

pgmpy 1.1.2: структура — Hill Climb + BIC; CPT — `BayesianEstimator` с `BDeu`.

2. Роль — валидатор.

Самостоятельная точность $\approx 52\%$ (ниже базовой), но плотность $P_B(\hat{y} | \epsilon)$ на нижнем 5-перцентиле даёт сигнал отбраковки.

3. Где включён.

Точно: **1 пара из 21** — `chocolate / contains_nuts`:
+6,6 пп точности при **+5,3 пп** расходов запасного слоя.

Эффект Bayes-валидатора в действии: chocolate / contains_nuts

Единственный атрибут из 21, на котором Bayes реально влияет на ответ (см. предыдущий слайд). Показано качество каскада с включённым валидатором — демонстрация, что Bayes полезен именно как точечный фильтр, а не как общий классификатор.

		Предсказание	
		нет	да
Истина	нет	698	51
	да	6	371


Матрица ошибок, $n = 1126$ ячеек шоколада

Класс	prec	recall	F1
нет (без орехов)	99,1 %	93,2 %	0,961
да (с орехами)	87,9 %	98,4 %	0,929
Итого	micro 94,9 %		0,945

Эффект Bayes-валидатора:

- ▶ перепроверяет 5,3 % подозрительных предсказаний → **+6,6 пп** точности,
- ▶ precision на «нет» **99,1 %** — критично

Перенос архитектуры на электронику: граф зависимостей




Сплошные стрелки — устойчивые связи ($\geq 95\%$ повторяемости в выборках), пунктир — менее устойчивые (50–80 %).

Заполнение каталога (300 моделей $\times$ 11 признаков, конфигурация без вызова языковой модели):



- ▶ точность восстановления **95,0 %** (дов. инт-л 88,8–97,8);
- ▶ прирост заполненности **+3,03 п. п.**, **0** вызовов языковой модели;
- ▶ сеть полностью предсказывает ОС и форм-фактор — **29 %** всех решений каскада при **94,1 %** точности.

Какой слой каскада заполняет какой признак (электроника)



Слой 4: вклад в каскад и качество на отказных ячейках

Слой 4 (LLM fallback): вклад в каскад и качество на отказных ячейках



Главный результат

95,5 %

точность каскада

93,0 %

сквозная (производственная) точность

Метрика	Значение	<i>n</i>
Макро-F1 каскада (взвеш. по ячейкам)	0,890	16 360
Макро-precision / макро-recall	0,918 / 0,881	16 360
Точность маршрутизатора категории	97,2 %	570
Покрытие сквозной цепочки	97,3 %	16 360

Точность каскада по категориям и атрибутам

Эталон — консенсус БЯМ, $n = 16\,360$ ячеек; agg-метрики взвешены по числу ячеек.

Категория	Ячеек	Точность	Макро-F1	Макро-prec	Макро-recall
Паста (8 атр.)	7 593	95,8 %	0,883	0,930	0,869
Шоколад (6 атр.)	6 475	94,9 %	0,894	0,902	0,893
Сыры (7 атр.)	2 292	95,8 %	0,897	0,920	0,883
Всего	16 360	95,5 %	0,890	0,918	0,881

Диапазон по 21 атрибуту: лучший: `cheeses.is_pdo` 99,7 % / F1 0,993 •
`pasta.is_gluten_free` 99,2 % / F1 0,978 • наихудший: `chocolate.flavor_profile`
87,5 % / F1 0,684 • `pasta.is_filled` 88,5 % / F1 0,786.

Каскад vs прямая БЯМ

«Прямая БЯМ» — одна модель на 100 % ячеек без L1/L2/L3 ($n = 16\,360$, без пересечения товарных кодов).

Конфигурация	Точность	ДИ Уилсона 95 %	Макро-F1	Стоимость	Дешевле в
Прямая Sonnet 4.5 (опорная)	83,8 %	[83,2; 84,4]	0,725	1,000	1×
Прямая gpt-oss-120b (открытая)	69,3 %	[68,6; 70,0]	0,561	0,030	33×
Каскад + Gemini 2.5 Flash	93,0 %	[92,6; 93,4]	0,890	0,0017	580×
Каскад + Sonnet 4.5	92,9 %	[92,5; 93,3]	0,888	0,041	24×
Каскад + gpt-oss-120b	90,6 %	[90,1; 91,1]	0,847	0,0012	810×

Демо обогащения карточки товара



chocolate asto · p=1.00

Lindt Excellence Dark 70% Cocoa

Бренд: Lindt Масса: 100 g SKU: LNDT-EXC-D70

7/9

подтверждено

Из карточки

3

Принято системой

4

На проверке

2

● На проверке: 2

● Расхождение с предложением: 1

Принять все

Дополнить

АТРИБУТ	ЗНАЧЕНИЕ	ИСТОЧНИК	УВЕРЕННОСТЬ	ПРОВЕРКА
Бренд brand	Lindt	из карточки	—	—
Масса нетто net_weight	100 g	из карточки	—	—
Состав composition	Cocoa mass, sugar, cocoa butter, soya lecithin, vanilla extract	из карточки	—	—
Категория category	Шоколад	я1	1.00	✓ принято авто
Тип шоколада chocolate_type	тёмный	гггх	1.00	✓ принято авто
Содержит орехи contains_nuts	Нет	я1	0.97	✓ принято авто
Добавки chocolate_extra	с орехами ≠ система предлагала: без добавок	я1	0.85	Сохранить ×
Органик is_organic	Нет	я1	0.99	✓ принято авто
Вкусовой профиль flavor_profile	горький	я1	0.86	✓ Принять ×

Выполнение требований к программному средству

Каждое НФР из ТЗ закрыто измеренным результатом на тестовой выборке.

Требование (НФР)	Целевое	Достигнуто	
N1. Точность каскада (cascade-only)	$\geq 85 \%$	95,5 %	✓
N1. Сквозная точность (e2e с L4)	$\geq 90 \%$	93,0 %	✓
N2. Сокращение стоимости	$\geq 2,5 \times$	580× (облако) / 810× (локально)	✓
N3. Латентность каскада	≤ 500 мс	~200 мс	✓
N3. Латентность с L4	≤ 5 с	~3–4 с	✓
N4. Многоязычность	≥ 5 языков	7 (FR, EN, DE, IT, ES, PT, RU)	✓
N5. Локальное развёртывание	да	gpt-oss-120b через Ollama	✓

Заключение

Задача	Полученный результат
1. Спроектировать каскад с по-атрибутной политикой	5 слоёв с явным отказом по калиброванному порогу; идентификация слоя-источника по каждому атрибуту.
2. Реализовать слои как независимо обновляемые компоненты	21 классификатор (3 категории, 8/6/7); конфиг τ_a поатрибутно; замена L2/L4 без правки ядра.
3. Подготовить эталон и контроль без пересечения кодов	Консенсус БЯМ $n=16\,360$ + контрольная ручная разметка $n=566$; без пересечения товарных кодов и брендов.
4. Оценить точность и стоимость; сравнить с прямой БЯМ	Каскад 95,5 % / F1 0,890, сквозная 93,0 %, ручной контроль 86,7 %; стоимость снижена в 24× / 580× раз.
5. Реализовать программный комплекс (REST + Web-UI)	docker-compose: Go-шлюз + FastAPI + Web-UI; 3 сценария L4; локальный режим (Ollama).

Спасибо за внимание

**Готов ответить на
вопросы.**



github.com/Qworl/diploma

В1. Метрики и обозначения (для вопросов)

AND-условие слоя 2. Предсказание $\hat{y}$ принимается

$\iff P_{ML}(\hat{y} \mid x) \geq \tau_a \wedge P_B(\hat{y} \mid e) \geq \theta_a$ — формализация ансамблевой оценки уверенности как конъюнкции порогов ML-классификатора (τ_a) и байесовского валидатора (θ_a).

Метрики:

- ▶ $\text{acc}_k^{\text{cov}} = \frac{|\hat{y}_k = y_k \wedge \hat{y}_k \neq \text{null}|}{|\hat{y}_k \neq \text{null}|}$ — точность на покрытой части (только по ячейкам, где $\hat{y} \neq \perp$);
- ▶ $\text{cov}_k = \frac{|\hat{y}_k \neq \text{null}|}{N}$ — покрытие, доля ячеек с ненулевым предсказанием;
- ▶ $\text{acc}_k^{\text{e2e}} = \text{acc}_k^{\text{cov}} \cdot \text{cov}_k$ — сквозная точность (отказ $\perp$ засчитывается как ошибка), production-realistic;
- ▶ cost_{LLM} — ожидаемая доля вызовов запасного слоя на 1000 ячеек (бюджет $\beta = 10\%$).

Связь $\text{acc}^{\text{e2e}} = \text{acc}^{\text{cov}} \cdot \text{cov}$ объясняет разрыв между только-каскадной точностью (95,5%) и сквозной с маршрутизатором (93,0%): часть ячеек теряется на $\text{cov} < 1$.

В1а. Сравнение с TXtract / MAVE / FrugalGPT / AutoMix

Критерий	TXtract	MAVE	FrugalGPT	AutoMix	Наша система
Поатрибутная политика	есть	есть	нет	нет	есть
Калиброванный отказ от ответа	нет	нет	нет	есть	есть
Маршрутизация по стоимости	нет	нет	есть	есть	есть
Контроль без пересечения кодов	нет	нет	нет	нет	есть
Гибридная архитектура слоёв	нет	нет	нет	нет	есть
Локальное развёртывание	частично	частично	нет	нет	есть

Ни один из существующих подходов не закрывает все шесть критериев одновременно — это и есть позиционирование разрабатываемой системы.

В2. Отрицательный результат: обучаемый маршрутизатор


Гипотеза Н1: обучаемый стоимостно-чувствительный маршрутизатор превосходит статическое правило хотя бы на одном из трёх бюджетов языковой модели (25 % / 40 % / 50 %).

Предрегистрация: `git cd9ac7a`, 2026-05-13 (за 1 ч 11 мин до создания артефакта).

MDE при $n = 1539$: $\approx 4,4$ пп (парный МакНемара, $\alpha/3 \approx 0,0167$).

Результат: $p_{\text{МакНемара}} = 0,74/0,49/1,00$ для бюджетов 25 / 40 / 50 % (все $> \alpha/3$). **Н1 отклонена**; принят статический маршрутизатор.

Парето: обучаемый vs статический



В3. Почему один классификатор на атрибут: multitask-эксперимент

Проверено три архитектуры на 7 высоко-/средне-/слабо-коррелированных парах (3 категории):

Архитектура	Победы vs Single	Итог
MultiOutput (sklearn)	7 / 5 / 2	≈ ничья
Cartesian (декарт. пр-во)	5 / 6 / 0	—

Cartesian даёт **+0,08–0,24 macro-F1** на парах с $V \geq 0,5$ и $|A \times B| \leq 15$ (milk_source $\times$ texture: +0,235; cocoa $\times$ nuts: +0,082), но *проигрывает* на крупных пространствах (pasta_shape $\times$ is_filled, $n_{\text{class}}=22$): −0,067.

Вывод. MultiOutput технически эквивалентен независимым классификаторам (нет shared gradients). Cartesian — кандидат для пар с сильной корреляцией ($V \geq 0,5$) и узким пространством (≤ 15 классов); в производственной конфигурации оставлен per-attribute вариант как наиболее прозрачный для цикла аудит → правка → переобучение одного атрибута.

В7. Где каскад слабее: precision/recall на 3 худших атрибутах

Производственная схема V6, эталон LLM-consensus (extended rerun, n=16 360).

Атрибут	Класс	n	prec	recall	F1
<i>chocolate.flavor_profile</i> — micro 87,5 %, macro-F1 0,684, n=1060					
	intense_bitter	397	91,1 %	98,0 %	0,944
	nutty	281	86,6 %	85,4 %	0,860
	sweet_creamy	190	80,8 %	84,2 %	0,825
	<i>salty_caramel (редкий)</i>	56	90,5 %	67,9 %	0,776
<i>pasta.is_filled</i> — micro 88,5 %, macro-F1 0,786, n=1225					
	false (не фаршированные)	958	87,2 %	100 %	0,931
	<i>true (фаршированные)</i>	267	100 %	47,2 %	0,641
<i>cheeses.texture</i> — micro 89,0 %, n=335					
	hard	109	95,5 %	96,3 %	0,959
	soft	97	91,3 %	97,9 %	0,945
	<i>cream (редкий)</i>	33	73,9 %	51,5 %	0,607

Паттерны recall просаживаются на редких классах (n < 60): такие двойки уходят в LLM до порога

В8. Стоимость языковой модели на 1 млн карточек

Каскад делегирует языковой модели лишь 4,1 % ячеек ($n = 17\,062$) — прямая прокси к стоимости. Сокращение затрат **95,9 % (в $24\times$ раз)** относительно «прямой языковой модели на всё».

Распределение по слоям: L1 (regex высокой точности) — 21,9 %, L2 (ML) — **73,2 %**, L3 (Bayes-валидатор) — 0,8 %, L4 (языковая модель) — 4,1 %.

Проекция на 1 млн карточек × 20 атрибутов ($\sim 2,0 \cdot 10^7$ ячеек):

- ▶ Прямая модель — оплачены все $\sim 2,0 \cdot 10^7$ вызовов.
- ▶ Каскад — оплачены лишь $\sim 8,2 \cdot 10^5$ вызовов (4,1 %).

Топ-3 затратных атрибутов для языковой модели: pasta.grain_type (32,9 %), pasta.pasta_shape (22,8 %), cheeses.is_pdo (13,6 %).

В9. Холодный старт: электроника (§5 ноутбука)


Демонстрация переноса методики на **новую категорию без регулярных правил**.

Электроника (8 атрибутов): смартфоны — RAM, объём памяти, диагональ экрана, поддержка 5G, ...

Перенос: активны только Слой 2 (ML + эмбединги) и Слой 4 (языковая модель); Слой 1 пропускается; Слой 3 — по обучающим парам.

Результат: холодный старт работает на ограниченной обучающей выборке, что подтверждает применимость каскада за пределами продуктового домена.

В10. Граф зависимостей атрибутов смартфонов (электроника)




Сплошные стрелки — устойчивые связи ($\geq 95\%$ повторяемости в выборках), пунктир — менее устойчивые (50–80 %).

Заполнение каталога (300 моделей $\times$ 11 признаков, конфигурация без вызова языковой модели):

- ▶ точность восстановления **95,0 %** (дов. инт-л 88,8–97,8);
- ▶ прирост заполненности **+3,03 п. п.**, **0** вызовов языковой модели;
- ▶ сеть полностью предсказывает ОС и форм-фактор — **29 %** всех решений каскада при **94,1 %** точности.

В пищевом домене та же сеть давала 6 % решений при 53 % точности и была отключена. Архитектура одна — каскад сам перераспределяет работу под структуру задачи предметной области.

В11. Какой слой каскада заполняет какой признак (электроника)



Доли решений каскада в режиме холодного старта на 300 моделях PhoneDB (конфигурация без вызова языковой модели). Сеть полностью держит операционную систему и форм-фактор; классификатор — бренд