

Система автоматизированного обогащения товарных данных для интернет-магазина

Фролов М. А.


Московский авиационный институт
Институт № 8, кафедра 806 «Вычислительная математика и программирование»
Научный руководитель: Судаков В. А.

Москва, 2026

Ручное обогащение карточек не масштабируется до 10^7 SKU

- ▶ Каталоги маркетплейсов — **десятки миллионов SKU**.
- ▶ Партнёры присылают **лишь базовый набор** полей.
- ▶ PIM-системы **хранят**, но **не извлекают** атрибуты.
- ▶ Ручное заполнение — **узкое место** вывода ассортимента.

$\sim 10^7$ SKU · часы на карточку ·
линейная стоимость от объёма



Прямой вызов большой языковой модели — слишком дорого

Противоречия

- ▶ **Процесс** — $10^7 +$ SKU vs пропускная способность контент-менеджеров.
- ▶ **Средства** — PIM хранит, но не извлекает атрибуты.
- ▶ **Технология** — точность БЯМ vs её **цена** на промышленных объёмах.

Задача ВКР. Программное средство обогащения товарных данных с заданной точностью при **кратном сокращении стоимости** относительно прямого вызова большой языковой модели и допускающее локальное развёртывание.

⇒ *перенос акцента с «одна большая модель на всё» на поатрибутную маршрутизацию между слоями разной стоимости.*

Аналоги: ни один не объединяет поатрибутную политику и контроль на новых товарах

Критерий	TXtract	MAVE	FrugalGPT	AutoMix	Наша система
Поатрибутная политика	✓	✓	—	—	✓
Калиброванный отказ от ответа	—	—	—	✓	✓
Маршрутизация по стоимости	—	—	✓	✓	✓
Контроль на непересекающихся товарах	—	—	—	—	✓
Гибридная архитектура слоёв	—	—	—	—	✓
Локальное развёртывание	частично	частично	—	—	✓

Ни одна из существующих систем не объединяет **поатрибутную политику**, **контроль на новых товарах** и **гибридную архитектуру** одновременно.

TXtract / MAVE — реализации Amazon / Google: возможен self-hosted, но требует GPU и инфраструктуры BERT-семейства.

Цель: построить каскад дешевле прямой LLM и доказать его качество

Цель. Программное средство обогащения товарных данных на основе гибридной каскадной архитектуры.

Частные задачи

1. Разработать архитектуру гибридного каскадного конвейера (5 слоёв) с поатрибутной политикой маршрутизации.
2. Реализовать каждый слой как самостоятельный программный компонент с независимым обновлением.
3. Построить эталонную разметку и тестовую выборку без пересечения товарных кодов (code-disjoint).
4. Провести экспериментальную оценку: точность, покрытие, стоимость; сравнение с прямым вызовом БЯМ.
5. Разработать демонстрационный программный комплекс с REST API и

Главная гипотеза: каскад дешевле и не теряет в точности

Объект. Процессы обогащения карточек товаров в интернет-магазинах.

Предмет. Методы и алгоритмы извлечения атрибутов, политики маршрутизации между слоями разной стоимости и протоколы их оценки.

Рабочее предположение.

- ▶ **Каскад** из слоёв разной стоимости (regex → ML → Bayes → LLM) обеспечивает заданную точность обогащения товарных данных.
- ▶ **Поатрибутная политика эскалации** по калиброванной уверенностикратно сокращает стоимость относительно прямого вызова большой языковой модели.
- ▶ **Локальное развёртывание** возможно на коммерчески доступной инфраструктуре.

На что опираемся: данные, теория, стек, инфраструктура

1. Унаследованная инфраструктура

PIM (Akeneo, Pimcore, Salsify) хранит, но не извлекает атрибуты.

2. Теоретическая основа

Многоязычные эмбединги, калиброванная классификация (Platt + isotonic), байесовские сети, prompt-инженерия (few-shot, schema-constrained).

3. Технологический стек

Python / FastAPI / Go-шлюз / React;
Docker-compose; XGBoost, sentence-transformers, pgmpy; Ollama для локальной языковой модели.

4. Открытые данные

Open Food Facts (4,5 млн SKU, ~40 % FR / 10 % EN / 7 % DE) + открытые источники по электронике для холодного старта.

Методы: системный анализ, ML, калибровка, предрегистрация

- ▶ **Системный анализ** — декомпозиция процесса, выявление противоречий
- ▶ **Управление требованиями** — ФР / НФР / А, интегральный критерий Q
- ▶ **Машинное обучение** — эмбединги + XGBoost, калибровка Platt + isotonic
- ▶ **Промпт-инженерия** — few-shot со схемой ответа, селективная эскалация
- ▶ **Предрегистрируемый эксперимент** — McNemar + Бонферрони, Wilson 95 % CI
- ▶ **Итеративная разработка** — цикл аудит → правки → переобучение → измерение

Что построено и измерено — обзор

1. **Требования и качество:** 6 ФР, 5 НФР, 3 А; критерий Q с 4 показателями.
2. **Методика:** 4-слойный каскад с поатрибутной политикой эскалации.
3. **Архитектура:** REST-микросервис, упакованный в `docker-compose`.
4. **Реализация:** ~15 тыс. строк Python, 21 пара «категория-атрибут» (8/6/7 для `pasta/chocolate/cheeses`), работающий e2e демо.
5. **Оценка:** достигнуты целевые показатели качества (точность, сокращение стоимости, покрытие, калибровка) — детали далее.

Задача формально: подобрать пороги $\tau_{i,a}$ при бюджете LLM $\leq 10\%$

Дано. Товар

$x = (\text{name}, \text{brand}, \text{ingr}, \text{qty}, \text{code})$;

множество атрибутов A , $|A| = 21$ (паста 8 / шоколад 7 / сыры 6); для каждого a — словарь $\mathcal{Y}_a$ с отказом $\perp$.

Политика обогащения.

$$\pi_a = f_4 \circ \sigma_3 \circ f_3 \circ \sigma_2 \circ f_2 \circ \sigma_1 \circ f_1$$

$f_i(x) \rightarrow (\hat{y}, c)$ — слой i возвращает значение и уверенность; σ_i — ворота: принять $\hat{y}$ при $c \geq \tau_{i,a}$, иначе передать дальше.

Оптимизационная задача.

$$\max_{\{\tau_{i,a}\}} \frac{1}{|A|} \sum_a \text{acc}_a^{e2e} \text{ при } \text{cost}_{\text{LLM}} \leq \beta = 10\%.$$

Ограничения

- ▶ признаки только из партнёрских полей (без `categories_tags` — анти-утечка);
- ▶ проверка на непересекающихся товарных кодах;
- ▶ локальное развёртывание возможно (слой 4 — open-model).

Требования: 6 функций + 4 нефункциональных + 3 архитектурных

Функциональные (что делает)

- ▶ **F1.** Значение каждого атрибута
- ▶ **F2.** Слой-источник предсказания
- ▶ **F3.** Калиброванная уверенность
 $c \in [0, 1]$
- ▶ **F4.** Эскалация на запасной слой
- ▶ **F5.** Байес-валидация
подозрительных решений
- ▶ **F6.** Поатрибутная настройка через
конфиг

Нефункциональные (как работает)

- ▶ **N1.** Доля LLM $\leq 10\%$ ячеек
- ▶ **N2.** Локальное развёртывание (без
внешних API)
- ▶ **N3.** Обобщение на новых товарных
кодах
- ▶ **N4.** Воспроизводимость через
`reproduce.sh`

Архитектурные (как устроено)

A1. `docker-compose`; **A2.** REST-контракт
между слоями; **A3.** холодный старт без
правки ядра.

Критерий качества Q — 4 показателя в свёртке с весами

Качество описано **четырьмя показателями** (точность, стоимость, покрытие, калибровка), сведёнными в интегральный критерий Q:


$$Q = w_1 \cdot \text{Acc} + w_2 \cdot \left(1 - \frac{C_{\text{LLM}}}{C_{\text{max}}}\right) + w_3 \cdot \text{Cov} - w_4 \cdot \text{ECE}$$

Acc — точность на непересекающихся товарных кодах (code-disjoint); $C_{\text{LLM}}/C_{\text{max}}$ — доля LLM-вызовов; Cov — покрытие каскадом до LLM; ECE — ошибка калибровки.

Веса: $w_1 = 0,40$, $w_2 = 0,30$, $w_3 = 0,20$, $w_4 = 0,10$ (приоритет точности над стоимостью согласован с типовыми требованиями РИМ-индустрии).

Показатель	Целевое	Достигнуто
Точность каскада	$\geq 90\%$	95,5 %
$C_{\text{LLM}}/C_{\text{max}}$	$\leq 0,10$	0,041
Cov (покрытие до LLM)	$\geq 0,90$	0,959
ECE (калибровка)	$\leq 0,05$	per-attr ниже целевого

Архитектура: Go-шлюз → FastAPI-каскад из 5 слоёв




Bayes — не классификатор, а валидатор плотностей; включён на 1 атрибуте

Слой 3 — pgmpy 1.1.2, структура направленного ациклического графа найдена алгоритмом **Hill Climb** с критерием **BIC**; условные вероятности через `BayesianEstimator` с априором `BDeu`.

Роль в production — селективный валидатор плотностей, а не классификатор:

- ▶ самостоятельная классификация $\approx 52\%$ (ниже majority baseline),
- ▶ но $P(\text{value} \mid \text{evidence})$ на нижнем 5-перцентиле даёт сигнал отбраковки,
- ▶ включён точно на **1 паре из 20** — `chocolate/contains_nuts`: **точность категории +6,6 пп** при росте затрат на LLM **+5,3 пп**



Что делает каждый слой: вход, алгоритм, условие эскалации

21 классификатор по парам «категория-атрибут» (8/6/7); бюджет LLM $\beta = 10\%$, фактически **4,1 %**.

Слой	Что делает	Когда не справляется	Доля
L0 router	XGBoost на эмбединге → катего- рия + OOD-флаг	OOD ⇒ слой 4 «как есть»	—
L1 regex	Поатрибутные шаблоны; точность 100 % на эталоне	Нет матча ⇒ слой 2	21,9 %
L2 ML	XGBoost на 768-мерном эмбед- динге; Platt + isotonic	$p_{\max} < \tau_a \Rightarrow$ слой 3	73,2 %
L3 Bayes	Валидатор плотностей $P_B(\hat{y} \mid e)$	$P_B < \theta_a \Rightarrow$ слой 4	0,8 %
L4 LLM	gpt-oss-120b / Sonnet 4.5 / Gemini Flash + few-shot	— (последний слой)	4,1 %

⇒ 95 % ячеек закрываются дешёвыми слоями (L1+L2+L3); LLM — только на сложном

Слой 2: XGBoost выбран по сочетанию точности, F1 и калибровки

Сравнение четырёх алгоритмов на одной выборке и одинаковом эмбединге (методология §3.3.7.5).

Классификатор	Micro-acc	Macro-F1	ECE	$t_{\text{обуч, с}}$
XGBoost (производственный)	92,02 %	0,849	0,026	1062
MLP (нейронная сеть)	92,67 %	0,857	0,031	54
Логистическая регрессия	91,85 %	0,836	0,035	8
Random Forest	89,94 %	0,809	0,027	523

Почему XGBoost. MLP даёт чуть выше точность, но **хуже калибровку** (ECE 0,031 vs 0,026) — критично для поатрибутных порогов τ_a . RF проигрывает на 2 п. п. по точности. Логрессия — слишком простая для разнородных категорий.

На чём учились и тестировали: OFF + 3 категории + 2 уровня эталона

Источник: Open Food Facts, 4,5 млн SKU (~40 % FR / 10 % EN / 7 % DE).

3 категории: паста (8 атр.), шоколад (7), сыры (7) — **21 пара** «категория-атрибут» (8/6/7).

Эталон: два уровня контрольной разметки — основной ($n = 16\,360$ cascade-valid) и проверочный ($n = 566$ cascade-valid, нижняя оценка точности).

Протокол: проверка на непересекающихся товарных кодах (code disjoint)

Категория	Атрибутов
Pasta	8
Chocolate	7
Cheeses	7
<i>Расширения:</i>	
Beverages	8
Cereals	8
Cosmetics	6
<i>Холодный старт:</i>	
Electronics	8

Главный результат: точность и стоимость

Метрика	Значение	<i>n</i>
Точность каскада (микро, CI Вильсона)	95,5 % [95,2; 95,8]	16 360
Макро-F1 каскада (cells-weighted)	0,890	16 360
Точность маршрутизатора категории	97,2 %	570
Покрытие сквозной цепочки	97,3 %	16 360
Точность сквозной цепочки	93,0 % [92,6; 93,4]	16 360
Нижняя оценка на ручной разметке	86,7 % (каскад 91,3 %)	566

Проверка на непересекающихся товарных кодах (code-disjoint). Доля языковой модели: 4,1 % ячеек ⇒ сокращение стоимости в 24× раз.


Каскад дешевле *и* точнее прямой LLM — на всех трёх моделях

Что значит «прямая LLM»: одна и та же модель спрашивается на 100 % ячеек, без слоёв L1/L2/L3. Сравнение на одной и той же выборке (n=16 360 cascade-valid).

Конфигурация	Точность	Стоимость	Дешевле в
Прямая Claude Sonnet 4.5 (опорная)	83,8 %	1,000	1×
Прямая gpt-oss-120b (открытая)	69,3 %	0,030	33×
Каскад + Gemini 2.5 Flash	93,0 %	0,0017	580×
Каскад + Claude Sonnet 4.5	92,9 %	0,041	24×
Каскад + gpt-oss-120b (локально)	90,6 %	0,0012	810×

Ключевые наблюдения: прямой Sonnet ниже каскада+Gemini Flash на **9,2 п. п.** при стоимости в **580 раз** выше; каскад с малой открытой моделью даёт **+21,3 п. п.** над

За счёт чего: вклад слоёв по 20 атрибутам



Соответствие требованиям: 6/6 ФР, 5/5 НФР, 4/4 показателя качества

1. **Соответствие требованиям.** Все 6 ФР, 5 НФР, 3 А реализованы; **4/4** показателя качества достигли целевых.
2. **Объём.** ~15 тыс. строк Python; 35+ модулей; 7 категориальных схем; 21 пара «категория-атрибут» (8/6/7).
3. **Демо.** `docker-compose`: React + Go + FastAPI; 5 REST-эндпоинтов; ~200 мс на запрос.
4. **Воспроизводимость.** ~70 тестов; ноутбук как исполняемый §3.3; `reproduce.sh` восстанавливает headline-цифры.

Что нового: методика, отрицательный результат, перенос на новую категорию

Научная значимость.

- ▶ Методика построения гибридного каскада с **поатрибутной калиброванной уверенностью** и **предрегистрируемым** протоколом оценки.
- ▶ Предрегистрированный **отказ** от гипотезы об обучаемом маршрутизаторе в пользу статической политики (простота и предсказуемость).
- ▶ Воспроизводимость методики подтверждена на новой категории (электроника) в режиме холодного старта.

Практическая значимость.

- ▶ Работающее ПО в `docker-compose`, интегрируется рядом с PIM.
- ▶ Кратное сокращение стоимости и ручной нагрузки контент-менеджеров.
- ▶ Возможность локального развёртывания — независимость от внешних API.


Почему числам можно верить: предрегистрация, code-disjoint, McNemar+Бонферрони

Достоверность:

- ▶ проверка на непересекающихся товарных кодах (code-disjoint): основная выборка $n=16\,360$ + проверочная $n=566$ cascade-valid (нижняя оценка);
- ▶ **предрегистрация** протокола гипотезы о маршрутизаторе в git cd9ac7a до создания артефакта;
- ▶ Wilson 95 % CI на всех headline-числах;
- ▶ McNemar + поправка Бонферрони ($\alpha/3$);
- ▶ воспроизведение через `reproduce.sh`.

Обоснованность. Признанные методы: sentence-transformers, XGBoost, байесовские сети, калибровка Platt + isotonic; сравнение с TXtract, MAVE, OpenTree, Ensembl, GPT, AutoML.

Демо: что видит КОНТЕНТ-МЕНЕДЖЕР за ~200 мс на запрос



Как внедрять, эксплуатировать и развивать систему

Внедрение

- ▶ `docker-compose` up рядом с PIM.
- ▶ Стартовый серебряный эталон из истории каталога.
- ▶ Поатрибутные пороги через JSON-конфиги.
- ▶ Языковая модель: внешний API или локальный Ollama.

Эксплуатация

- ▶ Мониторинг доли языковой модели ($\leq 10\%$).
- ▶ Точность на выборке $n \geq 200$ еженедельно.
- ▶ Аудит при росте байесовских флагов $> 5\%$.
- ▶ Верификация только отмеченных ячеек.

Развитие

- ▶ Холодный старт на новые категории.
- ▶ Расширение схем атрибутов.
- ▶ Замена базовой модели эмбедингов на более крупную.
- ▶ Подключение более дешёвых языковых моделей.

Эффект в одном экране: 95,5 % / 93,0 % / 4,1 % LLM / 24× дешевле

95,5 %

точность каскада
($n=16\,360$)

93,0 %

точность
производственной
цепочки

4,1 %

доля ячеек,
уходящих в языковую
модель

24×

сокращение стоимости
относительно прямого
вызова

⇒ кратное сокращение ручной нагрузки и стоимости обогащения
при сохранении локального развёртывания.

Что сделано: 5 задач → 5 результатов

Задача	Результат
1. Архитектура каскада	5 слоёв с конъюнктивным AND-условием на пороги; явный отказ слоя; идентификация слоя-источника каждого предсказания.
2. Реализация слоёв	21 классификатор по 3 категориям (8/6/7); независимое обновление; <code>docker-compose</code> : Go-шлюз + Python/FastAPI ML-сервис + Web-UI.
3. Эталонная разметка	LLM-consensus gold $n=16\,360$ + human gold $n=688$ в-scope (566 cascade-valid); code-disjoint split (brand overlap 82–85 %).
4. Экспериментальная оценка	точность каскада 95,5 % / 0,890 макро-F1, производственная 93,0 %, человеческий gold 86,7 %; сокращение стоимости 24× архитектурное / 580× комбинированное.
5. Демо-комплекс	<code>docker-compose</code> (Go + FastAPI + Web-UI); REST-контракт; 3 сценария Layer 4 (Sonnet 4.5 / Gemini Flash / open gpt-oss-120b).


Итого: точность каскада 95,5 % / макро-F1 0,890, производственная оценка

Спасибо за внимание

Точность каскада **95,5 %**,
производственной цепочки **93,0 %**,
сокращение стоимости в **24×** раз.

Исходный код, ноутбук §3.3 в исполняемом
виде, демо-комплекс и текст работы — в
репозитории.

Вопросы?



github.com/Qworl/diploma

В0. Метрики и обозначения (для вопросов)

AND-условие слоя 2. Предсказание $\hat{y}$ принимается

$\iff P_{\text{ML}}(\hat{y} \mid x) \geq \tau_a \wedge P_B(\hat{y} \mid \mathbf{e}) \geq \theta_a$ — формализация ансамблевой оценки уверенности как конъюнкции порогов ML-классификатора (τ_a) и байесовского валидатора (θ_a).

Метрики:

- ▶ $\text{acc}_k^{\text{cov}} = \frac{|\hat{y}_k=y_k \wedge \hat{y}_k \neq \text{null}|}{|\hat{y}_k \neq \text{null}|}$ — точность на покрытой части (только по ячейкам, где $\hat{y} \neq \perp$);
- ▶ $\text{cov}_k = \frac{|\hat{y}_k \neq \text{null}|}{N}$ — покрытие, доля ячеек с ненулевым предсказанием;
- ▶ $\text{acc}_k^{\text{e2e}} = \text{acc}_k^{\text{cov}} \cdot \text{cov}_k$ — сквозная точность (отказ $\perp$ засчитывается как ошибка), production-realistic;
- ▶ cost_{LLM} — ожидаемая доля вызовов запасного слоя на 1000 ячеек (бюджет $\beta = 10\%$).

Связь $\text{acc}^{\text{e2e}} = \text{acc}^{\text{cov}} \cdot \text{cov}$ объясняет разрыв между только-каскадной точностью

В1. Отрицательный результат: обучаемый маршрутизатор

Гипотеза Н1: обучаемый
стоимостно-чувствительный маршрутизатор
превосходит статическое правило хотя бы на
одном из трёх бюджетов языковой модели
(25 % / 40 % / 50 %).


Предрегистрация: git cd9ac7a, 2026-05-13
02:11 (за 1 ч 11 мин до создания артефакта).

Поправка Бонферрони: $\alpha/3 \approx 0,0167$.

Минимально различимый эффект (MDE)
при $n = 1539$: $\approx 4,4$ пп (парный McNemar).

Результат: $p_{\text{McNemar}} = 0,74/0,49/1,00$ для
бюджетов 25 / 40 / 50 % (все $> \alpha/3$).

Парето: обучаемый vs статический




В2. Байесовский слой: роль валидатора плотностей вместо классификатора

Что построено. Байесовская сеть на структуре Hill Climb + BIC (на серебряной разметке, 15 тыс. товаров на непересекающихся товарных кодах (code-disjoint)); условные вероятности доучены на `CONCAT(silver, gold-train ×10)` с априорной BDeu.

Роль классификатора отвергнута. Эмпирическая точность на трудном остатке после слоя 2 — около 52 %, ниже мажорной точки отсчёта. Сеть переориентирована в валидатор плотностей: $P(\hat{y} \mid \text{evidence})$ ниже 5-го перцентиля — ячейка помечается и понижается на следующий слой.

Производственное включение — точечное. Из 20 пар «категория-атрибут» валидатор активирован только на одной паре: chocolate / contains_nuts



В3. Серебряный сигнал vs контрольная разметка

Серебряная разметка (консенсус тегов OFF + 3 языковые модели + слепая разметка Orpus) служит **обучающим** сигналом. Контрольная выборка получена по аудит-циклу.

Цикл «аудит — правки экстрактора — переобучение — измерение» воспроизведён для всех 3 категорий с приростом **+18,2, +16,3, +14,4** пп.

Калибровка уверенности — комбинация Platt + изотонической регрессии поатрибутно; ошибка ECE измеряется на отдельной выборке.

В4. Утечки и борьба с ними

Запрет утечки categories_tags в эмбединги.

Эмбединги Слой 2 строятся **только** из партнёрских полей: product_name + brands + ingredients_text + quantity.categories_tags — это **выход** обогащения, не вход; использование как признака привело бы к утечке целевой переменной.

Разбиение по непересекающимся товарным кодам (60/20/20; brand overlap train↔eval 82–85%). Бренды в обучающей, валидационной и контрольной выборках не пересекаются — гарантия обобщения на новые бренды.

Анализ по расстоянию k-NN (§3.3.7.3): точность **не падает** на удалённых от обучающей выборки товарах — монотонный рост от Q1 (82,7 %) до Q4 (91,6 %).

B5. Многоязычность

Языковой состав OFF: $\approx 40\%$ FR, 10% EN, 7% DE, остальное — прочие.

Эмбединг: `paraphrase-multilingual-mpnet-base-v2` (50+ языков, архитектура MPNet, общее семантическое пространство).

Поатрибутно-поязыковой срез ($n=3257$ ячеек, предыдущая выборка до extended rerun 2026-05-27 — пересчёт перенесён в перспективу развития темы): взвешенная точность стабильна по основным языкам.

Под балансировку каскад не оптимизировался — это естественный выигрыш многоязычной базовой модели эмбедингов.

В6. Стоимость языковой модели на 1 млн SKU

Каскад делегирует языковой модели лишь 4,1 % ячеек ($n = 17\,062$) — прямая прокси к стоимости. Сокращение затрат **95,9 % (в $24\times$ раз)** относительно «прямой языковой модели на всё».

Распределение по слоям: L1 (regex высокой точности) — 21,9 %, L2 (ML) — **73,2 %**, L3 (regex низкой точности) — 0,8 %, L4 (языковая модель) — 4,1 %.

Проекция на 1 млн SKU $\times$ 20 атрибутов ($\sim 2,0 \cdot 10^7$ ячеек):

- ▶ Прямая модель — оплачены все $\sim 2,0 \cdot 10^7$ вызовов.
- ▶ Каскад — оплачены лишь $\sim 8,2 \cdot 10^5$ вызовов (4,1 %).

Топ-3 затратных атрибутов для языковой модели: pasta.grain_type (32,9 %), pasta.pasta_shape (22,8 %), cheeses.is_pdo (13,6 %).

В7. Холодный старт: электроника (§5 ноутбука)

Демонстрация переноса методики на **новую категорию без регулярных правил**.

Электроника (8 атрибутов): смартфоны — RAM, объём памяти, диагональ экрана, поддержка 5G, ...

Перенос: активны только Слой 2 (ML + эмбединги) и Слой 4 (языковая модель); Слой 1 пропускается; Слой 3 — по обучающим парам.

Результат: холодный старт работает на ограниченной обучающей выборке, что подтверждает применимость каскада за пределами продуктового домена.

В8. Где каскад слабее: precision/recall на 3 худших атрибутах

Производственная схема V6, эталон LLM-consensus (extended rerun, n=16 360).

Атрибут	Класс	n	prec	recall	F1
<i>chocolate.flavor_profile — micro 87,5 %, macro-F1 0,684, n=1060</i>					
	intense_bitter	397	91,1 %	98,0 %	0,944
	nutty	281	86,6 %	85,4 %	0,860
	sweet_creamy	190	80,8 %	84,2 %	0,825
	salty_caramel (редкий)	56	90,5 %	67,9 %	0,776
<i>pasta.is_filled — micro 88,5 %, macro-F1 0,786, n=1225</i>					
	false (не фаршированные)	958	87,2 %	100 %	0,931
	true (фаршированные)	267	100 %	47,2 %	0,641
<i>cheeses.texture — micro 89,0 %, n=335</i>					
	hard	109	95,5 %	96,3 %	0,959
	soft	97	91,3 %	97,9 %	0,945
	cream (редкий)	33	73,9 %	51,5 %	0,607

B9. chocolate/contains_nuts — атрибут с активным Bayes-валидатором

Единственная пара из 20, где Bayes-валидатор включён в production (см. B2).
Структура ошибок после фильтрации:

Класс	n	precision	recall	F1
false (без орехов)	749	99,1 %	93,2 %	0,961
true (с орехами)	377	87,9 %	98,4 %	0,929
Сумма	1126	micro 94,9 %		macro-F1 0,945

Почему именно Bayes-валидатор. Атрибут безопасный (аллергия — наличие орехов важно подтвердить жёстко). Распределение асимметричное: false-предсказания *критичны*, true-предсказания допускают перепроверку. Bayes-плотность ловит сомнительные false и эскалирует их в LLM — **+6,6 п. п.** категориальной точности chocolate при **+5,3 п. п.** расхолов на LLM.

B10. Macro-F1 на ручной разметке: 0,843 cells-weighted

Консервативная нижняя оценка на независимом эталоне ручной разметки (Claude Opus 4, $n=688$ в-scope, $n=566$ cascade-valid).

Метрика	LLM-consensus ($n=16\,360$)	Ручной gold ($n=566$)
Cascade micro-acc	95,5 %	91,3 %
Cascade macro-F1 (cells-weighted)	0,890	0,843
Cascade macro-F1 (attr-unweighted)	0,892	0,833
Сквозная (производственная) acc	93,0 %	86,7 %

Разрыв 4,2 п. п. на cascade micro-acc и **0,047** на макро-F1 объясняется тремя причинами (детали в §3.3 ВКР):

- ▶ ручной gold — независимый сигнал, не коррелирует с обучающим silver,
- ▶ меньший n (566 vs 16 360) даёт более широкий доверительный интервал,